QML Lecture

양자 머신러닝
의료 이미지 데이터 증강



오리엔테이션

의료 데이터셋을 활용한 양자 머신러닝 실습

이론 → 데이터 EDA · 전처리 · 회로 구성 → 실습 실행

1일차

11/13(금)

이론 설명

데이터셋 소개
+ QGAN · MediQ-GAN 논문 아키텍처

2일차

11/20(금)

실습 - 전처리 + QGAN 학습

3일차

11/27(금)

실습 - MediQ-GAN 학습

오리엔테이션

학습목표

INDEX

1. HAM10000 데이터셋 EDA
2. QGAN과 고전 GAN의 차이 - patch 방식 아키텍처 설명
3. 아키텍처 '전체가 양자'(QGAN)와 '일부만 양자'(MediQ-GAN, 듀얼스트림) 차이 구분

HAM10000 데이터셋

"Human Against Machine with 10000 training images" - 피부병변 진단 AI 연구의 대표 벤치마크

10,015

총 이미지 수

피부경검사(dermatoscopic) 촬영

7

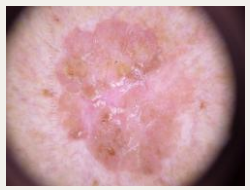
병변 클래스 수

akiec · bcc · bkl · df · mel · nv · vasc

600×450

원본 해상도

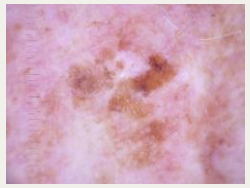
RGB, 실제 임상 촬영 이미지



akiec · 광선각화증



bcc · 기저세포암



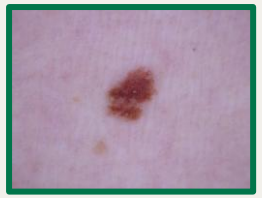
bkl · 양성각화증



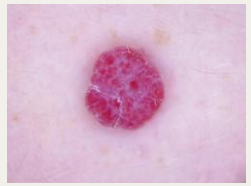
df · 피부섬유종



mel · 흑색종



nv · 모반



vasc · 혈관병변

병변 유형	코드	이미지 수	비율
광선각화증 (Actinic keratoses)	akiec	327	3.3%
기저세포암 (Basal cell carcinoma)	bcc	514	5.1%
양성각화증 (Benign keratosis-like lesions)	bkl	1,099	11.0%
피부섬유종 (Dermatofibroma)	df	115	1.1%
흑색종 (Melanoma)	mel	1,113	11.1%
모반 (Melanocytic nevi)	nv	6,705	66.9%
혈관병변 (Vascular lesions)	vasc	142	1.4%

이미지·데이터 출처: HAM10000 (Tschandl et al., Scientific Data 5, 180161, 2018)

EDA 분석 결과 : 데이터 불균형

클래스	이미지 수
광선각화증 (akiec)	327
기저세포암 (bcc)	514
양성각화증 (bkl)	1,099
피부섬유종 (df)	115
흑색종 (mel)	1,113
모반 (nv)	6,705
혈관병변 (vasc)	142

클래스 불균형 데이터 처리 방법

방법	설명	한계
Under Sampling 언더샘플링	소수 클래스에 맞춰, 다수 클래스를 줄임	정보 손실 - 6,700장 넘게 버려야 함
Over Sampling 오버샘플링	소수클래스를 복제해서 늘림	복제본이라 새로운 정보가 없음 - 과적합 위험
Augmentation 기하학적 증강	회전·반전·크롭 등으로 변형	병변의 실제 형태·질감 다양성은 만들지 못함
생성모델(GAN/QGAN)	학습된 분포에서 '새로운' 그럴듯한 샘플 생성	품질 검증 필요

초점

- QGAN이 '고전 GAN보다 좋다'가 결론은 아님
- QGAN의 실제 동작 방식과 조건을 논문 데이터로 확인

표 출처: HAM10000 메타데이터 (Tschandl et al., Scientific Data 5, 180161, 2018)

CHAPTER 1

논문 ① QGAN

Quantum GAN 기반 피부병변 이미지 증강 - patch method 아키텍처

제목	Data Augmentation in Cancer Image Classification Problem with Quantum GAN
기여점	7+1큐빗 · Sub Generator 16개 · patch 방식으로 피부 이미지를 생성해 소수 클래스(DF) 증강
검증 방식	생성 이미지로 CNN 분류기를 학습시켜, 증강 전/후 AUC-ROC·정확도를 비교(고전 GAN과도 비교)
핵심 내용	"Generator" 아키텍처 사례 - model-level hybrid

QGAN 기본 개념 - 고전 GAN과 무엇이 다른가

생성자(Generator) · 판별자(Discriminator)가 경쟁하며 학습하는 구조는 동일

고전 GAN

Generator = 신경망(예: CNN/MLP)

무작위 노이즈 벡터 → 신경망 통과 → 이미지

학습 파라미터 = 가중치 행렬

Discriminator도 고전 신경망

QGAN

Generator = 변분 양자회로(PQC)

무작위 각도 노이즈 → 큐빗 회전으로 인코딩 → 측정

학습 파라미터 = 회전 게이트의 각도

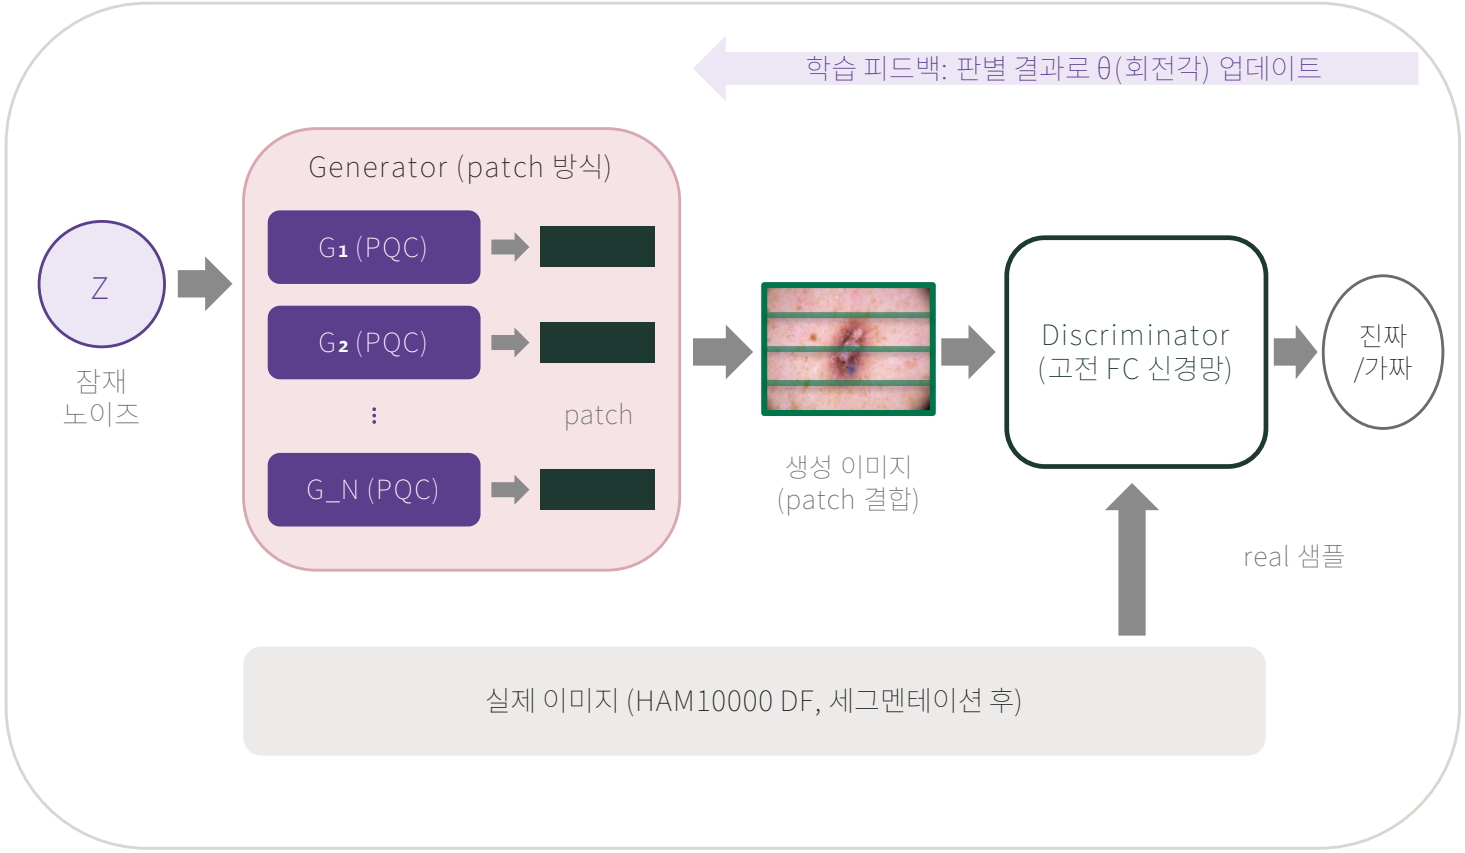
Discriminator는 그대로 고전 신경망(비대칭 구조)

핵심

Discriminator는 그대로, Generator만 양자회로 교체

QGAN 아키텍처 다이어그램 - patch 기반 Generator

Generator-Discriminator 구조를 도식으로 재구성



원 논문 Fig. 10 구조를 도식으로 재구성: Andra et al., Quantum Machine Intelligence 7, 90 (2025)

Patch 방식 아키텍처

큐빗 한 세트로 이미지 전체를 만들기 어려워, 여러 개의 '작은 회로'가 조각(patch)을 나눠 생성

Sub Generator 1
PQC → patch

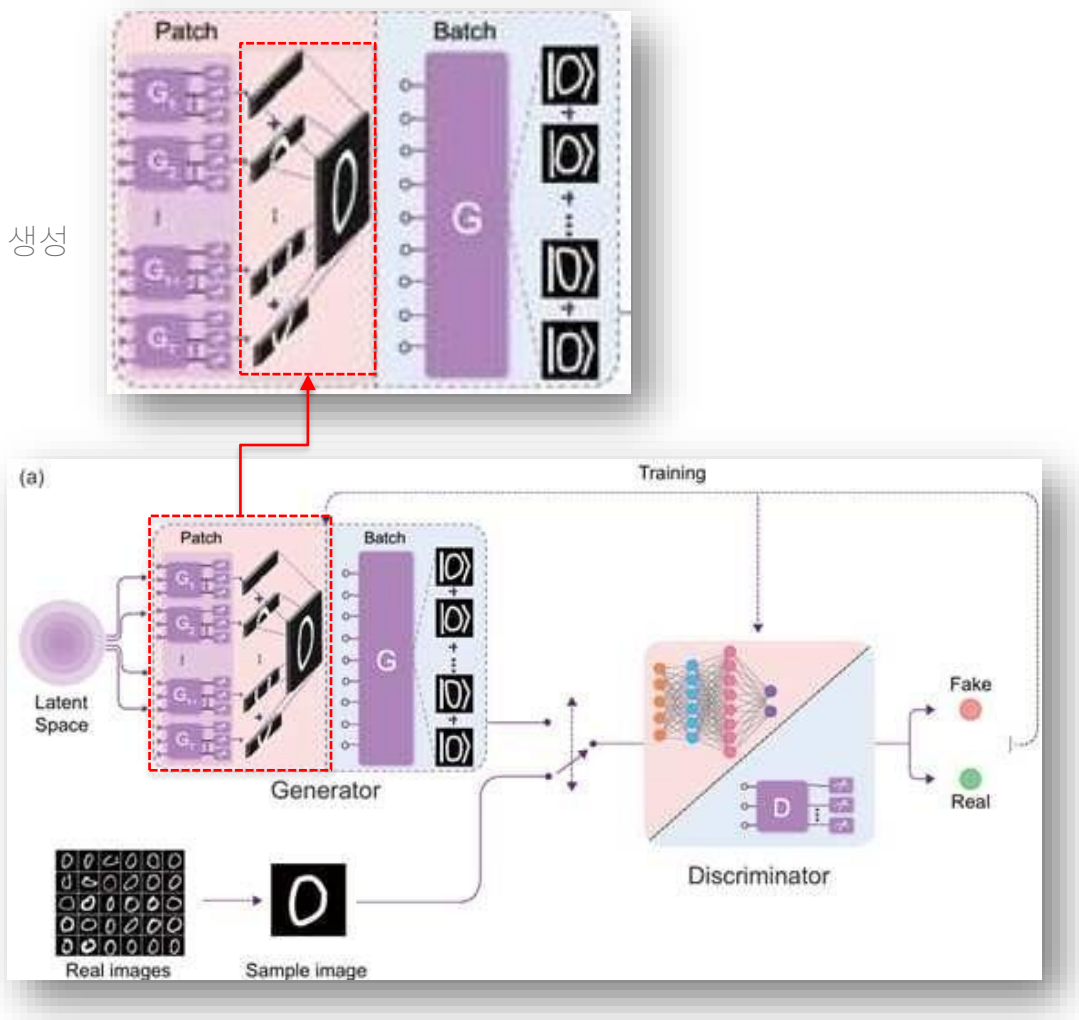
Sub Generator 2
PQC → patch

Sub Generator 3
PQC → patch

Sub Generator N
PQC → patch

(논문: 16개 Sub Generator)

patch 1 + patch 2 + patch 3
+ ••• + patch N
→ 이어 붙여 최종 이미지 벡터



Sub Generator 회로 상세

각 Sub Generator = 3단계로 이루어진 하나의 변분 양자회로(PQC)

① 노이즈 인코딩

무작위 각도를 RY 게이트로 각 큐빗에 회전시켜 입력

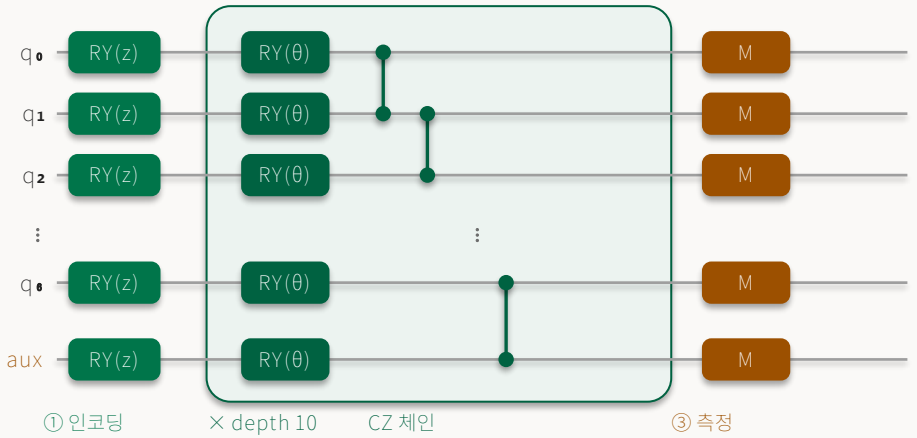
② 변분 레이어 (반복)

학습 가능한 RY 회전 + 인접 큐빗 CZ 얽힘 - 각도가 '학습되는 가중치'

③ 측정

보조큐빗까지 전체 측정 후, 보조큐빗=0인 항목만 patch로 사용(사후선택)

Sub Generator 1개 회로 (논문 Table 3 기준, 8큐빗)



측정 결과 $2^8 = 256$개 확률 중 보조큐빗 = 0 인 128개만 선택(post-selection) → patch 1장

Sub Generator 16개의 patch를 이어붙여 이미지 1장을 구성

항목	값
큐빗 수	데이터 7 + 보조(ancilla) 1 = 총 8
Sub Generator 수	16개
회로 깊이(PQC depth)	10
학습률 / epoch	0.1 / 2,000

Discriminator 구조 + 평가 프로토콜

"QGAN이 잘 만들었는지"는 생성 이미지 직접 확인 대신 별도 CNN 분류기 성능으로 검증

Discriminator (Table 4)

Table 4 · Discriminator	값
Layer 수	5 (완전연결)
활성화 함수	ReLU
출력층 활성화	Sigmoid
PQC 깊이 (생성자)	10
학습률	5×10^{-3}
Epoch	2,000
손실 함수	Binary Cross Entropy

평가용 CNN

Table 1 · CNN 학습 설정	값
학습률	15×10^{-4} ($=1.5\times10^{-3}$)
손실 함수	Binary Cross Entropy
Optimizer	ADAM
정규화 레이어	Batch Normalization 2D
출력 활성화	Sigmoid
파라미터 수	460k

Table 2 · Conv 레이어	값
Kernel 크기	3
Stride	1
활성화 함수	ReLU
정규화 레이어	Batch Normalization 2D
Max Pooling	2×2

표 내용 출처: Andra et al., Quantum Machine Intelligence 7, 90 (2025), Table 1·2·4

결과 ① - DF vs NV 분류 성능 개선

Table 6: QGAN 증강 후 AUC-ROC 개선



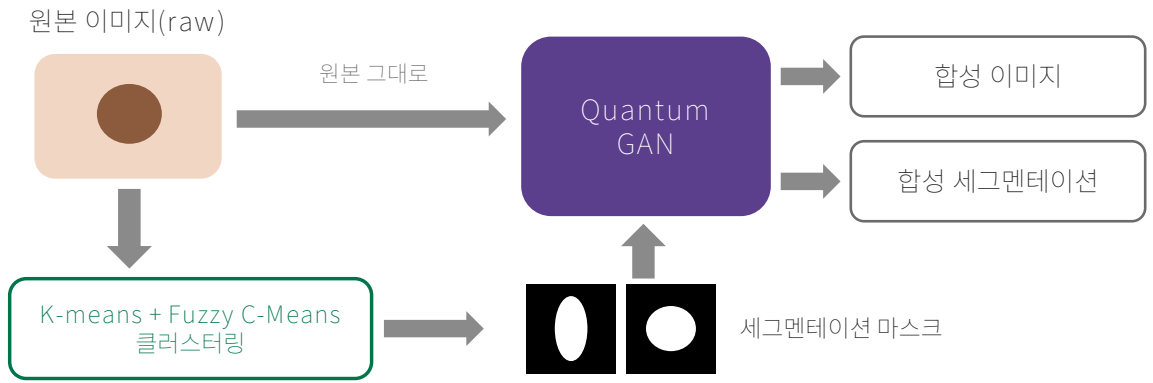
결과 ② - 조건부 증강 효과

세그멘테이션 전처리 이미지에서만 증강 효과 있음

입력 전처리 방식	QGAN 증강 효과
원본/리사이즈 이미지	증강 효과 없음 - 오히려 성능 저하
세그멘테이션(K-means+FCM) 전처리 이미지	증강 효과 있음 - 성능 개선

왜 중요한가

실제로는 배경 노이즈를 제거한(세그멘테이션) 입력에서만
생성 품질이 분류 성능 개선으로 이어짐



원 논문 파이프라인을 도식으로 재구성: Andra et al., Quantum Machine Intelligence 7, 90 (2025)

결과 ③ - 고전 GAN과의 비교

Table 11: 조건에 따라 승자 교체 - "양자가 항상 이긴다"는 아님

입력 조건	정확도 비교	비고
원본(raw) 이미지	고전 GAN (정확도 0.98)	QGAN 열세
세그멘테이션 이미지	QGAN (정확도 0.96 vs 0.95)	AUC는 0.97로 동률

해석

"고전 대비 무조건적 속도·성능 우위"가 성공 기준이 아니라,
(1) 문제→양자 파이프라인의 실제 성립 여부, (2) 어떤 조건에서 고전과 동등·우위인지(crossover 조건) 평가

CHAPTER 2

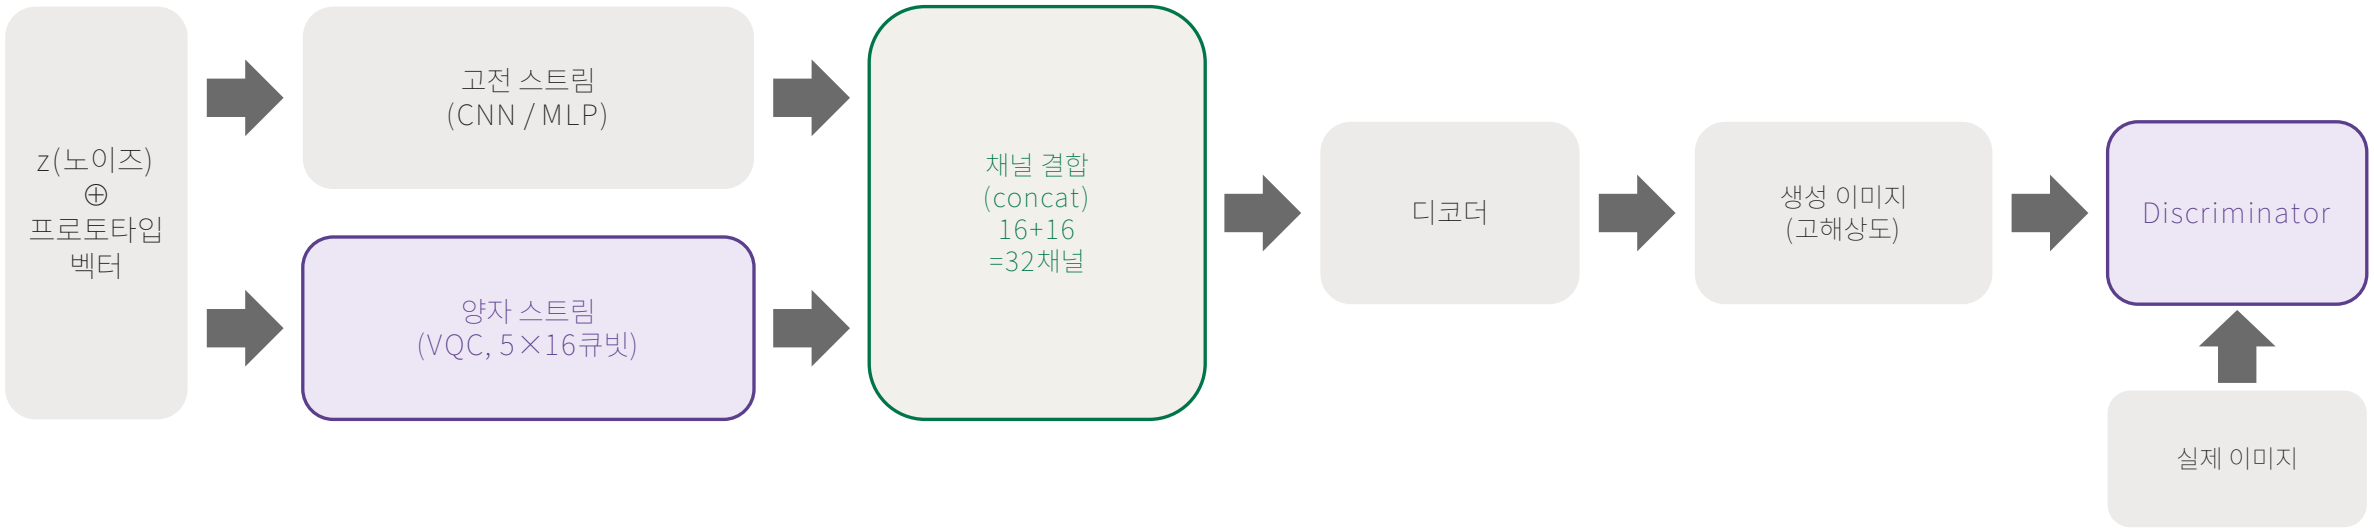
논문 ② MediQ-GAN

듀얼스트림 구조로 모델 아키텍처 '일부만' 양자화한 생성 모델

논문	MediQ-GAN (arXiv:2506.21015)
핵심 기여	Generator를 고전 스트림 + 양자 스트림 둘로 나눠 병렬 처리 후 융합(skip-connection) - 의료영상 3종 데이터셋 검증
검증 방식	DCGAN · WGAN-GP · StyleGAN2-ADA 등 고전 SOTA 및 MosaiQ(양자)와 클래스별 FID · LPIPS로 비교, 실제 IBM 하드웨어 실행까지 확인
이 강의에서의 역할	"Generator 일부만 양자"인 아키텍처의 대표 사례 - layer-level hybrid

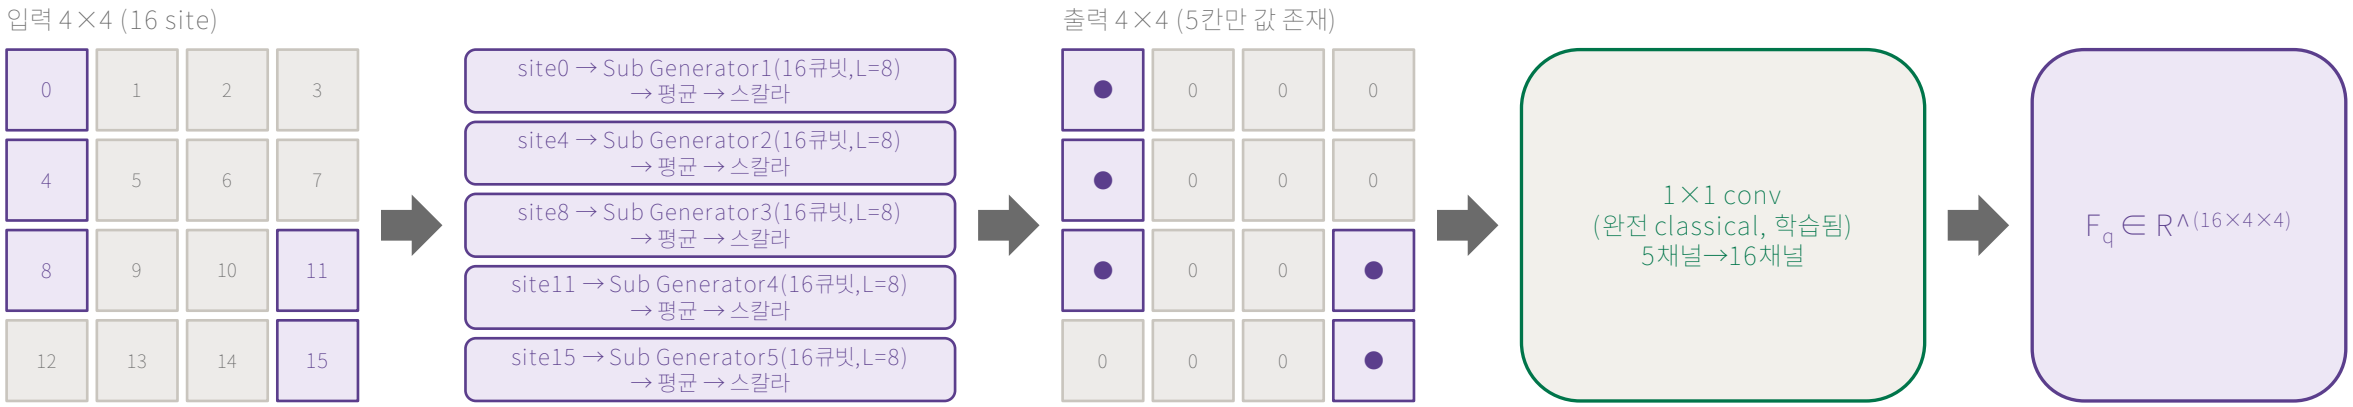
MediQ-GAN 아키텍처 다이어그램 - 듀얼스트림 Generator

고전 스트림과 양자 스트림을 함께 학습해 합치는 구조를 도식으로 재구성



Sub Generator 상세 - 16 site 중 5개만 실제 양자 처리

나머지 11칸은 classical 1×1 conv의 편향값만 받음 (공식 GitHub 코드 기준)



site 선택: linspace(0,15,5)round → [0, 4, 8, 11, 15] (row×4+col). 나머지 11칸은 그 Sub Generator의 4×4 맵에서 0으로 남음.
1×1 conv는 칸별 독립 처리(이웃 안 봄) - 값이 있는 5칸만 진짜 양자 스칼라를 16채널로 투영, 나머지 11칸은 학습된 편향(bias)뿐. 이후 8×8 업샘플에서만 보간으로 살짝 섞임.

Hybrid 분류체계 - " 어디까지가 양자인가"

같은 '양자 생성모델'이라도 Generator 전체/일부 양자 여부로 구분됨

모델 레벨 하이브리드

예: HAM10000 QGAN, MosaiQ

Generator = 처음부터 끝까지 양자회로

Discriminator만 고전

PCA 등 고전 전처리가 있어도, Generator 는 양자 회로 구성

레이어 레벨 하이브리드

예: MediQ-GAN

Generator 내부가 고전 스트림 + 양자 스트림으로 병렬 분기

두 스트림을 skip-connection으로 concat 후 디코딩

"레이어 하나 안에서도" 양자·고전이 공존

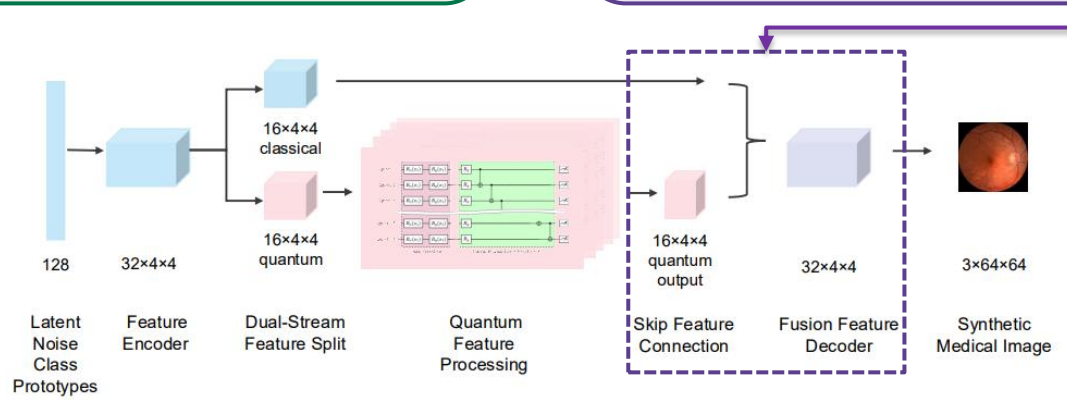
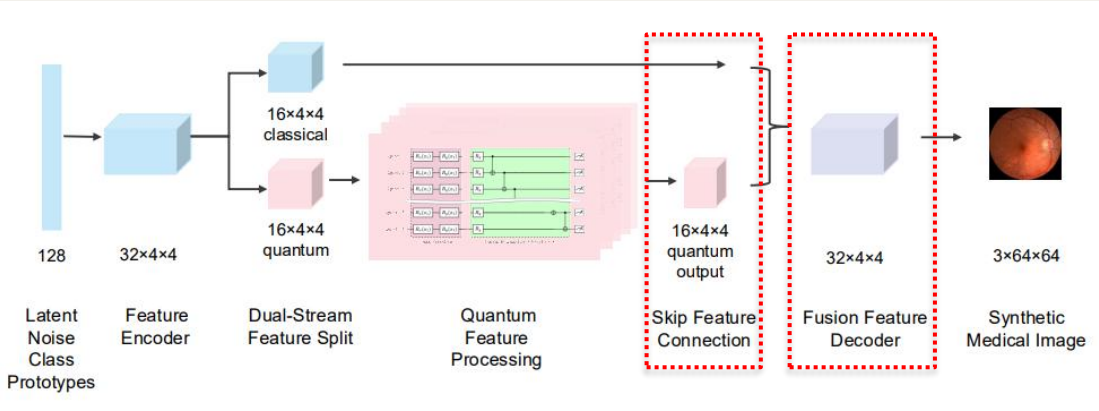


그림 출처: Jiao et al., MediQ-GAN, arXiv:2506.21015 (CC BY 4.0)

듀얼스트림 Generator 아키텍처

입력을 절반씩 나눠 고전 인코더와 양자회로(VQC)가 병렬 처리 후 하나로 합침



고전 스트림

classical encoder / conv

양자 스트림

5 × 16큐빗 VQC (8층 깊이)

skip-connection 융합 (concat)

고전 디코더 → 생성 이미지

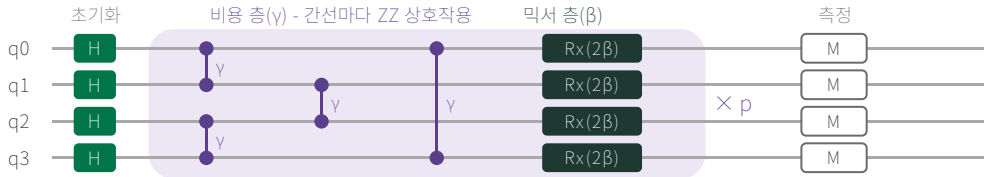
인코딩: angle encoding(Rx→Ry) · 학습레이어: Ry+CNOT 반복 · 측정: X-basis readout

그림 출처: Jiao et al., MediQ-GAN, arXiv:2506.21015 (CC BY 4.0)

VQC · VQA · QAOA와의 관계

같은 '파라미터화된 회로 + 고전 최적화' 구조 공유, 인코딩 대상과 목적은 상이

개념	정의
VQA (Variational Quantum Algorithm)	파라미터화된 양자회로 + 고전 최적화 루프를 사용하는 알고리즘 상위 범주
VQC (Variational Quantum Classifier/Circuit)	분류 등 지도학습 목적의 구체적 구현 - 데이터 인코딩 + 학습 가능한 ansatz로 구성 (MediQ-GAN의 양자 아키텍처 방식)
QAOA (Quantum Approximate Optimization Algorithm)	조합최적화 문제(MaxCut 등) 등 목적 - cost layer(γ)와 mixer layer(β)를 번갈아 적용



공통점 vs 차이점

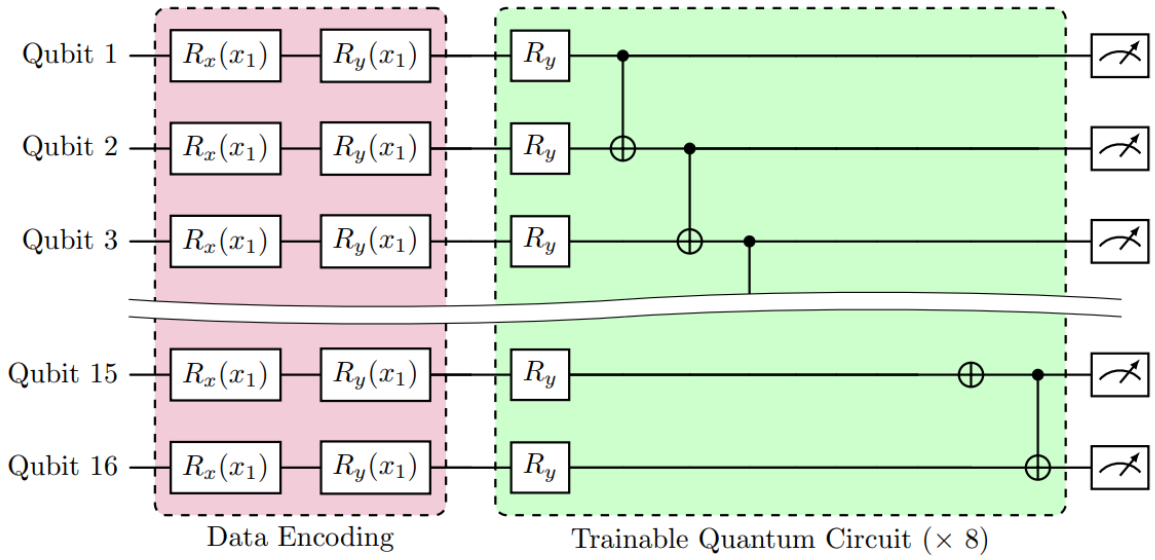
- 공통점: 파라미터화된 회로 → 측정 → 고전 optimizer가 파라미터 업데이트(hybrid loop)
- 차이점: 인코딩 대상(데이터 vs 문제)과 학습 목표

회로 안의 두 종류 파라미터 - 인코딩 vs 학습

데이터를 넣는 게이트와 학습으로 값이 바뀌는 게이트, 역할 차이

구분	위치 / 값의 성격
인코딩 파라미터	회로 앞단, 데이터 인코딩 게이트 - 입력 데이터 x (대부분 고정, 학습 대상 아님)
학습 파라미터 θ	인코딩 이후 variational ansatz - 회전 게이트 각도, CNOT, entangling 게이트 사이사이에 위치, 학습으로 업데이트됨

레이어 = 회전게이트(θ, 파라미터 O) + CNOT 체인(파라미터 X, 얽힘 담당)
16큐빗 × 8층 → Sub Generator당 파라미터 128개 (5개 합계 640개)



※ 그림은 논문 기준(Rx→Ry · CNOT), 공식 코드는 RY→RX · CZ - 3일차 데모는 코드 기준

그림 출처: Jiao et al., MediQ-GAN, arXiv:2506.21015 (CC BY 4.0)

VQC의 출력값 - bitstring이 아니라 연속값(기댓값)

단일 측정은 0/1, 모델이 실제로 쓰는 값은 여러 번 측정을 평균낸 기댓값

$$m(z;\Theta) = (\langle X_1 \rangle, \ldots, \langle X_N \rangle) \in [-1, 1]^N$$

항목	내용
단일 shot 결과	이산적 0/1 bitstring - 확률적 결과
실제 모델 출력	$\langle X_i \rangle$ 연속값(continuous) - classical decoder에 바로 투입 가능, gradient 계산도 가능
수치 안정화	h(m) = σ(LeakyReLU(LayerNorm(m))) 적용 후 classical stream과 fusion

실제 채택 방식 - Exact State Vector Simulation

논문 코드(mediq-gan.py) 결과

```
dev = qml.device("lightning.qubit", wires=args.n_qubits)
@qml.qnode(dev, interface="torch", diff_method="adjoint")
def circuit(...):
    ...
    return [qml.expval(qml.PauliX(i)) for i in range(args.n_qubits)]
```

항목	내용
shots 미지정	PennyLane 기본값 shots=None → 분석적(exact) 기댓값 계산, 반복 측정 없음
diff_method="adjoint"	정확한 state vector 접근이 있어야만 가능한 gradient 계산법 - 데모도 공식 레포와 동일하게 adjoint 사용
state vector 규모	n큐빗 = 2^n차원 복소벡터로 완전 표현(16qubit→65,536차원, 노트북 처리 가능) - 게이트 적용=유니터리 행렬곱(확률적 요소 없음)

'Hardware-agnostic'의 정확한 의미

논문 원문 그대로 인용 시 오해하기 쉬운 표현

논문 원문 인용

"Our approach is quantum-inspired and hardware-agnostic: the correctness does not depend on quantum execution, and quantum devices serve only to accelerate computation."

구분	내용
오해 (X)	하드웨어를 아예 안 썼다는 뜻
정확한 뜻 (O)	모델의 타당성이 특정 실행 환경(시뮬레이터 vs 실제 큐빗)에 좌우되지 않도록 설계했다는 뜻
학습(training)	state vector 시뮬레이터로 진행
NISQ evaluation	학습 완료된 회로를 IBM Marrakesh 실기에 올려 inference만 검증 (노이즈로 성능 소폭 저하되었으나 비교 가능한 수준)

shot 기반으로 학습한다면 - Parameter-shift Rule

Exact statevector 방식이 아니라, gradient를 구할 때 쓰는 규칙

$$\partial \langle X_i \rangle / \partial \theta_j = [\langle X_i \rangle(\theta_j + \pi/2) - \langle X_i \rangle(\theta_j - \pi/2)] / 2$$

개념	설명
계산 방식	회로 내부를 역전파로 거슬러 올라가는 게 아니라, θ_j를 shift한 회로를 처음부터 끝까지 2번 새로 실행해 얻은 결과값의 단순 뺄셈
순전파(forward) 시점	shift된 회로는 전혀 실행되지 않음 - 원래 θ값으로 1번만 실행, 그 출력이 다음 classical 레이어로 전달
역전파(backward) 시점	$+\pi/2$, $-\pi/2$ 두 회로가 파라미터 하나마다 개별적으로 실행됨

전체 chain rule: $dLoss/d\theta_j = dLoss/d\langle X_i \rangle$ (classical backprop) × $d\langle X_i \rangle/d\theta_j$ (parameter-shift, 뺄셈 기반)

계산 비용 – 현재 학습의 어려움

파라미터 수만큼 회로를 반복 실행해야 하는 구조적 한계

총 회로 실행 횟수 = 1 (순전파) + 2P (파라미터 별 +shift, −shift)

파라미터 수 P	회로 실행 횟수
640 (5개×N16×L8)	1 + 1,280 = 1,281회
10,000	1 + 20,000 = 20,001회

측정 횟수까지 곱하면

총 측정 횟수 = 회로 실행 횟수 × shots.

- P=10,000, shots=1,024 → 20,001×1,024 ≈ 약 2,048만 회.
- 배치 32 · 학습 스텝 10,000까지 포함하면 → $20,001 \times 1,024 \times 32 \times 10,000 \approx 6.5 \times 10^{12}$(약 6.5조 회)

CHAPTER 3

내용 정리

두 논문 비교 요약 및 정리

QGAN 및 MediQ-GAN 정리

구분	QGAN	MediQ-GAN
Hybrid 유형	모델 레벨(Generator 전체 양자)	레이어 레벨(듀얼스트림)
큐빗 규모	7+1큐빗 × Sub Generator 16개	5 × 16큐빗 VQC(스트림 하나)
데이터셋	HAM10000 (피부병변, 2클래스 집중)	ISIC2019 · ODIR-5k · RetinaMNIST
검증 방식	증강 전/후 CNN 분류 성능(AUC-ROC)	클래스별 FID·LPIPS + 실기(IBM) 검증

현재 단계에서의 QML 연구 방향

QML 연구 방향 中 연산 비용 개선 논의되고 있음

판단 대상	결론
parameter-shift 구현	비현실적 - 계산상 명확함
QML 연구 전체의 가치	유효함 - 아래 방향의 연구가 활발히 진행 중

SPSA (Simultaneous Perturbation Stochastic Approximation)

파라미터 개수와 무관하게 매 스텝 회로 2번만 실행해 gradient 근사(정확도는 다소 하락)

Classical shadow tomography

적은 측정 횟수로 여러 관측량을 동시 추정

Quantum Natural Gradient (QNG)

더 적은 스텝으로 수렴시켜 전체 실행 횟수 절감

DLA (Dynamical Lie Algebra) 기반 회로 설계

barren plateau를 피하며 필요한 파라미터/깊이 최소화

이미지 생성 분야에서 양자 알고리즘 유의점

양자 생성 모델은 양자 데이터, 헤밀토니안 상태 등을 만드는 데 특화되어 있기에, 기존 데이터가 많은 영역, 모델, 컴퓨팅이 잘하는 영역에 대한 성과는 검증 단계

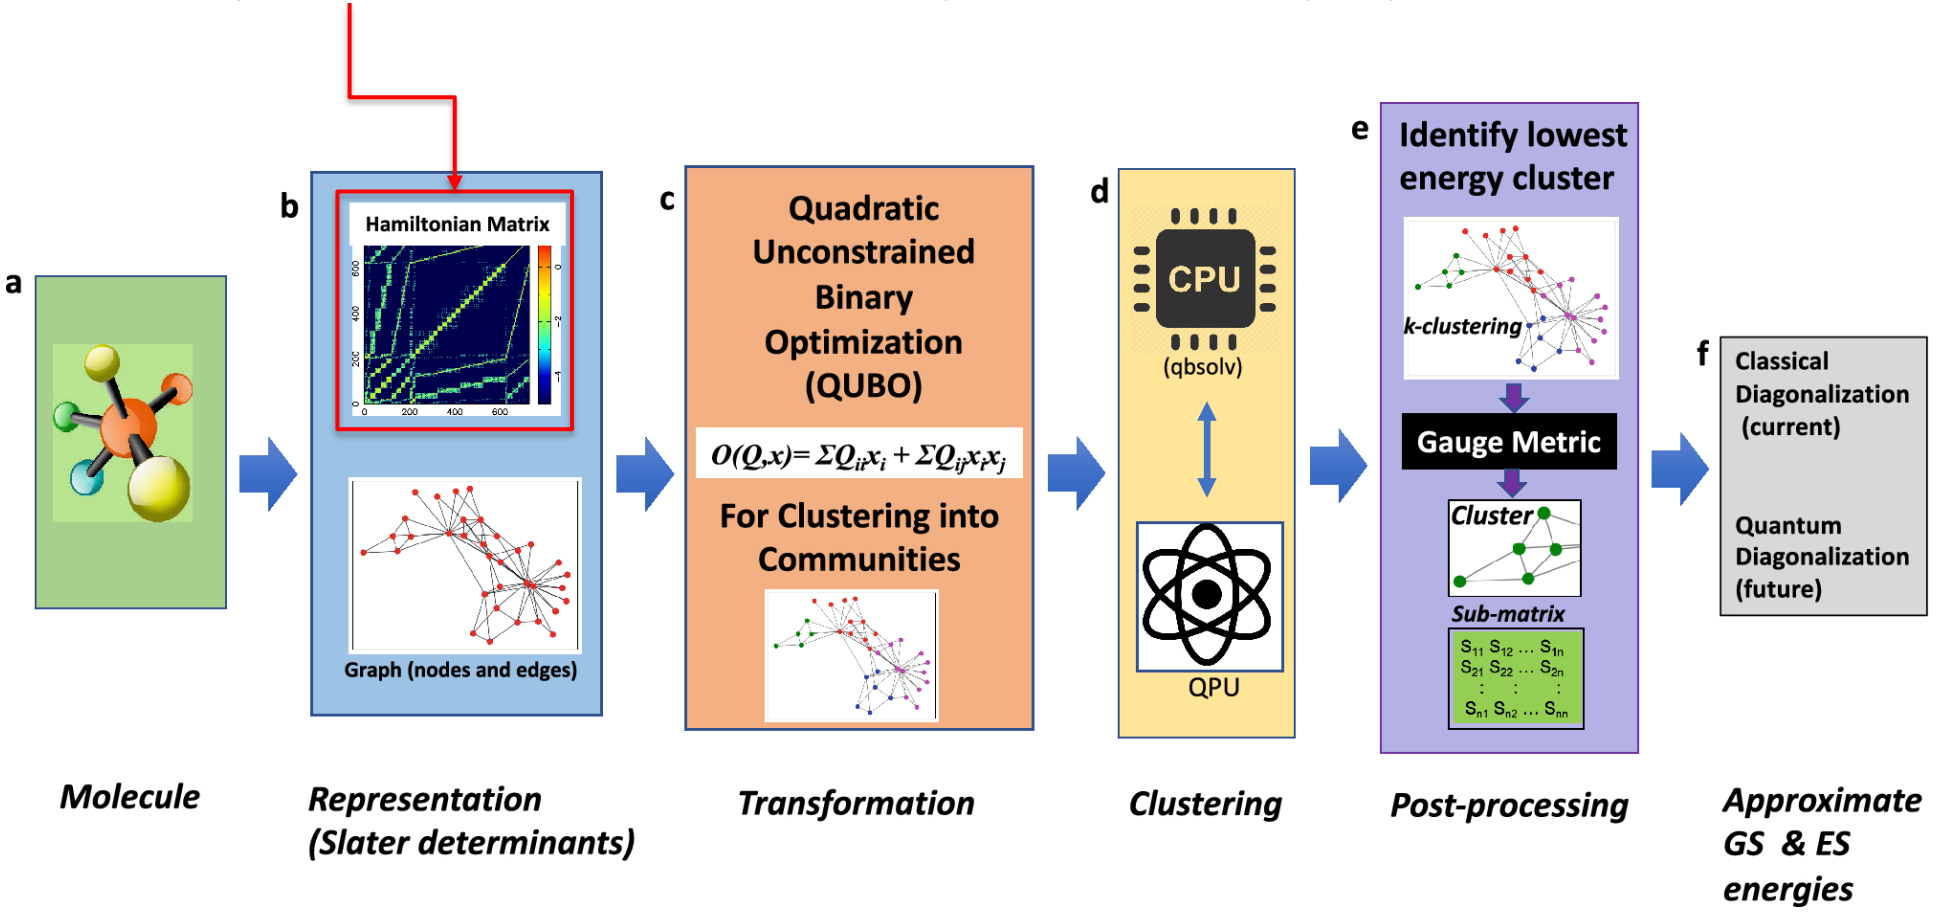


그림 출처: https://www.nature.com/articles/s41598-021-83561-x (CC BY 4.0)



감사합니다.