QML Lecture

양자 머신러닝
의료 이미지 데이터 증강

오리엔테이션

의료 데이터셋을 활용한 양자 머신러닝 실습

이론 → 데이터 EDA·전처리·회로 구성 → 실습 실행

1일차

이론 설명

데이터셋 소개
+ QGAN·MediQ-GAN 논문 아키텍처

2일차

실습 - 전처리 + QGAN 학습

3일차

실습 - MediQ-GAN 학습

오리엔테이션

학습목표

INDEX

1. HAM10000 데이터셋 EDA와 클래스 불균형 문제
2. GAN 학습 구조·평가 지표(FID, LPIPS)와 양자회로 기초(qubit, 게이트, 측정, VQC)
3. QGAN과 고전 GAN의 차이 - patch 방식 아키텍처
4. 아키텍처 '전체가 양자'(QGAN)와 '일부만 양자'(MediQ-GAN, dual-stream) 차이 구분
5. 두 논문의 결과를 같은 기준(비교 대상, 지표, 실행 환경)으로 해석

HAM10000 데이터셋

"Human Against Machine with 10,000 training images" - 피부병변 진단 AI 연구의 대표 벤치마크

10,015

총 이미지 수

피부경검사(dermatoscopic) 촬영

7

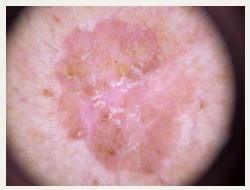
병변 클래스 수

akiec · bcc · bkl · df · mel · nv · vasc

600×450

원본 해상도

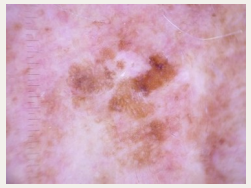
RGB, 실제 임상 촬영 이미지



akiec · 광선각화증



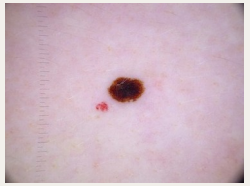
bcc · 기저세포암



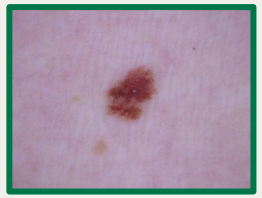
bkl · 양성각화증



df · 피부섬유종



mel · 흑색종



nv · 모반



vasc · 혈관병변

병변 유형	코드	이미지 수	비율
광선각화증 (Actinic keratoses)	akiec	327	3.3%
기저세포암 (Basal cell carcinoma)	bcc	514	5.1%
양성각화증 (Benign keratosis-like lesions)	bkl	1,099	11.0%
피부섬유종 (Dermatofibroma)	**df**	**115**	**1.1%**
흑색종 (Melanoma)	mel	1,113	11.1%
모반 (Melanocytic nevi)	**nv**	**6,705**	**66.9%**
혈관병변 (Vascular lesions)	vasc	142	1.4%

이미지·데이터 출처: HAM10000 (Tschandl et al., Scientific Data 5, 180161, 2018)

01 · 데이터셋

EDA 분석 결과 : 데이터 불균형

클래스 불균형 데이터 처리 방법

클래스	이미지 수
광선각화증 (akiec)	327
기저세포암 (bcc)	514
양성각화증 (bkl)	1,099
피부섬유종 (df)	**115**
흑색종 (mel)	1,113
모반 (nv)	**6,705**
혈관병변 (vasc)	142

방법	설명	한계
Under sampling	소수 클래스에 맞춰, 다수 클래스를 줄임	정보 손실 - NV 6,500장 넘게 버려야 함
Over sampling	소수 클래스를 복제해서 늘림	복제본이라 새로운 정보가 없음 - 과적합 위험
Augmentation 기하학적 증강	회전·반전·크롭 등으로 변형	병변의 실제 형태·질감 다양성은 만들지 못함
생성모델(GAN/QGAN)	학습된 분포에서 '새로운' 그럴듯한 샘플 생성	품질 검증 필요

초점

- QGAN이 '고전 GAN보다 좋다'가 결론은 아님
- QGAN의 실제 동작 방식과 조건을 논문 데이터로 확인

표 출처: HAM10000 메타데이터 (Tschandl et al., Scientific Data 5, 180161, 2018)

PRELIMINARY

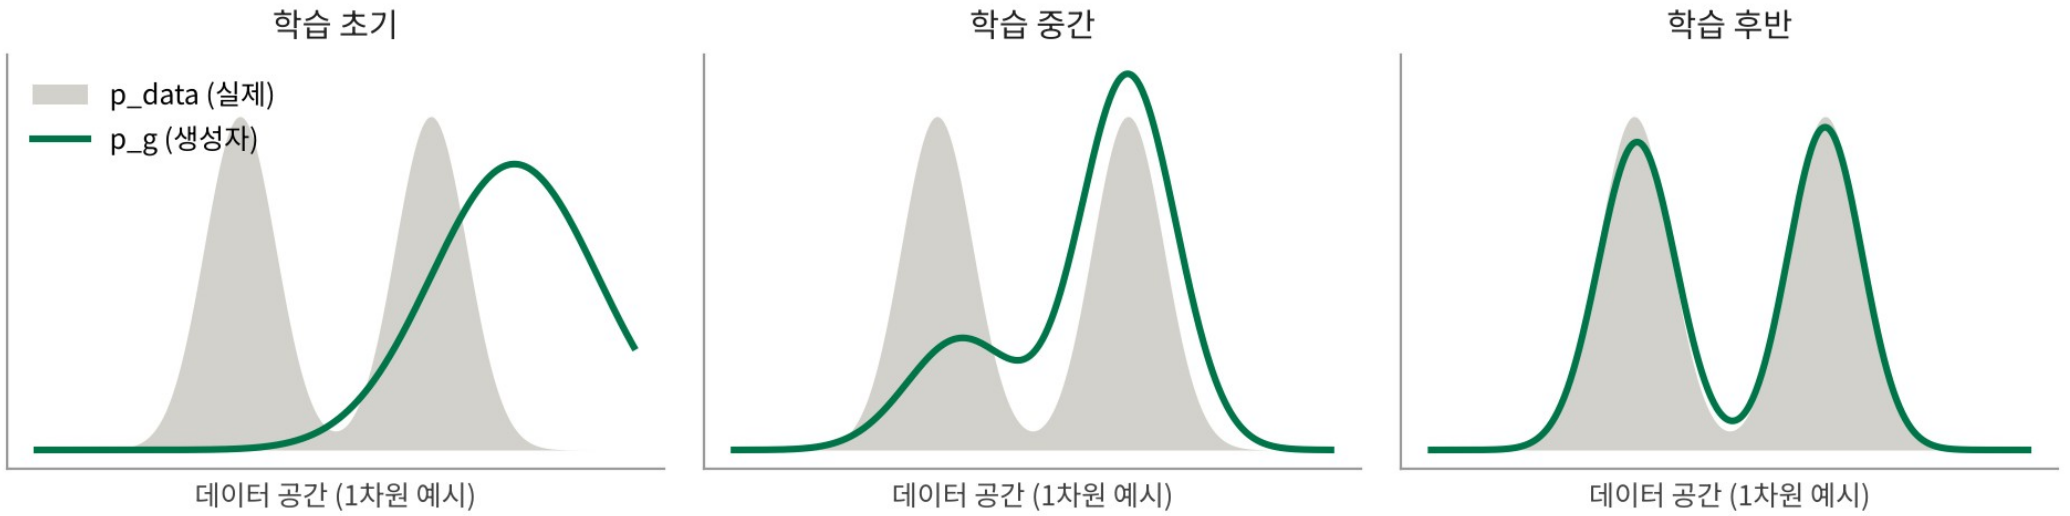
사전 지식

두 논문을 읽는 데 필요한 GAN과 양자회로 기초

GAN	생성자·판별자의 minimax 학습, 학습 불안정성(mode collapse)과 WGAN-GP, 생성 품질 평가 지표(FID, LPIPS)
양자회로	qubit과 상태벡터, 회전·얽힘 게이트, 측정과 기댓값, variational quantum circuit(VQC)의 hybrid 학습 루프, 시뮬레이션의 한계
이후 내용과의 관계	이 장에서 정의한 용어(RY, CNOT, 기댓값, WGAN-GP, FID)를 QGAN·MediQ-GAN 설명에서 그대로 사용함

GAN: 적대적 학습으로 데이터 분포를 근사하는 생성모델

Generative Adversarial Network(생성적 적대 신경망). Goodfellow et al., NeurIPS 2014



- **목적**: 실제 분포 p_data를 근사하는 생성 분포 p_g를 학습해 새 샘플을 만듦
- **구성**: 생성자 G와 판별자 D, 두 신경망
- **학습 신호**: D의 판단이 G의 손실이 됨. 정답 이미지와 픽셀 단위로 비교하지 않음

의료 이미지 증강에서의 용도

희귀 병변은 수집이 어렵고 개인정보 문제로 공유가 제한됨

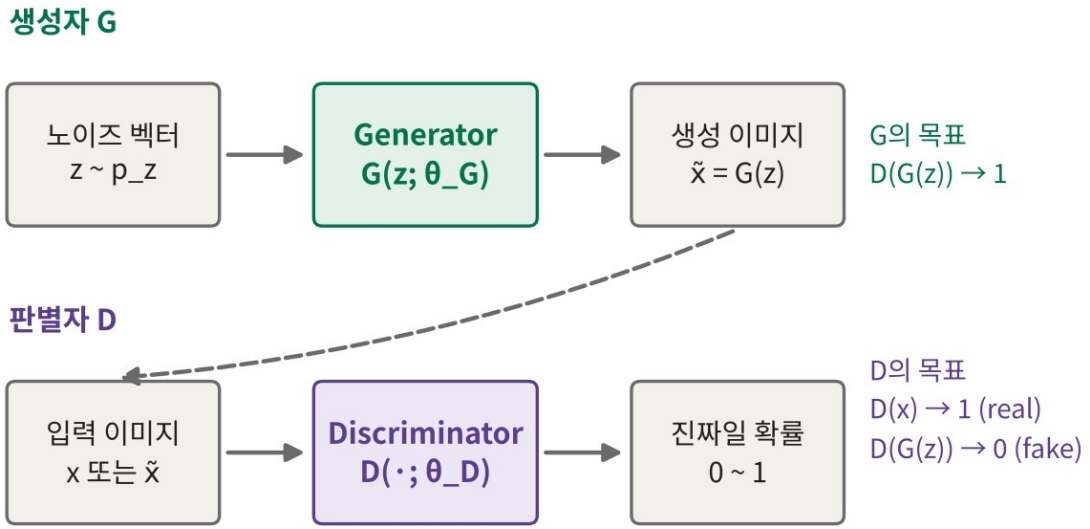
소수 클래스(df 115장)를 새 샘플로 보충. 유용성은 지표로 별도 검증

그림: 개념도(1차원 예시). 수치 데이터가 아님

사전 지식 · GAN

생성자와 판별자의 역할

두 신경망은 입력·출력이 다르고 목표가 서로 반대임. 이 반대 관계가 '적대적'의 의미임



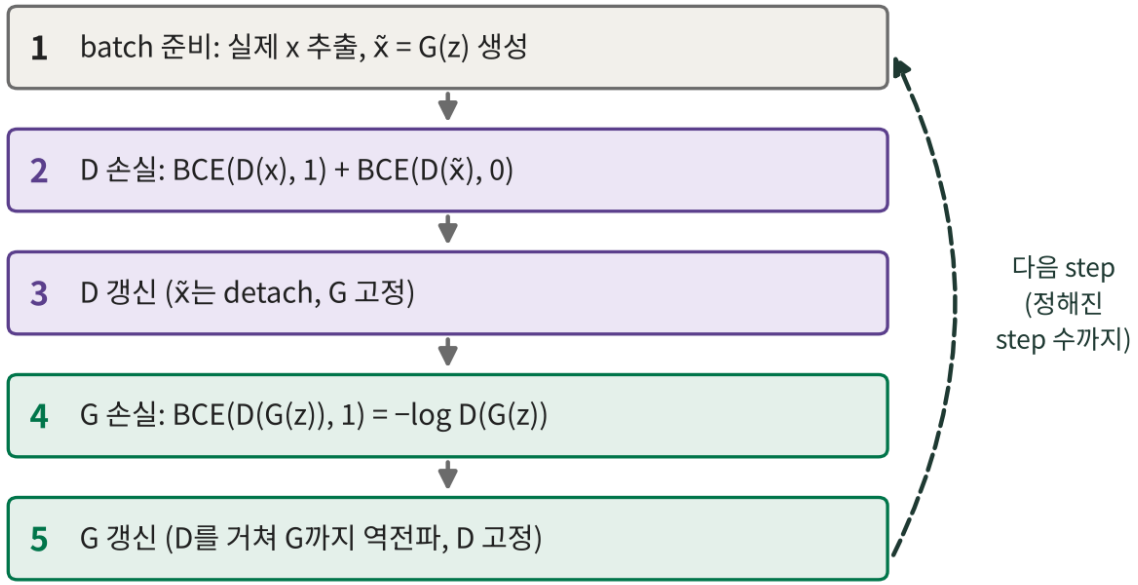
항목	생성자 G	판별자 D
입력	노이즈 벡터 z	이미지 (실제 x 또는 생성 x̃)
출력	이미지 x̃ = G(z)	진짜일 확률 (0 ~ 1)
목표	D(G(z))를 1에 가깝게	D(x)는 1, D(G(z))는 0에 가깝게
모델 유형	생성모델	이진 분류기
2일차 구현	양자회로 4개, 파라미터 280개	5층 완전연결, 파라미터 19,201개

실습과의 연결

QGAN · MediQ-GAN은 G에만 양자회로를 넣음. 2일차는 D가 G보다 약 70배 커서 학습률을 G 0.05, D 0.001로 다르게 둠 (2일차 노트북)

학습 과정: 판별자와 생성자를 번갈아 갱신

한 step 안에서 D를 먼저, G를 나중에 갱신함. 2·3일차 노트북의 학습 루프와 같은 순서임



종료와 손실 해석

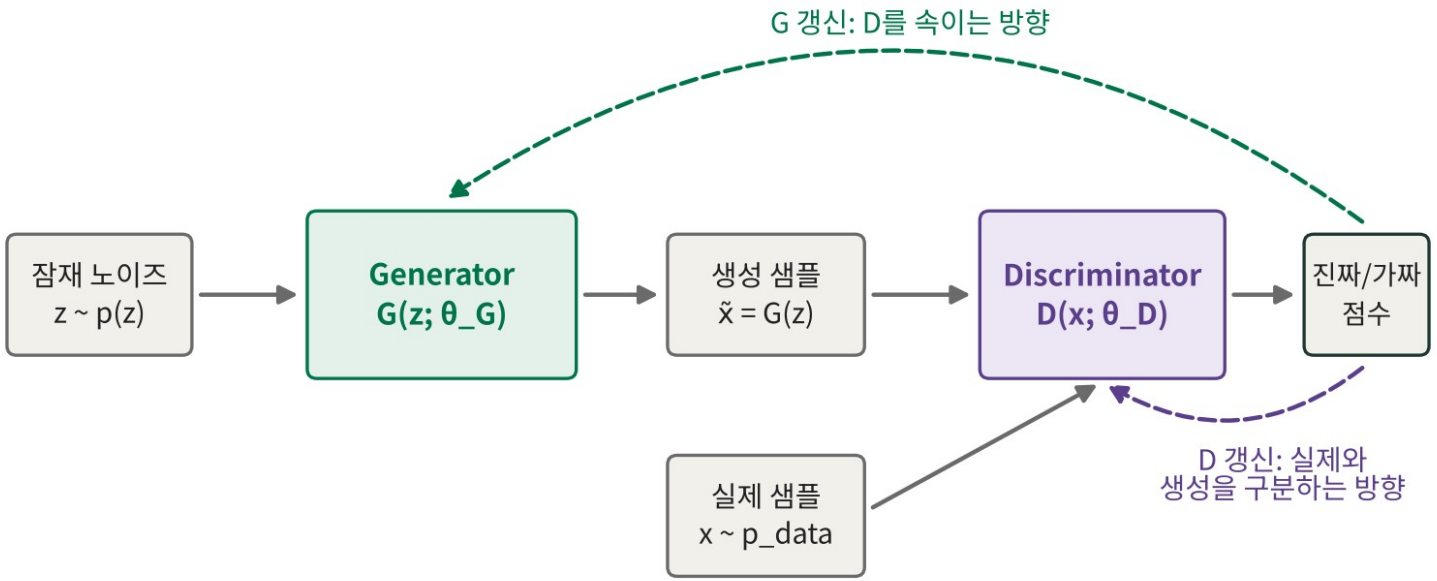
- 보상이 아니라 손실의 gradient로 파라미터를 갱신함
- 학습은 정해진 step 수에서 멈춤 (2일차 400 step). 생성 분포가 실제와 같아지는 시점을 손실로 알 수는 없음
- 이론상 평형(p_g = p_data)에서 D = 1/2이고 이때 D 손실 2 ln 2 ≈ 1.386, G 손실 ln 2 ≈ 0.693. 2일차 로그의 기준값
- D 손실이 0에 가까우면 D가 압도해 G의 gradient가 약해짐
- 품질은 손실이 아닌 평가 지표로 판단함 (이어지는 지표 슬라이드)

코드 대응 (2일차 노트북)

loss_d = bce(disc(batch), 1) + bce(disc(gen(B).detach()), 0) → opt_d.step() / loss_g = bce(disc(gen(B)), 1) → opt_g.step()

GAN의 목적함수(minimax)

앞의 학습 과정을 하나의 목적함수와 갱신 방향으로 정식화함



- **D 갱신**: 실제 x는 1, 생성 x̃는 0으로 분류하도록 V를 최대화
- **G 갱신**: D가 x̃를 1로 판단하도록 V를 최소화
- **D의 최적해**: D*(x) = p_data(x) / (p_data(x) + p_g(x)). p_g = p_data이면 1/2
- QGAN · MediQ-GAN은 이 구조에서 G만 양자회로를 포함함

$$\min_G \max_D \; V(D, G) = E[\log D(x)] + E[\log(1 - D(G(z)))]$$

x ~ p_data(실제), z ~ p_z(노이즈). G의 손실은 학습 초반 gradient 소실을 피하려고 −log D(G(z))로 바꿔 쓰는 경우가 많음

학습 불안정성과 WGAN-GP

원 GAN의 손실은 학습이 불안정하고, 두 논문은 서로 다른 학습 목표를 사용함

문제	현상	원인
Vanishing gradient	D가 너무 잘 구분하면 G의 gradient가 0에 수렴	두 분포의 support가 겹치지 않으면 JS divergence가 상수
Mode collapse	G가 일부 유형의 샘플만 반복 생성	D가 다양성을 직접 평가하지 않음
진동	손실이 수렴하지 않고 진동	두 모델을 동시에 최적화하는 min-max 구조

항목	원 GAN (BCE)	WGAN-GP
D의 출력	확률 (시그모이드)	실수 점수 (critic)
손실	BCE: $\log D(x) + \log(1 - D(G(z)))$	$E[D(x)] - E[D(G(z))] + \lambda \cdot GP$
거리	Jensen-Shannon	Wasserstein-1
안정화	없음	critic gradient 노름을 1로 유도 (1-Lipschitz)
사용 논문	**QGAN (Table 4)**	**MediQ-GAN (식 (1)·(2))**

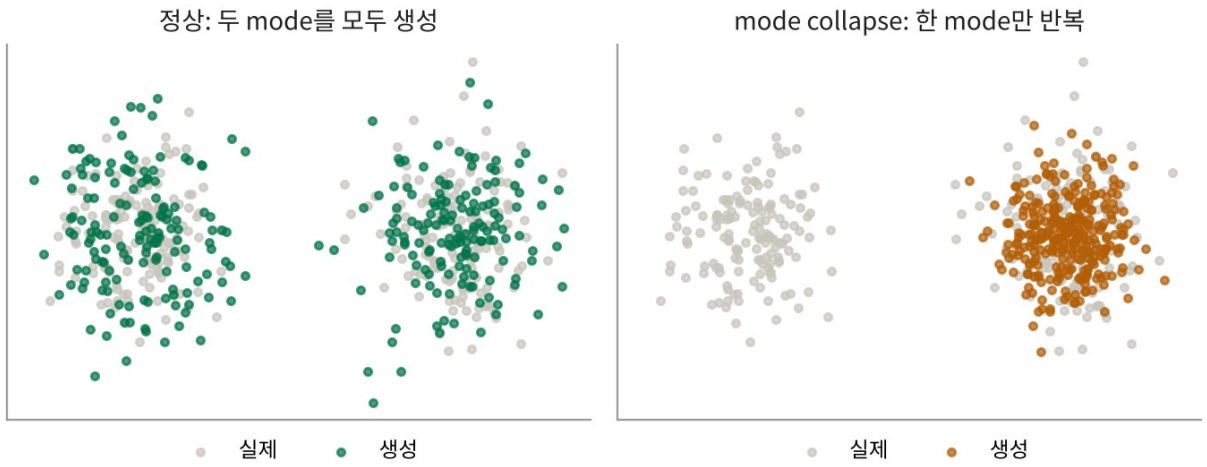
용어와 실습 연결

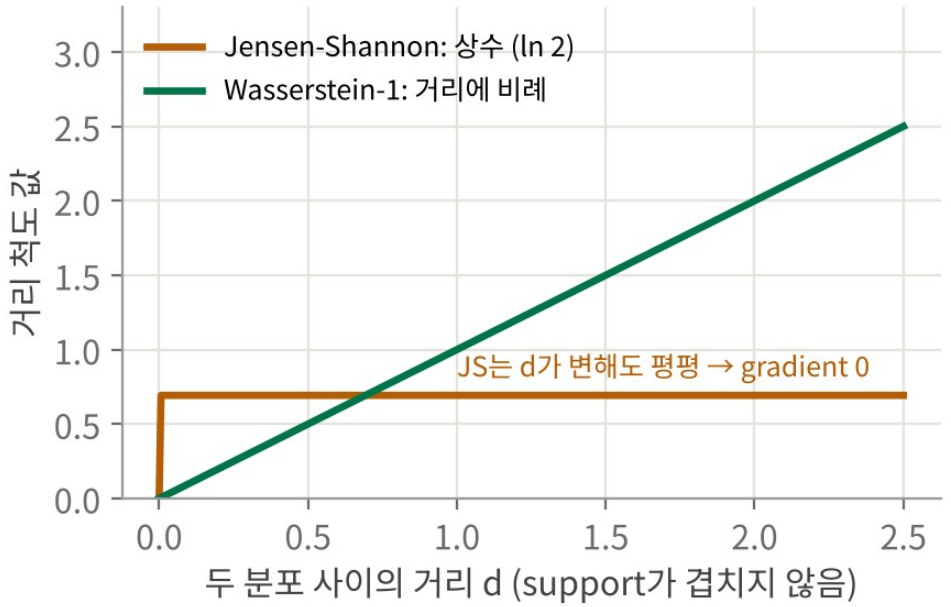
support: 분포가 0이 아닌 값을 갖는 영역. JS divergence, Wasserstein-1: 두 확률분포 사이의 거리 척도. 1-Lipschitz: 입력이 변할 때 출력 변화율이 1 이하인 함수

3일차: MediQ-GAN을 생성자 학습률 0.02로 학습하면 3 epoch 만에 mode collapse가 발생함. 원 논문이 WGAN-GP critic을 쓰는 이유에 해당함

학습 불안정성 시각화: mode collapse, JS 대 Wasserstein

앞 슬라이드의 두 문제를 2차원 예시와 거리 척도 비교로 확인함





mode collapse

- 실제 분포가 두 mode(예: 서로 다른 두 병변 형태)를 가져도 한 mode만 반복하면 판별자를 속일 수 있음
- 다양성 지표(LPIPS, 샘플 간 거리)로 점검함

vanishing gradient와 WGAN

- support가 겹치지 않으면 JS는 ln 2로 일정해 생성자에게 방향 정보가 없음
- Wasserstein-1은 거리에 비례해 gradient가 남음

개념도(2차원 예시와 점질량 분포 가정). 수치 데이터가 아님

생성 품질 평가: 지표별 측정 대상

생성 이미지의 품질은 눈으로 판단하기 어려워 정량 지표를 병행함. 용어는 이어지는 세 장에서 풀어 설명함

지표	측정 대상	방향
Downstream 분류 성능 (AUC-ROC, 정확도)	생성 이미지를 학습 데이터에 추가했을 때 분류기 성능 변화 QGAN 논문, MediQ-GAN Table 1	높을수록 좋음
FID	실제와 생성 이미지의 Inception 특징 분포(평균·공분산) 사이 Fréchet 거리 MediQ-GAN 논문 (클래스별)	낮을수록 좋음
intra-class LPIPS	같은 클래스 생성 이미지 쌍의 지각적 거리 평균. mode collapse 점검 MediQ-GAN 논문	높을수록 다양
지표 4종 (실습)	픽셀 분포, 클래스 평균 상관, 최근접 실제 거리, 샘플 다양성 2·3일차 노트북 (16×16에서는 FID 사용 불가)	지표별 상이

해석 시 유의

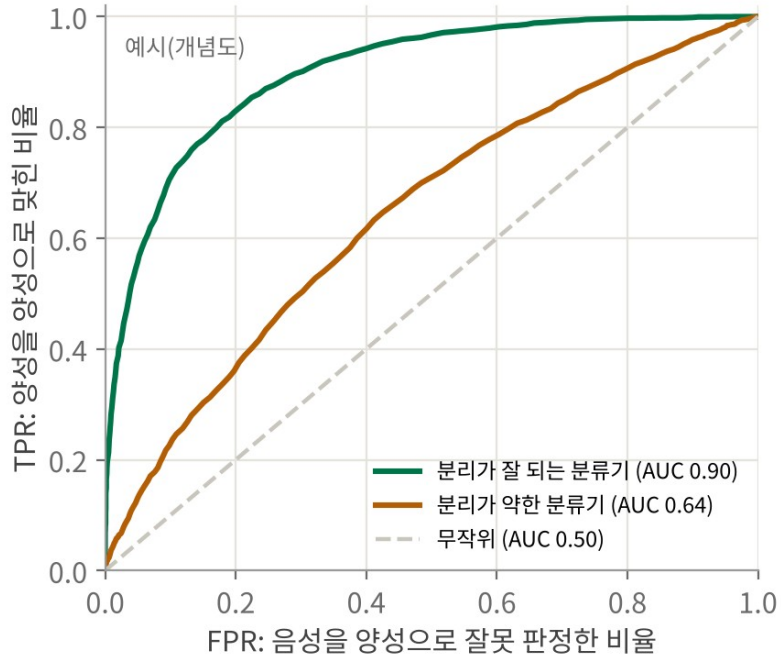
- FID가 낮아도 LPIPS가 낮으면 비슷한 이미지만 생성한 것이므로 두 지표를 함께 봄
- 표본이 적은 클래스(df 115장)에서는 FID 공분산 추정이 불안정함
- 분류 성능은 분류기와 증강 비율에 의존함
- 정확도만으로는 불균형 데이터의 성능을 판단하기 어려워 AUC를 함께 봄

사전 지식 · 평가 지표

지표 용어 ① 분류 성능: 정확도, ROC, AUC

증강 효과를 분류기 성능으로 확인할 때 쓰는 용어

용어	설명
downstream 평가	생성 이미지를 실제로 쓰는 후속 작업(여기서는 분류)의 성능으로 생성 품질을 간접 평가
양성 / 음성	찾으려는 클래스(df)를 양성, 비교 클래스(nv)를 음성으로 둠 (이진 분류)
정확도	전체 중 맞힌 비율, (TP + TN) / 전체. df 대 nv 분류에서 nv가 98.3%(6,705 / 6,820)이므로 모두 nv로 답해도 98.3%라서 불균형 데이터에서는 높게 나옴
ROC 곡선	판정 기준값(threshold)을 바꾸며 TPR(양성을 맞힌 비율)과 FPR(음성을 양성으로 잘못 판정한 비율)을 그린 곡선
AUC	ROC 곡선 아래 면적. 무작위 양성이 무작위 음성보다 높은 점수를 받을 확률. 0.5는 무작위, 1.0은 완벽. 기준값과 클래스 비율의 영향을 덜 받음



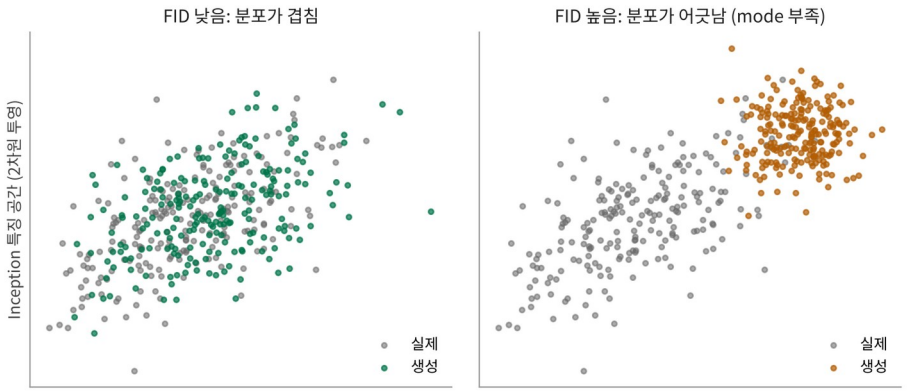
TP, TN: 양성, 음성을 맞힌 수. 곡선이 왼쪽 위로 휠수록 AUC가 큼

지표 용어 ② FID: Inception 특징과 Fréchet 거리

실제 이미지 집합과 생성 이미지 집합이 얼마나 비슷한 분포인지를 한 숫자로 나타냄

용어	설명
Inception 특징	ImageNet으로 사전학습한 Inception-v3의 마지막 pooling 출력(2,048차원). 이미지를 숫자 벡터로 바꾼 표현
특징 분포	이미지 집합을 특징 공간의 점 구름으로 보고 평균 μ와 공분산 Σ로 요약(가우시안 근사)
Fréchet 거리	두 가우시안 사이의 거리. 평균 차이와 분산 형태 차이를 함께 반영함
FID 해석	0에 가까울수록 두 분포가 비슷함. 클래스당 표본이 적으면 Σ 추정이 불안정함

$$\mathrm{FID} = \| \mu_r - \mu_g \|^2 + \mathrm{Tr}(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{1/2})$$



읽는 법

- r은 실제(real), g는 생성(generated) 이미지 집합
- 왼쪽 그림: 분포가 겹쳐 FID 낮음. 오른쪽: 분포가 어긋나고 일부 영역만 덮어 FID 높음
- 이 강의의 실습은 16×16이라 Inception 입력 크기에 맞지 않아 FID를 쓰지 않음

지표 용어 ③ LPIPS: 지각적 거리와 다양성

같은 클래스에서 만든 이미지끼리 얼마나 다른지로 mode collapse를 점검함



d가 클수록 두 이미지가 지각적으로 다름 → 쌍 평균이 높을수록 생성 이미지가 다양함

용어

- **지각적 거리**: 픽셀 값 차이가 아니라 사전학습 CNN 특징으로 잰 이미지 간 차이. 사람의 유사성 판단과 더 잘 맞음
- **LPIPS**: Learned Perceptual Image Patch Similarity. layer별 특징 차이를 학습된 가중치로 합산한 거리

intra-class LPIPS의 해석

- **intra-class**: 같은 클래스 안의 생성 이미지 쌍만 비교함
- 값이 실제 이미지 쌍의 값에 가까우면 다양성이 충분하고, 크게 낮으면 비슷한 이미지만 만드는 mode collapse

 정의 출처: Zhang et al., The Unreasonable Effectiveness of Deep Features as a Perceptual Metric (CVPR 2018)

양자 컴퓨팅과 양자 머신러닝

양자회로를 머신러닝 모델의 일부로 쓰는 접근을 데이터와 알고리즘 종류로 분류함



정의

- **양자 컴퓨팅**: 중첩, 얽힘, 간섭을 이용하는 계산 모델. 입력은 큐빗, 연산은 양자 게이트, 출력은 측정
- **양자 머신러닝(QML)**: 양자회로를 학습 가능한 모델의 일부로 사용함
- **hybrid**: 회로는 일부이고 입출력 처리, 손실 계산, optimizer는 고전 컴퓨터가 담당함

이 강의의 범위

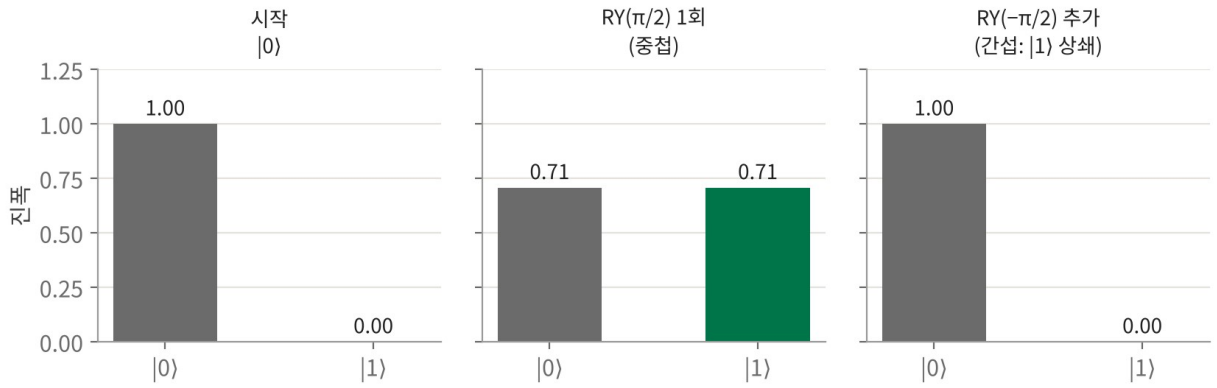
QGAN과 MediQ-GAN은 고전 데이터(이미지)를 각도로 바꿔 양자회로에 넣는 CQ 유형임. 양자 컴퓨터가 이미지를 직접 읽는다는 뜻이 아니라, 회로가 파라미터를 가진 함수로 쓰이는 것임

분류 출처: Schuld, Sinayskiy & Petruccione, Contemporary Physics 56 (2015)

양자 연산의 세 가지 성질: 중첩, 얽힘, 간섭

세 성질이 회로 안에서 각각 어떤 역할을 하는지를 이 강의의 회로와 연결함

성질	의미	이 강의의 회로에서의 역할
중첩	큐빗이 |0⟩과 |1⟩의 진폭을 동시에 가짐. 측정하면 확률에 따라 하나로 정해짐	RY(θ)로 각도를 조절해 측정 확률을 정함 (노이즈 encoding, 학습 파라미터)
얽힘	여러 큐빗의 측정 결과가 독립이 아니라 상관을 가짐	CNOT, CZ로 픽셀 또는 특징 사이의 상관을 표현함
간섭	진폭이 더해지거나 상쇄되어 측정 확률이 달라짐	variational layer가 진폭을 조합해 확률 분포를 만들고, 학습은 이 결과를 조절함

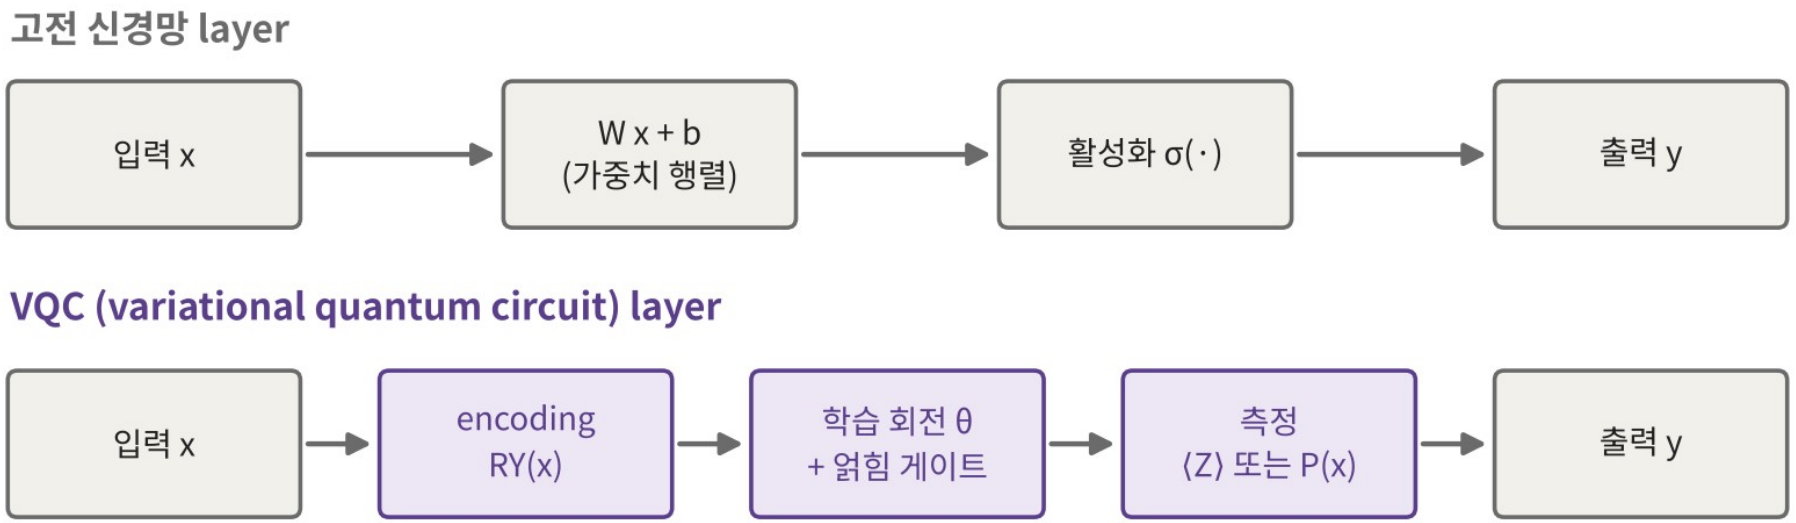


간섭 예시

- RY(π/2)로 |0⟩과 |1⟩의 진폭이 각각 0.71로 나뉨 (중첩)
- RY(−π/2)를 이어 적용하면 |1⟩의 진폭이 $0.71 \times 0.71 - 0.71 \times 0.71 = 0$으로 상쇄되어 |0⟩만 남음 (간섭)

고전 layer와 VQC layer

VQC(variational quantum circuit)는 입력과 출력이 고전 값이므로 신경망의 layer 하나처럼 쓸 수 있음



입력 표현

- 고전: 벡터를 그대로 사용
- VQC: 값을 회전각으로 변환(encoding)해 큐빗에 넣음

연산과 비선형성

- 고전: 행렬곱 + 활성화 함수
- VQC: 유니터리 연산(선형, 노름 보존). 비선형성은 encoding의 삼각함수와 측정 확률(진폭의 제곱)에서 생김

파라미터와 학습

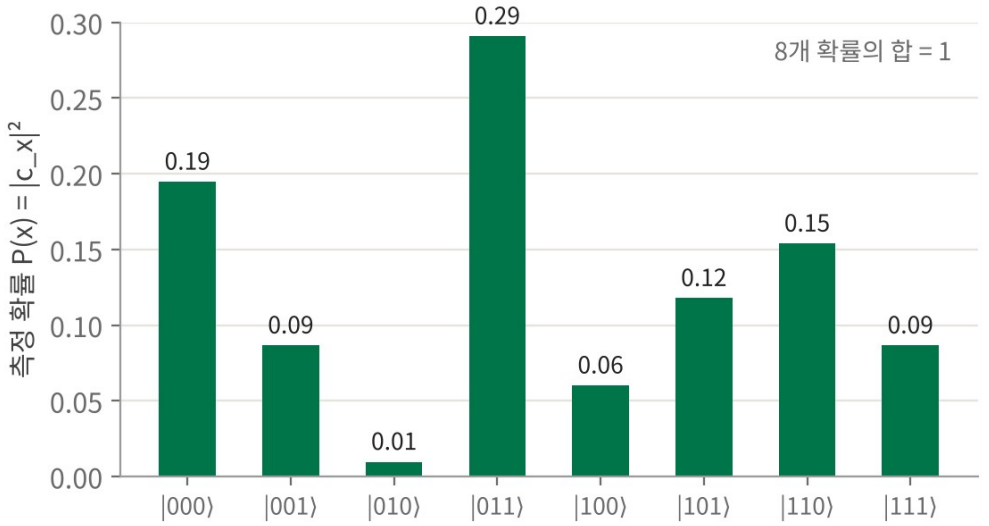
- 고전: 가중치 행렬, backpropagation
- VQC: 회전각 θ, adjoint 또는 parameter-shift로 gradient 계산

qubit과 상태벡터

n큐빗 상태는 2^n개의 복소 진폭이며, 측정 확률은 진폭 크기의 제곱

$$|\psi\rangle = \alpha|0\rangle + \beta|1\rangle,\ |\alpha|^2 + |\beta|^2 = 1$$
$$\text{n큐빗: } |\psi\rangle = \Sigma\, c_x\, |x\rangle,\ P(x) = |c_x|^2$$

구분	고전	양자
상태	n bit = 문자열 하나	n큐빗 = 2^n 진폭 벡터
갱신	논리 연산	유니터리 행렬 곱 (노름 보존)
읽기	값을 그대로 읽음	측정 시 확률 P(x)로 bitstring 하나 결정

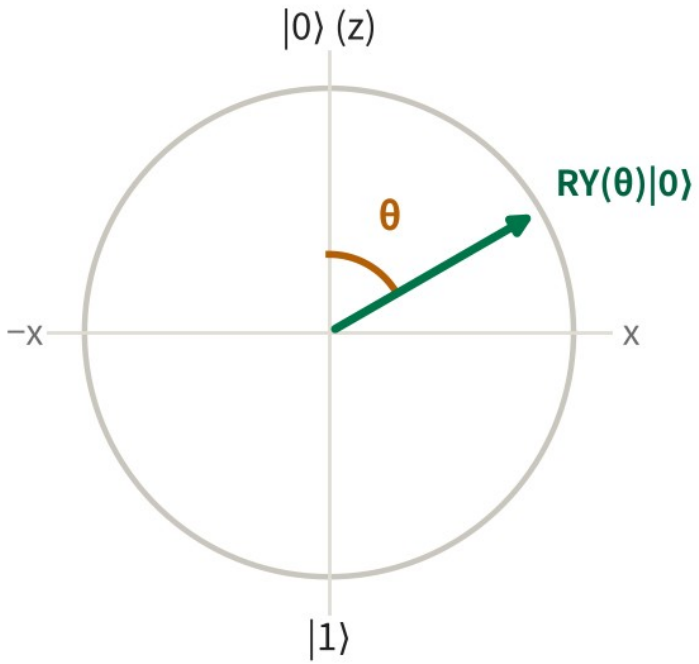


이후 논문과의 연결

- QGAN: 데이터 7큐빗 → 확률 128개 = patch 픽셀 128개
- MediQ-GAN: 16큐빗 → 상태벡터 65,536차원

1큐빗 상태의 시각화: Bloch 구 단면과 RY 회전

RY(θ)는 상태를 x-z 평면의 원 위에서 θ만큼 회전시키고, 측정 확률은 z축 성분이 정함



$\theta = \pi/3$: $P(0) = \cos^2(\theta/2) = 0.75$, $P(1) = \sin^2(\theta/2) = 0.25$

항목	설명
Bloch 구	1큐빗 순수 상태를 구 위의 한 점으로 나타냄. 북극이 $\|0\rangle$, 남극이 $\|1\rangle$
RY(θ)	y축 주위의 회전. 상태가 x-z 평면을 벗어나지 않아 이 슬라이드는 그 단면을 그림
측정 확률	z축 성분이 정함. 북극에 가까울수록 0이 나올 확률이 큼
RX, RZ	RX는 x축 주위, RZ는 z축 주위의 회전. RZ는 확률을 바꾸지 않고 위상만 바꿔 간섭에 영향을 줌

읽는 법

$\theta = 0$이면 $|0\rangle$, $\theta = \pi$이면 $|1\rangle$, $\theta = \pi/2$이면 x축 방향(50 : 50). 학습은 이 θ들을 조정해 확률 분포를 만드는 과정임

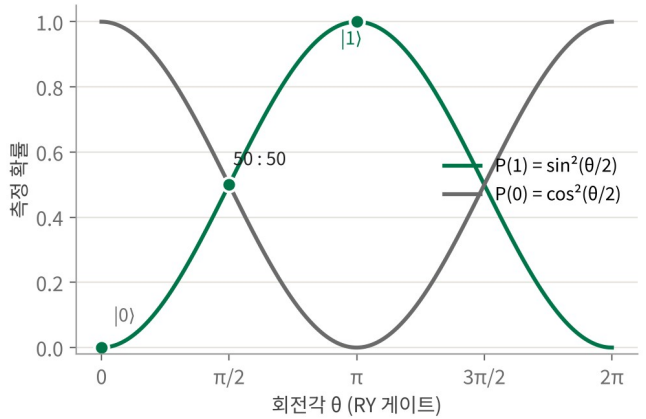
게이트: 회전과 얽힘

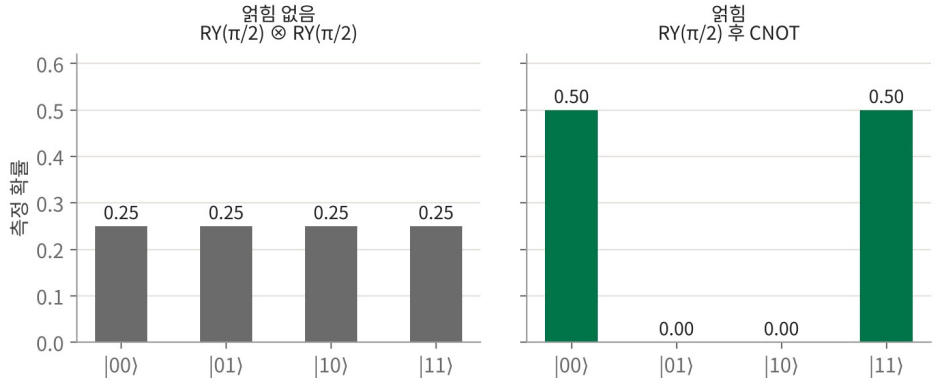
두 논문의 회로는 회전 게이트와 얽힘 게이트 두 종류로만 구성됨

게이트	작용	학습 대상
RY(θ)	$\|0\rangle \rightarrow \cos(\theta/2)\|0\rangle + \sin(\theta/2)\|1\rangle$ $P(1) = \sin^2(\theta/2)$	θ (학습)
RX(θ)	X축 회전. MediQ-GAN의 encoding에 사용	입력값 (고정)
CNOT	제어 큐빗이 1이면 목표 큐빗 반전	파라미터 없음
CZ	두 큐빗이 모두 1이면 위상에 −1	파라미터 없음

두 논문의 회로 구성

- QGAN: RY(z) encoding → [RY(θ) + CZ 체인] × depth 10
- MediQ-GAN: RX, RY encoding → [RY(θ) + CNOT 체인] × 8





측정과 기댓값

측정 한 번은 bitstring 하나이고, 모델이 쓰는 값은 반복 측정의 통계량

출력 방식	정의와 출력 크기	사용 논문
확률 분포 P(x)	2^n개 basis state의 측정 확률 출력 크기 2^n (지수)	QGAN
기댓값 ⟨X_i⟩	큐빗별 관측량의 평균, −1 ~ 1 출력 크기 n (선형)	MediQ-GAN

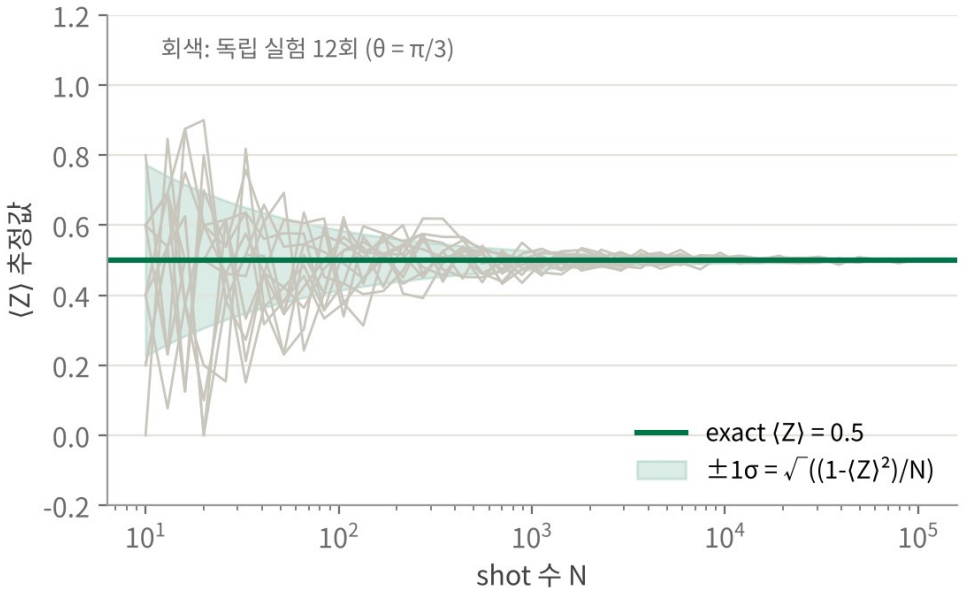
$$\langle Z \rangle = P(0) - P(1) \in [-1, 1]$$

$$\text{shot N회 추정의 표준오차} = \sqrt{((1 - \langle Z \rangle^2) / N)} \leq 1/\sqrt{N}$$

출력 구조의 차이

QGAN: 8큐빗 중 ancilla qubit = 0인 128개 확률을 patch 픽셀로 사용

MediQ-GAN: 16큐빗 → 기댓값 16개를 특징으로 사용, 이미지는 고전 decoder가 생성

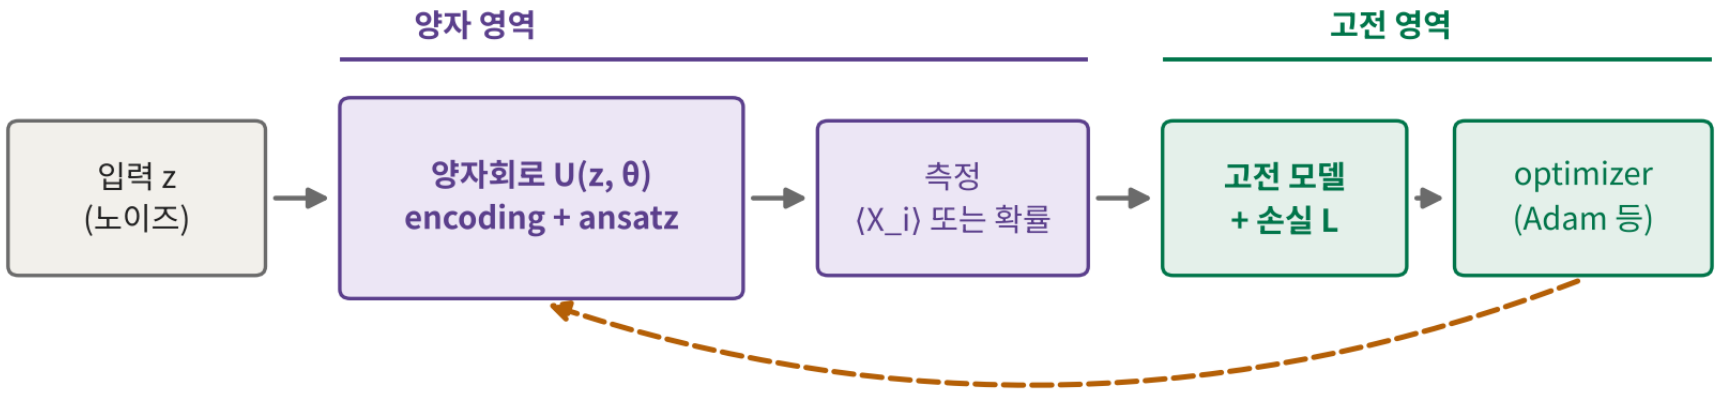


정밀도를 10배 높이려면 shot이 100배 필요함. 이 비용이 뒤의 VQC 학습 비용 계산에 들어감

시뮬레이터에서 shots를 지정하지 않으면 이 오차 없이 exact 기댓값을 계산함

PQC·VQC와 hybrid 학습 루프

PQC(parameterized quantum circuit)를 variational 방식으로 학습시킨 것이 VQC(variational quantum circuit)임. QGAN 논문은 PQC, MediQ-GAN 논문은 VQC로 부름



θ 갱신: ∂L/∂θ (adjoint 또는 parameter-shift)

encoding

- 입력을 회전각으로 변환 (angle encoding). 두 논문 모두 사용
- 대안인 amplitude encoding은 2ⁿ개 값을 적재하나 상태 준비 회로가 깊어질 수 있음

ansatz

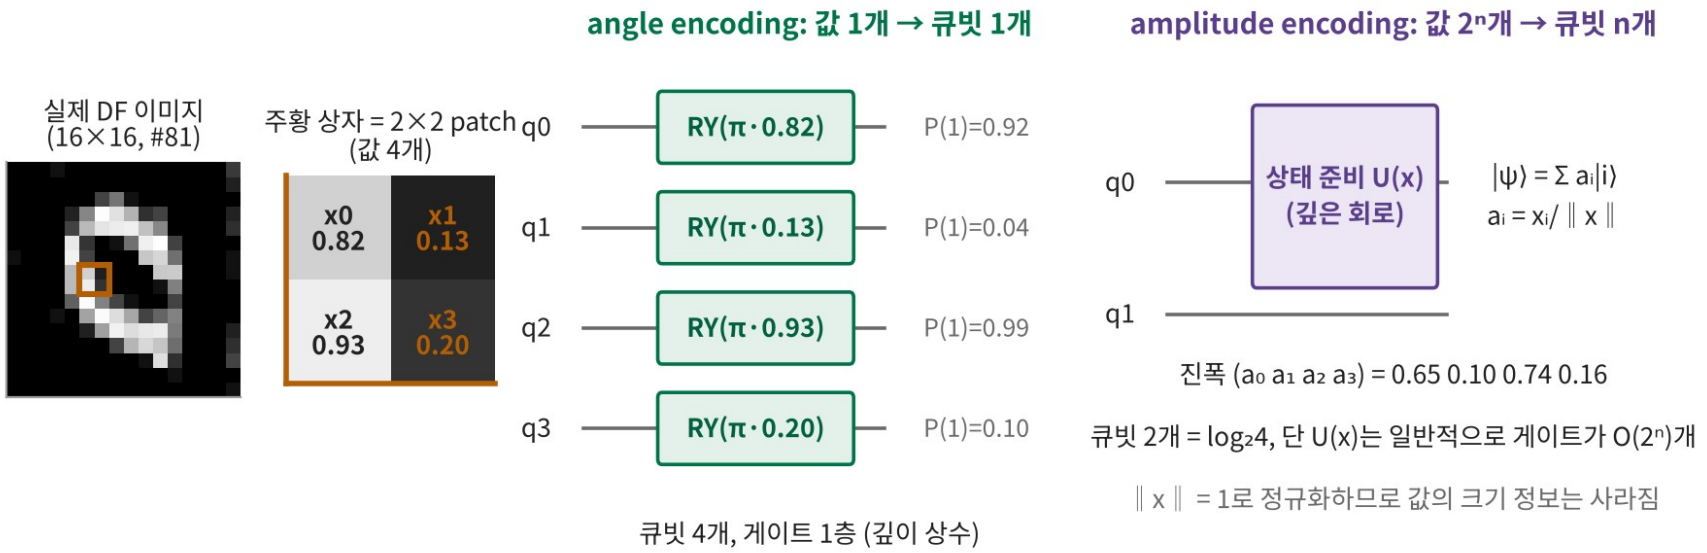
- 학습 가능한 회전 + 얽힘 게이트의 반복
- 두 논문 모두 hardware-efficient 구조 (RY + CNOT 또는 CZ)

gradient

- 시뮬레이터: adjoint 또는 backpropagation
- 실기: parameter-shift rule, 파라미터마다 회로 2회 추가 실행

Encoding 방식 비교: angle encoding과 amplitude encoding

같은 값 4개(실제 DF 이미지의 2×2 patch)를 두 방식으로 큐빗에 넣는 예

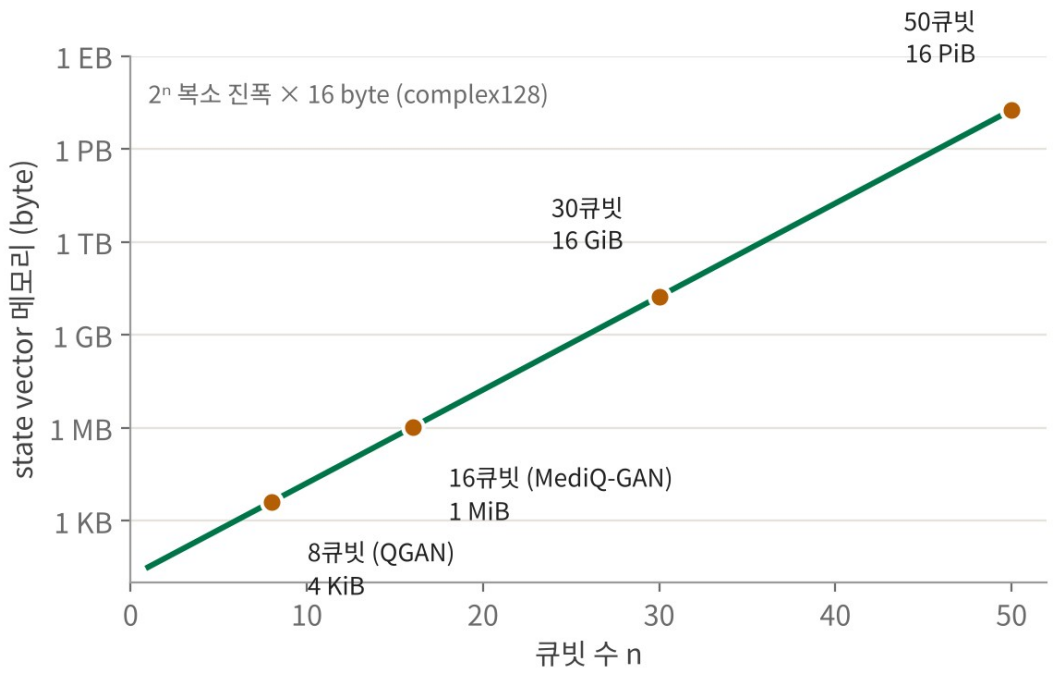


비교	angle encoding	amplitude encoding
큐빗 수	값 n개 → 큐빗 n개	값 2^n개 → 큐빗 n개
회로 깊이	게이트 1층	상태 준비 회로가 일반적으로 깊음
두 논문	QGAN RY(z), MediQ-GAN RX → RY	사용하지 않음

두 논문에서 encoding되는 값은 이미지가 아니라 노이즈(QGAN)와 특징 벡터(MediQ-GAN)임. 위 이미지는 두 방식을 비교하기 위한 예시임

시뮬레이션의 한계와 학습 가능성

state vector 시뮬레이션은 큐빗 수에 지수적이고, 회로가 넓고 깊을수록 학습이 어려워짐



항목	내용
시뮬레이션 규모	16큐빗은 1 MiB로 노트북에서 처리 가능. 30큐빗부터 16 GiB로 일반 PC 한계
해석	정확히 시뮬레이션되는 규모의 회로는 양자 우위의 근거가 아님. MediQ-GAN 논문도 quantum-inspired로 규정하고 양자 소자를 계산 가속 용도로 한정
NISQ 실기	게이트 오류와 decoherence로 얕은 회로만 신뢰 가능
Barren plateau	큐빗 수·깊이가 커질수록 gradient 분산이 지수적으로 감소하는 현상
표현력 대 학습 가능성	표현력이 큰 회로일수록 barren plateau 위험이 큼. MediQ-GAN은 DLA 분석으로 depth 8을 선택

BREAK

휴식

10분 후 재개

여기까지

HAM10000 클래스 불균형 → GAN 구조·학습 불안정성 → 평가 지표 용어(정확도, AUC, FID, LPIPS) → 양자 컴퓨팅·QML 개요, 상태벡터, 게이트, 측정, VQC 학습 루프, encoding 방식, 시뮬레이션 한계

이어서

Chapter 1 QGAN (구조, 학습 step, 결과) → Chapter 2 MediQ-GAN (dual-stream, WGAN-GP, 결과) → Chapter 3 정리

CHAPTER 1

논문 ① QGAN

Quantum GAN 기반 피부병변 이미지 증강 - patch method 아키텍처

제목	Data Augmentation in Cancer Image Classification Problem with Quantum GAN
기여점	7+1큐빗 · sub-generator 16개 · patch 방식으로 피부 이미지를 생성해 소수 클래스(DF) 증강
검증 방식	생성 이미지로 CNN 분류기를 학습시켜, 증강 전/후 AUC-ROC·정확도를 비교(고전 GAN과도 비교)
핵심 내용	"Generator" 아키텍처 사례 - model-level hybrid

QGAN 기본 개념 - 고전 GAN과 무엇이 다른가

생성자(Generator)·판별자(Discriminator)가 경쟁하며 학습하는 구조는 동일

고전 GAN

Generator = 신경망(예: CNN/MLP)

무작위 노이즈 벡터 → 신경망 통과 → 이미지

학습 파라미터 = 가중치 행렬

Discriminator도 고전 신경망

QGAN

Generator = parameterized quantum circuit(PQC)

무작위 각도 노이즈 → 큐빗 회전으로 encoding → 측정

학습 파라미터 = 회전 게이트의 각도

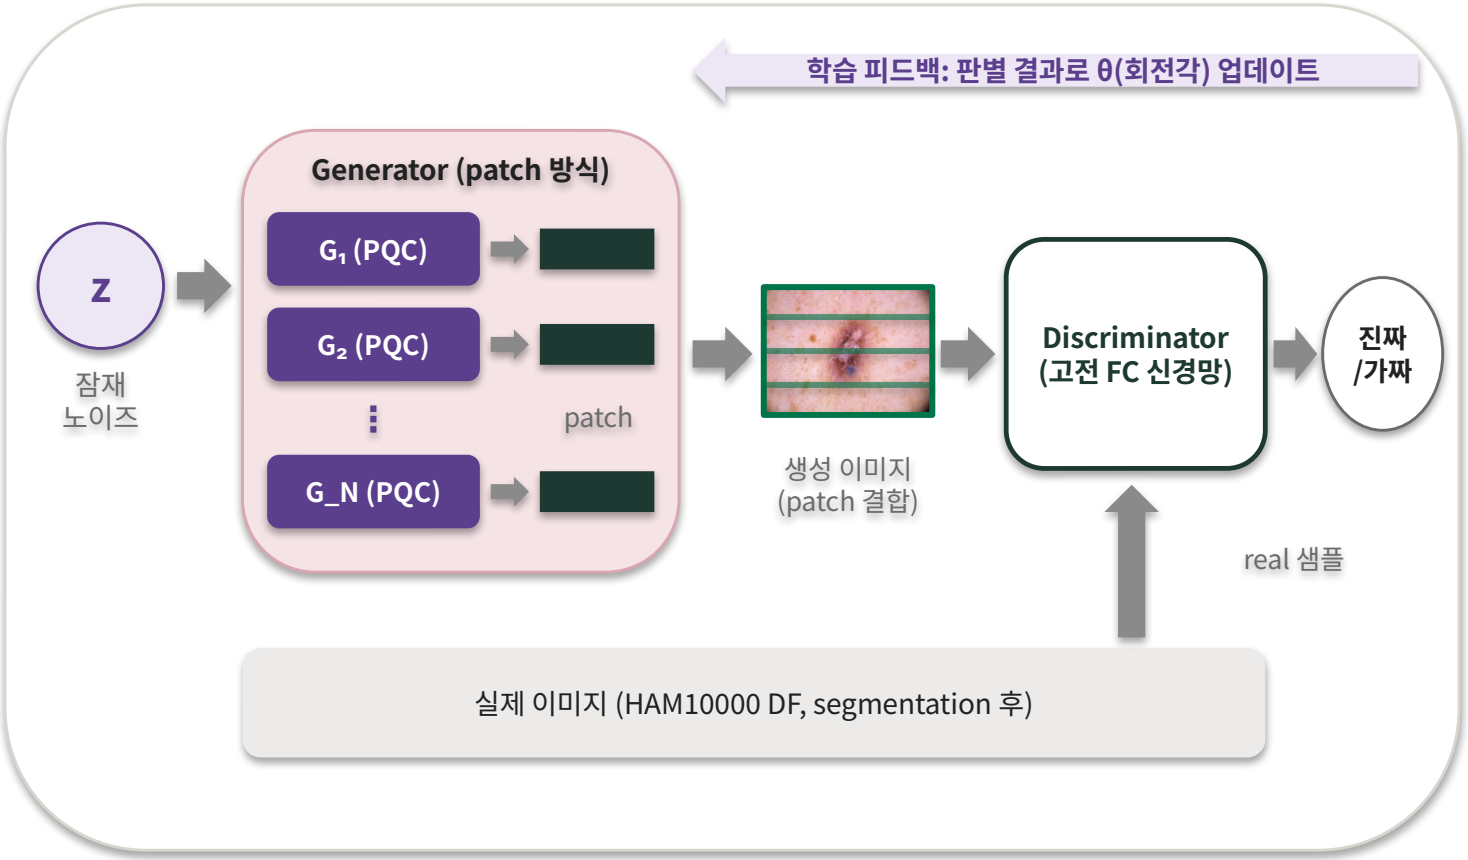
Discriminator는 그대로 고전 신경망(비대칭 구조)

핵심

Discriminator는 그대로, Generator만 양자회로 교체

QGAN 아키텍처 다이어그램 - patch 기반 Generator

Generator-Discriminator 구조를 도식으로 재구성



원 논문 Fig. 10 구조를 도식으로 재구성: Andra et al., Quantum Machine Intelligence 7, 90 (2025)

Patch 방식 아키텍처

큐빗 한 세트로 이미지 전체를 만들기 어려워, 여러 개의 '작은 회로'가 조각(patch)을 나눠 생성

sub-generator 1
PQC → patch

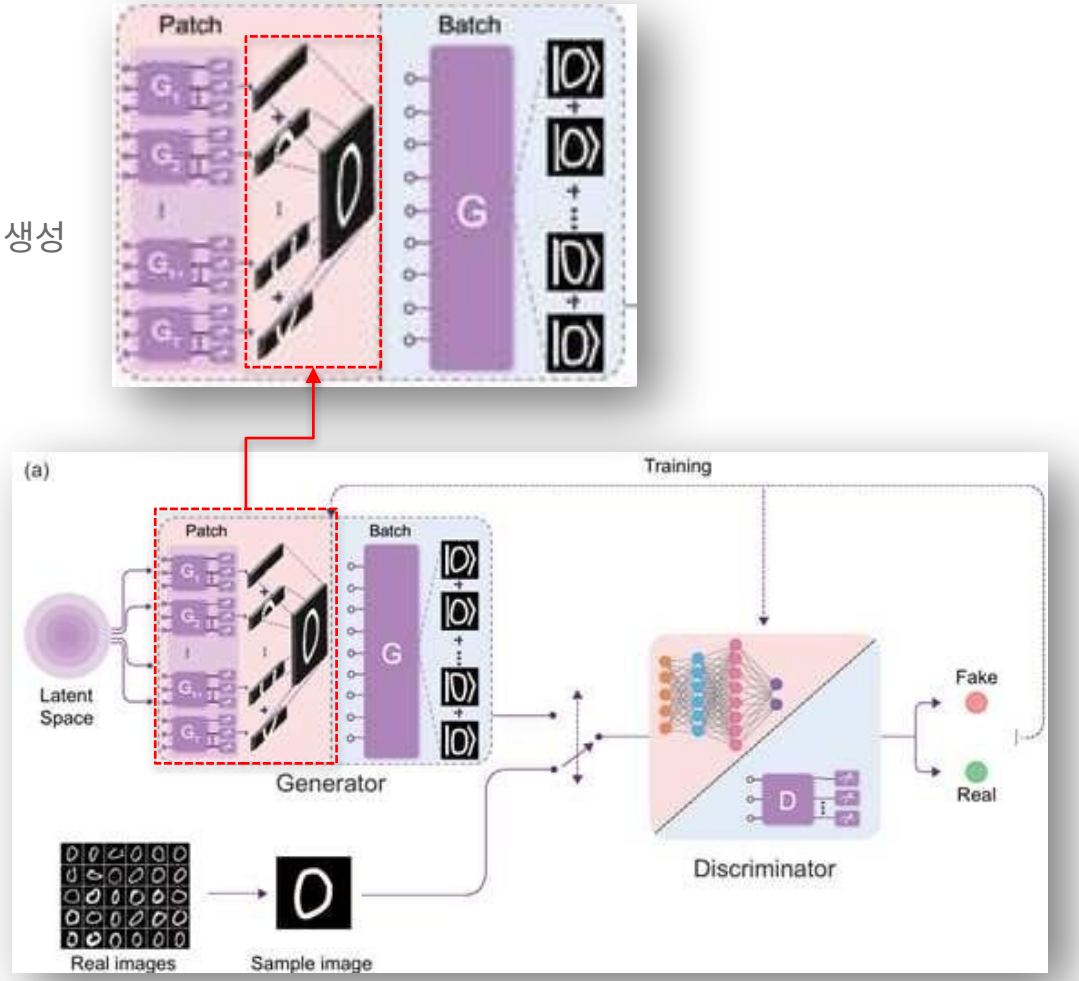
sub-generator 2
PQC → patch

sub-generator 3
PQC → patch

sub-generator N
PQC → patch

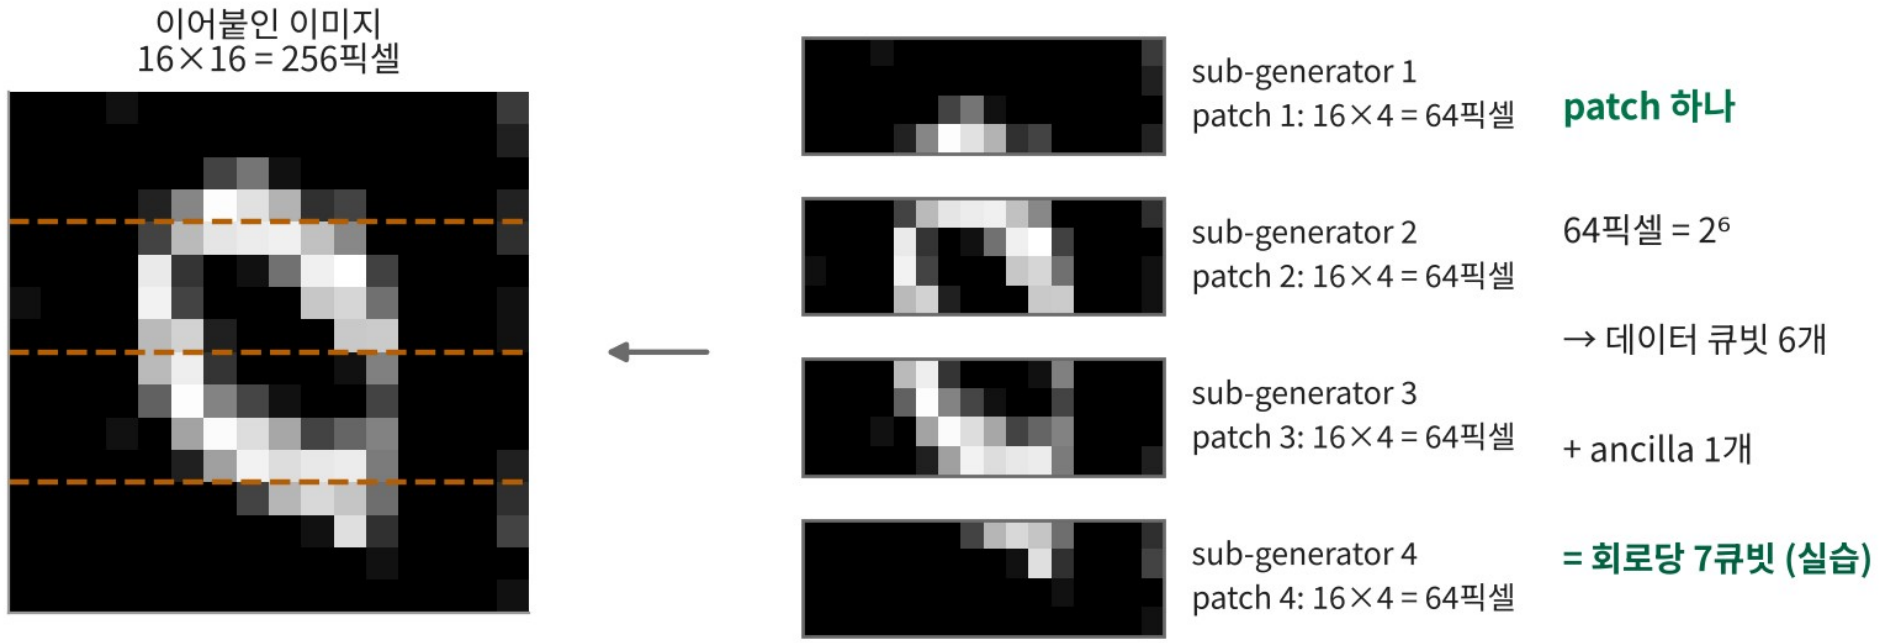
(논문: 16개 sub-generator)

patch 1 + patch 2 + patch 3
+ … + patch N
→ 이어 붙여 최종 이미지 벡터



patch 분할 예시: 16×16 = 4 patch × 64픽셀

큐빗 수에 맞춰 이미지를 띠로 나누고, sub-generator마다 patch 하나를 생성함



논문과 실습의 구성

논문: sub-generator 16개 × 데이터 큐빗 7개(patch당 128픽셀). 실습: 4개 × 6개(patch당 64픽셀). patch는 서로 독립인 회로가 만들어 경계가 어긋날 수 있음

sub-generator 회로 상세

각 sub-generator = 3단계로 이루어진 하나의 parameterized quantum circuit(

① 노이즈 encoding

무작위 각도를 RY 게이트로 각 큐빗에 회전시켜 입력

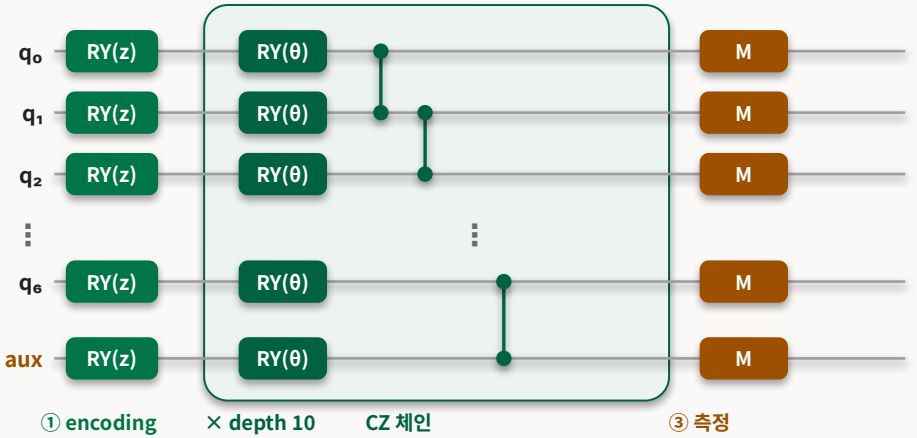
② variational layer (반복)

학습 가능한 RY 회전 + 인접 큐빗 CZ 얽힘 - 각도가 '학습되는 가중치'

③ 측정

ancilla qubit까지 전체 측정 후, ancilla qubit=0인 항목만 patch로 사용(post-selection)

sub-generator 1개 회로 (논문 Table 3 기준, 8큐빗)



측정 결과 $2^8 = 256$개 확률 중 ancilla qubit = 0 인 128개만 선택(post-selection) → patch 1장

sub-generator 16개의 patch를 이어붙여 이미지 1장을 구성

항목	값
큐빗 수	데이터 7 + ancilla 1 = 총 8
sub-generator 수	16개
회로 깊이(PQC depth)	10
학습률 / epoch	0.1 / 2,000

QGAN 한 step의 학습 과정

판별자와 생성자를 번갈아 갱신하며, 생성자의 gradient는 회로 파라미터 θ까지 전달됨

단계	동작	손실
1 생성	z → sub-generator 16개 → patch 결합 → 생성 이미지 $\tilde{x}$	-
2 D 갱신	실제 x는 1, 생성 $\tilde{x}$는 0으로 분류하도록 D의 가중치 갱신	$L_D = -[\log D(x) + \log(1 - D(\tilde{x}))]$ (BCE)
3 G 갱신	D가 $\tilde{x}$를 1로 판단하도록 회로 각도 θ 갱신	$L_G = -\log D(\tilde{x})$ (non-saturating)
4 반복	2,000 epoch (논문 Table 3·4)	-

설정에서 확인할 점

- 학습률: 생성자 0.1, 판별자 5×10^{-3} (Table 3·4). 생성자가 20배 큼
- 논문은 손실을 Binary Cross Entropy로 표기함. G 손실 형태는 일반적인 non-saturating 형태로 적은 것임
- 실습(2일차)은 sub-generator 4개, 600 step으로 줄인 설정을 사용함

Discriminator 구조 + 평가 프로토콜

"QGAN이 잘 만들었는지"는 생성 이미지 직접 확인 대신 별도 CNN 분류기 성능으로 검증

Discriminator (Table 4)

Table 4 · Discriminator	값
Layer 수	5 (완전연결)
활성화 함수	ReLU
출력층 활성화	Sigmoid
PQC 깊이 (생성자)	10
학습률	5×10^{-3}
Epoch	2,000
손실 함수	Binary Cross Entropy

평가용 CNN

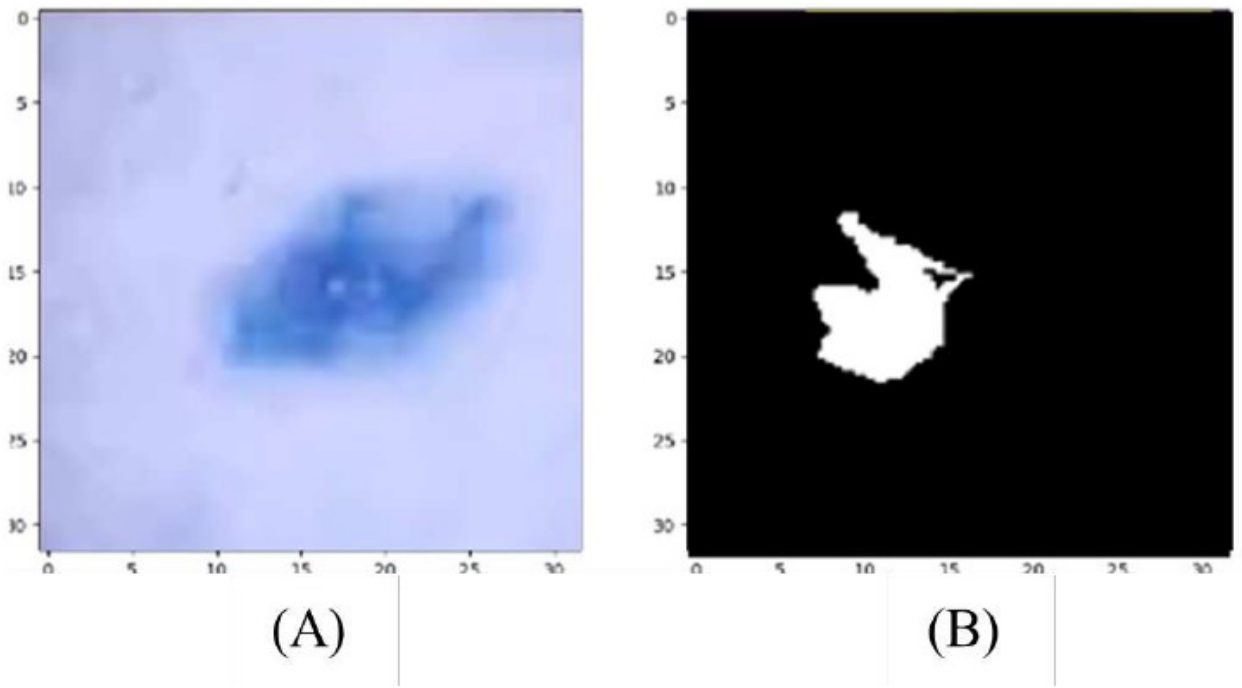
Table 1 · CNN 학습 설정	값
학습률	15×10^{-4} ($=1.5\times10^{-3}$)
손실 함수	Binary Cross Entropy
Optimizer	ADAM
정규화 layer	Batch Normalization 2D
출력 활성화	Sigmoid
파라미터 수	460k

Table 2 · Conv layer	값
Kernel 크기	3
Stride	1
활성화 함수	ReLU
정규화 layer	Batch Normalization 2D
Max Pooling	2×2

표 내용 출처: Andra et al., Quantum Machine Intelligence 7, 90 (2025), Table 1·2·4

결과 0 - QGAN 생성 이미지

논문 Fig. 21: 원본 유래 합성 이미지(A)와 합성 segmentation(B)



관찰

- 병변의 위치와 대략적인 경계는 재현됨
- 해상도가 낮아 질감 같은 세부는 확인하기 어려움
- 이 논문은 FID 같은 생성 품질 지표를 제시하지 않고(프리프린트 기준) 증강 후 분류 성능으로 간접 검증함
- 따라서 우열 판단의 근거는 다음 슬라이드의 분류 성능임

그림 출처: Andra et al., Fig. 21 (프리프린트 Research Square rs-5191116v1, CC BY 4.0)

결과 ① - DF vs NV 분류 성능 개선

Table 6: QGAN 증강 후 AUC-ROC 개선



막대 높이는 0부터 비례. 증가폭은 +0.017이며, 이 저장소의 8×8 재현 실험에서는 AUC +0.004, 정확도는 오히려 하락해 개선으로 단정하지 않음 (README 참고)

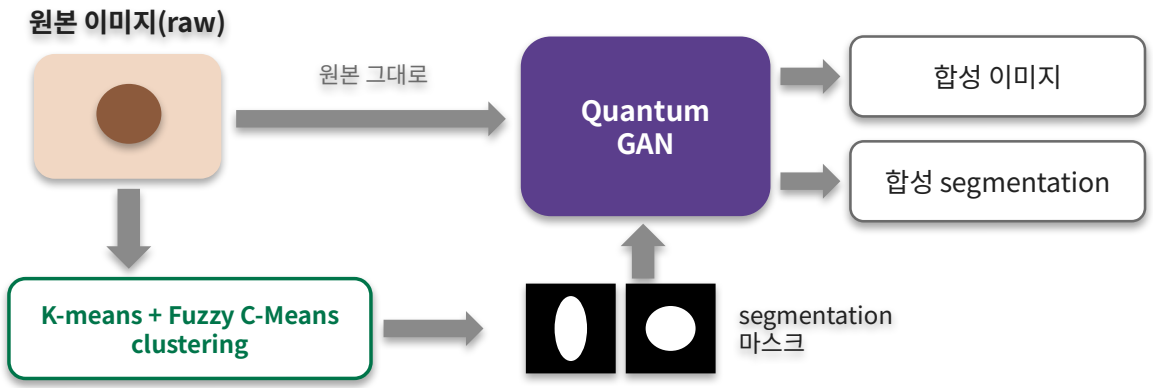
결과 ② - 조건부 증강 효과

segmentation 전처리 이미지에서만 증강 효과 있음

입력 전처리 방식	QGAN 증강 효과
원본/리사이즈 이미지	증강 효과 없음 - 오히려 성능 저하
segmentation(K-means+FCM) 전처리 이미지	증강 효과 있음 - 성능 개선

왜 중요한가

실제로는 배경 노이즈를 제거한(segmentation) 입력에서만
생성 품질이 분류 성능 개선으로 이어짐



원 논문 pipeline을 도식으로 재구성: Andra et al., Quantum Machine Intelligence 7, 90 (2025)

결과 ③ - 고전 GAN과의 비교

Table 11: 조건에 따라 승자 교체 - "양자가 항상 이긴다"는 아님

입력 조건	정확도 비교	비고
원본(raw) 이미지	**고전 GAN (정확도 0.98 vs 0.89)**	QGAN 열세
segmentation 이미지	**QGAN (정확도 0.96 vs 0.95)**	AUC는 0.97로 동률

해석

"고전 대비 무조건적 속도·성능 우위"가 성공 기준이 아니라,
(1) 문제→양자 pipeline의 실제 성립 여부, (2) 어떤 조건에서 고전과 동등·우위인지(crossover 조건) 평가

CHAPTER 2

논문 ② MediQ-GAN

dual-stream 구조로 모델 아키텍처 '일부만' 양자화한 생성 모델

논문

MediQ-GAN (arXiv:2506.21015)

핵심 기여

Generator를 고전 stream + 양자 stream 둘로 나눠 병렬 처리 후 융합(skip-connection) - 의료영상 3종 데이터셋 검증

검증 방식

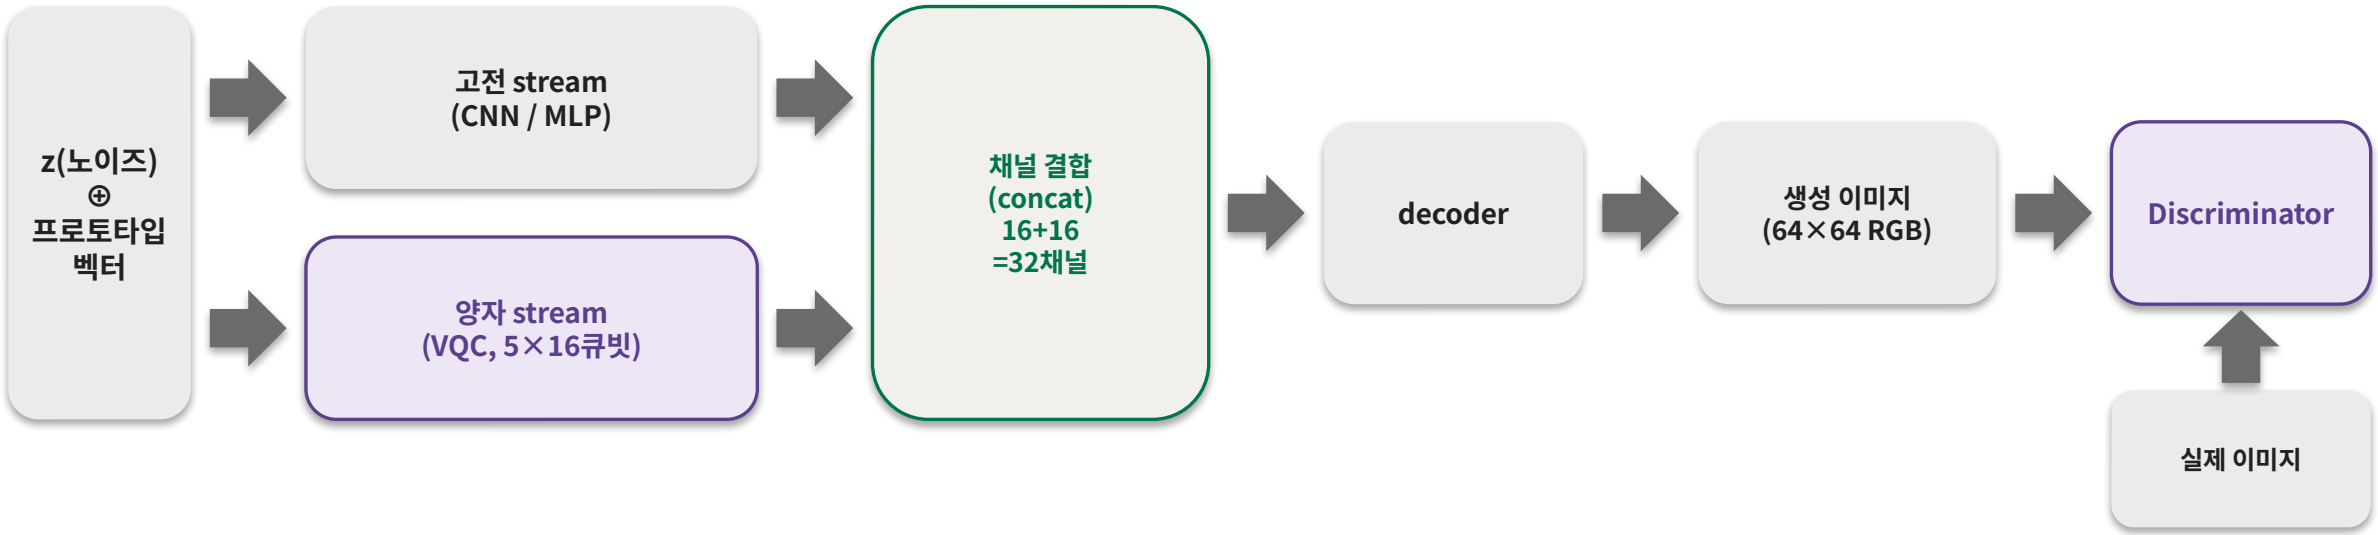
DCGAN · WGAN-GP · StyleGAN2-ADA 등 고전 SOTA 및 MosaiQ(양자)와 클래스별 FID · LPIPS로 비교,
실제 IBM 하드웨어 실행까지 확인

이 강의에서의 역할

"Generator 일부만 양자"인 아키텍처의 대표 사례 - layer-level hybrid

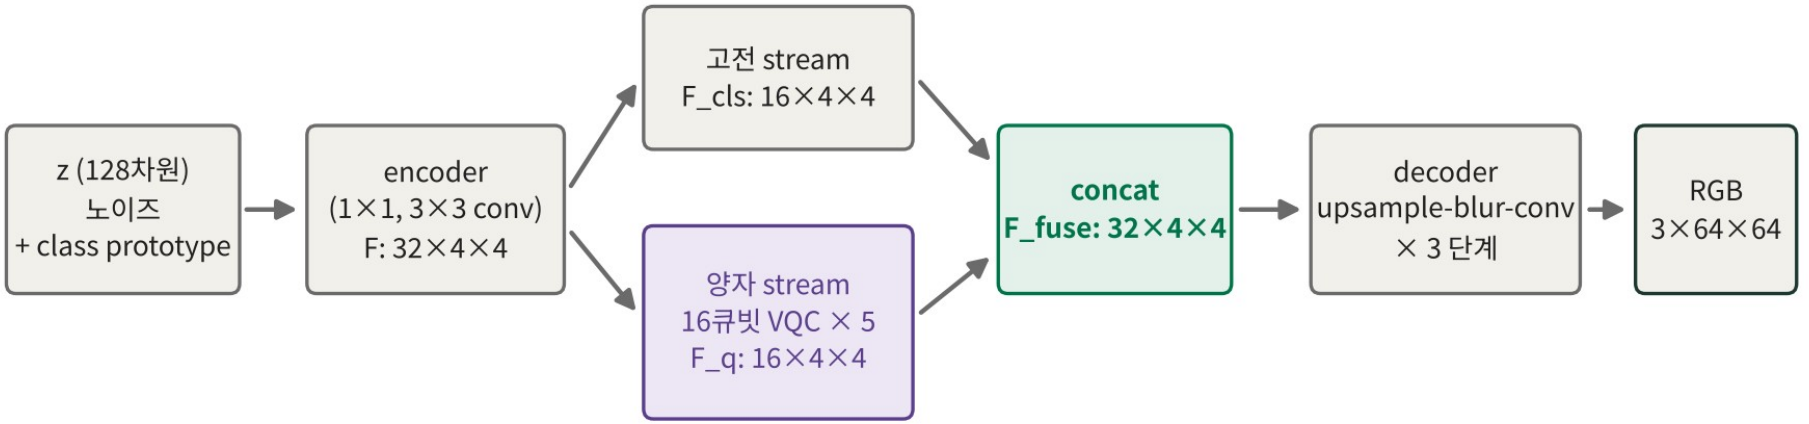
MediQ-GAN 아키텍처 다이어그램 - dual-stream Generator

고전 stream과 양자 stream을 함께 학습해 합치는 구조를 도식으로 재구성



입력 구성과 decoder

class prototype을 노이즈에 결합하고, 양자 stream 출력은 decoder에서 64×64 RGB로 복원



encoder 출력 32채널 중 16채널을 양자 stream에 투입

prototype conditioning

- EfficientNet-B0(30 epoch 미세조정) 특징의 클래스별 평균 벡터를 노이즈에 결합
- centroid 간 거리를 최대화하는 regularization loss로 클래스 구분 유지

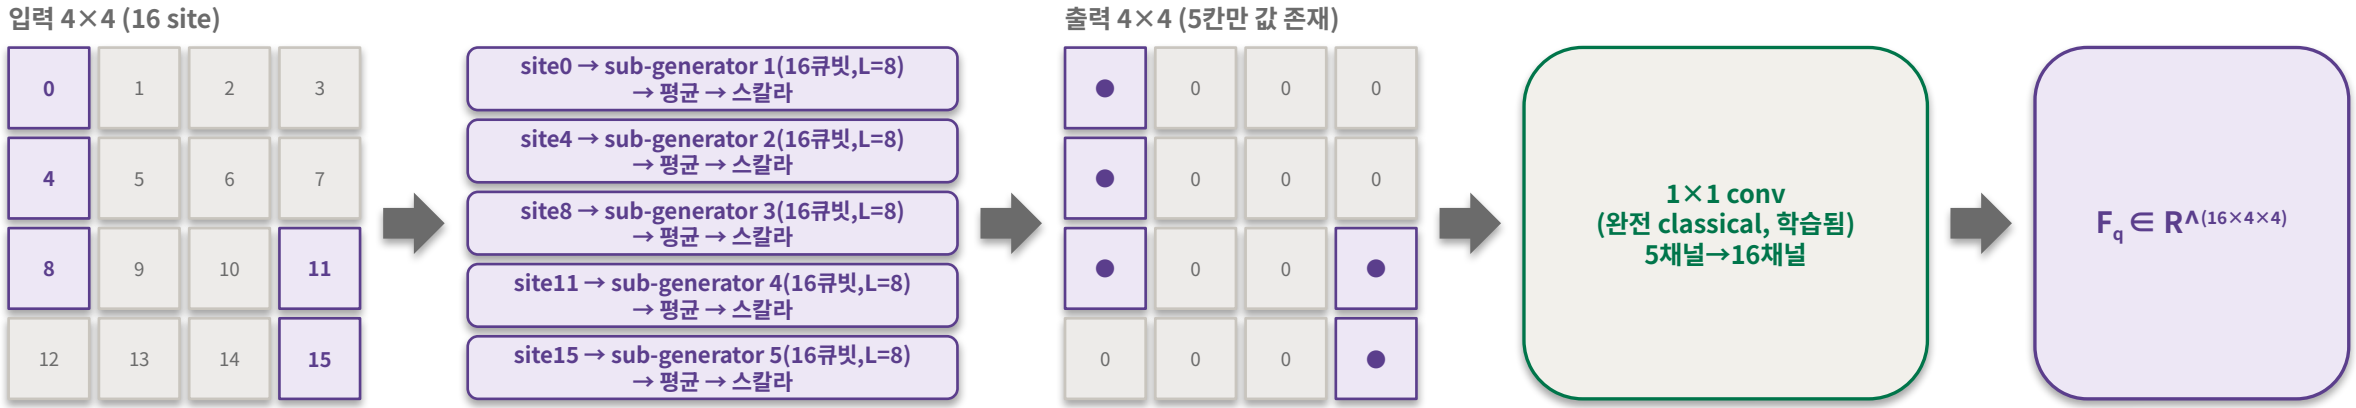
decoder

- 3×3 conv → upsample-blur-conv 3단계 → 3×3 conv
- 양자 stream 출력과 고전 stream 출력을 concat한 32×4×4를 3×64×64로 확대

구조 출처: Jiao et al., arXiv:2506.21015 Method 절

sub-generator 상세 - 16 site 중 5개만 실제 양자 처리

나머지 11칸은 classical 1×1 conv의 편향값만 받음 (공식 GitHub 코드 기준)



site 선택: linspace(0,15,5)round → [0, 4, 8, 11, 15] (row×4+col). 나머지 11칸은 그 sub-generator의 4×4 맵에서 0으로 남음.
1×1 conv는 칸별 독립 처리(이웃 안 봄) - 값이 있는 5칸만 진짜 양자 스칼라를 16채널로 투영, 나머지 11칸은 학습된 편향(bias)뿐. 이후 8×8 업샘플에서만 보간으로 살짝 섞임.

Hybrid 분류체계 - "어디까지가 양자인가"

같은 '양자 생성모델'이라도 Generator 전체/일부 양자 여부로 구분됨

model-level hybrid

예: HAM10000 QGAN, MosaiQ

Generator = 처음부터 끝까지 양자회로

Discriminator만 고전

PCA 등 고전 전처리가 있어도, Generator 는 양자 회로 구성

layer-level hybrid

예: MediQ-GAN

Generator 내부가 고전 stream + 양자 stream으로 병렬 분기

두 stream을 skip-connection으로 concat 후 디코딩

"layer 하나 안에서도" 양자·고전이 공존

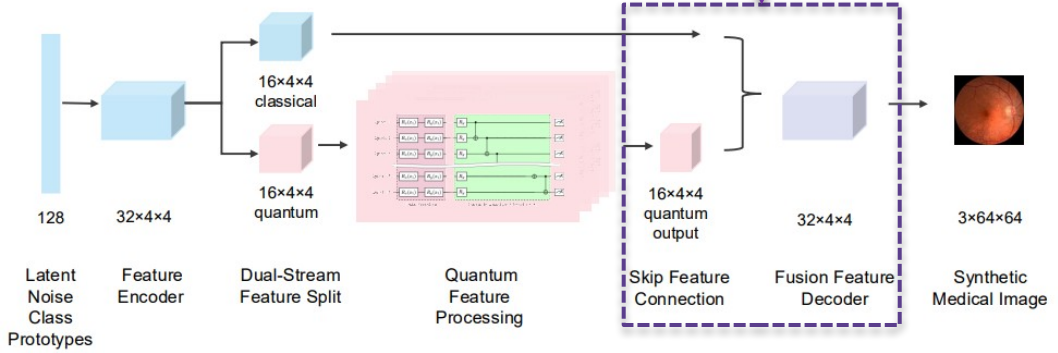
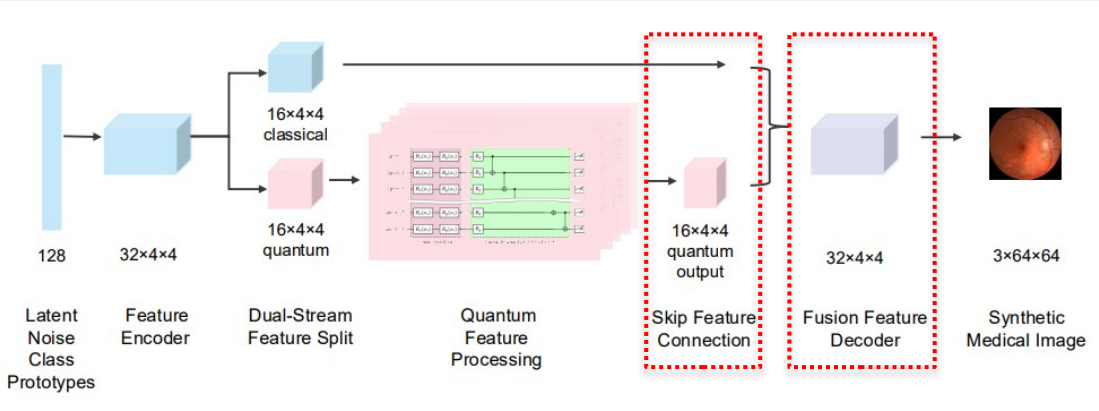


그림 출처: Jiao et al., MediQ-GAN, arXiv:2506.21015 (CC BY 4.0)

dual-stream Generator 아키텍처

입력을 절반씩 나눠 고전 인코더와 양자회로(VQC)가 병렬 처리 후 하나로 합침



고전 stream

classical encoder / conv

양자 stream

5 × 16큐빗 VQC (8층 깊이)

skip-connection 융합 (concat)

고전 decoder → 생성 이미지

encoding: angle encoding(Rx→Ry) · 학습 layer: Ry+CNOT 반복 · 측정: X-basis readout

그림 출처: Jiao et al., MediQ-GAN, arXiv:2506.21015 (CC BY 4.0)

critic과 학습 목표

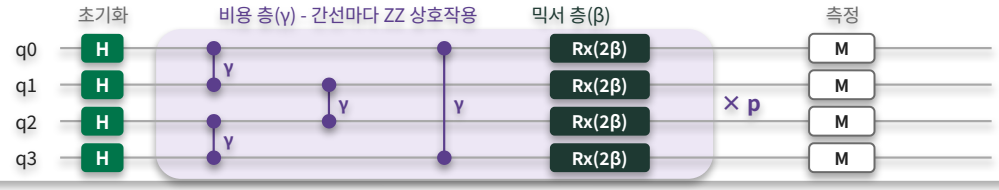
critic은 고전 convolutional network로 유지하고, 학습 목표는 WGAN-GP를 사용

항목	내용
학습 목표	WGAN-GP: $L = E[D(x)] - E[D(G(z))] + \lambda \cdot E[(\| \nabla D(\hat{x}) \|_2 - 1)^2]$ (논문 식 (1)·(2))
critic 구조	원 WGAN-GP 논문의 convolutional 구조, 입력 3×64×64
critic을 고전으로 둔 이유 (논문)	1. 3×64×64 입력을 매 iteration 처리해야 하므로 NISQ 소자에서 구현이 비현실적 2. 안정적이고 잘 알려진 critic을 두어 성능 향상을 양자 설계의 효과로 귀속
QGAN과의 차이	QGAN: 5층 완전연결 + BCE (Table 4) MediQ-GAN: convolution + WGAN-GP
실습과의 차이	3일차: MLP 판별자 + 표준 BCE, lr 2×10^{-4}, betas (0.5, 0.999)로 25 epoch 완주 (README '원 논문과 다른 점')

VQC · VQA·QAOA와의 관계

같은 '파라미터화된 회로 + 고전 최적화' 구조 공유, encoding 대상과 목적은 상이

개념	정의
VQA (Variational Quantum Algorithm)	parameterized quantum circuit(PQC) + 고전 최적화 루프를 사용하는 알고리즘 상위 범주
VQC (Variational Quantum Circuit / Classifier)	PQC를 variational 방식으로 학습시키는 구현. 분류 등 지도학습에 쓰며 data encoding + 학습 가능한 ansatz로 구성 (MediQ-GAN의 양자 stream)
QAOA (Quantum Approximate Optimization Algorithm)	조합최적화 문제(MaxCut 등) 등 목적 - cost layer(γ)와 mixer layer(β)를 번갈아 적용



공통점 vs 차이점

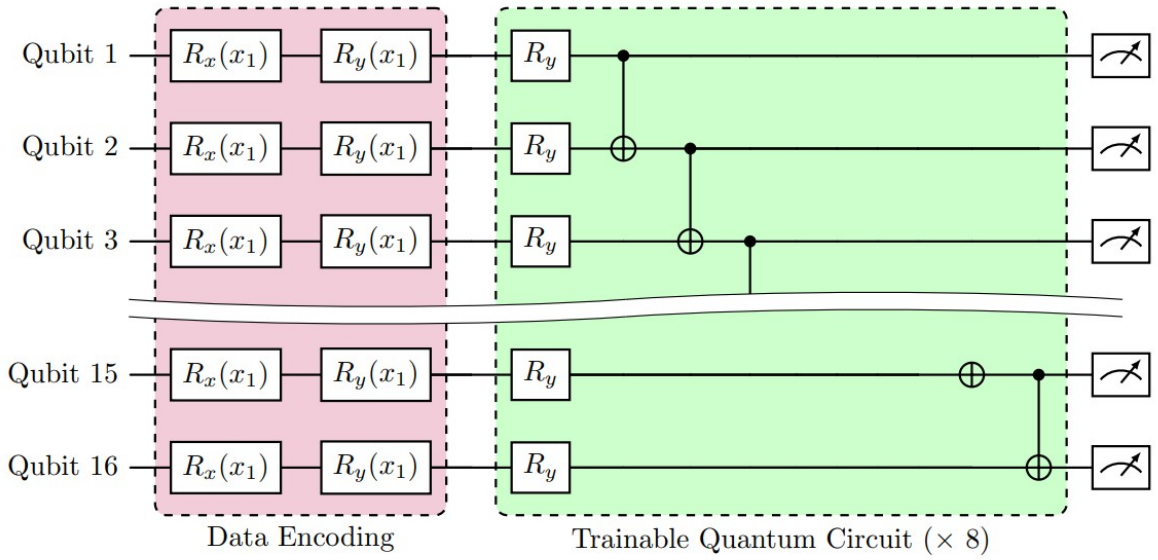
- 공통점: PQC → 측정 → 고전 optimizer가 파라미터 업데이트(hybrid loop)
- 차이점: encoding 대상(데이터 vs 문제)과 학습 목표

회로 안의 두 종류 파라미터 - encoding vs 학습

데이터를 넣는 게이트와 학습으로 값이 바뀌는 게이트, 역할 차이

구분	위치 / 값의 성격
encoding 파라미터	회로 앞단, 데이터 encoding 게이트 - 입력 데이터 x (대부분 고정, 학습 대상 아님)
학습 파라미터 θ	encoding 이후 variational ansatz - 회전 게이트 각도, CNOT, entangling 게이트 사이사이에 위치, 학습으로 업데이트됨

layer = 회전게이트(θ, 파라미터 O) + CNOT 체인(파라미터 X, 얽힘 담당)
16큐빗 × 8층 → sub-generator당 파라미터 128개 (5개 합계 640개)



※ 그림은 논문 기준(Rx→Ry·CNOT), 공식 코드는 RY→RX·CZ - 3일차 데모는 코드 기준

그림 출처: Jiao et al., MediQ-GAN, arXiv:2506.21015 (CC BY 4.0)

VQC의 출력값 - bitstring이 아니라 연속값(기댓값)

단일 측정은 0/1, 모델이 실제로 쓰는 값은 여러 번 측정을 평균낸 기댓값

$$m(z;\Theta) = (\langle X_1\rangle, \ldots, \langle X_N\rangle) \in [-1, 1]^N$$

항목	내용
단일 shot 결과	이산적 0/1 bitstring - 확률적 결과
실제 모델 출력	$\langle X_i\rangle$ 연속값(continuous) - classical decoder에 바로 투입 가능, gradient 계산도 가능
수치 안정화	h(m) = σ(LeakyReLU(LayerNorm(m))) 적용 후 classical stream과 fusion

실제 채택 방식 - Exact State Vector Simulation

공식 코드(mediq-gan.py) 설정

```
dev = qml.device("lightning.qubit", wires=args.n_qubits)
@qml.qnode(dev, interface="torch", diff_method="adjoint")
def circuit(...):
    ...
    return [qml.expval(qml.PauliX(i)) for i in range(args.n_qubits)]
```

항목	내용
shots 미지정	PennyLane 기본값 shots=None → 분석적(exact) 기댓값 계산, 반복 측정 없음
diff_method="adjoint"	정확한 state vector 접근이 있어야만 가능한 gradient 계산법 - 데모도 공식 레포와 동일하게 adjoint 사용
state vector 규모	n큐빗 = 2ⁿ차원 복소벡터로 완전 표현(16qubit→65,536차원, 노트북 처리 가능) - 게이트 적용=유니터리 행렬곱(확률적 요소 없음)

'Hardware-agnostic'의 정확한 의미

논문 원문 그대로 인용 시 오해하기 쉬운 표현

논문 원문 인용

"Our approach is quantum-inspired and **hardware-agnostic**: the correctness does not depend on quantum execution, and quantum devices serve only to accelerate computation."

구분	내용
오해 (X)	하드웨어를 아예 안 썼다는 뜻
정확한 뜻 (O)	모델의 타당성이 특정 실행 환경(시뮬레이터 vs 실제 큐빗)에 좌우되지 않도록 설계했다는 뜻
학습(training)	state vector 시뮬레이터로 진행
NISQ evaluation	학습 완료된 회로를 IBM Marrakesh 실기에 올려 inference만 검증 (클래스별 FID +19 ~ +79 상승, 논문은 '비교 가능한 수준'으로 평가)

shot 기반으로 학습한다면 - Parameter-shift Rule

Exact statevector 방식이 아니라, gradient를 구할 때 쓰는 규칙

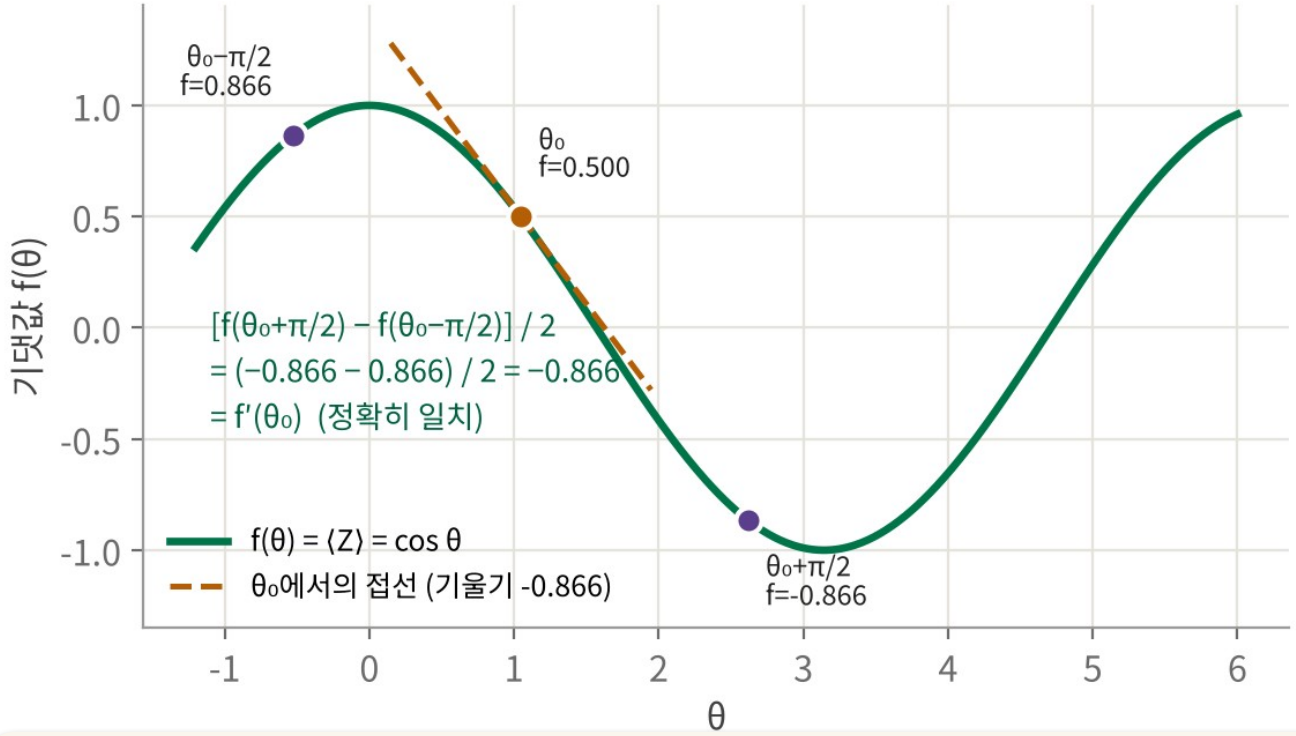
$$\partial \langle X_i \rangle / \partial \theta_j = [\langle X_i \rangle(\theta_j+\pi/2) - \langle X_i \rangle(\theta_j-\pi/2)] / 2$$

개념	설명
계산 방식	회로 내부를 역전파로 거슬러 올라가는 게 아니라, θ_j를 shift한 회로를 처음부터 끝까지 2번 새로 실행해 얻은 결과값의 단순 뺄셈
순전파(forward) 시점	shift된 회로는 전혀 실행되지 않음 - 원래 θ값으로 1번만 실행, 그 출력이 다음 classical layer로 전달
역전파(backward) 시점	$+\pi/2$, $-\pi/2$ 두 회로가 파라미터 하나마다 개별적으로 실행됨

전체 chain rule: $dLoss/d\theta_j = dLoss/d\langle X_i \rangle$ (classical backprop) × $d\langle X_i \rangle/d\theta_j$ (parameter-shift, 뺄셈 기반)

parameter-shift rule 예시: f(θ) = ⟨Z⟩ = cos θ

shift한 회로 두 번의 기댓값 차이로 정확한 미분을 얻음



계산 순서 ($\theta_o = \pi/3$)

- $f(\theta_o) = \cos(\pi/3) = 0.500$
- $\theta_o + \pi/2$ 회로를 실행: $f = -0.866$
- $\theta_o - \pi/2$ 회로를 실행: $f = 0.866$
- 차이를 2로 나눔: $(-0.866 - 0.866) / 2 = -0.866 = -\sin\theta_o = f'(\theta_o)$

유의점

파라미터마다 회로를 2번 더 실행해야 하고, shot 기반이면 각 기댓값에 통계 오차가 붙음. 시뮬레이터에서는 adjoint나 backpropagation으로 대체함

계산 비용 - 현재 학습의 어려움

파라미터 수만큼 회로를 반복 실행해야 하는 구조적 한계

총 회로 실행 횟수 = C (순전파 회로 수) + 2P (파라미터 별 +shift, −shift)

파라미터 수 P	회로 실행 횟수
640 (회로 5개 × 16큐빗 × 8층)	5 + 1,280 = 1,285회
10,000	1 + 20,000 = 20,001회

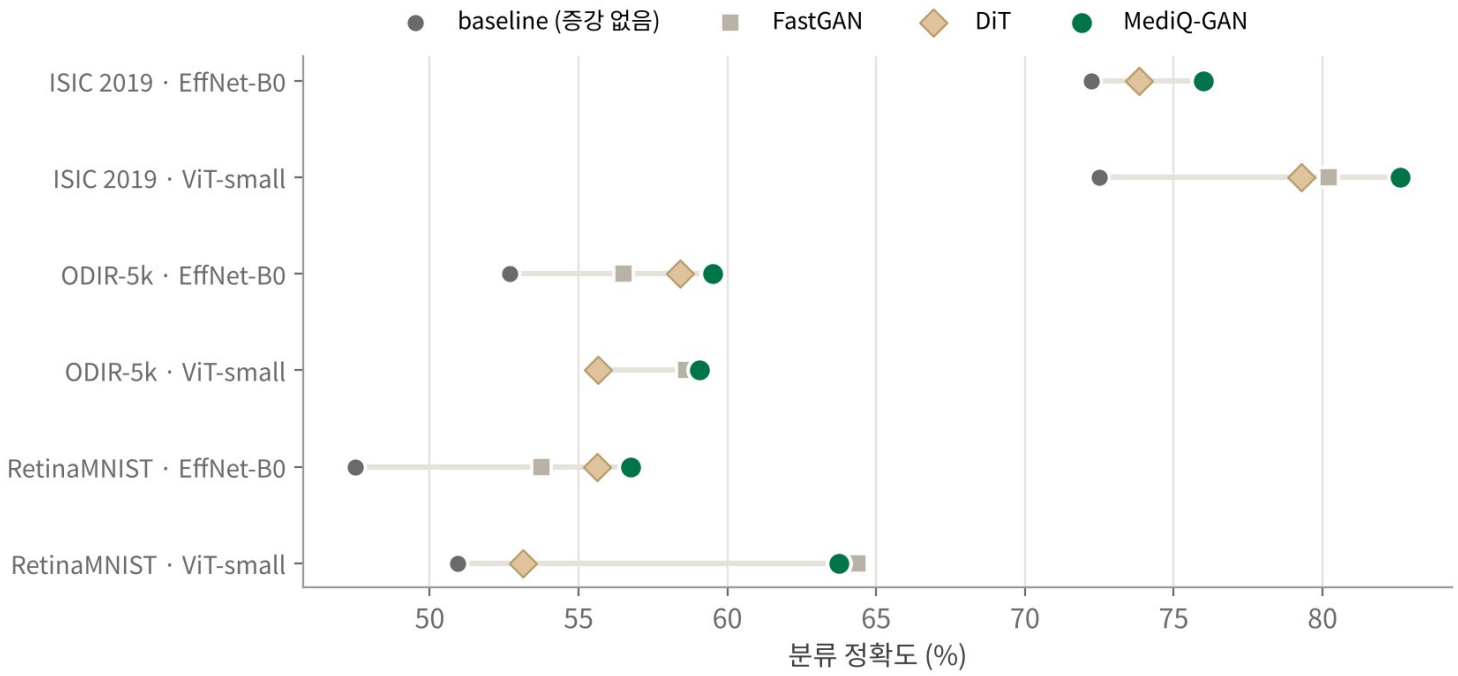
측정 횟수까지 곱하면

총 측정 횟수 = 회로 실행 횟수 × shots.

- P=10,000, shots=1,024 → 20,001×1,024 ≈ 약 2,048만 회.
- batch 32·학습 step 10,000까지 포함하면 → 20,001×1,024×32×10,000 ≈ 6.5×10^{12}(약 6.5조 회)

결과 ① - 분류 성능 (Table 1)

baseline 대비 정확도는 3개 데이터셋 · 2개 분류기 모두에서 상승하나, 모든 행에서 최고는 아님



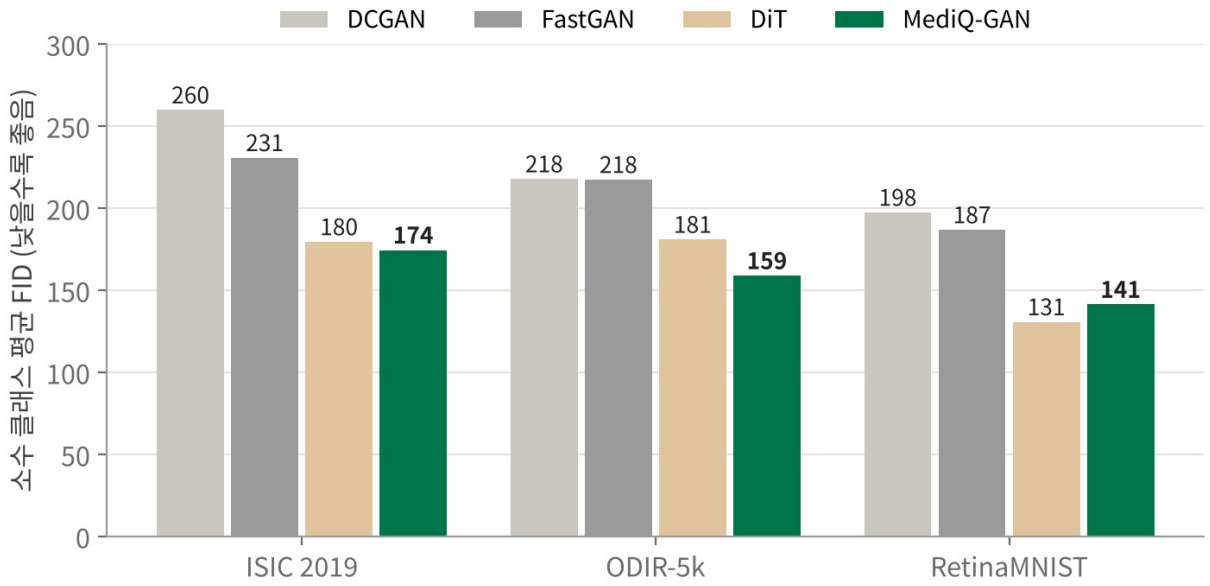
읽는 법

- EfficientNet-B0 정확도 상승: ISIC +3.75, ODIR +6.83, RetinaMNIST +9.25
- ViT-small 정확도 상승: +10.11, +3.44, +12.82
- RetinaMNIST ViT-small: FastGAN 64.37이 MediQ-GAN 63.75보다 높음
- ISIC ViT-small AUC: FastGAN 0.9549 > 0.9517
- MosaiQ는 baseline 이하 (ISIC ViT-small 50.25%)

수치 출처: Jiao et al., arXiv:2506.21015 Table 1

결과 ② - 생성 품질: FID와 LPIPS

소수 클래스 FID는 ISIC·ODIR에서 MediQ-GAN이 가장 낮고, RetinaMNIST에서는 DiT가 더 낮음



해석

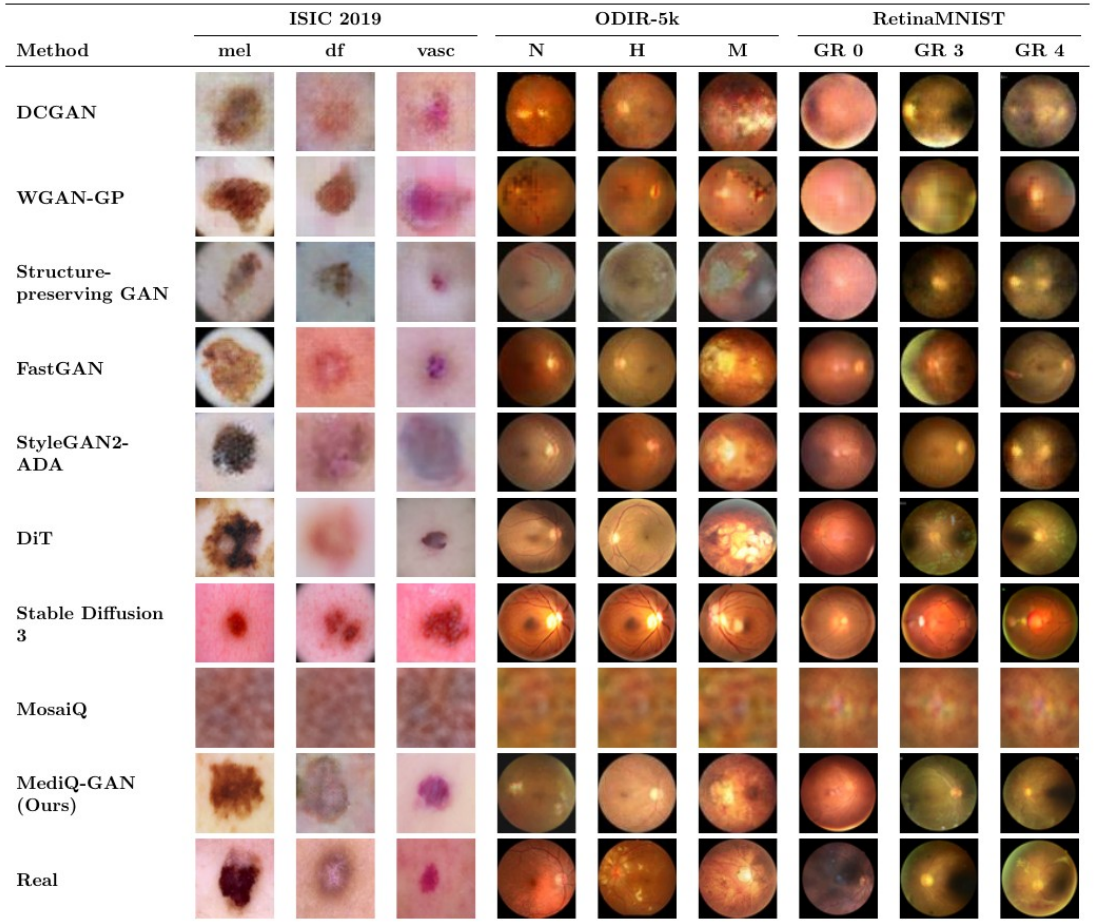
- DiT는 확산 모델로 용량이 훨씬 큼. 논문 서술은 'best or second-best'
- MosaiQ: FID 316 ~ 593, RetinaMNIST LPIPS 0.079로 거의 같은 이미지만 생성
- FID는 클래스당 표본이 적을수록 불안정함

소수 클래스 평균 LPIPS (높을수록 다양)	Real	DiT	FastGAN	MediQ-GAN
ISIC 2019	0.457	0.367	0.422	0.409
ODIR-5k	0.612	0.609	0.609	0.601
RetinaMNIST	0.396	0.321	0.394	0.384

수치 출처: Jiao et al., Extended Data Table 2·3

결과 ③ - 생성 이미지 비교 (Fig. 2)

열은 데이터셋별 대표 클래스, 행은 방법, 마지막 행은 실제 이미지



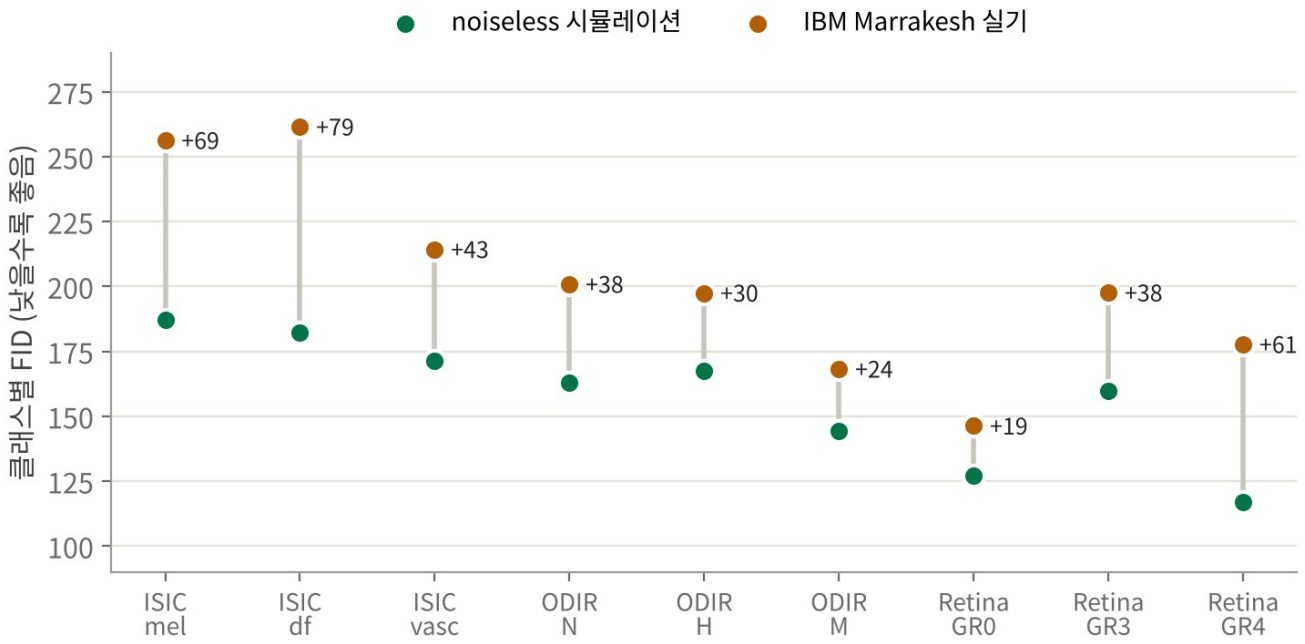
논문의 정성 서술

- DCGAN, Structure-preserving GAN: 흐린 dermoscopic 질감
- StyleGAN2-ADA: 다수 클래스는 개선, 희소 클래스에서 약함
- FastGAN, DiT: 데이터가 극히 적은 ISIC df에서 구조 손실
- MosaiQ: PCA 축소로 색과 구조가 사라진 흐린 패치
- MediQ-GAN: 클래스 특징 보존 (논문 서술)
- 저자의 정성 평가이므로 FID, LPIPS와 함께 해석함

그림 출처: Jiao et al., arXiv:2506.21015 Fig. 2 (CC BY 4.0)

결과 ④ - IBM 실기 검증

학습된 회로를 IBM Marrakesh에서 inference만 실행: 모든 클래스에서 FID 상승



읽는 법

- 범위: 데이터셋별 대표 클래스 9개, inference만 (학습은 시뮬레이션)
- FID 상승폭: +19 (RetinaMNIST GR0) ~ +79 (ISIC df)
- 논문 평가: 시뮬레이션보다 약간 낮으나 비교 가능한 수준

비교

ISIC df: 실기 FID 261.5는 FastGAN 225.0보다 나쁘고 DCGAN 272.6보다 좋음. 노이즈에 무너지지 않는다는 근거이며, 실기에서 고전 baseline보다 우위라는 근거는 아님

수치 출처: Jiao et al., Extended Data Table 4, Table 2

결과 ⑤ - 생성자의 학습 가능성 분석

Jacobian 특이값 분포와 DLA 분석으로 hybrid 생성자를 평가함

분석	의미	논문 결과
effective rank, participation ratio	잠재 방향 중 출력에 실제 영향을 주는 비율 (높을수록 좋음)	특이값 감쇠가 고전 baseline보다 완만 (Extended Data Fig. 3)
log10 condition number	생성자 conditioning (낮을수록 좋음)	MediQ-GAN 2.09 / 2.04 / 2.01 (ISIC / ODIR / Retina) DCGAN 2.54 / 2.54 / 2.44, StyleGAN2-ADA 5.78 / 6.25 / 6.58
DLA 분석	회로가 만드는 변환군의 차원으로 표현력과 barren plateau 위험을 판단	depth 8에서 표현력이 충분하고 barren plateau를 피함
ablation	양자 채널 수, VQC 개수	늘릴수록 성능과 effective rank 개선, 현 설정 이후 이득 감소. 16채널 · 5 VQC는 시뮬레이션 비용과 절충

한계

논문 결론: MediQ-GAN은 모든 unconstrained benchmark에서 고전 생성모델을 넘어서지는 못함. 이 분석은 생성자의 수치적 성질에 대한 것임

수치 출처: Jiao et al., Extended Data Table 5, Discussion

CHAPTER 3

내용 정리

03 · 내용 정리

두 논문 비교 요약 및 정리

QGAN 및 MediQ-GAN 정리

구분	QGAN	MediQ-GAN
Hybrid 유형	model-level (Generator 전체 양자)	layer-level (dual-stream)
큐빗 규모	7+1큐빗 × sub-generator 16개	5 × 16큐빗 VQC(stream 하나)
데이터셋	HAM10000 (피부병변, 2클래스 집중)	ISIC2019 · ODIR-5k · RetinaMNIST
검증 방식	증강 전/후 CNN 분류 성능(AUC-ROC)	클래스별 FID·LPIPS + 실기(IBM) 검증

두 논문을 읽을 때의 점검 항목

양자 생성모델 논문의 주장을 평가할 때 적용하는 다섯 가지 기준

점검 항목	QGAN	MediQ-GAN
비교 대상	고전 vanilla GAN 1종	고전 GAN 5종, 확산 모델 2종, MosaiQ
평가 방식	분류 성능 (AUC-ROC, 정확도)	분류 성능 + FID + LPIPS
양자 요소의 범위	생성자 전체	생성자 일부 (공식 코드 기준 16개 위치 중 5개)
조건 의존성	segmentation 입력에서만 증강 효과	모든 지표에서 최고는 아님 (결과 ①, ②)
한계의 명시	개선 폭 AUC +0.017. 이 저장소 8×8 재현에서는 정확도 하락	실기 검증은 inference에 한정. 고전 모델을 전 영역에서 넘지는 못함

2·3일차 실습과의 대응

회로 사양은 유지하고 해상도와 학습량을 줄여 Colab 무료 CPU에서 끝까지 실행

이론 (1일차)	실습 구현	원 논문과의 차이
QGAN patch 생성자	2일차: sub-generator 4개 × 7큐빗(데이터 6 + ancilla 1), depth 10	논문: 16개 × 8큐빗. 16×16 그레이스케일
QGAN 판별자	5층 완전연결 (2·3일차 공통)	동일 (Table 4)
MediQ-GAN dual-stream	3일차: 양자 stream 16큐빗 × 5, depth 8. 10 epoch checkpoint에서 20 step 미세조정	고전 부분·판별자는 MLP + 표준 BCE (논문: conv + WGAN-GP)
평가	지표 4종 (16×16에서 FID 불가)	논문: FID, LPIPS, 분류 성능
실행 환경	PennyLane exact 시뮬레이션, Colab CPU	논문: GPU, IBM 실기는 inference

실측 (로컬 CPU, README)

QGAN 600 step: 클래스 평균 상관 0.195. MediQ-GAN 25 epoch: 0.365, 단 다양성은 실제의 약 1/8. 두 모델의 평균 형태와 다양성 절충이 다르게 나타남

현재 단계에서의 QML 연구 방향

QML 연구에서는 연산 비용을 줄이는 방향이 논의되고 있음

판단 대상	결론
parameter-shift 구현	비현실적 - 계산상 명확함
QML 연구 전체의 가치	유효함 - 아래 방향의 연구가 활발히 진행 중

SPSA (Simultaneous Perturbation Stochastic Approximation)

파라미터 개수와 무관하게 매 step 회로 2번만 실행해 gradient 근사(정확도는 다소 하락)

Classical shadow tomography

적은 측정 횟수로 여러 관측량을 동시 추정

Quantum Natural Gradient (QNG)

더 적은 step으로 수렴시켜 전체 실행 횟수 절감

DLA (Dynamical Lie Algebra) 기반 회로 설계

barren plateau를 피하며 필요한 파라미터/깊이 최소화

이미지 생성 분야에서 양자 알고리즘 유의점

양자 생성 모델은 **양자 데이터, 해밀토니안 상태 등을 만드는 데** 특화되어 있기에, **기존 데이터가 많은 영역, 모델, 컴퓨팅이 잘하는 영역에 대한 성과는 검증 단계**

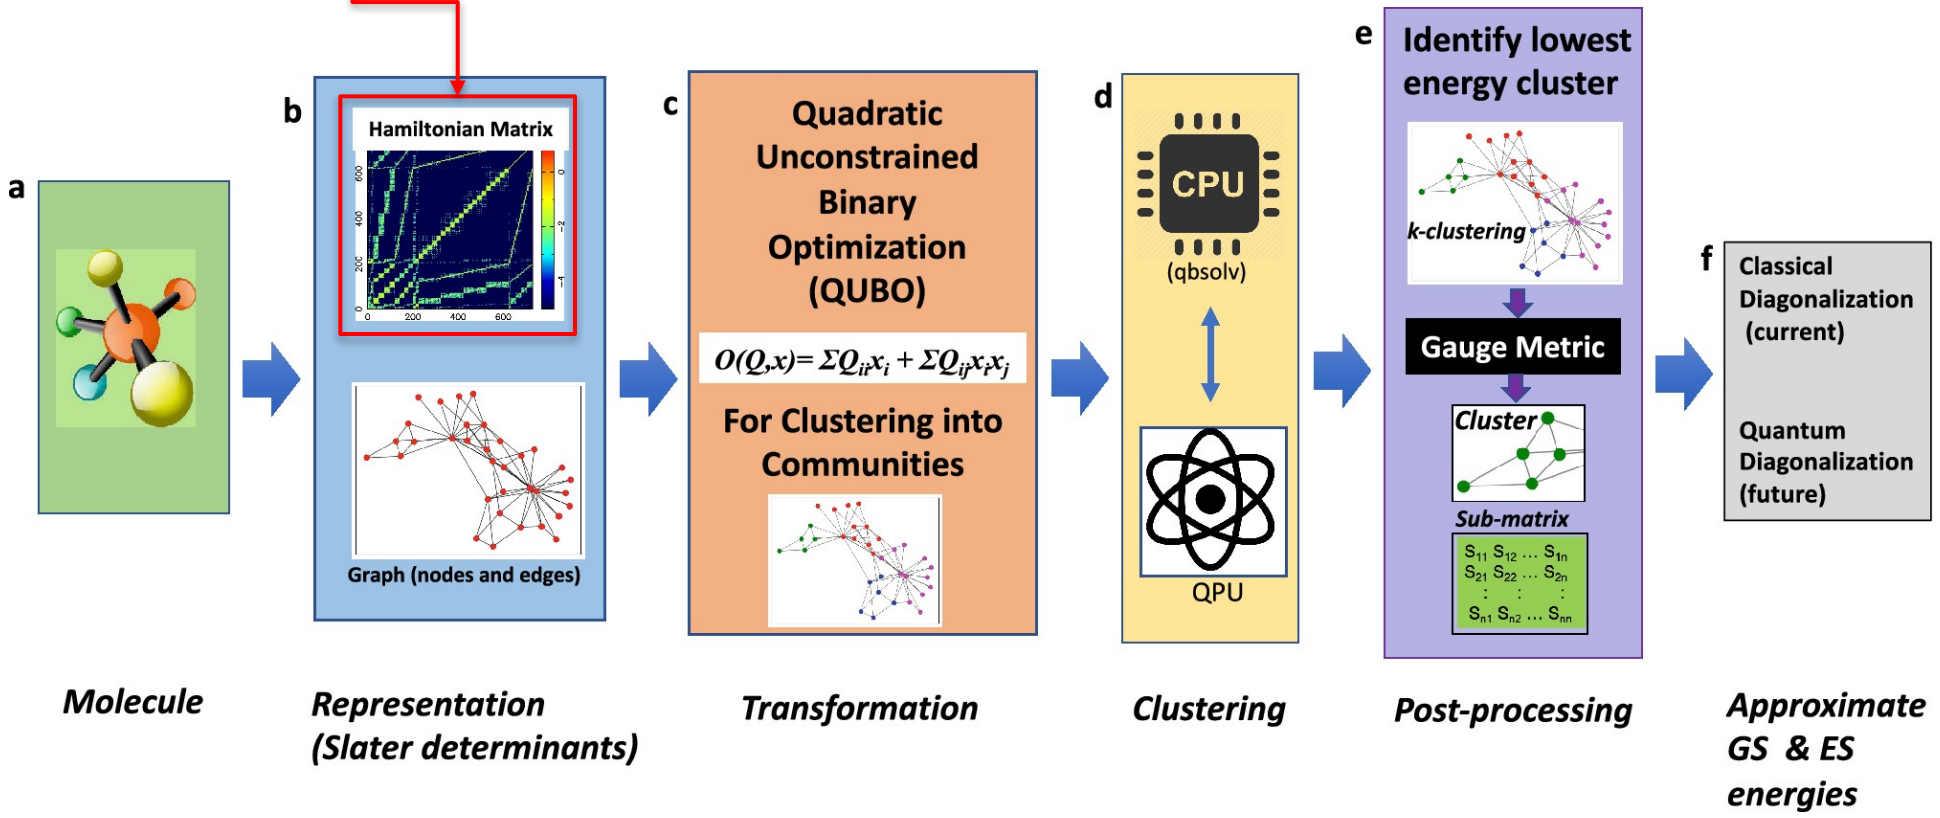


그림 출처: https://www.nature.com/articles/s41598-021-83561-x (CC BY 4.0)

감사합니다.