QML Lecture

양자 머신러닝
의료 이미지 데이터 증강

오리엔테이션

의료 데이터셋을 활용한 양자 머신러닝 실습

이론 → 데이터 EDA·전처리·회로 구성 → 실습 실행

1일차

이론 설명

데이터셋 소개
+ QGAN·MediQ-GAN 논문 아키텍처

2일차

실습 - 전처리 + QGAN 학습

3일차

실습 - MediQ-GAN 학습

오리엔테이션

학습목표

INDEX

1. HAM10000 데이터셋 EDA와 클래스 불균형 문제
2. GAN 학습 구조·평가 지표(FID, LPIPS)와 양자회로 기초(qubit, 게이트, 측정, PQC)
3. QGAN과 고전 GAN의 차이 - patch 방식 아키텍처
4. 아키텍처 '전체가 양자'(QGAN)와 '일부만 양자'(MediQ-GAN, dual-stream) 차이 구분
5. 두 논문의 결과를 같은 기준(비교 대상, 지표, 실행 환경)으로 해석

HAM10000 데이터셋

"Human Against Machine with 10000 training images" - 피부병변 진단 AI 연구의 대표 벤치마크

10,015

총 이미지 수

피부경검사(dermatoscopic) 촬영

7

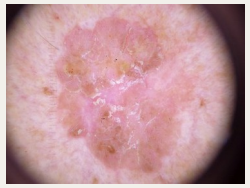
병변 클래스 수

akiec · bcc · bkl · df · mel · nv · vasc

600×450

원본 해상도

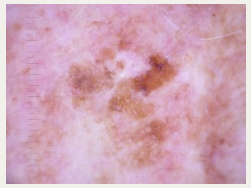
RGB, 실제 임상 촬영 이미지



akiec · 광선각화증



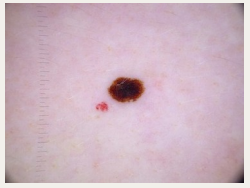
bcc · 기저세포암



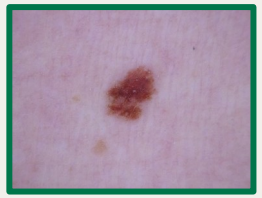
bkl · 양성각화증



df · 피부섬유종



mel · 흑색종



nv · 모반



vasc · 혈관병변

병변 유형	코드	이미지 수	비율
광선각화증 (Actinic keratoses)	akiec	327	3.3%
기저세포암 (Basal cell carcinoma)	bcc	514	5.1%
양성각화증 (Benign keratosis-like lesions)	bkl	1,099	11.0%
피부섬유종 (Dermatofibroma)	**df**	**115**	**1.1%**
흑색종 (Melanoma)	mel	1,113	11.1%
모반 (Melanocytic nevi)	**nv**	**6,705**	**66.9%**
혈관병변 (Vascular lesions)	vasc	142	1.4%

이미지·데이터 출처: HAM10000 (Tschandl et al., Scientific Data 5, 180161, 2018)

01 · 데이터셋

EDA 분석 결과 : 데이터 불균형

클래스 불균형 데이터 처리 방법

클래스	이미지 수
광선각화증 (akiec)	327
기저세포암 (bcc)	514
양성각화증 (bkl)	1,099
피부섬유종 (df)	**115**
흑색종 (mel)	1,113
모반 (nv)	**6,705**
혈관병변 (vasc)	142

방법	설명	한계
Under sampling	소수 클래스에 맞춰, 다수 클래스를 줄임	정보 손실 - NV 6,500장 넘게 버려야 함
Over sampling	소수 클래스를 복제해서 늘림	복제본이라 새로운 정보가 없음 - 과적합 위험
Augmentation 기하학적 증강	회전·반전·크롭 등으로 변형	병변의 실제 형태·질감 다양성은 만들지 못함
생성모델(GAN/QGAN)	학습된 분포에서 '새로운' 그럴듯한 샘플 생성	품질 검증 필요

초점

- QGAN이 '고전 GAN보다 좋다'가 결론은 아님
- QGAN의 실제 동작 방식과 조건을 논문 데이터로 확인

표 출처: HAM10000 메타데이터 (Tschandl et al., Scientific Data 5, 180161, 2018)

PRELIMINARY

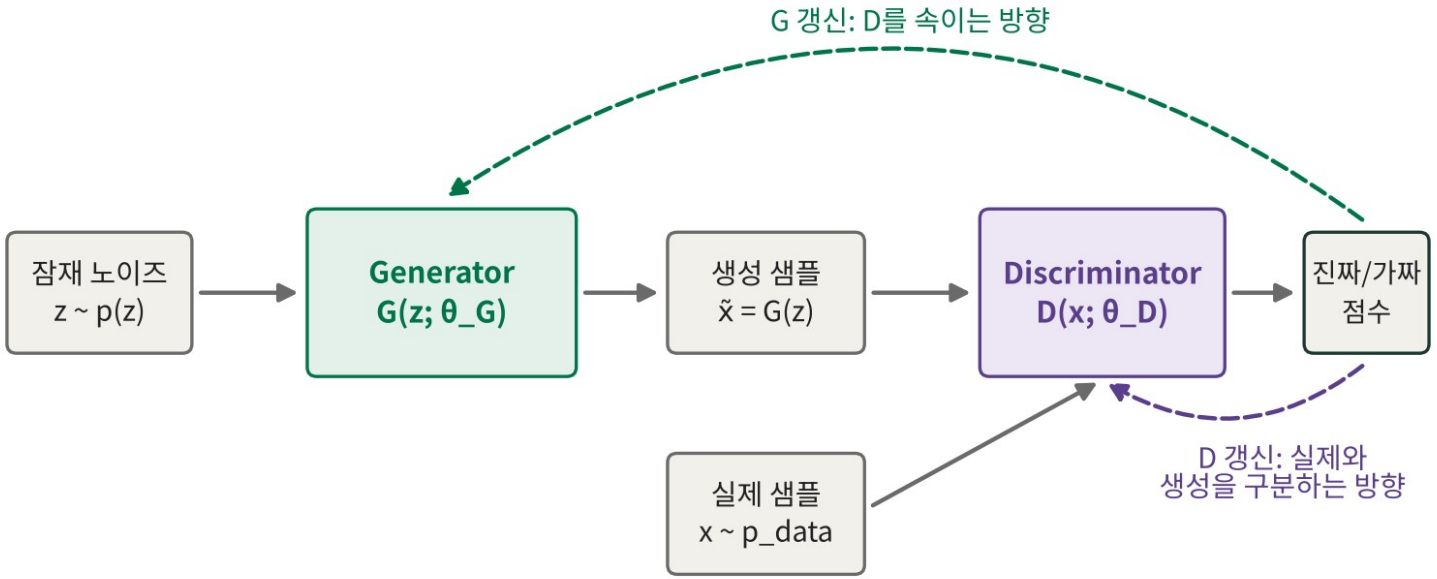
사전 지식

두 논문을 읽는 데 필요한 GAN과 양자회로 기초

GAN	생성자·판별자의 minimax 학습, 학습 불안정성(mode collapse)과 WGAN-GP, 생성 품질 평가 지표(FID, LPIPS)
양자회로	qubit과 상태벡터, 회전·얽힘 게이트, 측정과 기댓값, 변분 양자회로(PQC)의 hybrid 학습 루프, 시뮬레이션의 한계
이후 내용과의 관계	이 장에서 정의한 용어(RY, CNOT, 기댓값, WGAN-GP, FID)를 QGAN·MediQ-GAN 설명에서 그대로 사용함

GAN의 구조와 학습 목표

생성자와 판별자가 하나의 목적함수를 반대 방향으로 최적화하는 minimax 구조



- **Generator**: 노이즈 z를 샘플로 변환. D가 생성 샘플을 진짜로 판단하도록 갱신
- **Discriminator**: 실제와 생성 샘플을 구분. 판별 정확도를 최대화하도록 갱신
- **학습 순서**: D 갱신과 G 갱신을 번갈아 반복
- QGAN · MediQ-GAN은 이 구조에서 G만 양자회로를 포함함

$$\min_G \max_D \; V(D, G) = \mathbb{E}[\log D(x)] + \mathbb{E}[\log(1 - D(G(z)))]$$

x ~ p_data(실제), z ~ p_z(노이즈). G의 손실은 학습 초반 gradient 소실을 피하려고 −log D(G(z))로 바꿔 쓰는 경우가 많음

학습 불안정성과 WGAN-GP

원 GAN의 손실은 학습이 불안정하고, 두 논문은 서로 다른 학습 목표를 사용함

문제	현상	원인
Vanishing gradient	D가 너무 잘 구분하면 G의 gradient가 0에 수렴	두 분포의 support가 겹치지 않으면 JS divergence가 상수
Mode collapse	G가 일부 유형의 샘플만 반복 생성	D가 다양성을 직접 평가하지 않음
진동	손실이 수렴하지 않고 진동	두 모델을 동시에 최적화하는 min-max 구조

항목	원 GAN (BCE)	WGAN-GP
D의 출력	확률 (시그모이드)	실수 점수 (critic)
손실	BCE: $\log D(x) + \log(1 - D(G(z)))$	$E[D(x)] - E[D(G(z))] + \lambda \cdot GP$
거리	Jensen-Shannon	Wasserstein-1
안정화	없음	critic gradient 노름을 1로 유도 (1-Lipschitz)
사용 논문	**QGAN (Table 4)**	**MediQ-GAN (식 (1)·(2))**

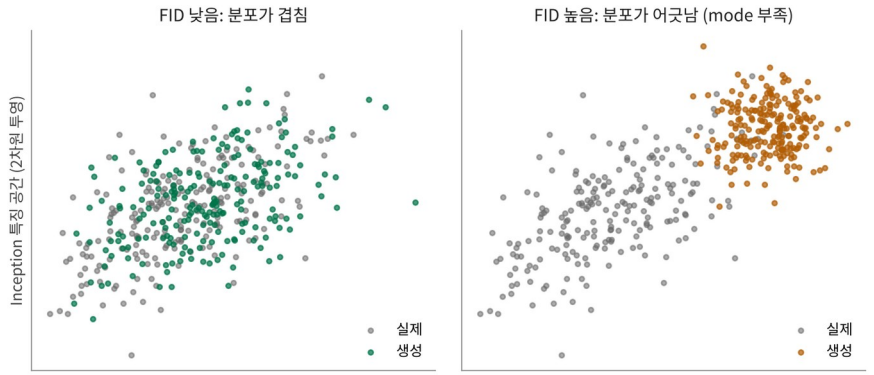
실습과의 연결

3일차: MediQ-GAN을 생성자 학습률 0.02로 학습하면 3 epoch 만에 mode collapse가 발생함. 원 논문이 WGAN-GP critic을 쓰는 이유에 해당함.

생성 품질 평가: 지표별 측정 대상

생성 이미지의 품질은 눈으로 판단하기 어려워 정량 지표를 병행함

지표	측정 대상	방향
Downstream 분류 성능 (AUC-ROC, 정확도)	생성 이미지를 학습 데이터에 추가했을 때 분류기 성능 변화 QGAN 논문, MediQ-GAN Table 1	높을수록 좋음
FID	실제와 생성 이미지의 Inception 특징 분포(평균·공분산) 사이 Fréchet 거리 MediQ-GAN 논문 (클래스별)	낮을수록 좋음
intra-class LPIPS	같은 클래스 생성 이미지 쌍의 지각적 거리 평균. mode collapse 점검 MediQ-GAN 논문	높을수록 다양
지표 4종 (실습)	픽셀 분포, 클래스 평균 상관, 최근접 실제 거리, 샘플 다양성 2·3일차 노트북 (16×16에서는 FID 사용 불가)	지표별 상이



해석 시 유의

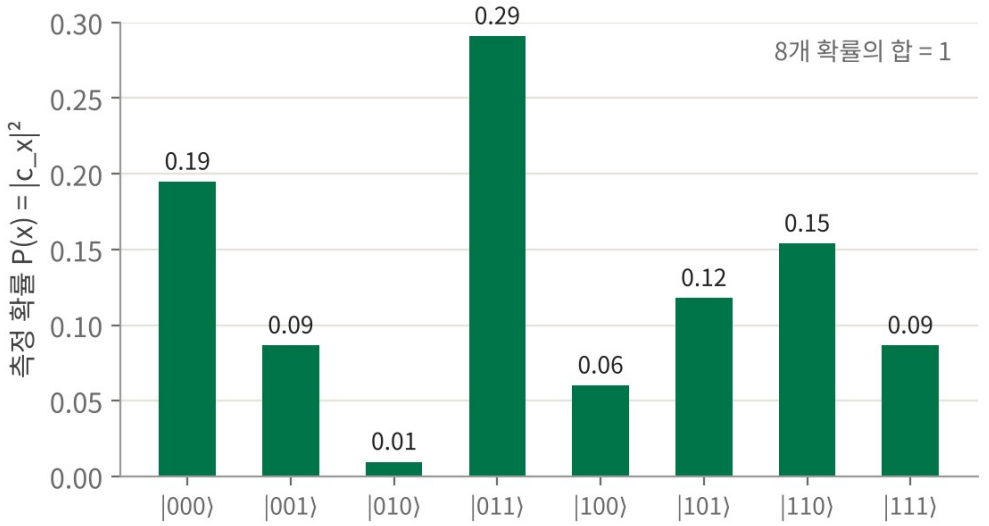
- FID가 낮아도 LPIPS가 낮으면 비슷한 이미지만 생성한 것이므로 두 지표를 함께 봄
- 표본이 적은 클래스(df 115장)에서는 FID 공분산 추정이 불안정함
- 분류 성능은 분류기와 증강 비율에 의존함

qubit과 상태벡터

n큐빗 상태는 2^n개의 복소 진폭이며, 측정 확률은 진폭 크기의 제곱

$$|\psi\rangle = \alpha|0\rangle + \beta|1\rangle,\quad |\alpha|^2 + |\beta|^2 = 1$$
$$\text{n큐빗: } |\psi\rangle = \Sigma\, c_x\,|x\rangle,\quad P(x) = |c_x|^2$$

구분	고전	양자
상태	n bit = 문자열 하나	n큐빗 = 2^n 진폭 벡터
갱신	논리 연산	유니터리 행렬 곱 (노름 보존)
읽기	값을 그대로 읽음	측정 시 확률 P(x)로 bitstring 하나 결정



이후 논문과의 연결

- QGAN: 데이터 7큐빗 → 확률 128개 = patch 픽셀 128개
- MediQ-GAN: 16큐빗 → 상태벡터 65,536차원

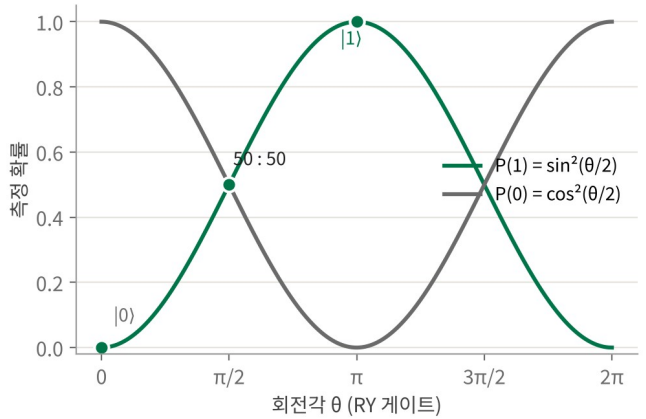
게이트: 회전과 얽힘

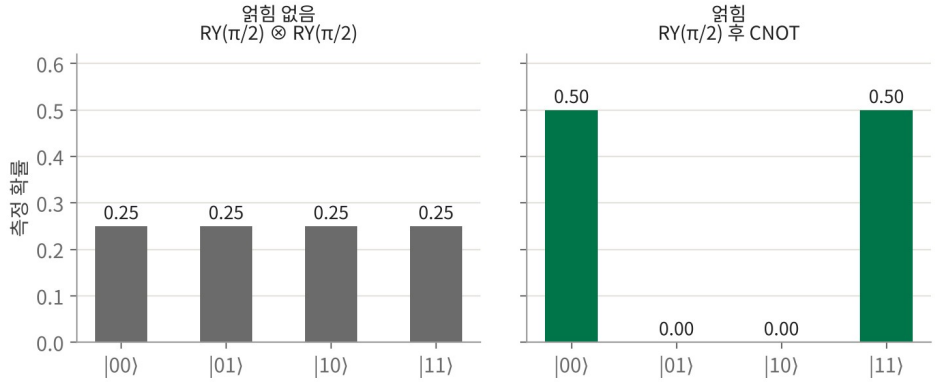
두 논문의 회로는 회전 게이트와 얽힘 게이트 두 종류로만 구성됨

게이트	작용	학습 대상
RY(θ)	$\|0\rangle \rightarrow \cos(\theta/2)\|0\rangle + \sin(\theta/2)\|1\rangle$ $P(1) = \sin^2(\theta/2)$	θ (학습)
RX(θ)	X축 회전. MediQ-GAN의 encoding에 사용	입력값 (고정)
CNOT	제어 큐빗이 1이면 목표 큐빗 반전	파라미터 없음
CZ	두 큐빗이 모두 1이면 위상에 −1	파라미터 없음

두 논문의 회로 구성

- QGAN: RY(z) encoding → [RY(θ) + CZ 체인] × depth 10
- MediQ-GAN: RX, RY encoding → [RY(θ) + CNOT 체인] × 8





측정과 기댓값

측정 한 번은 bitstring 하나이고, 모델이 쓰는 값은 반복 측정의 통계량

출력 방식	정의와 출력 크기	사용 논문
확률 분포 P(x)	2^n개 basis state의 측정 확률 출력 크기 2^n (지수)	QGAN
기댓값 ⟨X_i⟩	큐빗별 관측량의 평균, −1 ~ 1 출력 크기 n (선형)	MediQ-GAN

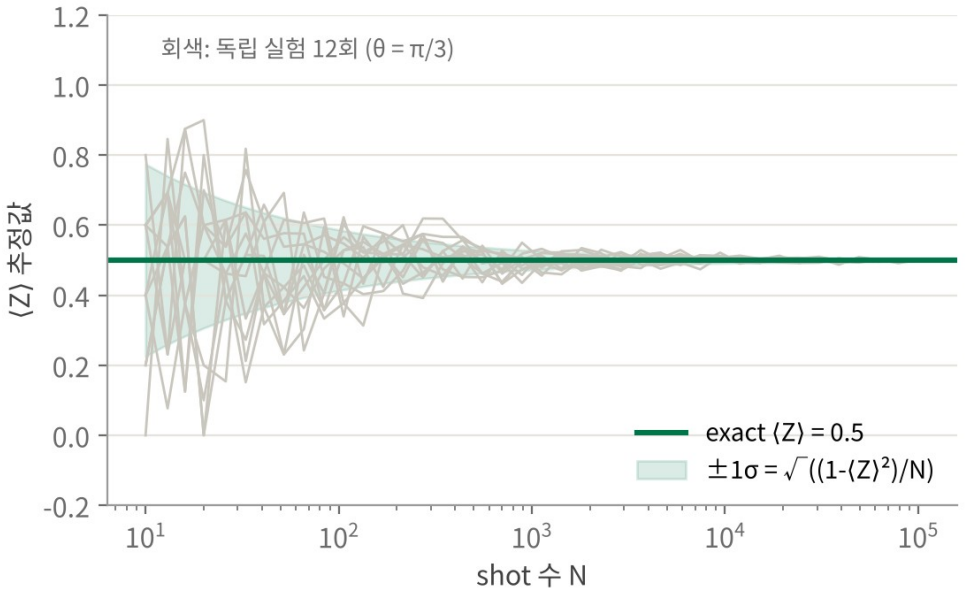
$$\langle Z \rangle = P(0) - P(1) \in [-1, 1]$$

$$\text{shot N회 추정의 표준오차} = \sqrt{((1 - \langle Z \rangle^2) / N)} \leq 1/\sqrt{N}$$

출력 구조의 차이

QGAN: 8큐빗 중 ancilla qubit = 0인 128개 확률을 patch 픽셀로 사용

MediQ-GAN: 16큐빗 → 기댓값 16개를 특징으로 사용, 이미지는 고전 decoder가 생성

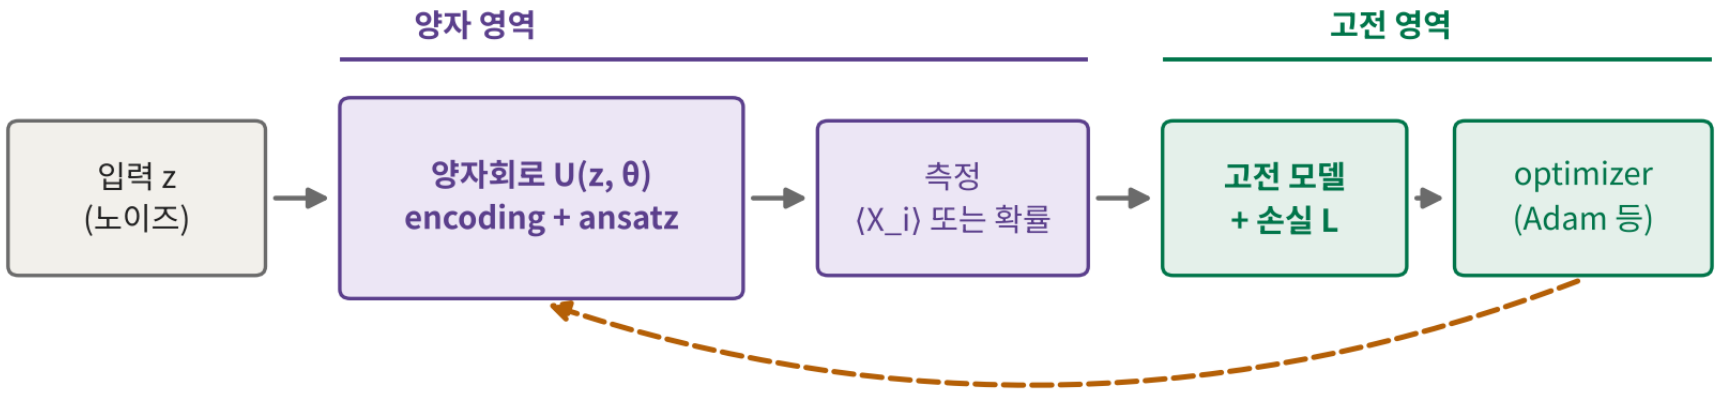


정밀도를 10배 높이려면 shot이 100배 필요함. 이 비용이 뒤의 VQC 학습 비용 계산에 들어감

시뮬레이터에서 shots를 지정하지 않으면 이 오차 없이 exact 기댓값을 계산함

변분 양자회로(PQC)와 hybrid 학습 루프

양자회로는 미분 가능한 하나의 layer로 쓰이고, 파라미터 갱신은 고전 optimizer가 담당함



encoding

- 입력을 회전각으로 변환 (angle encoding). 두 논문 모두 사용
- 대안인 amplitude encoding은 2ⁿ개 값을 적재하나 상태 준비 회로가 깊어질 수 있음

ansatz

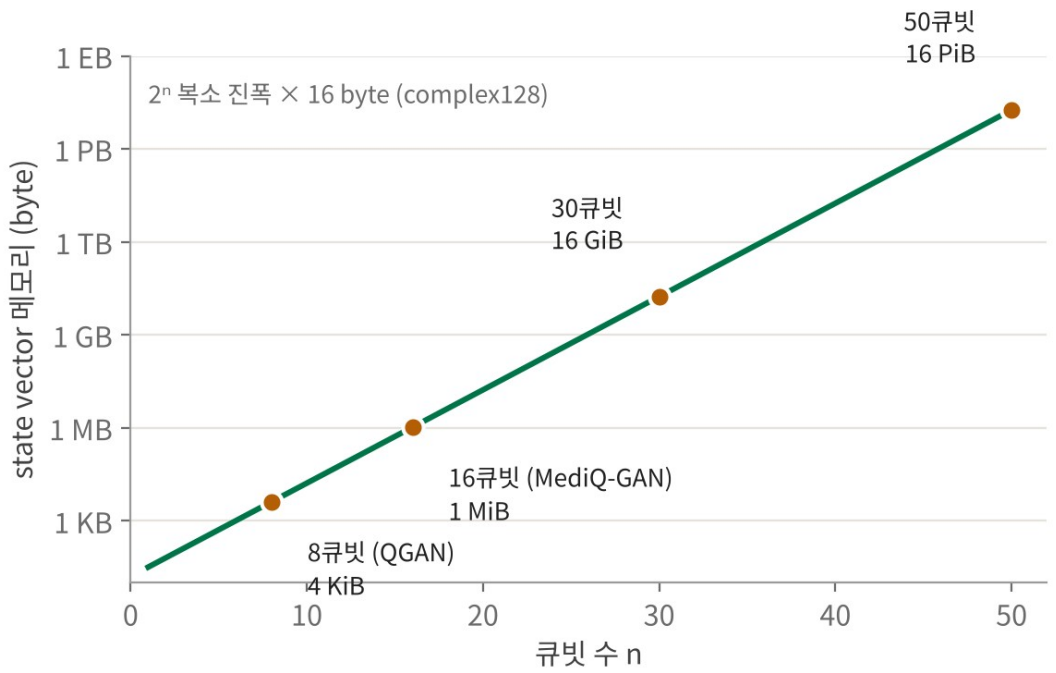
- 학습 가능한 회전 + 얽힘 게이트의 반복
- 두 논문 모두 hardware-efficient 구조 (RY + CNOT 또는 CZ)

gradient

- 시뮬레이터: adjoint 또는 backpropagation
- 실기: parameter-shift rule, 파라미터마다 회로 2회 추가 실행

시뮬레이션의 한계와 학습 가능성

state vector 시뮬레이션은 큐빗 수에 지수적이고, 회로가 넓고 깊을수록 학습이 어려워짐



항목	내용
시뮬레이션 규모	16큐빗은 1 MiB로 노트북에서 처리 가능. 30큐빗부터 16 GiB로 일반 PC 한계
해석	정확히 시뮬레이션되는 규모의 회로는 양자 우위의 근거가 아님. MediQ-GAN 논문도 quantum-inspired로 규정하고 양자 소자를 계산 가속 용도로 한정
NISQ 실기	게이트 오류와 decoherence로 얕은 회로만 신뢰 가능
Barren plateau	큐빗 수·깊이가 커질수록 gradient 분산이 지수적으로 감소하는 현상
표현력 대 학습 가능성	표현력이 큰 회로일수록 barren plateau 위험이 큼. MediQ-GAN은 DLA 분석으로 depth 8을 선택

BREAK

휴식

10분 후 재개

여기까지	HAM10000 클래스 불균형 → GAN 구조·학습 불안정성·평가 지표 → qubit, 게이트, 측정, PQC 학습 루프
이어서	Chapter 1 QGAN (patch 방식, 학습 step, 결과) → Chapter 2 MediQ-GAN (dual-stream, WGAN-GP, 결과) → Chapter 3 정리

CHAPTER 1

논문 ① QGAN

Quantum GAN 기반 피부병변 이미지 증강 - patch method 아키텍처

제목	Data Augmentation in Cancer Image Classification Problem with Quantum GAN
기여점	7+1큐빗 · sub-generator 16개 · patch 방식으로 피부 이미지를 생성해 소수 클래스(DF) 증강
검증 방식	생성 이미지로 CNN 분류기를 학습시켜, 증강 전/후 AUC-ROC·정확도를 비교(고전 GAN과도 비교)
핵심 내용	"Generator" 아키텍처 사례 - model-level hybrid

QGAN 기본 개념 - 고전 GAN과 무엇이 다른가

생성자(Generator)·판별자(Discriminator)가 경쟁하며 학습하는 구조는 동일

고전 GAN

Generator = 신경망(예: CNN/MLP)

무작위 노이즈 벡터 → 신경망 통과 → 이미지

학습 파라미터 = 가중치 행렬

Discriminator도 고전 신경망

QGAN

Generator = 변분 양자회로(PQC)

무작위 각도 노이즈 → 큐빗 회전으로 encoding → 측정

학습 파라미터 = 회전 게이트의 각도

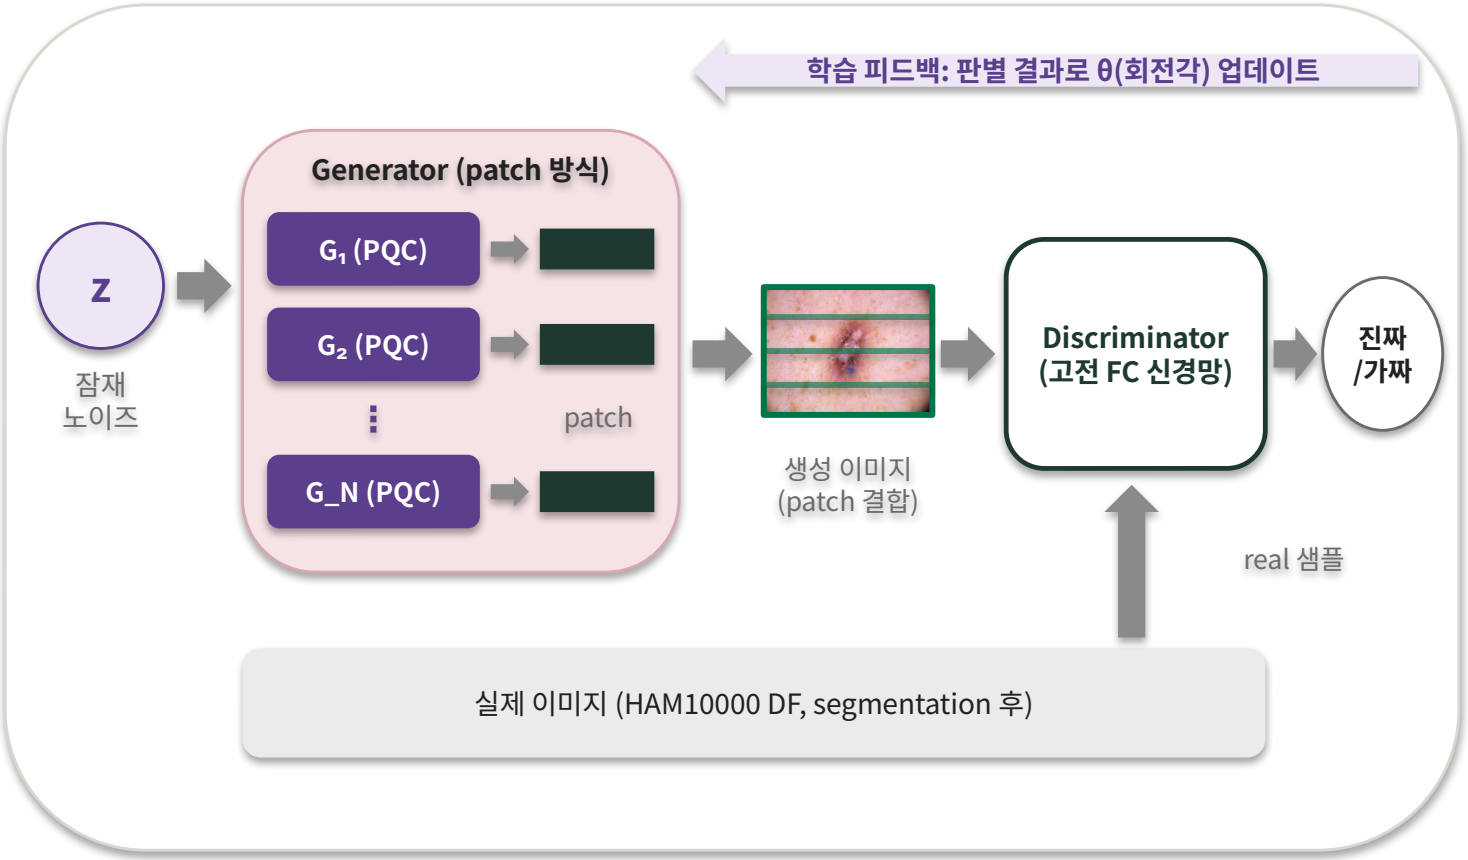
Discriminator는 그대로 고전 신경망(비대칭 구조)

핵심

Discriminator는 그대로, Generator만 양자회로 교체

QGAN 아키텍처 다이어그램 - patch 기반 Generator

Generator-Discriminator 구조를 도식으로 재구성



원 논문 Fig. 10 구조를 도식으로 재구성: Andra et al., Quantum Machine Intelligence 7, 90 (2025)

Patch 방식 아키텍처

큐빗 한 세트로 이미지 전체를 만들기 어려워, 여러 개의 '작은 회로'가 조각(patch)을 나눠 생성

sub-generator 1
PQC → patch

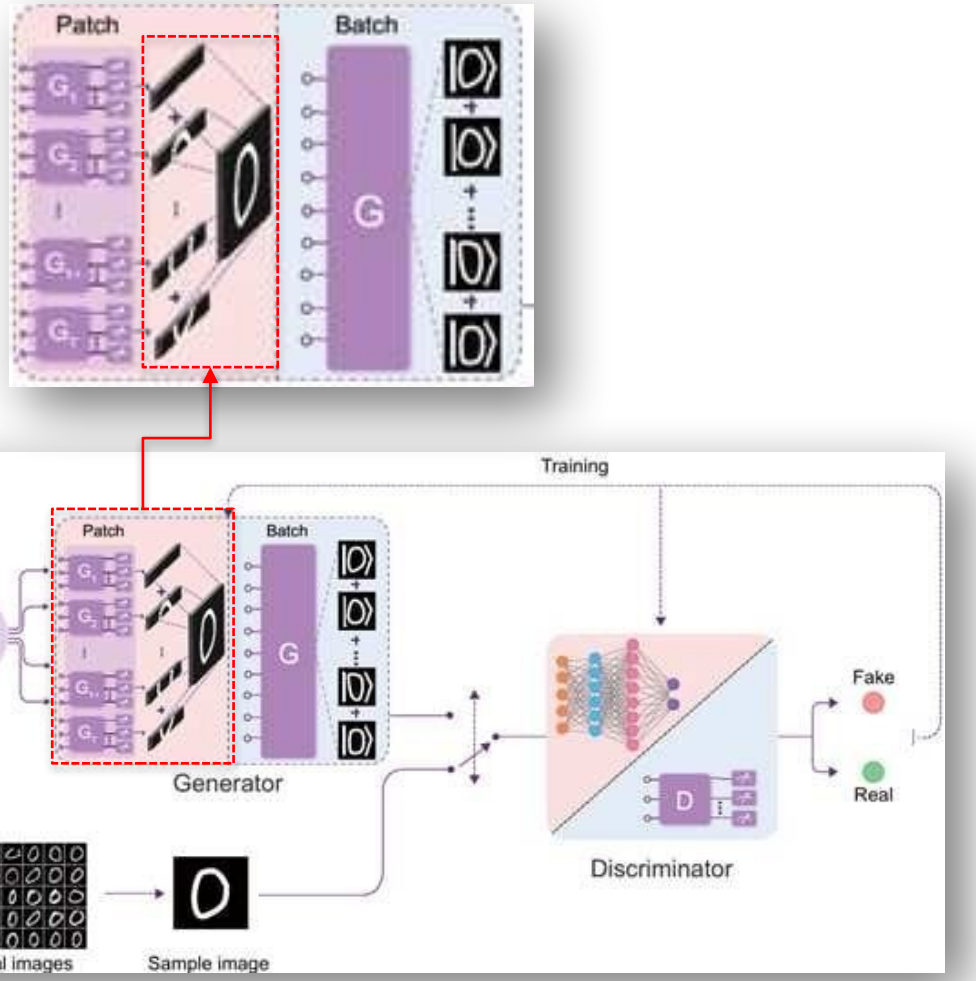
sub-generator 2
PQC → patch

sub-generator 3
PQC → patch

sub-generator N
PQC → patch

(논문: 16개 sub-generator)

patch 1 + patch 2 + patch 3
+ … + patch N
→ 이어 붙여 최종 이미지 벡터



sub-generator 회로 상세

각 sub-generator = 3단계로 이루어진 하나의 변분 양자회로(PQC)

① 노이즈 encoding

무작위 각도를 RY 게이트로 각 큐빗에 회전시켜 입력

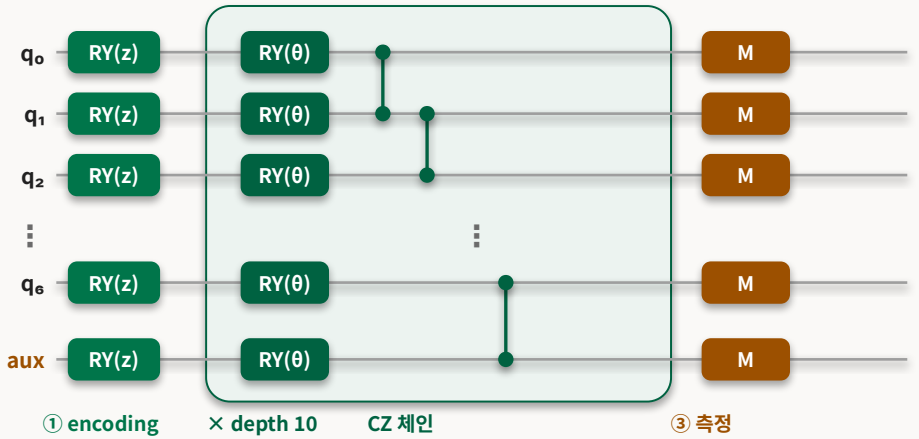
② 변분 layer (반복)

학습 가능한 RY 회전 + 인접 큐빗 CZ 얽힘 - 각도가 '학습되는 가중치'

③ 측정

ancilla qubit까지 전체 측정 후, ancilla qubit=0인 항목만 patch로 사용(post-selection)

sub-generator 1개 회로 (논문 Table 3 기준, 8큐빗)



측정 결과 $2^8 = 256$개 확률 중 ancilla qubit = 0 인 128개만 선택(post-selection) → patch 1장

sub-generator 16개의 patch를 이어붙여 이미지 1장을 구성

항목	값
큐빗 수	데이터 7 + ancilla 1 = 총 8
sub-generator 수	16개
회로 깊이(PQC depth)	10
학습률 / epoch	0.1 / 2,000

QGAN 한 step의 학습 과정

판별자와 생성자를 번갈아 갱신하며, 생성자의 gradient는 회로 파라미터 θ까지 전달됨

단계	동작	손실
1 생성	z → sub-generator 16개 → patch 결합 → 생성 이미지 $\tilde{x}$	-
2 D 갱신	실제 x는 1, 생성 $\tilde{x}$는 0으로 분류하도록 D의 가중치 갱신	$L_D = -[\log D(x) + \log(1 - D(\tilde{x}))]$ (BCE)
3 G 갱신	D가 $\tilde{x}$를 1로 판단하도록 회로 각도 θ 갱신	$L_G = -\log D(\tilde{x})$ (non-saturating)
4 반복	2,000 epoch (논문 Table 3·4)	-

설정에서 확인할 점

- 학습률: 생성자 0.1, 판별자 5×10^{-3} (Table 3·4). 생성자가 20배 큼
- 논문은 손실을 Binary Cross Entropy로 표기함. G 손실 형태는 일반적인 non-saturating 형태로 적은 것임
- 실습(2일차)은 sub-generator 4개, 600 step으로 줄인 설정을 사용함

Discriminator 구조 + 평가 프로토콜

"QGAN이 잘 만들었는지"는 생성 이미지 직접 확인 대신 별도 CNN 분류기 성능으로 검증

Discriminator (Table 4)

Table 4 · Discriminator	값
Layer 수	5 (완전연결)
활성화 함수	ReLU
출력층 활성화	Sigmoid
PQC 깊이 (생성자)	10
학습률	5×10^{-3}
Epoch	2,000
손실 함수	Binary Cross Entropy

평가용 CNN

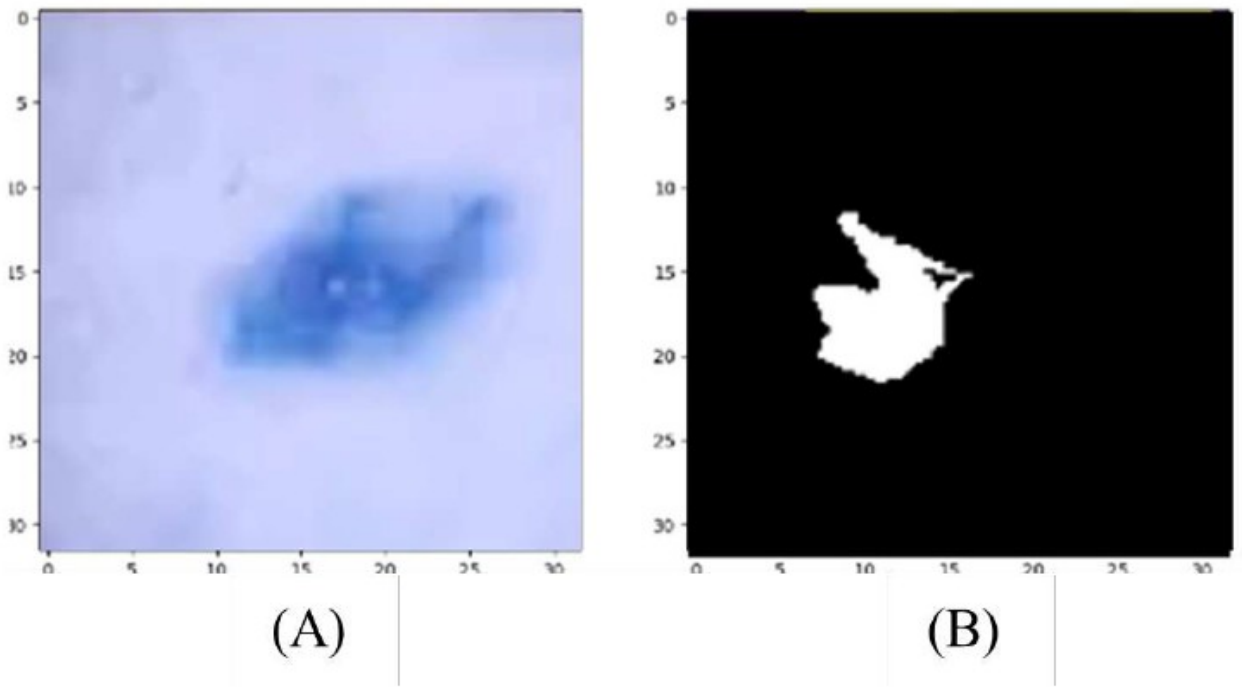
Table 1 · CNN 학습 설정	값
학습률	15×10^{-4} ($=1.5\times10^{-3}$)
손실 함수	Binary Cross Entropy
Optimizer	ADAM
정규화 layer	Batch Normalization 2D
출력 활성화	Sigmoid
파라미터 수	460k

Table 2 · Conv layer	값
Kernel 크기	3
Stride	1
활성화 함수	ReLU
정규화 layer	Batch Normalization 2D
Max Pooling	2×2

표 내용 출처: Andra et al., Quantum Machine Intelligence 7, 90 (2025), Table 1·2·4

결과 0 - QGAN 생성 이미지

논문 Fig. 21: 원본 유래 합성 이미지(A)와 합성 segmentation(B)



관찰

- 병변의 위치와 대략적인 경계는 재현됨
- 해상도가 낮아 질감 같은 세부는 확인하기 어려움
- 이 논문은 FID 같은 생성 품질 지표를 제시하지 않고(프리프린트 기준) 증강 후 분류 성능으로 간접 검증함
- 따라서 우열 판단의 근거는 다음 슬라이드의 분류 성능임

그림 출처: Andra et al., Fig. 21 (프리프린트 Research Square rs-5191116v1, CC BY 4.0)

결과 ① - DF vs NV 분류 성능 개선

Table 6: QGAN 증강 후 AUC-ROC 개선



막대 높이는 0부터 비례. 증가폭은 +0.017이며, 이 저장소의 8×8 재현 실험에서는 AUC +0.004, 정확도는 오히려 하락해 개선으로 단정하지 않음 (README 참고)

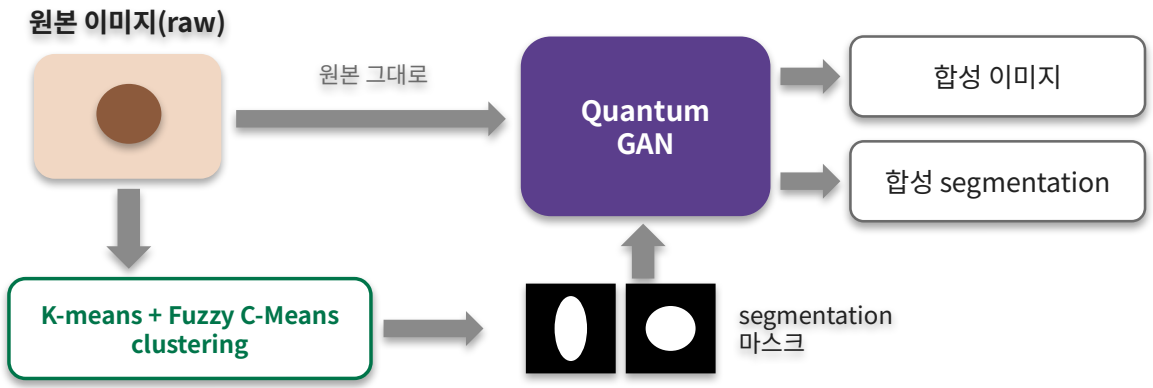
결과 ② - 조건부 증강 효과

segmentation 전처리 이미지에서만 증강 효과 있음

입력 전처리 방식	QGAN 증강 효과
원본/리사이즈 이미지	증강 효과 없음 - 오히려 성능 저하
segmentation(K-means+FCM) 전처리 이미지	증강 효과 있음 - 성능 개선

왜 중요한가

실제로는 배경 노이즈를 제거한(segmentation) 입력에서만
생성 품질이 분류 성능 개선으로 이어짐



원 논문 pipeline을 도식으로 재구성: Andra et al., Quantum Machine Intelligence 7, 90 (2025)

결과 ③ - 고전 GAN과의 비교

Table 11: 조건에 따라 승자 교체 - "양자가 항상 이긴다"는 아님

입력 조건	정확도 비교	비고
원본(raw) 이미지	**고전 GAN (정확도 0.98 vs 0.89)**	QGAN 열세
segmentation 이미지	**QGAN (정확도 0.96 vs 0.95)**	AUC는 0.97로 동률

해석

"고전 대비 무조건적 속도·성능 우위"가 성공 기준이 아니라,
(1) 문제→양자 pipeline의 실제 성립 여부, (2) 어떤 조건에서 고전과 동등·우위인지(crossover 조건) 평가

CHAPTER 2

논문 ② MediQ-GAN

dual-stream 구조로 모델 아키텍처 '일부만' 양자화한 생성 모델

논문

MediQ-GAN (arXiv:2506.21015)

핵심 기여

Generator를 고전 stream + 양자 stream 둘로 나눠 병렬 처리 후 융합(skip-connection) - 의료영상 3종 데이터셋 검증

검증 방식

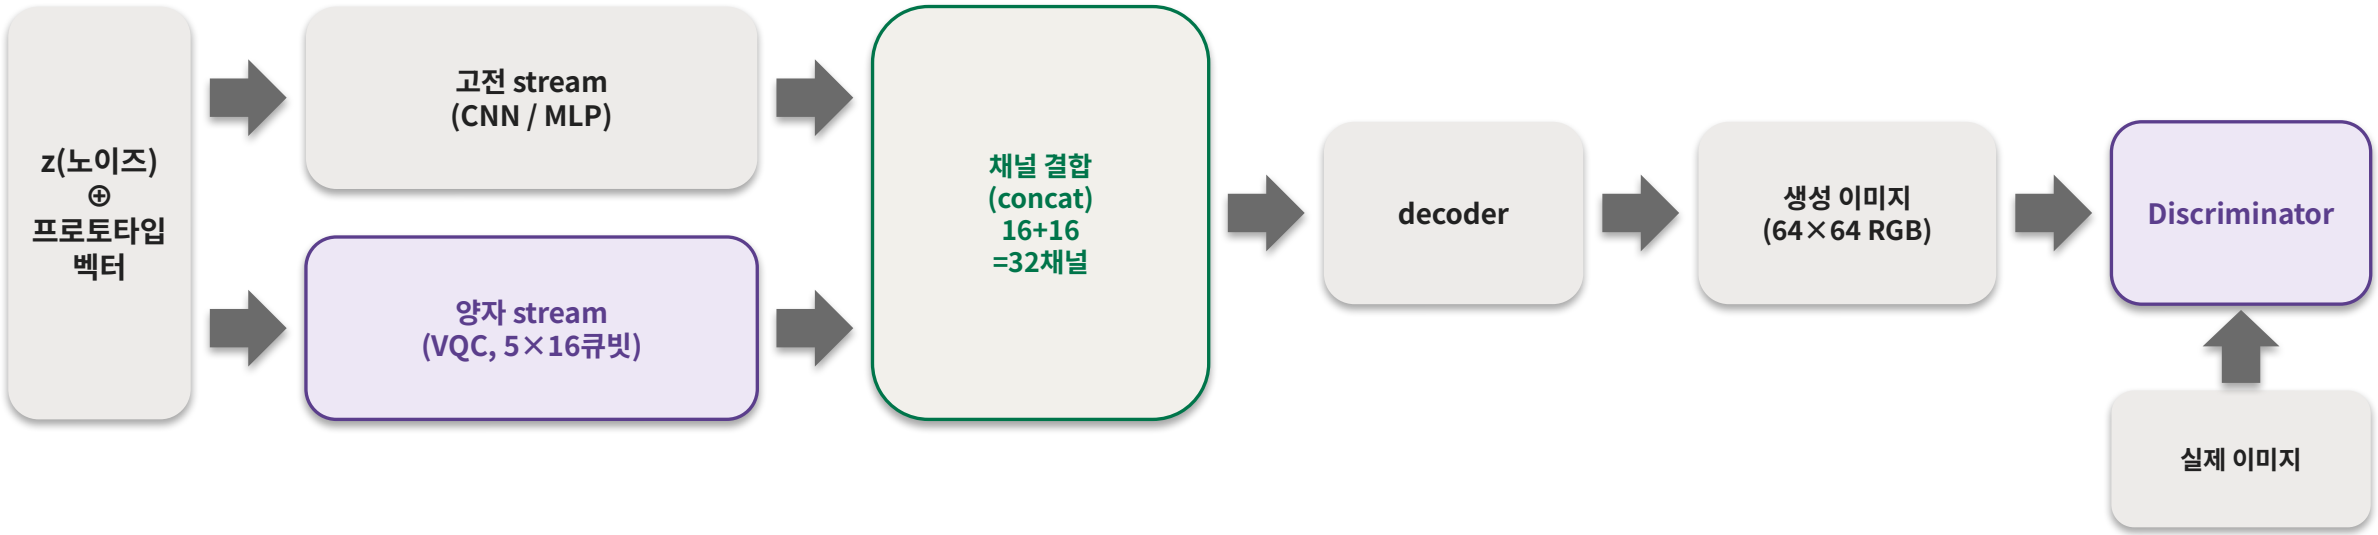
DCGAN·WGAN-GP·StyleGAN2-ADA 등 고전 SOTA 및 MosaiQ(양자)와 클래스별 FID·LPIPS로 비교,
실제 IBM 하드웨어 실행까지 확인

이 강의에서의 역할

"Generator 일부만 양자"인 아키텍처의 대표 사례 - layer-level hybrid

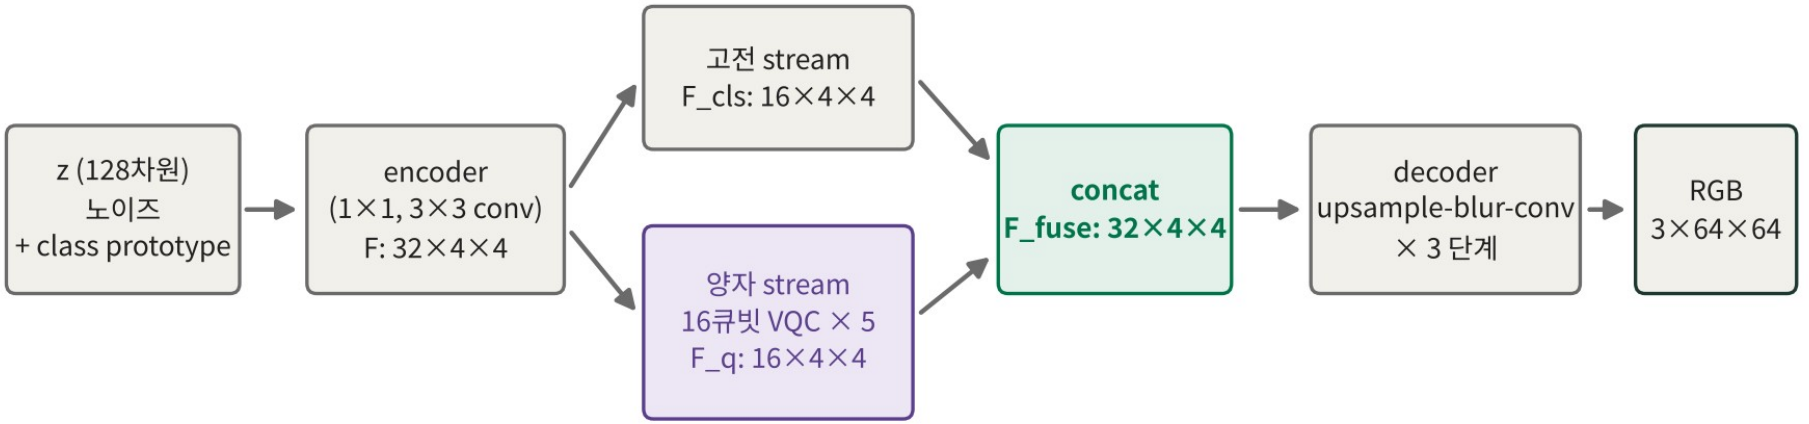
MediQ-GAN 아키텍처 다이어그램 - dual-stream Generator

고전 stream과 양자 stream을 함께 학습해 합치는 구조를 도식으로 재구성



입력 구성과 decoder

class prototype을 노이즈에 결합하고, 양자 stream 출력은 decoder에서 64×64 RGB로 복원



encoder 출력 32채널 중 16채널을 양자 stream에 투입

prototype conditioning

- EfficientNet-B0(30 epoch 미세조정) 특징의 클래스별 평균 벡터를 노이즈에 결합
- centroid 간 거리를 최대화하는 regularization loss로 클래스 구분 유지

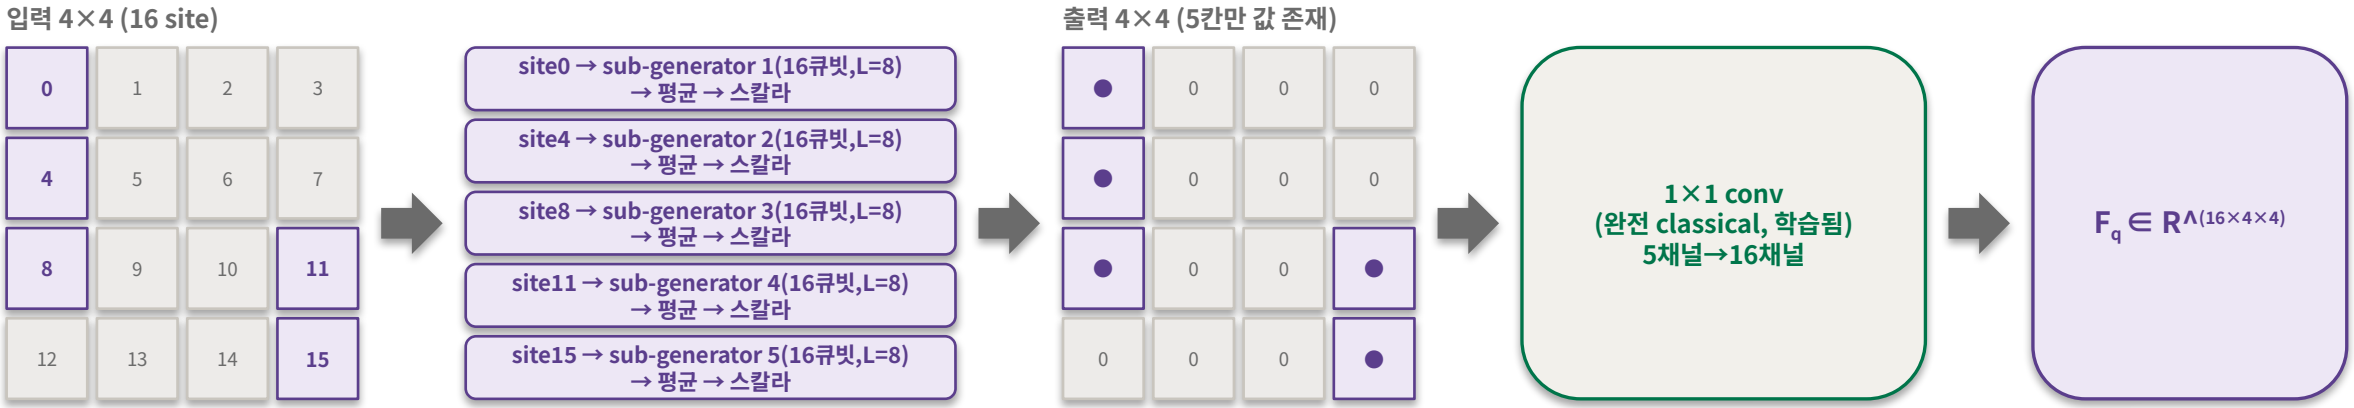
decoder

- 3×3 conv → upsample-blur-conv 3단계 → 3×3 conv
- 양자 stream 출력과 고전 stream 출력을 concat한 32×4×4를 3×64×64로 확대

구조 출처: Jiao et al., arXiv:2506.21015 Method 절

sub-generator 상세 - 16 site 중 5개만 실제 양자 처리

나머지 11칸은 classical 1×1 conv의 편향값만 받음 (공식 GitHub 코드 기준)



site 선택: linspace(0,15,5)round → [0, 4, 8, 11, 15] (row×4+col). 나머지 11칸은 그 sub-generator의 4×4 맵에서 0으로 남음.
1×1 conv는 칸별 독립 처리(이웃 안 봄) - 값이 있는 5칸만 진짜 양자 스칼라를 16채널로 투영, 나머지 11칸은 학습된 편향(bias)뿐. 이후 8×8 업샘플에서만 보간으로 살짝 섞임.

Hybrid 분류체계 - "어디까지가 양자인가"

같은 '양자 생성모델'이라도 Generator 전체/일부 양자 여부로 구분됨

model-level hybrid

예: HAM10000 QGAN, MosaiQ

Generator = 처음부터 끝까지 양자회로

Discriminator만 고전

PCA 등 고전 전처리가 있어도, Generator 는 양자 회로 구성

layer-level hybrid

예: MediQ-GAN

Generator 내부가 고전 stream + 양자 stream으로 병렬 분기

두 stream을 skip-connection으로 concat 후 디코딩

"layer 하나 안에서도" 양자·고전이 공존

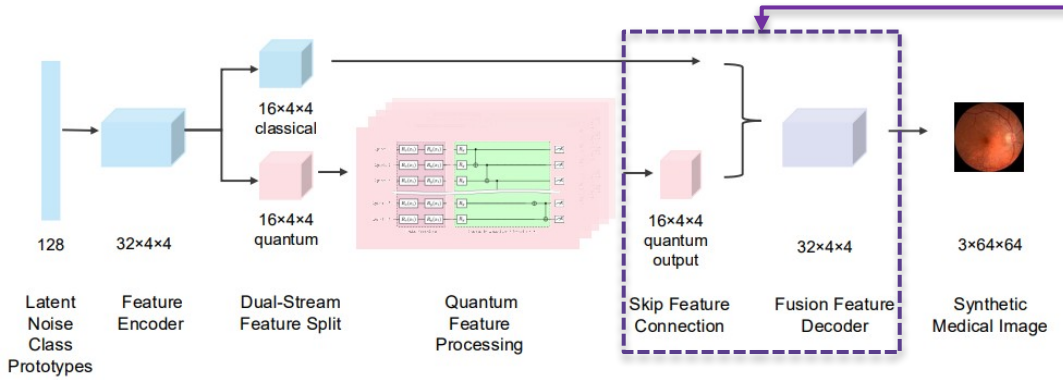
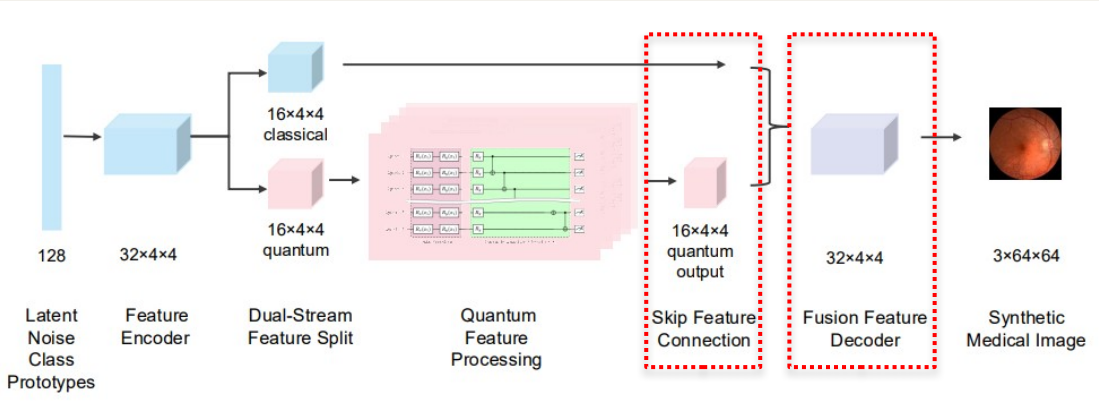


그림 출처: Jiao et al., MediQ-GAN, arXiv:2506.21015 (CC BY 4.0)

dual-stream Generator 아키텍처

입력을 절반씩 나눠 고전 인코더와 양자회로(VQC)가 병렬 처리 후 하나로 합침



고전 stream

classical encoder / conv

양자 stream

5 × 16큐빗 VQC (8층 깊이)

skip-connection 융합 (concat)

고전 decoder → 생성 이미지

encoding: angle encoding(Rx→Ry) · 학습 layer: Ry+CNOT 반복 · 측정: X-basis readout

그림 출처: Jiao et al., MediQ-GAN, arXiv:2506.21015 (CC BY 4.0)

critic과 학습 목표

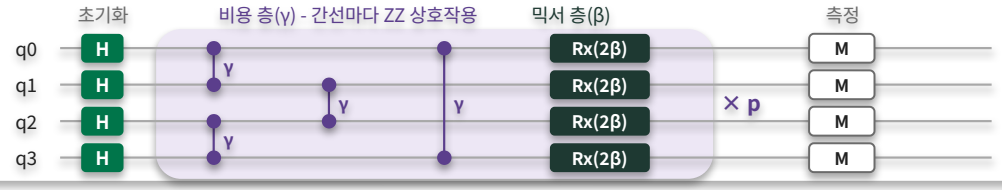
critic은 고전 convolutional network로 유지하고, 학습 목표는 WGAN-GP를 사용

항목	내용
학습 목표	WGAN-GP: $L = E[D(x)] - E[D(G(z))] + \lambda \cdot E[(\| \nabla D(\hat{x}) \|_2 - 1)^2]$ (논문 식 (1)·(2))
critic 구조	원 WGAN-GP 논문의 convolutional 구조, 입력 3×64×64
critic을 고전으로 둔 이유 (논문)	1. 3×64×64 입력을 매 iteration 처리해야 하므로 NISQ 소자에서 구현이 비현실적 2. 안정적이고 잘 알려진 critic을 두어 성능 향상을 양자 설계의 효과로 귀속
QGAN과의 차이	QGAN: 5층 완전연결 + BCE (Table 4) MediQ-GAN: convolution + WGAN-GP
실습과의 차이	3일차: MLP 판별자 + 표준 BCE, lr 2×10^{-4}, betas (0.5, 0.999)로 25 epoch 완주 (README '원 논문과 다른 점')

VQC · VQA·QAOA와의 관계

같은 '파라미터화된 회로 + 고전 최적화' 구조 공유, encoding 대상과 목적은 상이

개념	정의
VQA (Variational Quantum Algorithm)	파라미터화된 양자회로 + 고전 최적화 루프를 사용하는 알고리즘 상위 범주
VQC (Variational Quantum Classifier/Circuit)	분류 등 지도학습 목적의 구체적 구현 - 데이터 encoding + 학습 가능한 ansatz로 구성 (MediQ-GAN의 양자 아키텍처 방식)
QAOA (Quantum Approximate Optimization Algorithm)	조합최적화 문제(MaxCut 등) 등 목적 - cost layer(γ)와 mixer layer(β)를 번갈아 적용



공통점 vs 차이점

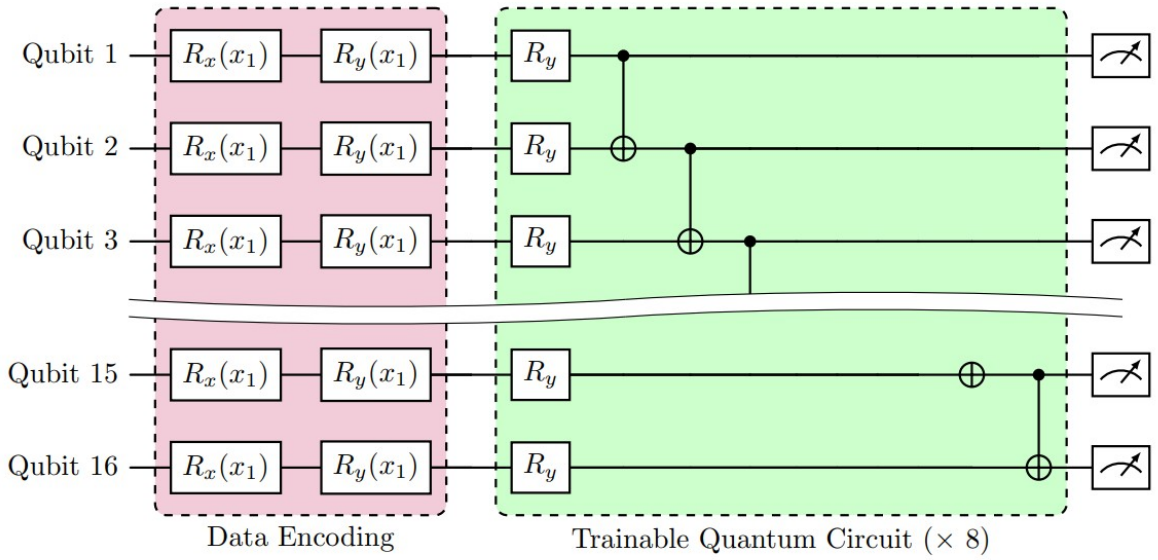
- 공통점: 파라미터화된 회로 → 측정 → 고전 optimizer가 파라미터 업데이트(hybrid loop)
- 차이점: encoding 대상(데이터 vs 문제)과 학습 목표

회로 안의 두 종류 파라미터 - encoding vs 학습

데이터를 넣는 게이트와 학습으로 값이 바뀌는 게이트, 역할 차이

구분	위치 / 값의 성격
encoding 파라미터	회로 앞단, 데이터 encoding 게이트 - 입력 데이터 x (대부분 고정, 학습 대상 아님)
학습 파라미터 θ	encoding 이후 variational ansatz - 회전 게이트 각도, CNOT, entangling 게이트 사이사이에 위치, 학습으로 업데이트됨

layer = 회전게이트(θ, 파라미터 O) + CNOT 체인(파라미터 X, 얽힘 담당)
16큐빗 × 8층 → sub-generator당 파라미터 128개 (5개 합계 640개)



※ 그림은 논문 기준(Rx→Ry·CNOT), 공식 코드는 RY→RX·CZ - 3일차 데모는 코드 기준

그림 출처: Jiao et al., MediQ-GAN, arXiv:2506.21015 (CC BY 4.0)

VQC의 출력값 - bitstring이 아니라 연속값(기댓값)

단일 측정은 0/1, 모델이 실제로 쓰는 값은 여러 번 측정을 평균낸 기댓값

$$m(z;\Theta) = (\langle X_1\rangle, \ldots, \langle X_N\rangle) \in [-1, 1]^N$$

항목	내용
단일 shot 결과	이산적 0/1 bitstring - 확률적 결과
실제 모델 출력	$\langle X_i\rangle$ 연속값(continuous) - classical decoder에 바로 투입 가능, gradient 계산도 가능
수치 안정화	h(m) = σ(LeakyReLU(LayerNorm(m))) 적용 후 classical stream과 fusion

실제 채택 방식 - Exact State Vector Simulation

공식 코드(mediq-gan.py) 설정

```
dev = qml.device("lightning.qubit", wires=args.n_qubits)
@qml.qnode(dev, interface="torch", diff_method="adjoint")
def circuit(...):
    ...
    return [qml.expval(qml.PauliX(i)) for i in range(args.n_qubits)]
```

항목	내용
shots 미지정	PennyLane 기본값 shots=None → 분석적(exact) 기댓값 계산, 반복 측정 없음
diff_method="adjoint"	정확한 state vector 접근이 있어야만 가능한 gradient 계산법 - 데모도 공식 레포와 동일하게 adjoint 사용
state vector 규모	n큐빗 = 2ⁿ차원 복소벡터로 완전 표현(16qubit→65,536차원, 노트북 처리 가능) - 게이트 적용=유니터리 행렬곱(확률적 요소 없음)

'Hardware-agnostic'의 정확한 의미

논문 원문 그대로 인용 시 오해하기 쉬운 표현

논문 원문 인용

"Our approach is quantum-inspired and **hardware-agnostic**: the correctness does not depend on quantum execution, and quantum devices serve only to accelerate computation."

구분	내용
오해 (X)	하드웨어를 아예 안 썼다는 뜻
정확한 뜻 (O)	모델의 타당성이 특정 실행 환경(시뮬레이터 vs 실제 큐빗)에 좌우되지 않도록 설계했다는 뜻
학습(training)	state vector 시뮬레이터로 진행
NISQ evaluation	학습 완료된 회로를 IBM Marrakesh 실기에 올려 inference만 검증 (클래스별 FID +19 ~ +79 상승, 논문은 '비교 가능한 수준'으로 평가)

shot 기반으로 학습한다면 - Parameter-shift Rule

Exact statevector 방식이 아니라, gradient를 구할 때 쓰는 규칙

$$\partial \langle X_i \rangle / \partial \theta_j = [\langle X_i \rangle(\theta_j+\pi/2) - \langle X_i \rangle(\theta_j-\pi/2)] / 2$$

개념	설명
계산 방식	회로 내부를 역전파로 거슬러 올라가는 게 아니라, θ_j를 shift한 회로를 처음부터 끝까지 2번 새로 실행해 얻은 결과값의 단순 뺄셈
순전파(forward) 시점	shift된 회로는 전혀 실행되지 않음 - 원래 θ값으로 1번만 실행, 그 출력이 다음 classical layer로 전달
역전파(backward) 시점	$+\pi/2$, $-\pi/2$ 두 회로가 파라미터 하나마다 개별적으로 실행됨

전체 chain rule: $dLoss/d\theta_j = dLoss/d\langle X_i \rangle$ (classical backprop) × $d\langle X_i \rangle/d\theta_j$ (parameter-shift, 뺄셈 기반)

계산 비용 - 현재 학습의 어려움

파라미터 수만큼 회로를 반복 실행해야 하는 구조적 한계

총 회로 실행 횟수 = C (순전파 회로 수) + 2P (파라미터 별 +shift, −shift)

파라미터 수 P	회로 실행 횟수
640 (회로 5개 × 16큐빗 × 8층)	5 + 1,280 = 1,285회
10,000	1 + 20,000 = 20,001회

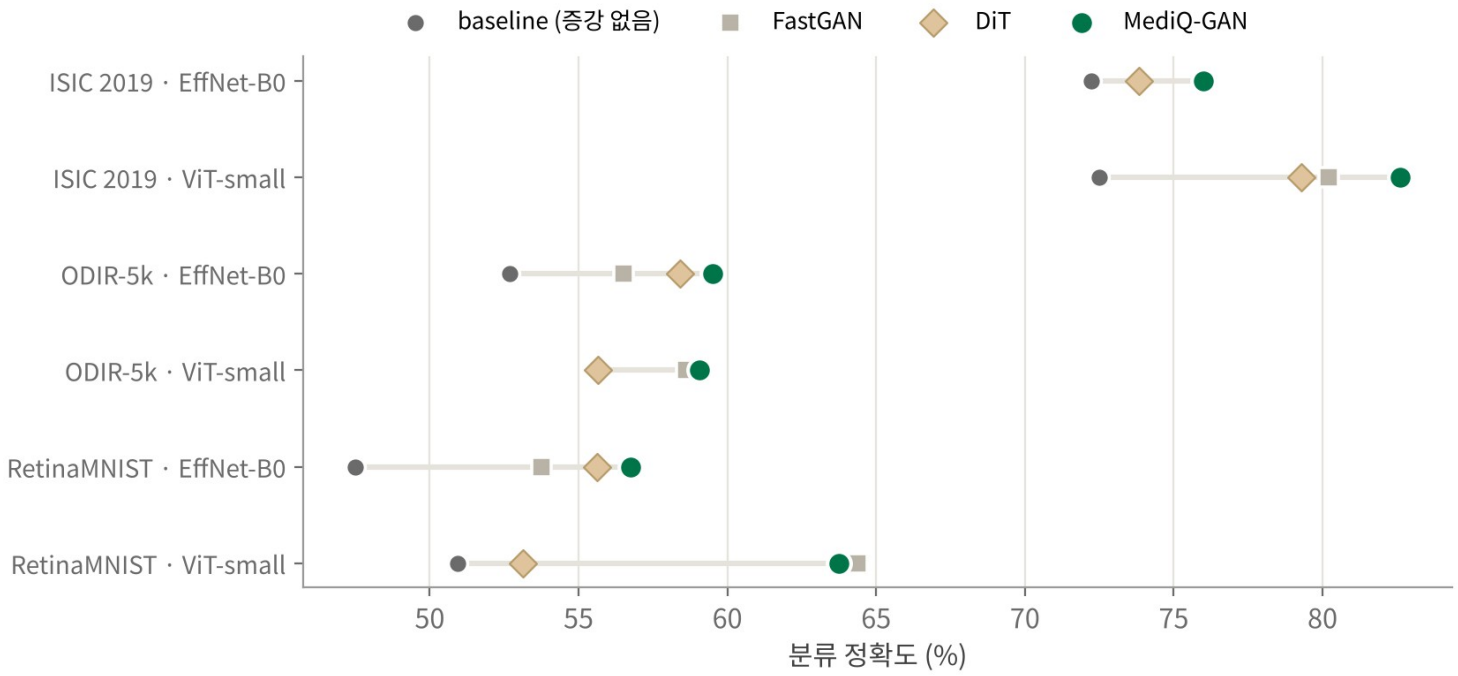
측정 횟수까지 곱하면

총 측정 횟수 = 회로 실행 횟수 × shots.

- P=10,000, shots=1,024 → 20,001×1,024 ≈ 약 2,048만 회.
- batch 32 · 학습 step 10,000까지 포함하면 → $20{,}001 \times 1{,}024 \times 32 \times 10{,}000 \approx 6.5 \times 10^{12}$(약 6.5조 회)

결과 ① - 분류 성능 (Table 1)

baseline 대비 정확도는 3개 데이터셋 · 2개 분류기 모두에서 상승하나, 모든 행에서 최고는 아님



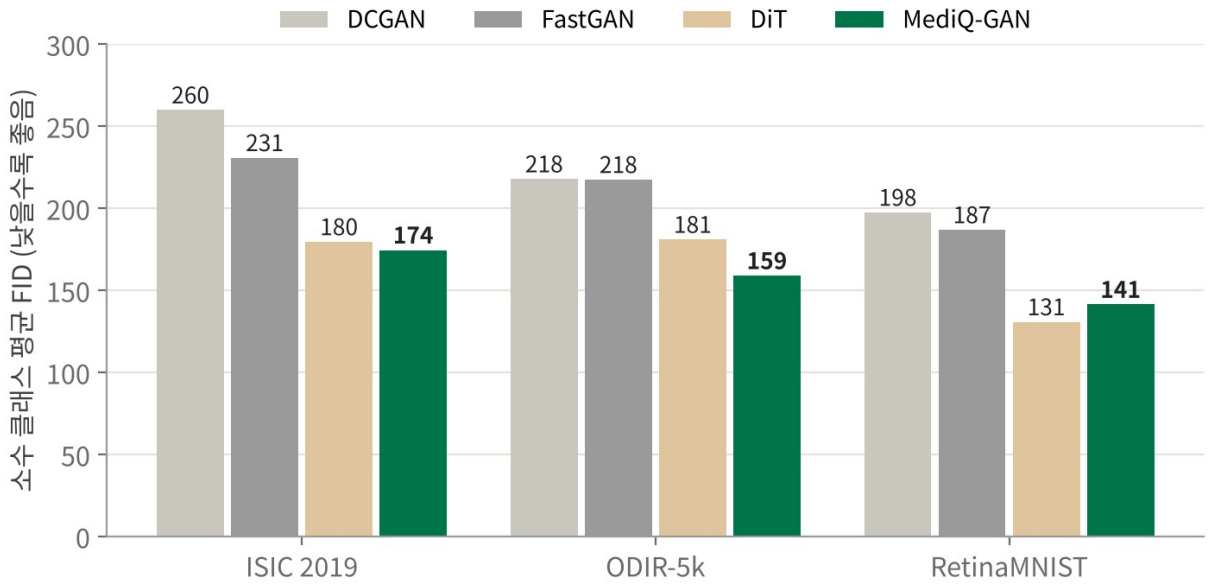
읽는 법

- EfficientNet-B0 정확도 상승: ISIC +3.75, ODIR +6.83, RetinaMNIST +9.25
- ViT-small 정확도 상승: +10.11, +3.44, +12.82
- RetinaMNIST ViT-small: FastGAN 64.37이 MediQ-GAN 63.75보다 높음
- ISIC ViT-small AUC: FastGAN 0.9549 > 0.9517
- MosaiQ는 baseline 이하 (ISIC ViT-small 50.25%)

수치 출처: Jiao et al., arXiv:2506.21015 Table 1

결과 ② - 생성 품질: FID와 LPIPS

소수 클래스 FID는 ISIC·ODIR에서 MediQ-GAN이 가장 낮고, RetinaMNIST에서는 DiT가 더 낮음



해석

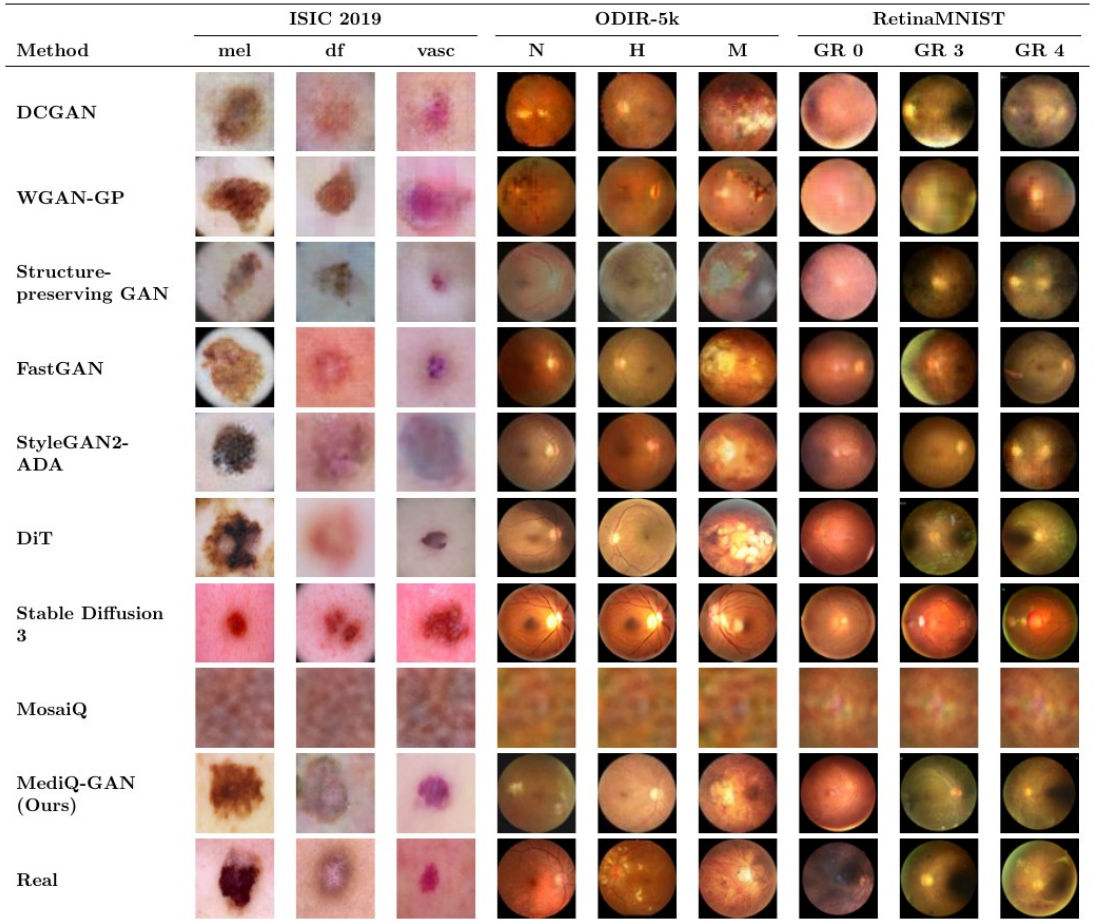
- DiT는 확산 모델로 용량이 훨씬 큼. 논문 서술은 'best or second-best'
- MosaiQ: FID 316 ~ 593, RetinaMNIST LPIPS 0.079로 거의 같은 이미지만 생성
- FID는 클래스당 표본이 적을수록 불안정함

소수 클래스 평균 LPIPS (높을수록 다양)	Real	DiT	FastGAN	MediQ-GAN
ISIC 2019	0.457	0.367	0.422	0.409
ODIR-5k	0.612	0.609	0.609	0.601
RetinaMNIST	0.396	0.321	0.394	0.384

수치 출처: Jiao et al., Extended Data Table 2·3

결과 ③ - 생성 이미지 비교 (Fig. 2)

열은 데이터셋별 대표 클래스, 행은 방법, 마지막 행은 실제 이미지



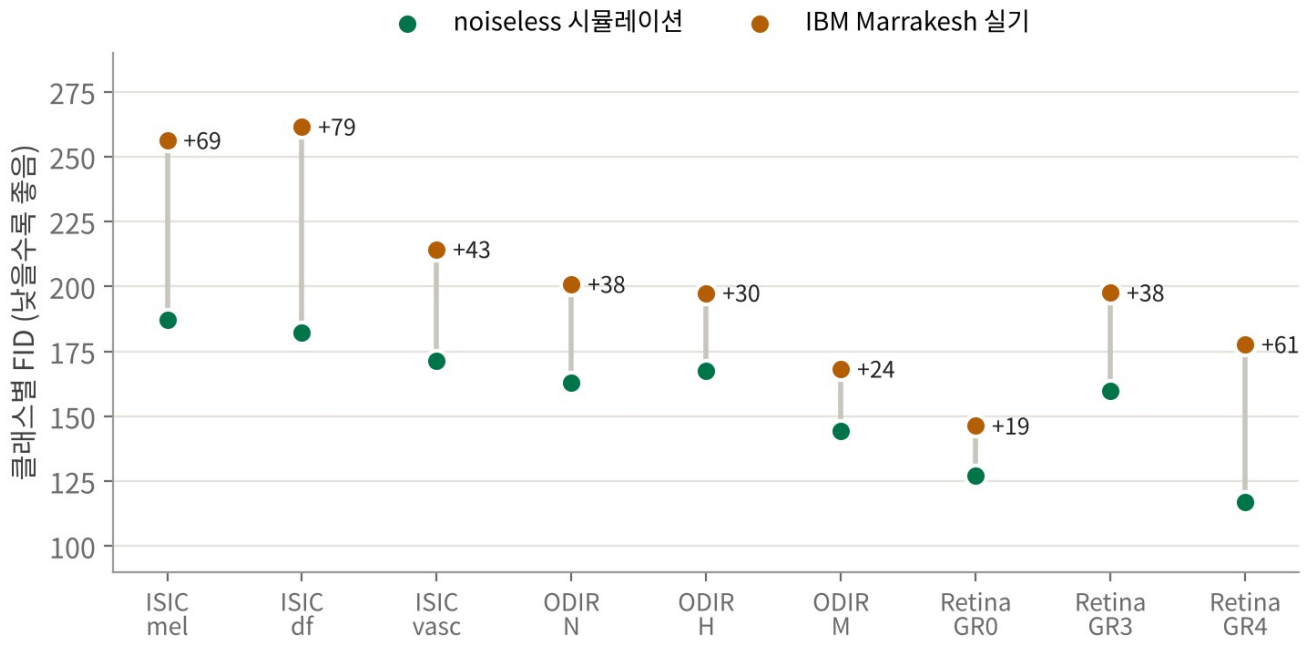
논문의 정성 서술

- DCGAN, Structure-preserving GAN: 흐린 dermoscopic 질감
- StyleGAN2-ADA: 다수 클래스는 개선, 희소 클래스에서 약함
- FastGAN, DiT: 데이터가 극히 적은 ISIC df에서 구조 손실
- MosaiQ: PCA 축소로 색과 구조가 사라진 흐린 패치
- MediQ-GAN: 클래스 특징 보존 (논문 서술)
- 저자의 정성 평가이므로 FID, LPIPS와 함께 해석함

그림 출처: Jiao et al., arXiv:2506.21015 Fig. 2 (CC BY 4.0)

결과 ④ - IBM 실기 검증

학습된 회로를 IBM Marrakesh에서 inference만 실행: 모든 클래스에서 FID 상승



읽는 법

- 범위: 데이터셋별 대표 클래스 9개, inference만 (학습은 시뮬레이션)
- FID 상승폭: +19 (RetinaMNIST GR0) ~ +79 (ISIC df)
- 논문 평가: 시뮬레이션보다 약간 낮으나 비교 가능한 수준

비교

ISIC df: 실기 FID 261.5는 FastGAN 225.0보다 나쁘고 DCGAN 272.6보다 좋음. 노이즈에 무너지지 않는다는 근거이며, 실기에서 고전 baseline보다 우위라는 근거는 아님

수치 출처: Jiao et al., Extended Data Table 4, Table 2

결과 ⑤ - 생성자의 학습 가능성 분석

Jacobian 특이값 분포와 DLA 분석으로 hybrid 생성자를 평가함

분석	의미	논문 결과
effective rank, participation ratio	잠재 방향 중 출력에 실제 영향을 주는 비율 (높을수록 좋음)	특이값 감쇠가 고전 baseline보다 완만 (Extended Data Fig. 3)
log10 condition number	생성자 conditioning (낮을수록 좋음)	MediQ-GAN 2.09 / 2.04 / 2.01 (ISIC / ODIR / Retina) DCGAN 2.54 / 2.54 / 2.44, StyleGAN2-ADA 5.78 / 6.25 / 6.58
DLA 분석	회로가 만드는 변환군의 차원으로 표현력과 barren plateau 위험을 판단	depth 8에서 표현력이 충분하고 barren plateau를 피함
ablation	양자 채널 수, VQC 개수	늘릴수록 성능과 effective rank 개선, 현 설정 이후 이득 감소. 16채널 · 5 VQC는 시뮬레이션 비용과 절충

한계

논문 결론: MediQ-GAN은 모든 unconstrained benchmark에서 고전 생성모델을 넘어서지는 못함. 이 분석은 생성자의 수치적 성질에 대한 것임

수치 출처: Jiao et al., Extended Data Table 5, Discussion

CHAPTER 3

내용 정리

두 논문 비교 요약 및 정리

QGAN 및 MediQ-GAN 정리

구분	QGAN	MediQ-GAN
Hybrid 유형	model-level (Generator 전체 양자)	layer-level (dual-stream)
큐빗 규모	7+1큐빗 × sub-generator 16개	5 × 16큐빗 VQC(stream 하나)
데이터셋	HAM10000 (피부병변, 2클래스 집중)	ISIC2019 · ODIR-5k · RetinaMNIST
검증 방식	증강 전/후 CNN 분류 성능(AUC-ROC)	클래스별 FID·LPIPS + 실기(IBM) 검증

두 논문을 읽을 때의 점검 항목

양자 생성모델 논문의 주장을 평가할 때 적용하는 다섯 가지 기준

점검 항목	QGAN	MediQ-GAN
비교 대상	고전 vanilla GAN 1종	고전 GAN 5종, 확산 모델 2종, MosaiQ
평가 방식	분류 성능 (AUC-ROC, 정확도)	분류 성능 + FID + LPIPS
양자 요소의 범위	생성자 전체	생성자 일부 (공식 코드 기준 16개 위치 중 5개)
조건 의존성	segmentation 입력에서만 증강 효과	모든 지표에서 최고는 아님 (결과 ①, ②)
한계의 명시	개선 폭 AUC +0.017. 이 저장소 8×8 재현에서는 정확도 하락	실기 검증은 inference에 한정. 고전 모델을 전 영역에서 넘지는 못함

2·3일차 실습과의 대응

회로 사양은 유지하고 해상도와 학습량을 줄여 Colab 무료 CPU에서 끝까지 실행

이론 (1일차)	실습 구현	원 논문과의 차이
QGAN patch 생성자	2일차: sub-generator 4개 × 7큐빗(데이터 6 + ancilla 1), depth 10	논문: 16개 × 8큐빗. 16×16 그레이스케일
QGAN 판별자	5층 완전연결 (2·3일차 공통)	동일 (Table 4)
MediQ-GAN dual-stream	3일차: 양자 stream 16큐빗 × 5, depth 8. 25 epoch 미세조정	고전 부분·판별자는 MLP + 표준 BCE (논문: conv + WGAN-GP)
평가	지표 4종 (16×16에서 FID 불가)	논문: FID, LPIPS, 분류 성능
실행 환경	PennyLane exact 시뮬레이션, Colab CPU	논문: GPU, IBM 실기는 inference

실측 (로컬 CPU, README)

QGAN 600 step: 클래스 평균 상관 0.195. MediQ-GAN 25 epoch: 0.365, 단 다양성은 실제의 약 1/8. 두 모델의 평균 형태와 다양성 절충이 다르게 나타남

현재 단계에서의 QML 연구 방향

QML 연구에서는 연산 비용을 줄이는 방향이 논의되고 있음

판단 대상	결론
parameter-shift 구현	비현실적 - 계산상 명확함
QML 연구 전체의 가치	유효함 - 아래 방향의 연구가 활발히 진행 중

SPSA (Simultaneous Perturbation Stochastic Approximation)

파라미터 개수와 무관하게 매 step 회로 2번만 실행해 gradient 근사(정확도는 다소 하락)

Classical shadow tomography

적은 측정 횟수로 여러 관측량을 동시 추정

Quantum Natural Gradient (QNG)

더 적은 step으로 수렴시켜 전체 실행 횟수 절감

DLA (Dynamical Lie Algebra) 기반 회로 설계

barren plateau를 피하며 필요한 파라미터/깊이 최소화

이미지 생성 분야에서 양자 알고리즘 유의점

양자 생성 모델은 **양자 데이터, 해밀토니안 상태 등을 만드는 데** 특화되어 있기에, **기존 데이터가 많은 영역, 모델, 컴퓨팅이 잘하는 영역에 대한 성과는 검증 단계**

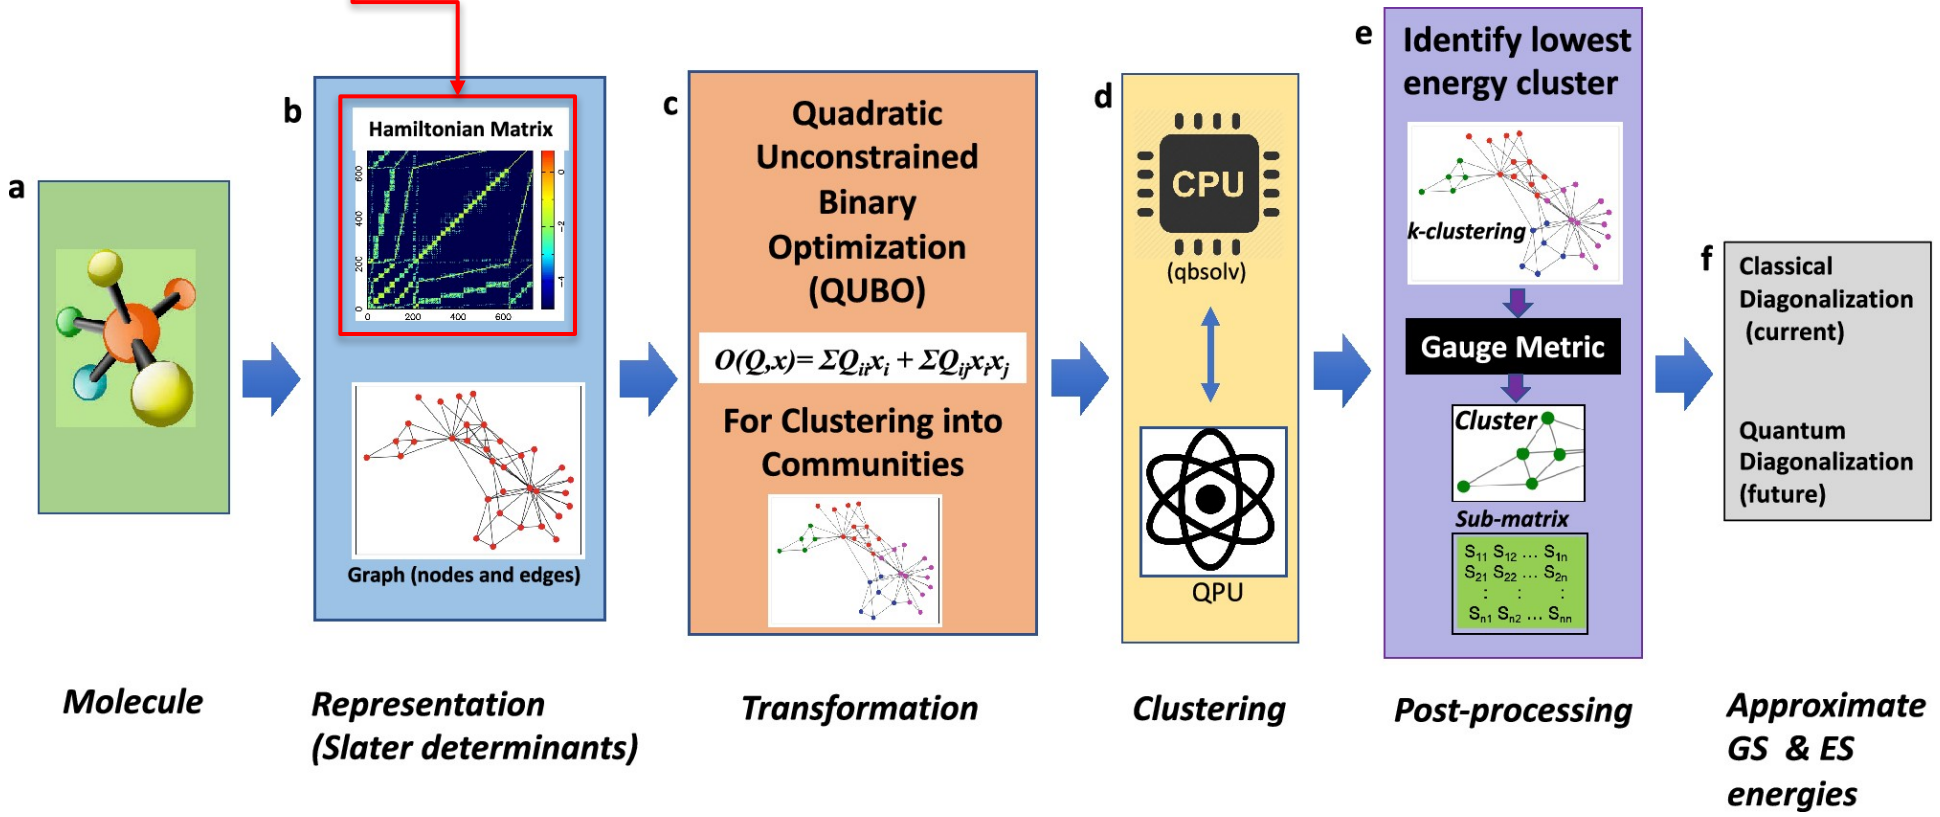


그림 출처: https://www.nature.com/articles/s41598-021-83561-x (CC BY 4.0)

감사합니다.