QML Lecture

양자 머신러닝
의료 이미지 데이터 증강

오리엔테이션

의료 데이터셋을 활용한 양자 머신러닝 실습

이론 → 데이터 EDA·전처리·회로 구성 → 실습 실행

1일차

11/13(금)

이론 설명

데이터셋 소개
+ QGAN·MediQ-GAN 논문 아키텍처

2일차

11/20(금)

실습 - 전처리 + QGAN 학습

3일차

11/27(금)

실습 - MediQ-GAN 학습

오리엔테이션

학습목표

INDEX

1. HAM10000 데이터셋 EDA
2. QGAN과 고전 GAN의 차이 - patch 방식 아키텍처 설명
3. 아키텍처 **'전체가 양자'(QGAN)**와 **'일부만 양자'(MediQ-GAN, dual-stream)** 차이 구분

HAM10000 데이터셋

"Human Against Machine with 10000 training images" - 피부병변 진단 AI 연구의 대표 벤치마크

10,015

총 이미지 수

피부경검사(dermatoscopic) 촬영

7

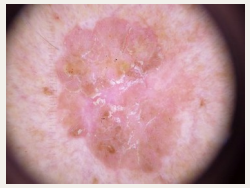
병변 클래스 수

akiec · bcc · bkl · df · mel · nv · vasc

600×450

원본 해상도

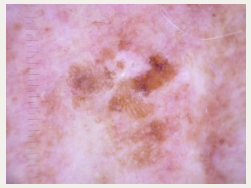
RGB, 실제 임상 촬영 이미지



akiec · 광선각화증



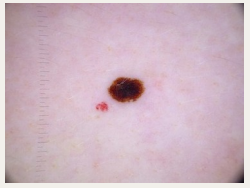
bcc · 기저세포암



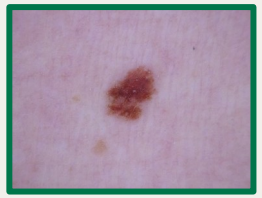
bkl · 양성각화증



df · 피부섬유종



mel · 흑색종



nv · 모반



vasc · 혈관병변

병변 유형	코드	이미지 수	비율
광선각화증 (Actinic keratoses)	akiec	327	3.3%
기저세포암 (Basal cell carcinoma)	bcc	514	5.1%
양성각화증 (Benign keratosis-like lesions)	bkl	1,099	11.0%
피부섬유종 (Dermatofibroma)	**df**	**115**	**1.1%**
흑색종 (Melanoma)	mel	1,113	11.1%
모반 (Melanocytic nevi)	**nv**	**6,705**	**66.9%**
혈관병변 (Vascular lesions)	vasc	142	1.4%

이미지·데이터 출처: HAM10000 (Tschandl et al., Scientific Data 5, 180161, 2018)

01 · 데이터셋

EDA 분석 결과 : 데이터 불균형

클래스 불균형 데이터 처리 방법

클래스	이미지 수
광선각화증 (akiec)	327
기저세포암 (bcc)	514
양성각화증 (bkl)	1,099
피부섬유종 (df)	**115**
흑색종 (mel)	1,113
모반 (nv)	**6,705**
혈관병변 (vasc)	142

방법	설명	한계
Under Sampling 언더샘플링	소수 클래스에 맞춰, 다수 클래스를 줄임	정보 손실 - 6,700장 넘게 버려야 함
Over Sampling 오버샘플링	소수클래스를 복제해서 늘림	복제본이라 새로운 정보가 없음 - 과적합 위험
Augmentation 기하학적 증강	회전·반전·크롭 등으로 변형	병변의 실제 형태·질감 다양성은 만들지 못함
생성모델(GAN/QGAN)	학습된 분포에서 '새로운' 그럴듯한 샘플 생성	품질 검증 필요

초점

- QGAN이 '고전 GAN보다 좋다'가 결론은 아님
- QGAN의 실제 동작 방식과 조건을 논문 데이터로 확인

표 출처: HAM10000 메타데이터 (Tschandl et al., Scientific Data 5, 180161, 2018)

CHAPTER 1

논문 ① QGAN

Quantum GAN 기반 피부병변 이미지 증강 - patch method 아키텍처

제목	Data Augmentation in Cancer Image Classification Problem with Quantum GAN
기여점	7+1큐빗 · Sub Generator 16개 · patch 방식으로 피부 이미지를 생성해 소수 클래스(DF) 증강
검증 방식	생성 이미지로 CNN 분류기를 학습시켜, 증강 전/후 AUC-ROC·정확도를 비교(고전 GAN과도 비교)
핵심 내용	"Generator" 아키텍처 사례 - model-level hybrid

QGAN 기본 개념 - 고전 GAN과 무엇이 다른가

생성자(Generator)·판별자(Discriminator)가 경쟁하며 학습하는 구조는 동일

고전 GAN

Generator = 신경망(예: CNN/MLP)

무작위 노이즈 벡터 → 신경망 통과 → 이미지

학습 파라미터 = 가중치 행렬

Discriminator도 고전 신경망

QGAN

Generator = 변분 양자회로(PQC)

무작위 각도 노이즈 → 큐빗 회전으로 encoding → 측정

학습 파라미터 = 회전 게이트의 각도

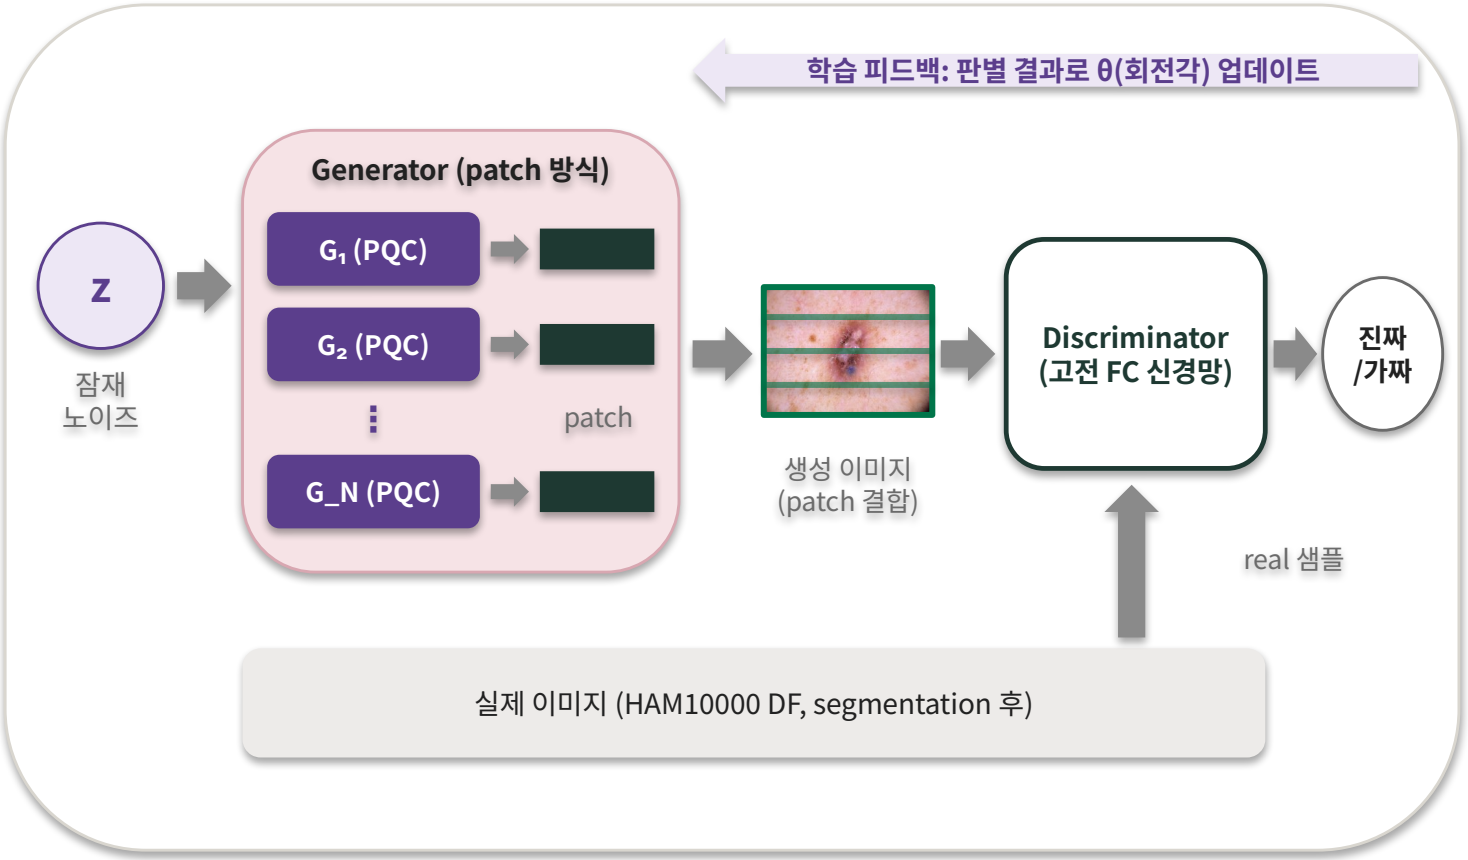
Discriminator는 그대로 고전 신경망(비대칭 구조)

핵심

Discriminator는 그대로, Generator만 양자회로 교체

QGAN 아키텍처 다이어그램 - patch 기반 Generator

Generator-Discriminator 구조를 도식으로 재구성



원 논문 Fig. 10 구조를 도식으로 재구성: Andra et al., Quantum Machine Intelligence 7, 90 (2025)

Patch 방식 아키텍처

큐빗 한 세트로 이미지 전체를 만들기 어려워, 여러 개의 '작은 회로'가 조각(patch)을 나눠 생성

Sub Generator 1
PQC → patch

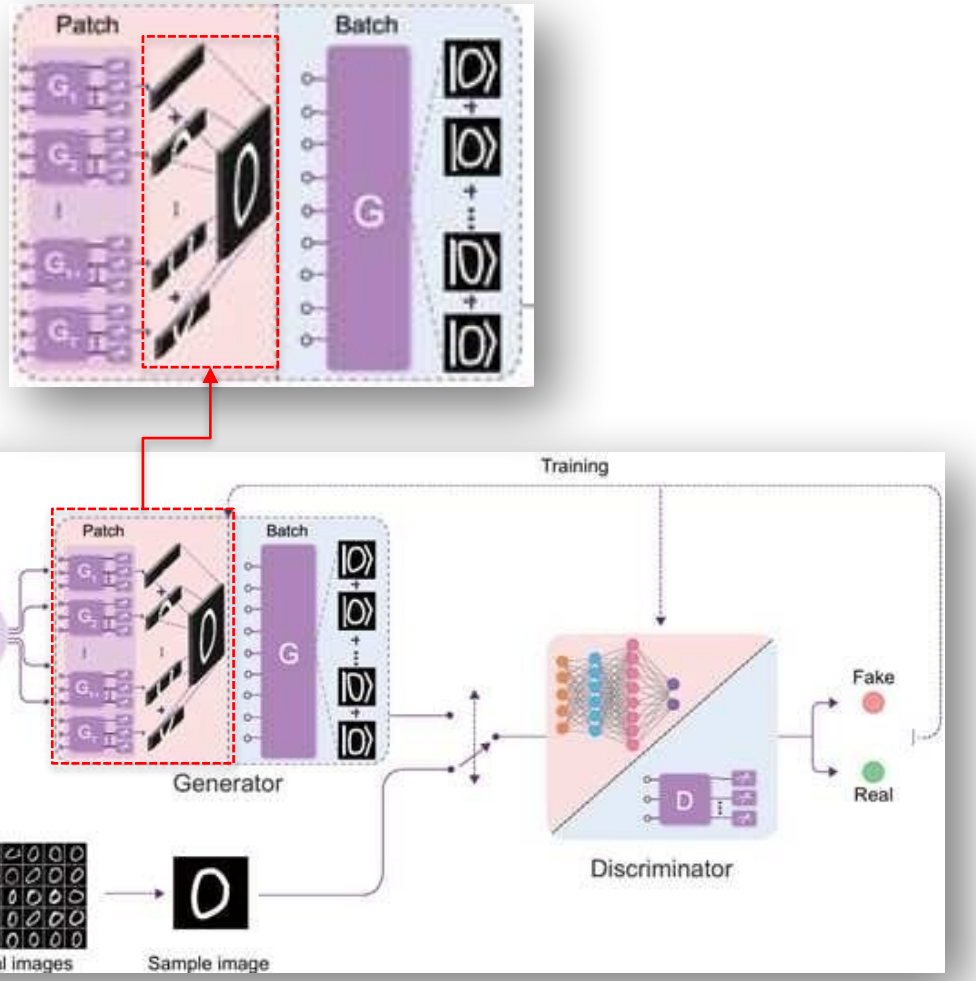
Sub Generator 2
PQC → patch

Sub Generator 3
PQC → patch

Sub Generator N
PQC → patch

(논문: 16개 Sub Generator)

patch 1 + patch 2 + patch 3
+ … + patch N
→ 이어 붙여 최종 이미지 벡터



Sub Generator 회로 상세

각 Sub Generator = 3단계로 이루어진 하나의 변분 양자회로(PQC)

① 노이즈 encoding

무작위 각도를 RY 게이트로 각 큐빗에 회전시켜 입력

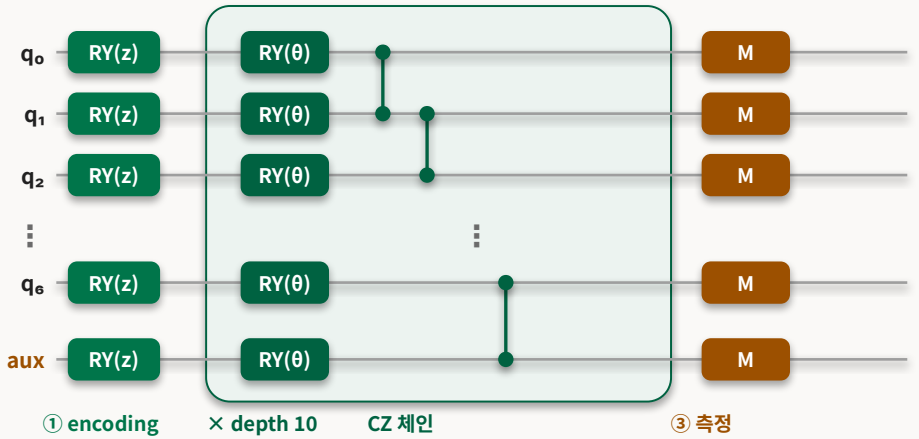
② 변분 layer (반복)

학습 가능한 RY 회전 + 인접 큐빗 CZ 얽힘 - 각도가 '학습되는 가중치'

③ 측정

ancilla qubit까지 전체 측정 후, ancilla qubit=0인 항목만 patch로 사용(post-selection)

Sub Generator 1개 회로 (논문 Table 3 기준, 8큐빗)



측정 결과 $2^8 = 256$개 확률 중 ancilla qubit = 0 인 128개만 선택(post-selection) → patch 1장

Sub Generator 16개의 patch를 이어붙여 이미지 1장을 구성

항목	값
큐빗 수	데이터 7 + 보조(ancilla) 1 = 총 8
Sub Generator 수	16개
회로 깊이(PQC depth)	10
학습률 / epoch	0.1 / 2,000

Discriminator 구조 + 평가 프로토콜

"QGAN이 잘 만들었는지"는 생성 이미지 직접 확인 대신 별도 CNN 분류기 성능으로 검증

Discriminator (Table 4)

Table 4 · Discriminator	값
Layer 수	5 (완전연결)
활성화 함수	ReLU
출력층 활성화	Sigmoid
PQC 깊이 (생성자)	10
학습률	5×10^{-3}
Epoch	2,000
손실 함수	Binary Cross Entropy

평가용 CNN

Table 1 · CNN 학습 설정	값
학습률	15×10^{-4} ($=1.5\times10^{-3}$)
손실 함수	Binary Cross Entropy
Optimizer	ADAM
정규화 layer	Batch Normalization 2D
출력 활성화	Sigmoid
파라미터 수	460k

Table 2 · Conv layer	값
Kernel 크기	3
Stride	1
활성화 함수	ReLU
정규화 layer	Batch Normalization 2D
Max Pooling	2×2

표 내용 출처: Andra et al., Quantum Machine Intelligence 7, 90 (2025), Table 1·2·4

결과 ① - DF vs NV 분류 성능 개선

Table 6: QGAN 증강 후 AUC-ROC 개선



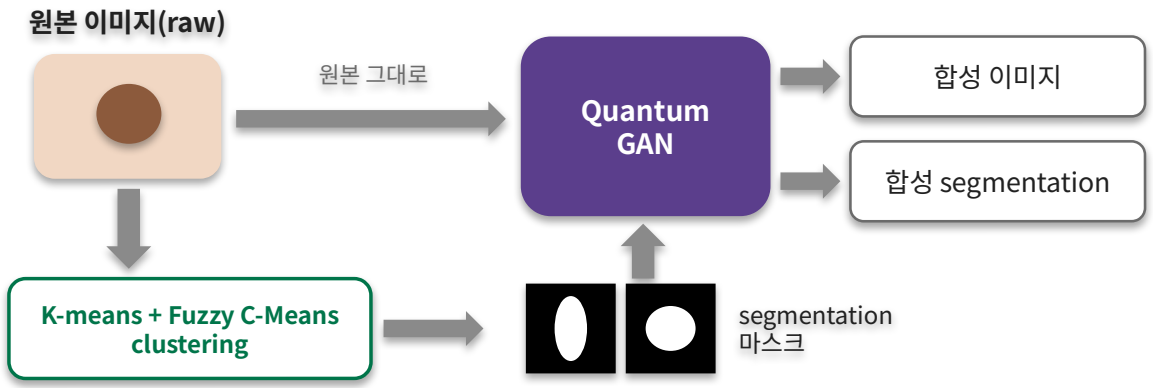
결과 ② - 조건부 증강 효과

segmentation 전처리 이미지에서만 증강 효과 있음

입력 전처리 방식	QGAN 증강 효과
원본/리사이즈 이미지	증강 효과 없음 - 오히려 성능 저하
segmentation(K-means+FCM) 전처리 이미지	증강 효과 있음 - 성능 개선

왜 중요한가

실제로는 배경 노이즈를 제거한(segmentation) 입력에서만
생성 품질이 분류 성능 개선으로 이어짐



원 논문 pipeline을 도식으로 재구성: Andra et al., Quantum Machine Intelligence 7, 90 (2025)

결과 ③ - 고전 GAN과의 비교

Table 11: 조건에 따라 승자 교체 - "양자가 항상 이긴다"는 아님

입력 조건	정확도 비교	비고
원본(raw) 이미지	**고전 GAN (정확도 0.98)**	QGAN 열세
segmentation 이미지	**QGAN (정확도 0.96 vs 0.95)**	AUC는 0.97로 동률

해석

"고전 대비 무조건적 속도·성능 우위"가 성공 기준이 아니라,
(1) 문제→양자 pipeline의 실제 성립 여부, (2) 어떤 조건에서 고전과 동등·우위인지(crossover 조건) 평가

CHAPTER 2

논문 ② MediQ-GAN

dual-stream 구조로 모델 아키텍처 '일부만' 양자화한 생성 모델

논문

MediQ-GAN (arXiv:2506.21015)

핵심 기여

Generator를 고전 stream + 양자 stream 둘로 나눠 병렬 처리 후 융합(skip-connection) - 의료영상 3종 데이터셋 검증

검증 방식

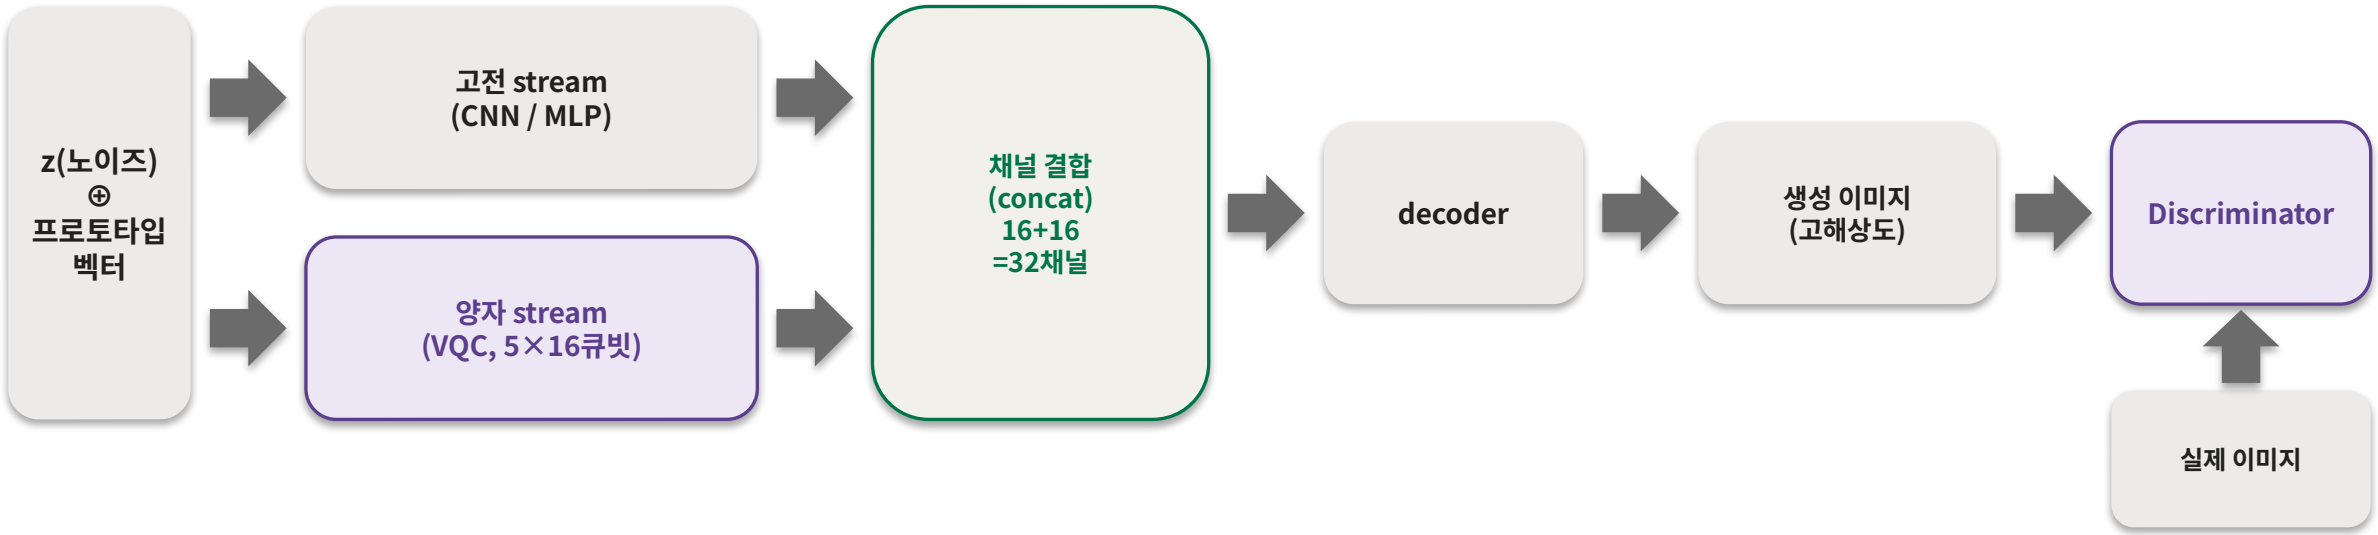
DCGAN · WGAN-GP · StyleGAN2-ADA 등 고전 SOTA 및 MosaiQ(양자)와 클래스별 FID · LPIPS로 비교,
실제 IBM 하드웨어 실행까지 확인

이 강의에서의 역할

"Generator 일부만 양자"인 아키텍처의 대표 사례 - layer-level hybrid

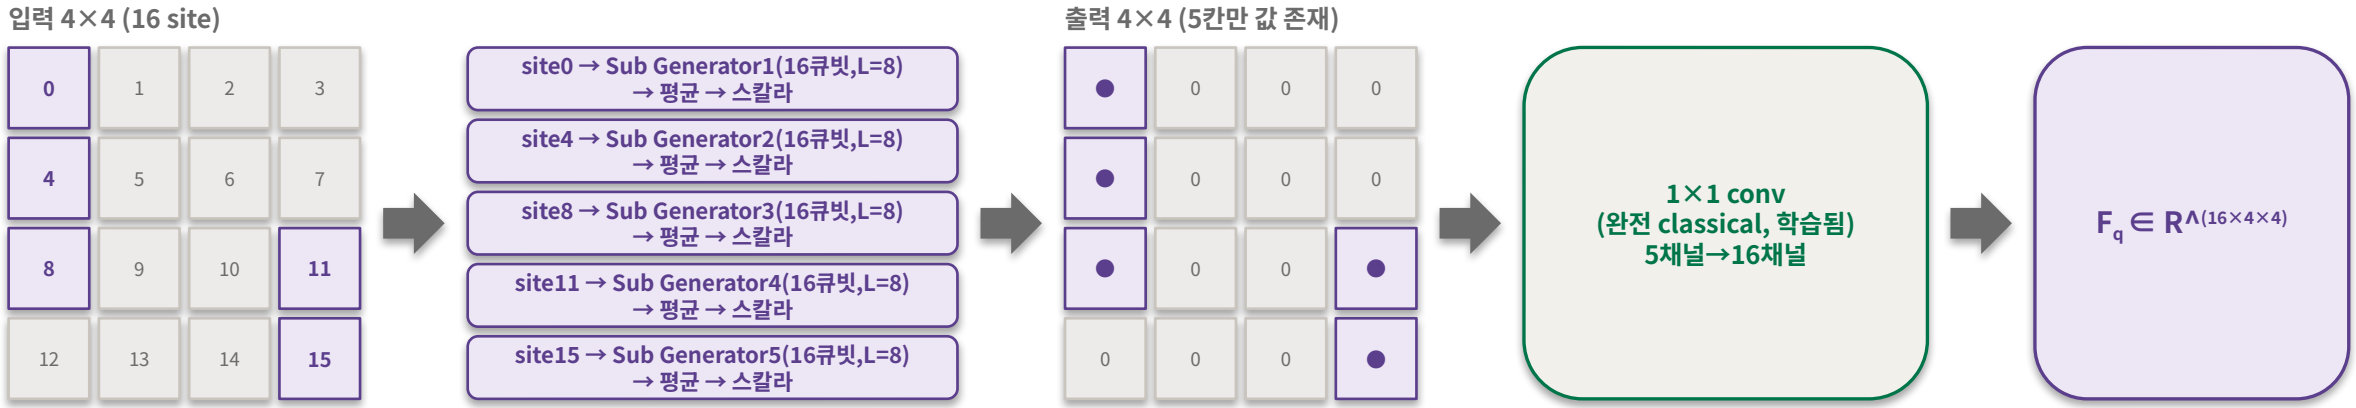
MediQ-GAN 아키텍처 다이어그램 - dual-stream Generator

고전 stream과 양자 stream을 함께 학습해 합치는 구조를 도식으로 재구성



Sub Generator 상세 - 16 site 중 5개만 실제 양자 처리

나머지 11칸은 classical 1×1 conv의 편향값만 받음 (공식 GitHub 코드 기준)



site 선택: linspace(0,15,5)round → [0, 4, 8, 11, 15] (row×4+col). 나머지 11칸은 그 Sub Generator의 4×4 맵에서 0으로 남음.
1×1 conv는 칸별 독립 처리(이웃 안 봄) - 값이 있는 5칸만 진짜 양자 스칼라를 16채널로 투영, 나머지 11칸은 학습된 편향(bias)뿐. 이후 8×8 업샘플에서만 보간으로 살짝 섞임.

Hybrid 분류체계 - "어디까지가 양자인가"

같은 '양자 생성모델'이라도 Generator 전체/일부 양자 여부로 구분됨

모델 레벨 hybrid

예: HAM10000 QGAN, MosaiQ

Generator = 처음부터 끝까지 양자회로

Discriminator만 고전

PCA 등 고전 전처리가 있어도, Generator 는 양자 회로 구성

layer 레벨 hybrid

예: MediQ-GAN

Generator 내부가 고전 stream + 양자 stream으로 병렬 분기

두 stream을 skip-connection으로 concat 후 디코딩

"layer 하나 안에서도" 양자·고전이 공존

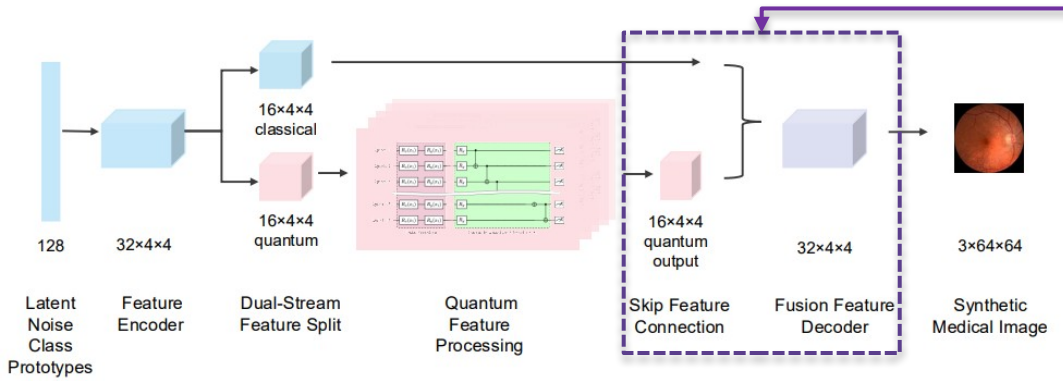
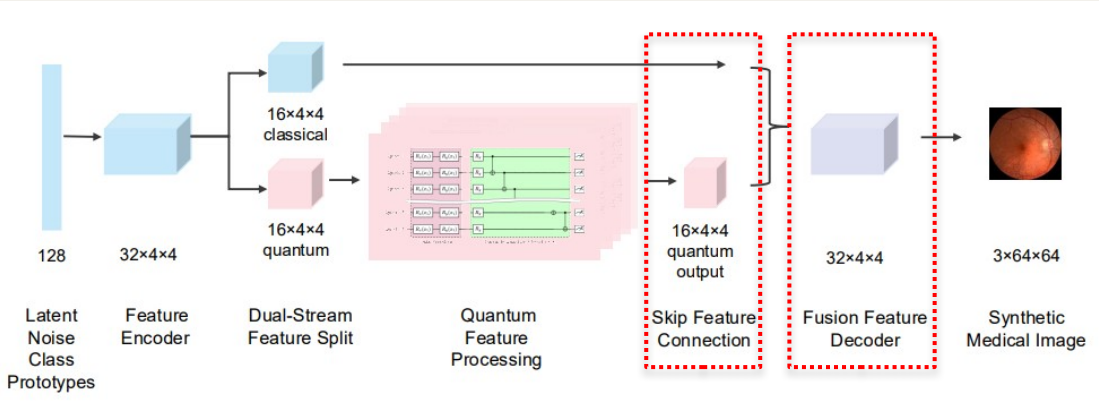


그림 출처: Jiao et al., MediQ-GAN, arXiv:2506.21015 (CC BY 4.0)

dual-stream Generator 아키텍처

입력을 절반씩 나눠 고전 인코더와 양자회로(VQC)가 병렬 처리 후 하나로 합침



고전 stream

classical encoder / conv

양자 stream

5 × 16큐빗 VQC (8층 깊이)

skip-connection 융합 (concat)

고전 decoder → 생성 이미지

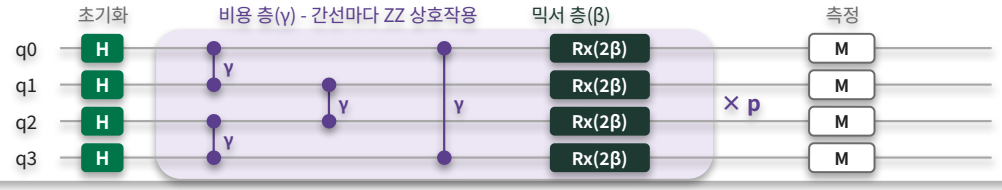
encoding: angle encoding(Rx→Ry) · 학습layer: Ry+CNOT 반복 · 측정: X-basis readout

그림 출처: Jiao et al., MediQ-GAN, arXiv:2506.21015 (CC BY 4.0)

VQC · VQA·QAOA와의 관계

같은 '파라미터화된 회로 + 고전 최적화' 구조 공유, encoding 대상과 목적은 상이

개념	정의
VQA (Variational Quantum Algorithm)	파라미터화된 양자회로 + 고전 최적화 루프를 사용하는 알고리즘 상위 범주
VQC (Variational Quantum Classifier/Circuit)	분류 등 지도학습 목적의 구체적 구현 - 데이터 encoding + 학습 가능한 ansatz로 구성 (MediQ-GAN의 양자 아키텍처 방식)
QAOA (Quantum Approximate Optimization Algorithm)	조합최적화 문제(MaxCut 등) 등 목적 - cost layer(γ)와 mixer layer(β)를 번갈아 적용



공통점 vs 차이점

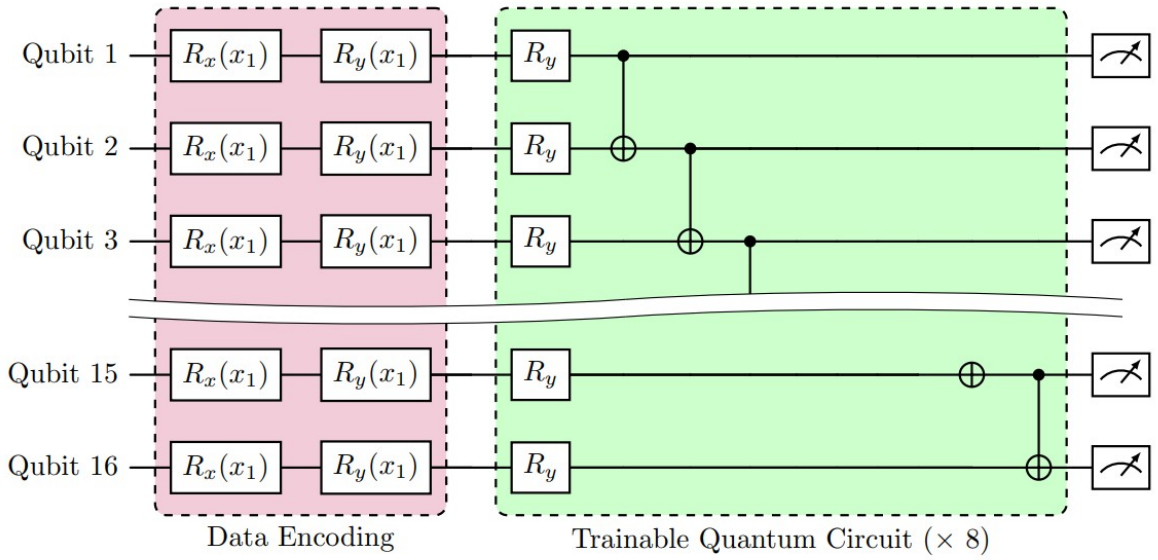
- 공통점: 파라미터화된 회로 → 측정 → 고전 optimizer가 파라미터 업데이트(hybrid loop)
- 차이점: encoding 대상(데이터 vs 문제)과 학습 목표

회로 안의 두 종류 파라미터 - encoding vs 학습

데이터를 넣는 게이트와 학습으로 값이 바뀌는 게이트, 역할 차이

구분	위치 / 값의 성격
encoding 파라미터	회로 앞단, 데이터 encoding 게이트 - 입력 데이터 x (대부분 고정, 학습 대상 아님)
학습 파라미터 θ	encoding 이후 variational ansatz - 회전 게이트 각도, CNOT, entangling 게이트 사이사이에 위치, 학습으로 업데이트됨

layer = 회전게이트(θ, 파라미터 O) + CNOT 체인(파라미터 X, 얽힘 담당)
16큐빗 × 8층 → Sub Generator당 파라미터 128개 (5개 합계 640개)



※ 그림은 논문 기준(Rx→Ry·CNOT), 공식 코드는 RY→RX·CZ - 3일차 데모는 코드 기준

그림 출처: Jiao et al., MediQ-GAN, arXiv:2506.21015 (CC BY 4.0)

VQC의 출력값 - bitstring이 아니라 연속값(기댓값)

단일 측정은 0/1, 모델이 실제로 쓰는 값은 여러 번 측정을 평균낸 기댓값

$$m(z;\Theta) = (\langle X_1\rangle, \ldots, \langle X_N\rangle) \in [-1, 1]^N$$

항목	내용
단일 shot 결과	이산적 0/1 bitstring - 확률적 결과
실제 모델 출력	$\langle X_i\rangle$ 연속값(continuous) - classical decoder에 바로 투입 가능, gradient 계산도 가능
수치 안정화	h(m) = σ(LeakyReLU(LayerNorm(m))) 적용 후 classical stream과 fusion

실제 채택 방식 - Exact State Vector Simulation

논문 코드(mediq-gan.py) 결과

```
dev = qml.device("lightning.qubit", wires=args.n_qubits)
@qml.qnode(dev, interface="torch", diff_method="adjoint")
def circuit(...):
    ...
    return [qml.expval(qml.PauliX(i)) for i in range(args.n_qubits)]
```

항목	내용
shots 미지정	PennyLane 기본값 shots=None → 분석적(exact) 기댓값 계산, 반복 측정 없음
diff_method="adjoint"	정확한 state vector 접근이 있어야만 가능한 gradient 계산법 - 데모도 공식 레포와 동일하게 adjoint 사용
state vector 규모	n큐빗 = 2ⁿ차원 복소벡터로 완전 표현(16qubit→65,536차원, 노트북 처리 가능) - 게이트 적용=유니터리 행렬곱(확률적 요소 없음)

'Hardware-agnostic'의 정확한 의미

논문 원문 그대로 인용 시 오해하기 쉬운 표현

논문 원문 인용

"Our approach is quantum-inspired and **hardware-agnostic**: the correctness does not depend on quantum execution, and quantum devices serve only to accelerate computation."

구분	내용
오해 (X)	하드웨어를 아예 안 썼다는 뜻
정확한 뜻 (O)	모델의 타당성이 특정 실행 환경(시뮬레이터 vs 실제 큐빗)에 좌우되지 않도록 설계했다는 뜻
학습(training)	state vector 시뮬레이터로 진행
NISQ evaluation	학습 완료된 회로를 IBM Marrakesh 실기에 올려 inference만 검증 (노이즈로 성능 소폭 저하되었으나 비교 가능한 수준)

shot 기반으로 학습한다면 - Parameter-shift Rule

Exact statevector 방식이 아니라, gradient를 구할 때 쓰는 규칙

$$\partial \langle X_i \rangle / \partial \theta_j = [\langle X_i \rangle(\theta_j+\pi/2) - \langle X_i \rangle(\theta_j-\pi/2)] / 2$$

개념	설명
계산 방식	회로 내부를 역전파로 거슬러 올라가는 게 아니라, θ_j를 shift한 회로를 처음부터 끝까지 2번 새로 실행해 얻은 결과값의 단순 뺄셈
순전파(forward) 시점	shift된 회로는 전혀 실행되지 않음 - 원래 θ값으로 1번만 실행, 그 출력이 다음 classical layer로 전달
역전파(backward) 시점	$+\pi/2$, $-\pi/2$ 두 회로가 파라미터 하나마다 개별적으로 실행됨

전체 chain rule: $dLoss/d\theta_j = dLoss/d\langle X_i \rangle$ (classical backprop) × $d\langle X_i \rangle/d\theta_j$ (parameter-shift, 뺄셈 기반)

계산 비용 – 현재 학습의 어려움

파라미터 수만큼 회로를 반복 실행해야 하는 구조적 한계

총 회로 실행 횟수 = 1 (순전파) + 2P (파라미터 별 +shift, −shift)

파라미터 수 P	회로 실행 횟수
640 (5개×N16×L8)	1 + 1,280 = 1,281회
10,000	1 + 20,000 = 20,001회

측정 횟수까지 곱하면

총 측정 횟수 = 회로 실행 횟수 × shots.

- P=10,000, shots=1,024 → 20,001×1,024 ≈ 약 2,048만 회.
- batch 32 · 학습 step 10,000까지 포함하면 → 20,001×1,024×32×10,000 ≈ 6.5×10^{12}(약 6.5조 회)

CHAPTER 3

내용 정리

두 논문 비교 요약 및 정리

QGAN 및 MediQ-GAN 정리

구분	QGAN	MediQ-GAN
Hybrid 유형	모델 레벨(Generator 전체 양자)	layer 레벨(dual-stream)
큐빗 규모	7+1큐빗 × Sub Generator 16개	5 × 16큐빗 VQC(stream 하나)
데이터셋	HAM10000 (피부병변, 2클래스 집중)	ISIC2019 · ODIR-5k · RetinaMNIST
검증 방식	증강 전/후 CNN 분류 성능(AUC-ROC)	클래스별 FID·LPIPS + 실기(IBM) 검증

현재 단계에서의 QML 연구 방향

QML 연구 방향 中 연산 비용 개선 논의되고 있음

판단 대상	결론
parameter-shift 구현	비현실적 - 계산상 명확함
QML 연구 전체의 가치	유효함 - 아래 방향의 연구가 활발히 진행 중

SPSA (Simultaneous Perturbation Stochastic Approximation)

파라미터 개수와 무관하게 매 step 회로 2번만 실행해 gradient 근사(정확도는 다소 하락)

Classical shadow tomography

적은 측정 횟수로 여러 관측량을 동시 추정

Quantum Natural Gradient (QNG)

더 적은 step으로 수렴시켜 전체 실행 횟수 절감

DLA (Dynamical Lie Algebra) 기반 회로 설계

barren plateau를 피하며 필요한 파라미터/깊이 최소화

이미지 생성 분야에서 양자 알고리즘 유의점

양자 생성 모델은 **양자 데이터, 헤밀토니안 상태 등을 만드는 데** 특화되어 있기에, **기존 데이터가 많은 영역, 모델, 컴퓨팅이 잘하는 영역에 대한 성과는 검증 단계**

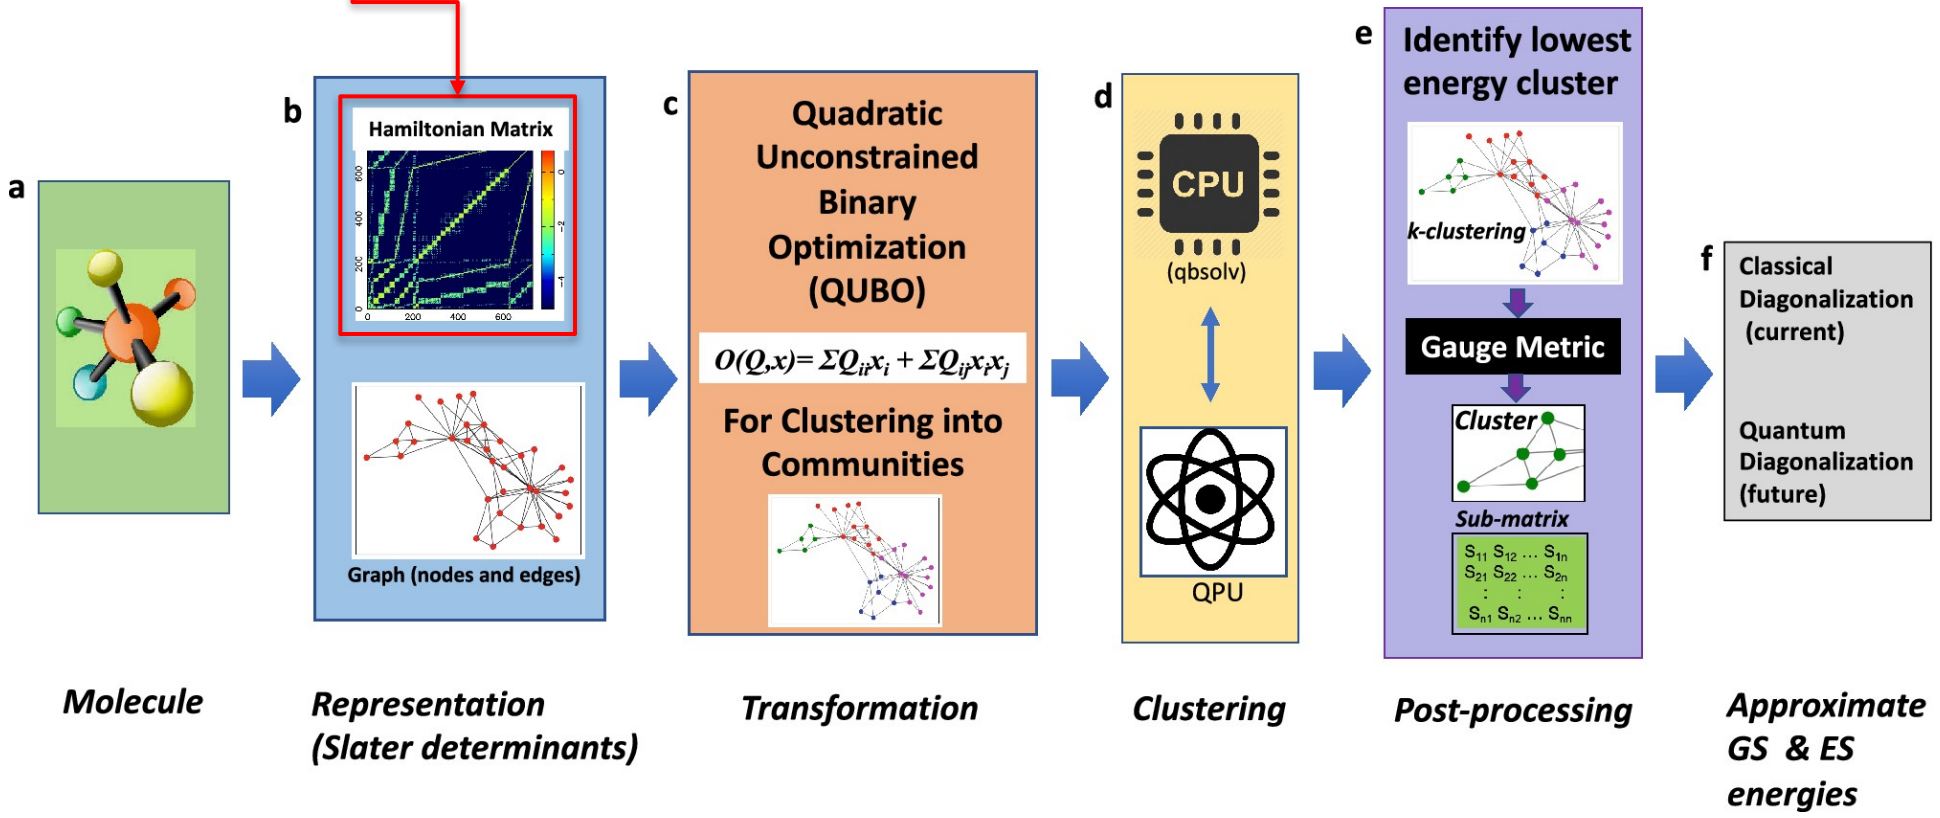


그림 출처: https://www.nature.com/articles/s41598-021-83561-x (CC BY 4.0)

감사합니다.