QML Lecture

양자 머신러닝
의료 이미지 데이터 증강

1

[약 2분]

오늘부터 3일간 진행할 양자 머신러닝 강의의 1일차입니다. 주제는 의료 이미지 데이터 증강이고, 1일차는 2·3일차 실습에 필요한 이론을 정리하는 시간입니다.

오늘 순서는 네 부분입니다. 먼저 HAM10000 데이터셋과 클래스 불균형 문제를 확인하고, 이어서 GAN과 양자회로의 기초를 정리합니다. 그다음 QGAN 논문과 MediQ-GAN 논문의 구조와 결과를 차례로 살펴보고, 마지막으로 두 논문을 같은 기준으로 비교합니다.

기초 부분이 끝나는 지점에서 한 차례 휴식을 두겠습니다. 전체 소요는 휴식을 제외하고 약 158분으로 예상합니다.



[약 2분]

3일간의 흐름을 먼저 보겠습니다. 오늘은 이론이고, 2일차에는 전처리와 QGAN 학습, 3일차에는 MediQ-GAN 학습을 Colab에서 직접 실행합니다.

이론과 실습의 대응 관계는 이 강의 마지막에 표로 다시 정리합니다. 오늘 나오는 구조도는 2·3일차 코드의 클래스와 함수에 거의 일대일로 대응하므로, 그림의 어느 부분이 코드의 어느 부분인지 염두에 두고 들으시면 됩니다.

오리엔테이션

학습목표

INDEX

1. HAM10000 데이터셋 EDA와 클래스 불균형 문제
2. GAN 학습 구조·평가 지표(FID, LPIPS)와 양자회로 기초(qubit, 게이트, 측정, PQC)
3. QGAN과 고전 GAN의 차이 - patch 방식 아키텍처
4. 아키텍처 '전체가 양자'(QGAN)와 '일부만 양자'(MediQ-GAN, dual-stream) 차이 구분
5. 두 논문의 결과를 같은 기준(비교 대상, 지표, 실행 환경)으로 해석

3

[약 2분]

오늘의 학습목표는 다섯 가지입니다.

첫째, HAM10000의 클래스 분포를 확인하고 불균형이 왜 문제인지 설명할 수 있어야 합니다. 둘째, GAN의 학습 구조와 평가 지표, 그리고 양자회로의 기본 요소를 이해합니다. 셋째, QGAN이 고전 GAN과 어디가 다른지, patch 방식이 무엇인지 설명합니다. 넷째, 생성자 전체가 양자회로인 QGAN과 일부만 양자인 MediQ-GAN의 구조적 차이를 구분합니다. 다섯째, 두 논문의 결과를 비교 대상, 지표, 실행 환경이라는 같은 기준으로 해석합니다.

마지막 항목은 논문의 수치를 그대로 받아들이지 않고 조건을 확인하며 읽는 연습이라는 점에서, 이후 실습 결과를 해석할 때도 그대로 적용됩니다.

01 · 데이터셋

HAM10000 데이터셋

"Human Against Machine with 10000 training images" - 피부병변 진단 AI 연구의 대표 벤치마크

10,015
총 이미지 수
피부경검사(dermatoscopic) 촬영

7
병변 클래스 수
akiec·bcc·bkl·df·mel·nv·vasc

600×450
원본 해상도
RGB, 실제 임상 촬영 이미지



akiec · 광선각화증 | bcc · 기저세포암 | bkl · 양성각화증 | **df · 피부섬유종**

mel · 흑색종 | **nv · 모반** | vasc · 혈관병변

병변 유형	코드	이미지 수	비율
광선각화증 (Actinic keratoses)	akiec	327	3.3%
기저세포암 (Basal cell carcinoma)	bcc	514	5.1%
양성각화증 (Benign keratosis-like lesions)	bkl	1,099	11.0%
피부섬유종 (Dermatofibroma)	**df**	**115**	**1.1%**
흑색종 (Melanoma)	mel	1,113	11.1%
모반 (Melanocytic nevi)	**nv**	**6,705**	**66.9%**
혈관병변 (Vascular lesions)	vasc	142	1.4%

4

이미지·데이터 출처: HAM10000 (Tschandl et al., Scientific Data 5, 180161, 2018)

[약 4분]

사용하는 데이터는 HAM10000입니다. 'Human Against Machine with 10000 training images'의 약자이고, 피부경 검사로 촬영한 이미지 10,015장으로 구성됩니다. 병변 클래스는 7개이고 원본 해상도는 600×450 RGB입니다. 출처는 Tschandl 등이 2018년 Scientific Data에 발표한 논문입니다.

오른쪽 표의 클래스별 수를 보면 편차가 매우 큽니다. 모반(nv)이 6,705장으로 66.9%를 차지하고, 피부섬유종(df)은 115장으로 1.1%입니다. 두 클래스의 비율은 약 1 대 58입니다.

이 강의에서 증강 대상은 df, 비교 기준은 nv입니다. 두 클래스를 강조 표시한 이유입니다.

01 · 데이터셋

EDA 분석 결과 : 데이터 불균형

클래스 불균형 데이터 처리 방법

클래스	이미지 수
광선각화증 (akiec)	327
기저세포암 (bcc)	514
양성각화증 (bkl)	1,099
피부섬유종 (df)	**115**
흑색종 (mel)	1,113
모반 (nv)	**6,705**
혈관병변 (vasc)	142

방법	설명	한계
Under sampling	소수 클래스에 맞춰, 다수 클래스를 줄임	정보 손실 - NV 6,500장 넘게 버려야 함
Over sampling	소수 클래스를 복제해서 늘림	복제본이라 새로운 정보가 없음 - 과적합 위험
Augmentation 기하학적 증강	회전·반전·크롭 등으로 변형	병변의 실제 형태·질감 다양성은 만들지 못함
생성모델(GAN/QGAN)	학습된 분포에서 '새로운' 그럴듯한 샘플 생성	품질 검증 필요

초점

- QGAN이 '고전 GAN보다 좋다'가 결론은 아님
- QGAN의 실제 동작 방식과 조건을 논문 데이터로 확인

5

표 출처: HAM10000 메타데이터 (Tschandl et al., Scientific Data 5, 180161, 2018)

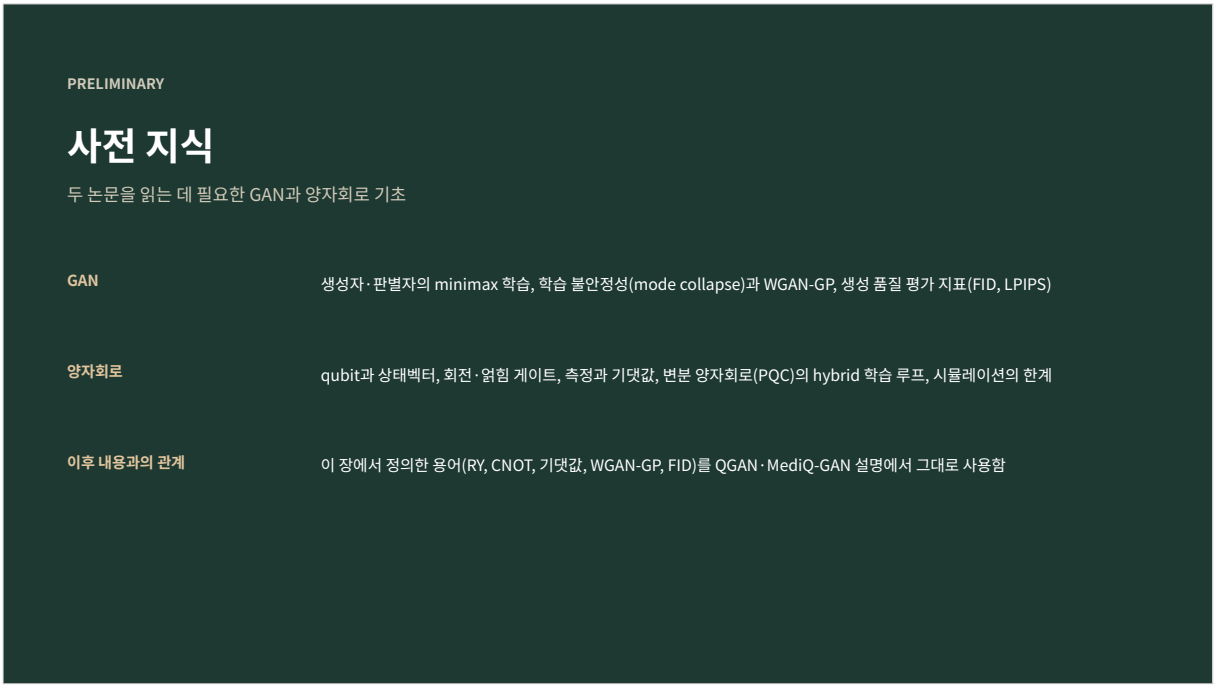
[약 4분]

불균형 데이터를 다루는 방법은 크게 네 가지입니다.

Under sampling은 다수 클래스를 줄이는 방법으로, nv를 df 수준으로 맞추려면 6,500장 넘게 버려야 해서 정보 손실이 큽니다. Over sampling은 소수 클래스를 복제하는 방법인데, 복제본에는 새로운 정보가 없어 과적합 위험이 있습니다. 기하학적 증강은 회전, 반전, 크롭으로 변형하지만 병변의 실제 형태와 질감의 다양성을 만들지는 못합니다.

생성모델은 학습한 분포에서 새로운 샘플을 만든다는 점에서 위 세 방법과 다릅니다. 다만 생성된 이미지가 실제로 유용한지는 별도로 검증해야 합니다.

아래 초점 상자에 적은 것처럼 이 강의의 질문은 'QGAN이 고전 GAN보다 좋은가'가 아닙니다. QGAN이 실제로 어떻게 동작하고 어떤 조건에서 성립하는지를 논문 데이터로 확인하는 것이 목적입니다.



[약 1분]

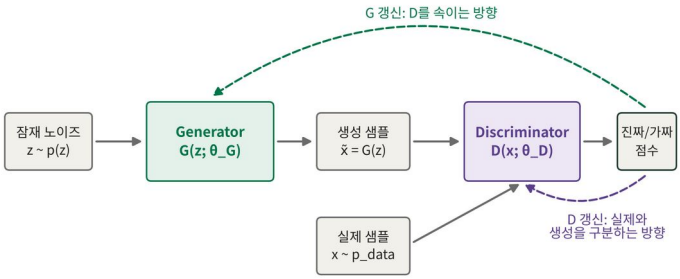
두 논문을 읽기 위한 최소한의 사전 지식을 먼저 정리하겠습니다. GAN 쪽에서는 학습 구조, 학습 불안정성과 WGAN-GP, 생성 품질을 평가하는 지표를 다루고, 양자회로 쪽에서는 qubit과 상태벡터, 게이트, 측정, 변분 양자회로의 학습 루프를 다룹니다.

여기서 정의한 용어는 이후 두 논문 설명에서 별도 설명 없이 사용합니다.

사전 지식 · GAN

GAN의 구조와 학습 목표

생성자와 판별자가 하나의 목적함수를 반대 방향으로 최적화하는 minimax 구조



- **Generator**: 노이즈 z를 샘플로 변환. D가 생성 샘플을 진짜로 판단하도록 갱신
- **Discriminator**: 실제와 생성 샘플을 구분. 판별 정확도를 최대화하도록 갱신
- **학습 순서**: D 갱신과 G 갱신을 번갈아 반복
- QGAN · MediQ-GAN은 이 구조에서 G만 양자회로를 포함함

$$\min_G \max_D \; V(D, G) = \mathbb{E}[\log D(x)] + \mathbb{E}[\log(1 - D(G(z)))]$$

x ~ p_data(실제), z ~ p_z(노이즈). G의 손실은 학습 초반 gradient 소실을 피하려고 −log D(G(z))로 바꿔 쓰는 경우가 많음

7

[약 4분]

GAN은 생성자와 판별자 두 모델로 구성됩니다. 생성자는 잠재 노이즈 z를 입력받아 샘플을 만들고, 판별자는 실제 샘플과 생성 샘플을 구분해 점수를 출력합니다.

학습은 아래 목적함수에 대한 minimax 게임입니다. 판별자는 V를 최대화하는 방향, 즉 실제는 1에 가깝게 생성은 0에 가깝게 분류하도록 갱신되고, 생성자는 V를 최소화하는 방향, 즉 판별자가 생성 샘플을 진짜로 판단하도록 갱신됩니다. 실제 구현에서는 두 모델을 번갈아 갱신합니다.

생성자의 손실은 log(1 − D(G(z)))를 그대로 쓰기보다 −log D(G(z))로 바꿔 쓰는 경우가 많습니다. 학습 초반에 판별자가 압도하면 앞의 형태는 gradient가 거의 0이 되기 때문입니다. 이 점은 다음 슬라이드의 학습 불안정성과 이어집니다.

QGAN과 MediQ-GAN 모두 이 구조에서 생성자만 양자회로를 포함하도록 바꾼 모델입니다. 그림의 Generator 상자 안이 이 강의 전체의 관심 대상입니다.

사전 지식 · GAN

학습 불안정성과 WGAN-GP

원 GAN의 손실은 학습이 불안정하고, 두 논문은 서로 다른 학습 목표를 사용함

문제	현상	원인
Vanishing gradient	D가 너무 잘 구분하면 G의 gradient가 0에 수렴	두 분포의 support가 겹치지 않으면 JS divergence가 상수
Mode collapse	G가 일부 유형의 샘플만 반복 생성	D가 다양성을 직접 평가하지 않음
진동	손실이 수렴하지 않고 진동	두 모델을 동시에 최적화하는 min-max 구조

항목	원 GAN (BCE)	WGAN-GP
D의 출력	확률 (시그모이드)	실수 점수 (critic)
손실	BCE: log D(x) + log(1 − D(G(z)))	E[D(x)] − E[D(G(z))] + λ·GP
거리	Jensen-Shannon	Wasserstein-1
안정화	없음	critic gradient 노름을 1로 유도 (1-Lipschitz)
사용 논문	**QGAN (Table 4)**	**MediQ-GAN (식 (1)·(2))**

실습과의 연결

3일차: MediQ-GAN을 생성자 학습률 0.02로 학습하면 3 epoch 만에 mode collapse가 발생함. 원 논문이 WGAN-GP critic을 쓰는 이유에 해당함.

8

[약 4분]

원 GAN의 학습은 불안정한 것으로 알려져 있습니다. 대표적인 문제는 세 가지입니다.

첫째, vanishing gradient입니다. 판별자가 너무 잘 구분하면 생성자에게 전달되는 gradient가 사라집니다. 이론적으로는 실제 분포와 생성 분포의 support가 겹치지 않을 때 Jensen-Shannon divergence가 상수가 되기 때문입니다. 둘째, mode collapse입니다. 생성자가 판별자를 속이기 쉬운 몇 가지 유형만 반복해서 만듭니다. 판별자가 다양성을 직접 평가하지 않으므로 생긴 현상입니다. 셋째, 두 모델을 동시에 최적화하는 구조 때문에 손실이 수렴하지 않고 진동하는 문제입니다.

WGAN은 거리 척도를 Wasserstein-1 거리로 바꿔 이 문제를 줄입니다. 판별자는 확률 대신 실수 점수를 내는 critic이 되고, 손실은 실제와 생성에 대한 critic 출력의 차이입니다. 이때 critic이 1-Lipschitz여야 하며, WGAN-GP는 critic gradient의 노름이 1에서 벗어나는 만큼 벌점을 부여해 이 조건을 맞춥니다.

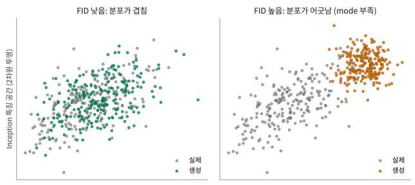
두 논문의 선택은 다릅니다. QGAN 논문은 Table 4에서 Binary Cross Entropy를 사용하고, MediQ-GAN 논문은 WGAN-GP를 기본 학습 목표로 삼습니다. 3일차 실습에서 생성자 학습률을 크게 잡으면 3 epoch 만에 mode collapse가 발생하는데, 이 현상이 MediQ-GAN 논문이 WGAN-GP critic을 쓰는 이유와 연결됩니다.

사전 지식 · GAN

생성 품질 평가: 지표별 측정 대상

생성 이미지의 품질은 눈으로 판단하기 어려워 정량 지표를 병행함

지표	측정 대상	방향
Downstream 분류 성능 (AUC-ROC, 정확도)	생성 이미지를 학습 데이터에 추가했을 때 분류기 성능 변화 QGAN 논문, MediQ-GAN Table 1	높을수록 좋음
FID	실제와 생성 이미지의 Inception 특징 분포(평균·공분산) 사이 Fréchet 거리 MediQ-GAN 논문 (클래스별)	낮을수록 좋음
intra-class LPIPS	같은 클래스 생성 이미지 쌍의 지각적 거리 평균. mode collapse 점검 MediQ-GAN 논문	높을수록 다양
지표 4종 (실습)	픽셀 분포, 클래스 평균 상관, 최근접 실제 거리, 샘플 다양성 2·3일차 노트북 (16×16에서는 FID 사용 불가)	지표별 상이



해석 시 유의

- FID가 낮아도 LPIPS가 낮으면 비슷한 이미지만 생성한 것이므로 두 지표를 함께 봄
- 표본이 적은 클래스(df 115장)에서는 FID 공분산 추정이 불안정함
- 분류 성능은 분류기와 증강 비율에 의존함

9

[약 4분]

생성 이미지의 품질은 눈으로 보는 것만으로 판단하기 어렵기 때문에 정량 지표를 함께 사용합니다. 이 강의에서 만나는 지표는 네 가지입니다.

첫째, downstream 분류 성능입니다. 생성 이미지를 학습 데이터에 추가했을 때 분류기의 AUC와 정확도가 어떻게 변하는지 봅니다. 목적에 가장 직접적이지만 분류기와 증강 비율에 따라 결과가 달라집니다. QGAN 논문이 이 방식을 쓰고, MediQ-GAN 논문도 Table 1에서 사용합니다.

둘째, FID입니다. 실제 이미지와 생성 이미지를 Inception 네트워크의 특징 공간으로 보낸 뒤 각각을 가우시안으로 근사하고, 두 분포 사이의 Fréchet 거리를 계산합니다. 낮을수록 좋습니다. 오른쪽 그림처럼 분포가 겹치면 낮고, 어긋나거나 일부 영역만 덮으면 높아집니다.

셋째, intra-class LPIPS입니다. 같은 클래스에서 생성한 이미지 쌍의 지각적 거리 평균으로, 높을수록 다양하다는 뜻이며 mode collapse 점검에 쓰입니다. FID가 낮아도 LPIPS가 낮으면 비슷한 이미지만 만든다는 의미이므로 두 지표를 함께 봅니다.

넷째, 실습에서 쓰는 지표 4종입니다. 실습은 16×16 해상도라 FID를 계산할 수 없어 별도 지표를 정의했습니다. 한 가지 유의할 점은 표본이 적은 클래스에서는 FID의 공분산 추정이 불안정하다는 것이고, df가 115장이라는 점을 고려하면 이 한계는 실제로 적용됩니다.

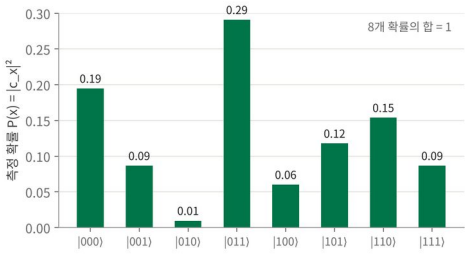
사전 지식 · 양자회로

qubit과 상태벡터

n큐빗 상태는 2ⁿ개의 복소 진폭이며, 측정 확률은 진폭 크기의 제곱

$$|\psi\rangle = \alpha|0\rangle + \beta|1\rangle, \quad |\alpha|^2 + |\beta|^2 = 1$$
$$\text{n큐빗: } |\psi\rangle = \Sigma\, c_x |x\rangle, \quad P(x) = |c_x|^2$$

구분	고전	양자
상태	n bit = 문자열 하나	n큐빗 = 2ⁿ 진폭 벡터
갱신	논리 연산	유니터리 행렬 곱 (노름 보존)
읽기	값을 그대로 읽음	측정 시 확률 P(x)로 bitstring 하나 결정



이후 논문과의 연결

- QGAN: 데이터 7큐빗 → 확률 128개 = patch 픽셀 128개
- MediQ-GAN: 16큐빗 → 상태벡터 65,536차원

10

[약 4분]

양자회로 기초를 다섯 장에 걸쳐 정리합니다. 첫 장은 상태 표현입니다.

1큐빗 상태는 |0⟩과 |1⟩의 선형결합 α|0⟩ + β|1⟩이고, 진폭의 제곱합은 1입니다. n큐빗이 되면 2의 n 제곱 개의 복소 진폭을 가진 벡터가 되며, 이것이 상태벡터입니다. 측정하면 basis state x가 $|c_x|^2$의 확률로 하나 나옵니다.

오른쪽 그림은 3큐빗 예시로, 진폭 8개가 측정 확률 8개로 바뀌고 합이 1이 됩니다. 고전 비트와의 차이는 표에 정리했습니다. 상태는 문자열 하나가 아니라 진폭 벡터이고, 게이트는 노름을 보존하는 유니터리 행렬 곱이며, 읽을 때는 확률에 따라 bitstring 하나가 확률적으로 결정됩니다.

이후 논문과 연결되는 숫자는 두 가지입니다. QGAN은 데이터 큐빗이 7개이므로 확률이 128개 나오고, 이 128개가 patch의 픽셀 값이 됩니다. MediQ-GAN의 양자 stream은 16큐빗이므로 상태벡터 차원이 65,536입니다.

사전 지식 · 양자회로

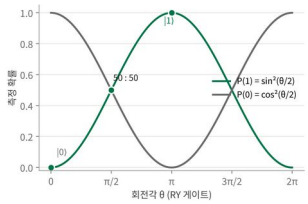
게이트: 회전과 얽힘

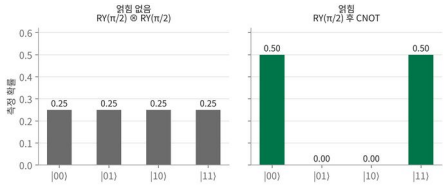
두 논문의 회로는 회전 게이트와 얽힘 게이트 두 종류로만 구성됨

게이트	작용	학습 대상
RY(θ)	$\|0\rangle \to \cos(\theta/2)\|0\rangle + \sin(\theta/2)\|1\rangle$ $P(1) = \sin^2(\theta/2)$	θ (학습)
RX(θ)	X축 회전. MediQ-GAN의 encoding에 사용	입력값 (고정)
CNOT	제어 큐빗이 1이면 목표 큐빗 반전	파라미터 없음
CZ	두 큐빗이 모두 1이면 위상에 −1	파라미터 없음

두 논문의 회로 구성

- QGAN: RY(z) encoding → [RY(θ) + CZ 체인] × depth 10
- MediQ-GAN: RX, RY encoding → [RY(θ) + CNOT 체인] × 8





11

[약 4분]

게이트를 보겠습니다. 두 논문의 회로는 회전 게이트와 얽힘 게이트 두 종류로만 구성됩니다.

RY(θ)는 Y축 회전이고, |0⟩에 적용하면 cos(θ/2)|0⟩ + sin(θ/2)|1⟩이 됩니다. 따라서 측정 시 1이 나올 확률은 $\sin^2(\theta/2)$입니다. 오른쪽 위 그래프가 이 관계이고, θ가 0이면 항상 0, π이면 항상 1, π/2이면 50 대 50입니다. 각도를 바꾸어 확률을 조절하는 것이 이 회로의 기본 동작이며, 학습 대상인 θ가 곧 이 각도입니다.

RX는 X축 회전으로 MediQ-GAN의 encoding에서 사용합니다. CNOT은 제어 큐빗이 1일 때 목표 큐빗을 뒤집고, CZ는 두 큐빗이 모두 1일 때 위상에 −1을 곱합니다. 둘 다 학습 파라미터가 없고 큐빗 사이의 얽힘만 담당합니다.

오른쪽 아래 그림이 얽힘의 효과입니다. 두 큐빗에 각각 RY(π/2)만 적용하면 네 결과가 각각 0.25로 독립입니다. 첫 큐빗에 RY(π/2)를 적용하고 CNOT을 걸면 00과 11만 0.5씩 나오는 Bell 상태가 되어 두 큐빗의 결과가 상관을 가집니다. 이 상관이 픽셀 사이의 관계를 표현하는 수단이 됩니다.

정리하면 QGAN은 RY encoding 뒤에 RY와 CZ 체인을 반복하고, MediQ-GAN은 RX, RY encoding 뒤에 RY와 CNOT 체인을 반복합니다.

사전 지식 · 양자회로

측정과 기댓값

측정 한 번은 bitstring 하나이고, 모델이 쓰는 값은 반복 측정의 통계량

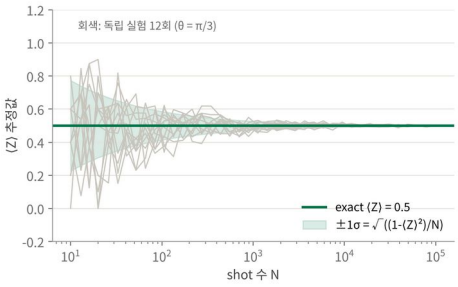
출력 방식	정의와 출력 크기	사용 논문
확률 분포 P(x)	2^n개 basis state의 측정 확률 출력 크기 2^n (지수)	QGAN
기댓값 ⟨X_i⟩	큐빗별 관측량의 평균, −1 ~ 1 출력 크기 n (선형)	MediQ-GAN

$$\langle Z \rangle = P(0) - P(1) \in [-1, 1]$$
$$\text{shot N회 추정의 표준오차} = \sqrt{((1 - \langle Z \rangle^2) / N)} \leq 1/\sqrt{N}$$

출력 구조의 차이

QGAN: 8큐빗 중 ancilla qubit = 0인 128개 확률을 patch 픽셀로 사용

MediQ-GAN: 16큐빗 → 기댓값 16개를 특징으로 사용, 이미지는 고전 decoder가 생성



정밀도를 10배 높이려면 shot이 100배 필요함. 이 비용이 뒤의 VQC 학습 비용 계산에 들어감

시뮬레이터에서 shots를 지정하지 않으면 이 오차 없이 exact 기댓값을 계산함

12

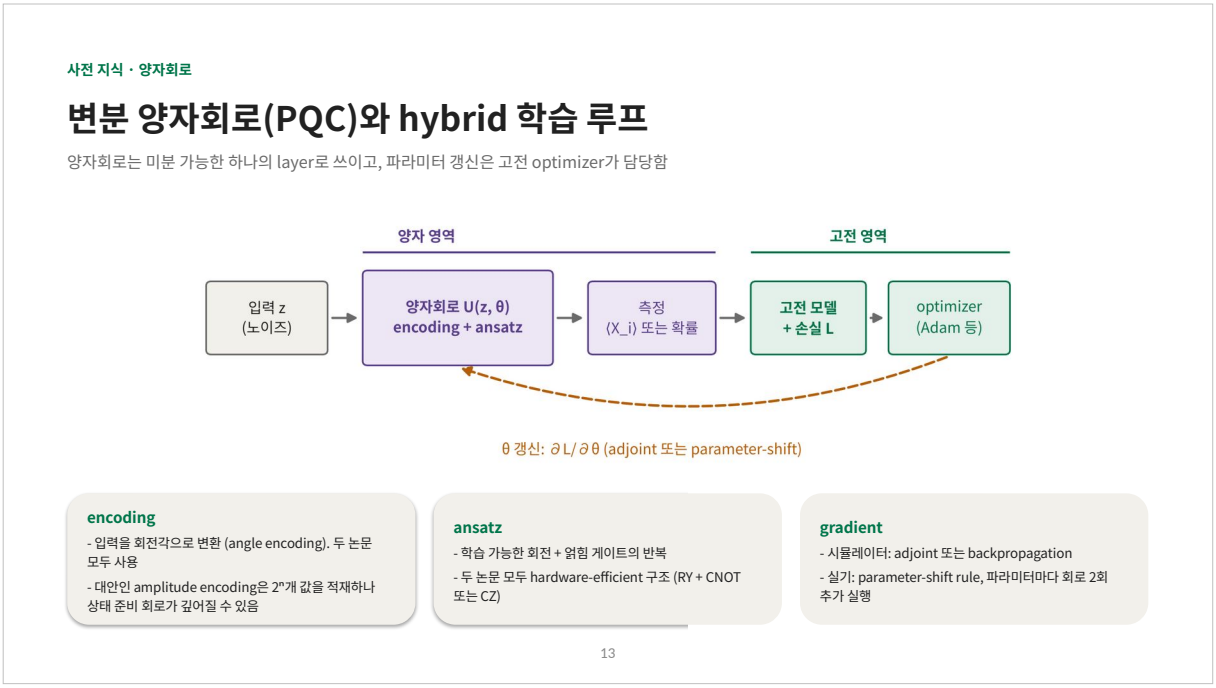
[약 4분]

측정과 기댓값입니다. 회로를 한 번 실행하고 측정하면 bitstring 하나가 나올 뿐이고, 모델이 쓰는 값은 반복 측정으로 얻은 통계량입니다. 이 통계량을 어떻게 정의하느냐가 두 논문의 출력 구조를 가릅니다.

QGAN은 2의 n제곱 개 basis state의 확률 분포 전체를 출력으로 씁니다. 8큐빗 중 ancilla qubit이 0인 128개를 patch의 픽셀 값으로 사용합니다. MediQ-GAN은 큐빗별 기댓값 ⟨X_i⟩를 씁니다. 16큐빗이면 출력이 16개이고, 값의 범위는 −1에서 1 사이입니다.

같은 큐빗 수에서 출력 차원이 전자는 지수적, 후자는 선형적으로 늘어난다는 점이 중요합니다. 이미지를 직접 쓰는 QGAN은 큐빗 수가 조금만 늘어도 patch 크기가 급격히 커지므로 여러 sub-generator로 나누고, MediQ-GAN은 양자 출력을 특징으로만 쓰고 이미지는 고전 decoder가 만듭니다.

shot 수와 정확도의 관계는 오른쪽 그래프입니다. 기댓값은 shot N회로 추정하고 표준오차가 $1/\sqrt{N}$ 이하로 줄어듭니다. 정밀도를 한 자리 올리려면 shot이 100배 필요하다는 뜻이고, 이 비용이 뒤에서 다룰 학습 비용 계산에 그대로 들어갑니다. 시뮬레이터에서 shot을 지정하지 않으면 이 오차 없이 정확한 기댓값을 계산합니다.



[약 4분]

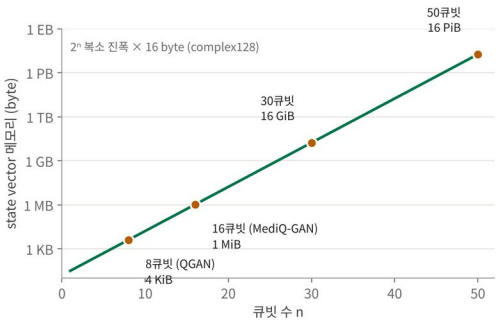
변분 양자회로, 즉 PQC의 학습 구조입니다. 그림의 흐름은 입력 z를 회로에 encoding하고, 학습 가능한 회전을 거쳐 측정하고, 측정값을 고전 모델에 넣어 손실을 계산하는 것입니다. 이후 optimizer가 손실의 gradient로 회로 파라미터 θ를 갱신합니다. 양자 영역은 앞의 두 상자이고 나머지는 모두 고전 영역입니다. 이 구조를 hybrid 학습 루프라고 부릅니다.

구성 요소는 세 가지입니다. encoding은 입력을 회전각으로 바꾸는 단계로, 두 논문 모두 angle encoding을 씁니다. 대안인 amplitude encoding은 n큐빗에 2의 n제곱 개 값을 담을 수 있지만 상태를 준비하는 회로가 깊어질 수 있습니다. ansatz는 학습 가능한 회전과 얽힘 게이트를 반복하는 부분이며, 두 논문 모두 hardware-efficient 구조입니다. gradient는 시뮬레이터에서는 adjoint나 backpropagation으로 효율적으로 구하고, 실제 하드웨어에서는 parameter-shift rule로 파라미터마다 회로를 두 번 더 실행합니다. 이 차이는 뒤에서 비용 계산으로 다시 다룹니다.

사전 지식 · 양자회로

시뮬레이션의 한계와 학습 가능성

state vector 시뮬레이션은 큐빗 수에 지수적이고, 회로가 넓고 깊을수록 학습이 어려워짐



항목	내용
시뮬레이션 규모	16큐빗은 1 MiB로 노트북에서 처리 가능. 30큐빗부터 16 GiB로 일반 PC 한계
해석	정확히 시뮬레이션되는 규모의 회로는 양자 우위의 근거가 아님. MediQ-GAN 논문도 quantum-inspired로 규정하고 양자 소자를 계산 가속 용도로 한정
NISQ 실기	게이트 오류와 decoherence로 얕은 회로만 신뢰 가능
Barren plateau	큐빗 수·깊이가 커질수록 gradient 분산이 지수적으로 감소하는 현상
표현력 대 학습 가능성	표현력이 큰 회로일수록 barren plateau 위험이 큼. MediQ-GAN은 DLA 분석으로 depth 8을 선택

14

[약 4분]

마지막으로 시뮬레이션의 한계와 학습 가능성입니다.

state vector 시뮬레이션은 큐빗 수에 지수적으로 메모리를 씁니다. complex128 기준으로 8큐빗은 4KiB, 16큐빗은 1MiB여서 노트북에서 문제없이 돌아가지만, 30큐빗은 16GiB, 50큐빗은 16PiB입니다. 이 강의의 두 모델은 모두 16큐빗 이하이므로 시뮬레이션이 가능합니다.

여기서 해석상 중요한 점이 있습니다. 고전 컴퓨터에서 정확히 시뮬레이션할 수 있는 규모의 회로는 양자 우위의 근거가 될 수 없습니다. MediQ-GAN 논문도 스스로를 quantum-inspired, hardware-agnostic이라고 규정하고, 양자 소자는 계산 가속 역할에 한정된다고 밝힙니다.

실제 NISQ 소자는 게이트 오류와 decoherence 때문에 얕은 회로만 신뢰할 수 있습니다. 또 회로가 넓고 깊을수록 barren plateau, 즉 gradient 분산이 지수적으로 줄어드는 현상이 나타나 학습이 어려워집니다. 표현력이 큰 회로일수록 이 위험이 커지므로 표현력과 학습 가능성은 절충 관계입니다. MediQ-GAN 논문은 dynamical Lie algebra 분석으로 depth 8이 충분한 표현력을 가지면서 barren plateau를 피한다고 밝힙니다.

이 장은 여기까지입니다. 10분간 휴식하겠습니다.

BREAK

휴식

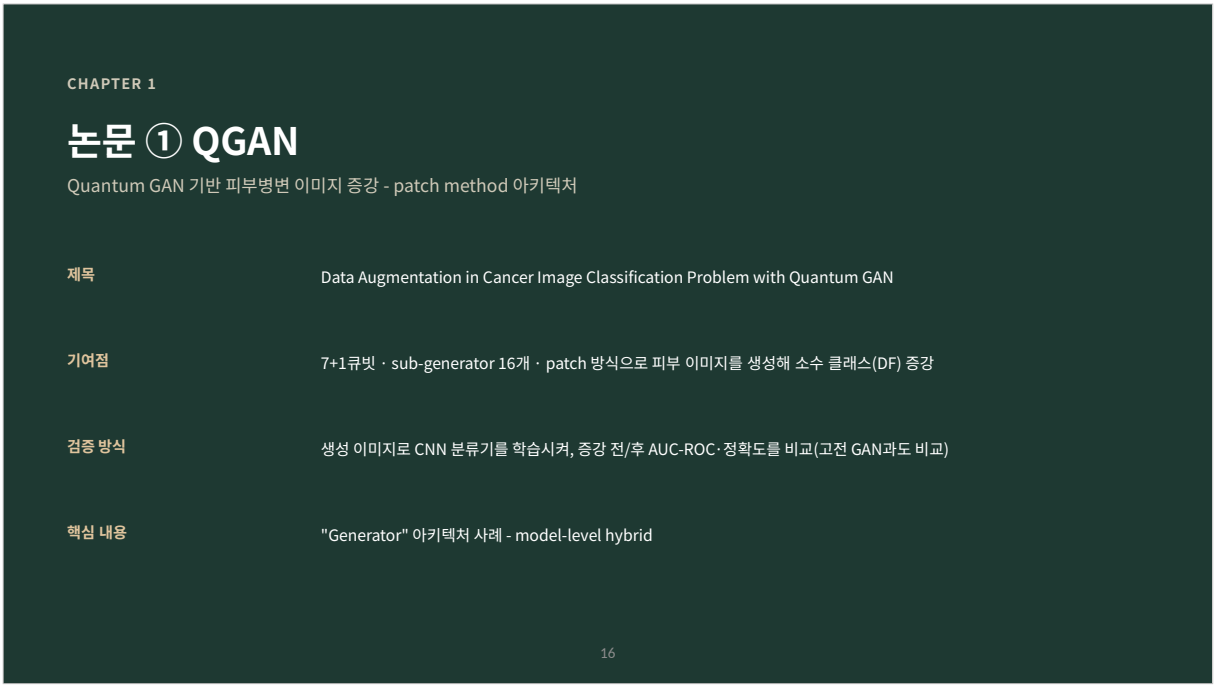
10분 후 재개

여기까지	HAM10000 클래스 불균형 → GAN 구조·학습 불안정성·평가 지표 → qubit, 게이트, 측정, PQC 학습 루프
이어서	Chapter 1 QGAN (patch 방식, 학습 step, 결과) → Chapter 2 MediQ-GAN (dual-stream, WGAN-GP, 결과) → Chapter 3 정리

15

휴식 시간입니다. 10분 후에 재개합니다.

재개 후에는 Chapter 1 QGAN의 patch 방식 구조부터 시작합니다. 휴식 중에 앞 내용에서 질문이 있으면 말씀해 주십시오.



[약 1분]

첫 번째 논문은 Andra 등이 Quantum Machine Intelligence 7권에 발표한 'Data Augmentation in Cancer Image Classification Problem with Quantum GAN'입니다.

기여는 7+1큐빗 회로 16개를 sub-generator로 두는 patch 방식으로 피부 이미지를 생성해 소수 클래스 df를 증강한 것입니다. 검증은 생성 이미지로 CNN 분류기를 학습시켜 증강 전후의 AUC-ROC와 정확도를 비교하고, 고전 GAN과도 비교하는 방식입니다. 이 강의에서는 생성자 전체가 양자회로인 model-level hybrid의 사례로 사용합니다.



[약 3분]

QGAN의 기본 개념입니다. 생성자와 판별자가 경쟁하며 학습하는 구조는 앞에서 본 GAN과 같고, 달라지는 것은 생성자의 구현입니다.

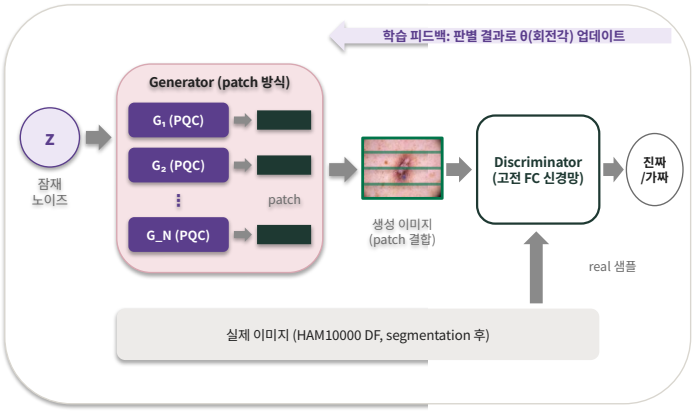
고전 GAN의 생성자는 CNN이나 MLP이고 학습 파라미터는 가중치 행렬입니다. QGAN의 생성자는 변분 양자회로이고, 무작위 각도 노이즈를 회전 게이트로 encoding한 뒤 측정하며, 학습 파라미터는 회전 게이트의 각도입니다. 판별자는 두 경우 모두 고전 신경망이므로 구조가 비대칭입니다.

정리하면 판별자는 그대로 두고 생성자만 양자회로로 교체한 모델입니다.

01 · QGAN 논문

QGAN 아키텍처 다이어그램 - patch 기반 Generator

Generator-Discriminator 구조를 도식으로 재구성



18

원 논문 Fig. 10 구조를 도식으로 재구성: Andra et al., Quantum Machine Intelligence 7, 90 (2025)

[약 3분]

논문 Fig. 10을 도식으로 재구성한 구조도입니다. 잠재 노이즈 z가 N개의 sub-generator에 들어가고, 각각의 PQC가 patch 하나를 출력합니다. patch를 이어 붙인 것이 생성 이미지이고, 판별자는 이 이미지와 실제 이미지를 입력받아 진짜 또는 가짜를 판별합니다.

위쪽 화살표가 학습 피드백입니다. 판별 결과로 계산한 손실이 회전각 θ까지 전달되어 갱신됩니다. 실제 이미지는 HAM10000의 df를 segmentation한 뒤의 이미지입니다. 이 전처리가 결과에서 중요한 역할을 하는데, 뒤의 결과 슬라이드에서 확인합니다.

01 · QGAN 논문

Patch 방식 아키텍처

큐빗 한 세트로 이미지 전체를 만들기 어려워, 여러 개의 '작은 회로'가 조각(patch)을 나눠 생성

sub-generator 1
PQC → patch

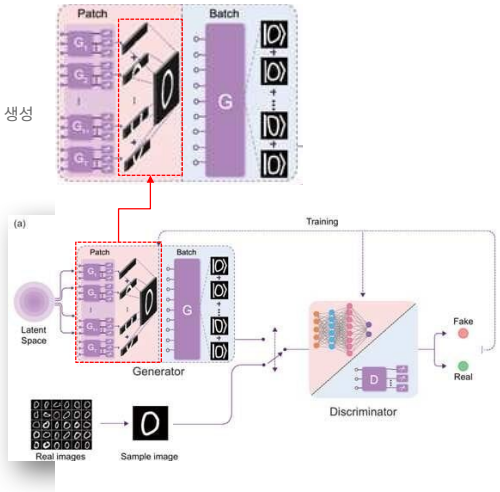
sub-generator 2
PQC → patch

sub-generator 3
PQC → patch

sub-generator N
PQC → patch

(논문: 16개 sub-generator)

patch 1 + patch 2 + patch 3 + ⋯ + patch N
→ 이어 붙여 최종 이미지 벡터



19

[약 3분]

patch 방식이 필요한 이유는 큐빗 수의 제약입니다. 큐빗 한 세트로 이미지 전체를 만들기 어려우므로 작은 회로 여러 개가 조각을 나누어 생성합니다. 논문은 sub-generator 16개를 사용하고, 각 patch를 이어 붙여 최종 이미지 벡터를 만듭니다.

오른쪽 그림은 논문의 원 도식으로, 빨간 점선 영역이 patch 부분입니다. 논문은 patch 외에 batch 방식도 제안하는데, 이 데이터에는 patch 방식을 적용했습니다. 이 구조는 기존 연구(Huang 등)의 patch GAN을 가져온 것이라는 점도 알아 두시면 좋습니다.

01 · QGAN 논문

sub-generator 회로 상세

각 sub-generator = 3단계로 이루어진 하나의 변분 양자회로(PQC)

① 노이즈 encoding

무작위 각도를 RY 게이트로 각 큐빗에 회전시켜 입력

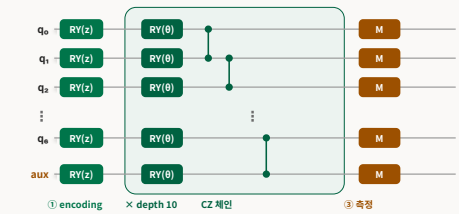
② 변분 layer (반복)

학습 가능한 RY 회전 + 인접 큐빗 CZ 얽힘 - 각도가 '학습되는 가중치'

③ 측정

ancilla qubit까지 전체 측정 후, ancilla qubit=0인 항목만 patch로 사용(post-selection)

sub-generator 1개 회로 (논문 Table 3 기준, 8큐빗)



측정 결과 $2^8 = 256$개 확률 중 ancilla qubit = 0 인 128개만 선택(post-selection) → patch 1장

sub-generator 16개의 patch를 이어붙여 이미지 1장을 구성

항목	값
큐빗 수	데이터 7 + ancilla 1 = 총 8
sub-generator 수	16개
회로 깊이(PQC depth)	10
학습률 / epoch	0.1 / 2,000

20

[약 5분]

sub-generator 하나의 회로를 단계별로 보겠습니다. 논문 Table 3 기준으로 8큐빗입니다.

첫째, 노이즈 encoding입니다. 무작위 각도를 RY 게이트로 각 큐빗에 넣습니다. 둘째, 변분 layer를 depth 10만큼 반복합니다. 각 layer는 학습 가능한 RY 회전과 인접 큐빗 사이의 CZ 얽힘으로 구성되고, 각도가 학습되는 가중치입니다. 셋째, 측정입니다. ancilla qubit까지 전체를 측정해 2의 8제곱, 즉 256개의 확률을 얻고, 그중 ancilla qubit이 0인 128개만 patch로 사용합니다. 이것이 post-selection입니다.

아래 표에 규격을 정리했습니다. 데이터 큐빗 7개와 ancilla 1개, sub-generator 16개, depth 10, 학습률 0.1, 2,000 epoch입니다.

ancilla qubit을 쓰는 이유는 다음과 같습니다. 데이터 큐빗만 측정하면 확률의 합이 항상 1이어서 배경이 대부분인 patch처럼 밝기 총합이 작은 경우를 표현할 수 없습니다. ancilla가 0인 항목만 쓰면 합이 0과 1 사이에서 자유로워집니다. 일반적인 ancilla의 용도인 오류 정정 등과는 목적이 다르다는 점에 유의하십시오.

01 · QGAN 논문

QGAN 한 step의 학습 과정

판별자와 생성자를 번갈아 갱신하며, 생성자의 gradient는 회로 파라미터 θ까지 전달됨

단계	동작	손실
1 생성	z → sub-generator 16개 → patch 결합 → 생성 이미지 $\tilde{x}$	-
2 D 갱신	실제 x는 1, 생성 $\tilde{x}$는 0으로 분류하도록 D의 가중치 갱신	$L_D = -[\log D(x) + \log(1 - D(\tilde{x}))]$ (BCE)
3 G 갱신	D가 $\tilde{x}$를 1로 판단하도록 회로 각도 θ 갱신	$L_G = -\log D(\tilde{x})$ (non-saturating)
4 반복	2,000 epoch (논문 Table 3·4)	-

설정에서 확인할 점

- 학습률: 생성자 0.1, 판별자 5×10^{-3} (Table 3·4). 생성자가 20배 큼
- 논문은 손실을 Binary Cross Entropy로 표기함. G 손실 형태는 일반적인 non-saturating 형태로 적은 것임
- 실습(2일차)은 sub-generator 4개, 600 step으로 줄인 설정을 사용함

21

[약 4분]

QGAN의 학습 한 step을 정리하겠습니다. 먼저 노이즈 z로 sub-generator 16개를 실행해 patch를 만들고 이어 붙여 생성 이미지를 얻습니다. 다음으로 판별자를 갱신합니다. 실제 이미지는 1, 생성 이미지는 0으로 분류하도록 Binary Cross Entropy를 최소화합니다. 이어서 생성자를 갱신합니다. 판별자가 생성 이미지를 1로 판단하도록 손실을 만들고, 이 손실의 gradient를 회로 각도 θ까지 전달합니다. 생성자 손실은 일반적인 non-saturating 형태로 적었고, 논문은 손실 함수를 Binary Cross Entropy로 표기합니다. 이 과정을 2,000 epoch 반복합니다.

설정에서 눈에 띄는 점은 학습률입니다. 생성자 0.1, 판별자 5×10^{-3}으로 생성자가 20배 큽니다. 두 모델의 갱신 속도가 크게 다르다는 뜻이므로, 실습에서 판별자가 이기는 현상이 나타나면 이 비율부터 확인해야 합니다. 2일차 실습에서 sub-generator 수와 학습량을 줄인 설정을 쓰는데, 그 차이는 마지막 정리 슬라이드에 표로 모아 두었습니다.

01 · QGAN 논문

Discriminator 구조 + 평가 프로토콜

"QGAN이 잘 만들었는지"는 생성 이미지 직접 확인 대신 별도 CNN 분류기 성능으로 검증

Discriminator (Table 4)

Table 4 · Discriminator	값
Layer 수	5 (완전연결)
활성화 함수	ReLU
출력층 활성화	Sigmoid
PQC 깊이 (생성자)	10
학습률	5×10^{-3}
Epoch	2,000
손실 함수	Binary Cross Entropy

평가용 CNN

Table 1 · CNN 학습 설정	값
학습률	15×10^{-4} (=1.5×10^{-3})
손실 함수	Binary Cross Entropy
Optimizer	ADAM
정규화 layer	Batch Normalization 2D
출력 활성화	Sigmoid
파라미터 수	460k

Table 2 · Conv layer	값
Kernel 크기	3
Stride	1
활성화 함수	ReLU
정규화 layer	Batch Normalization 2D
Max Pooling	2×2

표 내용 출처: Andra et al., Quantum Machine Intelligence 7, 90 (2025), Table 1·2·4

[약 3분]

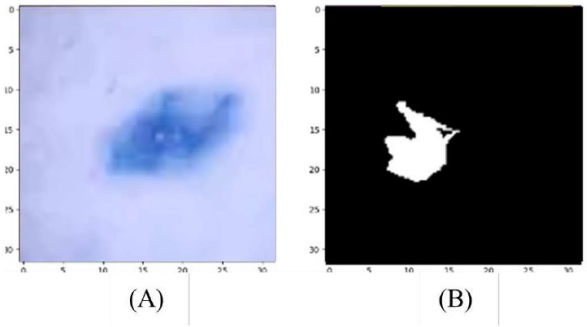
판별자와 평가 방법입니다. 판별자는 Table 4 기준으로 5층 완전연결 신경망이고, 활성화는 ReLU, 출력층은 시그모이드, 학습률은 5×10^{-3}, 2,000 epoch, 손실은 Binary Cross Entropy입니다.

이 논문의 검증 방식은 생성 이미지를 직접 평가하는 대신 별도의 CNN 분류기 성능으로 확인하는 것입니다. 오른쪽이 평가용 CNN의 설정입니다. 학습률 1.5×10^{-3}, Adam, Batch Normalization, 파라미터 약 46만 개의 작은 네트워크입니다. 논문에는 FID 같은 생성 품질 지표가 없다는 점이 이후 MediQ-GAN 논문과의 차이입니다.

01 · QGAN 논문 결과

결과 0 - QGAN 생성 이미지

논문 Fig. 21: 원본 유래 합성 이미지(A)와 합성 segmentation(B)



관찰

- 병변의 위치와 대략적인 경계는 재현됨
- 해상도가 낮아 질감 같은 세부는 확인하기 어려움
- 이 논문은 FID 같은 생성 품질 지표를 제시하지 않고(프리프린트 기준) 증강 후 분류 성능으로 간접 검증함
- 따라서 우열 판단의 근거는 다음 슬라이드의 분류 성능임

그림 출처: Andra et al., Fig. 21 (프리프린트 Research Square rs-5191116v1, CC BY 4.0)

[약 2분]

논문이 제시한 QGAN 생성 이미지입니다. (A)는 원본 이미지에서 유래한 합성 이미지이고 (B)는 합성 segmentation입니다. 해상도가 낮아 병변의 대략적인 위치와 경계가 재현되는 수준이며, 질감 같은 세부는 확인하기 어렵습니다.

이 논문은 생성 이미지의 품질을 FID 같은 지표로 보고하지 않고 분류 성능으로 간접 검증하므로, 이미지 자체에서 판단할 수 있는 것은 제한적입니다. 판단 근거는 다음 슬라이드의 분류 성능입니다.

01 · QGAN 논문 결과

결과 ① - DF vs NV 분류 성능 개선

Table 6: QGAN 증강 후 AUC-ROC 개선



막대 높이는 0부터 비례. 증가폭은 +0.017이며, 이 저장소의 8×8 재현 실험에서는 AUC +0.004, 정확도는 오히려 하락해 개선으로 단정하지 않음 (README 참고)

[약 3분]

첫 번째 결과입니다. Table 6 기준으로 df 대 nv 분류에서 QGAN 증강 후 AUC-ROC가 0.953에서 0.970으로 올랐습니다. 막대의 높이는 0부터 비례하도록 그렸고, 증가 폭은 +0.017입니다.

이 수치는 개선 폭이 작다는 점을 같이 보셔야 합니다. 이 저장소에서 8×8 해상도로 재현한 실험에서는 AUC가 +0.004 올랐지만 정확도는 0.946에서 0.913으로 오히려 떨어졌습니다. df가 92장 규모에서는 이 차이를 개선이라고 단정하기 어렵습니다. 그래서 2·3일차 실습의 평가 지표를 분류 성능이 아닌 지표 4종으로 바꾸었습니다.

01 · QGAN 논문 결과

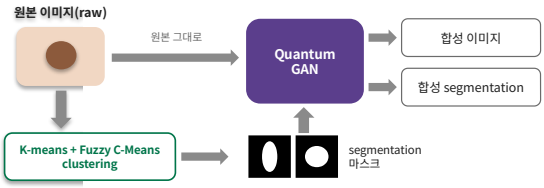
결과 ② - 조건부 증강 효과

segmentation 전처리 이미지에서만 증강 효과 있음

입력 전처리 방식	QGAN 증강 효과
원본/리사이즈 이미지	증강 효과 없음 - 오히려 성능 저하
segmentation(K-means+FCM) 전처리 이미지	증강 효과 있음 - 성능 개선

왜 중요한가

실제로는 배경 노이즈를 제거한(segmentation) 입력에서만 생성 품질이 분류 성능 개선으로 이어짐



25

원 논문 pipeline을 도식으로 재구성: Andra et al., Quantum Machine Intelligence 7, 90 (2025)

[약 3분]

두 번째 결과는 증강 효과가 입력 전처리에 따라 달라진다는 것입니다. 원본이나 단순 리사이즈 이미지로 학습했을 때는 QGAN 증강의 효과가 없거나 오히려 성능이 떨어졌고, K-means와 Fuzzy C-means로 segmentation한 이미지에서만 성능이 개선되었습니다.

오른쪽 그림이 논문의 pipeline입니다. 원본 이미지에서 clustering으로 병변 마스크를 만들고, 이 마스크 이미지로 QGAN을 학습해 합성 이미지와 합성 segmentation을 얻습니다. 배경 잡음을 제거한 입력에서만 생성 품질이 분류 성능으로 이어졌다는 의미입니다. 2일차 실습의 전처리가 segmentation인 이유가 여기에 있습니다.

01 · QGAN 논문 결과

결과 ③ - 고전 GAN과의 비교

Table 11: 조건에 따라 승자 교체 - "양자가 항상 이긴다"는 아님

입력 조건	정확도 비교	비고
원본(raw) 이미지	고전 GAN (정확도 0.98 vs 0.89)	QGAN 열세
segmentation 이미지	QGAN (정확도 0.96 vs 0.95)	AUC는 0.97로 동률

해석

"고전 대비 무조건적 속도·성능 우위"가 성공 기준이 아니라,
(1) 문제→양자 pipeline의 실제 성립 여부, (2) 어떤 조건에서 고전과 동등·우위인지(crossover 조건) 평가

26

[약 3분]

세 번째 결과는 고전 GAN과의 비교입니다. Table 11 기준으로 승자가 조건에 따라 바뀝니다.

원본 이미지에서는 고전 GAN이 정확도 0.98, QGAN이 0.89로 QGAN이 열세입니다. segmentation 이미지에서는 QGAN 0.96, 고전 GAN 0.95로 근소하게 앞서고, AUC는 0.97로 같습니다.

해석은 아래에 적은 대로입니다. 고전 대비 무조건적 우위를 성공 기준으로 삼지 않고, 첫째 문제와 양자 pipeline이 실제로 성립하는지, 둘째 어떤 조건에서 고전과 동등하거나 우위인지를 평가해야 합니다. 이 결과는 양자가 항상 이긴다는 근거가 아닙니다.



[약 1분]

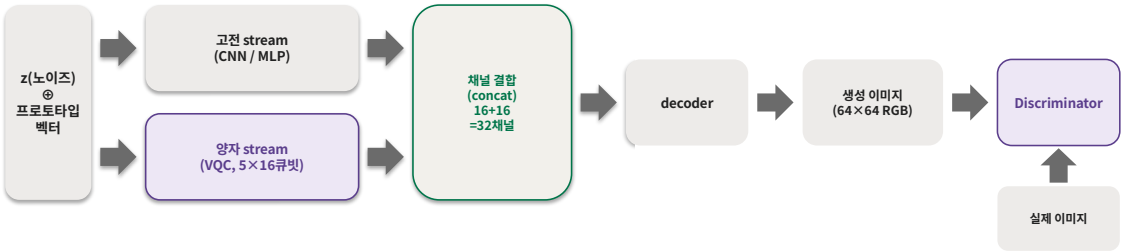
두 번째 논문은 MediQ-GAN입니다. arXiv 2506.21015로, Jiao 등이 발표했습니다.

핵심 기여는 생성자를 고전 stream과 양자 stream으로 나누어 병렬 처리한 뒤 skip-connection으로 융합한 것입니다. 의료영상 세 가지 데이터셋에서 DCGAN, WGAN-GP, StyleGAN2-ADA 같은 고전 모델과 양자 모델 MosaiQ를 클래스별 FID와 LPIPS로 비교하고, 실제 IBM 하드웨어 실행까지 확인했습니다. 이 강의에서는 생성자 일부만 양자인 layer-level hybrid의 대표 사례로 사용합니다.

02 · MEDIQ-GAN 논문

MediQ-GAN 아키텍처 다이어그램 - dual-stream Generator

고전 stream과 양자 stream을 함께 학습해 합치는 구조를 도식으로 재구성



28

[약 3분]

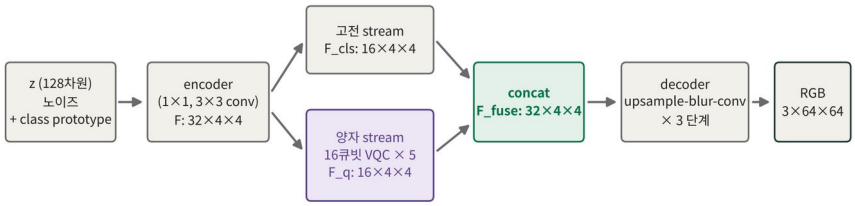
MediQ-GAN의 생성자 구조도입니다. 노이즈 z에 클래스 프로토타입 벡터를 결합해 입력으로 쓰고, 이 입력이 고전 stream과 양자 stream으로 갈라집니다. 양자 stream은 16큐빗 VQC를 다섯 개 사용합니다. 두 stream의 출력을 16채널씩 이어 붙여 32채널로 만들고, decoder가 64×64 RGB 이미지로 복원합니다. 판별자는 고전 네트워크입니다.

QGAN과 비교해 보면 양자회로가 이미지 픽셀을 직접 만들지 않고 특징 맵의 일부를 처리한다는 점이 가장 큰 차이입니다.

02 · MEDIQ-GAN 논문

입력 구성과 decoder

class prototype을 노이즈에 결합하고, 양자 stream 출력은 decoder에서 64×64 RGB로 복원



encoder 출력 32채널 중 16채널을 양자 stream에 투입

prototype conditioning

- EfficientNet-B0(30 epoch 미세조정) 특징의 클래스별 평균 벡터를 노이즈에 결합
- centroid 간 거리를 최대화하는 regularization loss로 클래스 구분 유지

decoder

- 3×3 conv → upsample-blur-conv 3단계 → 3×3 conv
- 양자 stream 출력과 고전 stream 출력을 concat한 32×4×4를 3×64×64로 확대

29

구조 출처: Jiao et al., arXiv:2506.21015 Method 절

[약 4분]

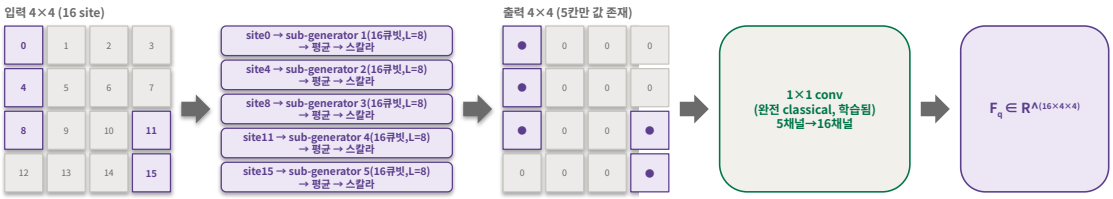
입력과 decoder를 구체적인 텐서 크기로 보겠습니다. 입력은 128차원 벡터 z이고, 노이즈에 클래스 prototype이 결합된 형태입니다. 작은 conv encoder가 이를 32×4×4 특징 맵으로 바꾸고, 절반인 16채널은 고전 stream, 나머지 16채널은 양자 stream으로 보냅니다. 양자 stream의 출력 16×4×4와 고전 stream의 16×4×4를 이어 붙이면 32×4×4가 되고, decoder가 이를 3×64×64 RGB로 키웁니다. decoder는 3×3 conv, upsample-blur-conv 세 단계, 마지막 3×3 conv로 구성됩니다.

prototype conditioning은 논문이 소수 클래스를 위해 도입한 장치입니다. EfficientNet-B0를 30 epoch 미세조정하고 최종 layer 특징의 클래스별 평균 벡터를 구해 노이즈에 결합합니다. 생성자가 클래스 공통 구조를 처음부터 학습하지 않고 클래스 내 변이에 용량을 쓰게 하려는 설계입니다. 다만 prototype만 쓰면 다양성이 줄 수 있어, 클래스 centroid 사이 거리를 최대화하는 prototype regularization loss를 추가했다고 논문은 설명합니다.

02 · MEDIQ-GAN 논문

sub-generator 상세 - 16 site 중 5개만 실제 양자 처리

나머지 11칸은 classical 1×1 conv의 편향값만 받음 (공식 GitHub 코드 기준)



site 선택: linspace(0,15,5)round → [0, 4, 8, 11, 15] (row×4+col). 나머지 11칸은 그 sub-generator의 4×4 맵에서 0으로 남음.
1×1 conv는 칸별 독립 처리(이웃 안 봄) - 값이 있는 5칸만 진짜 양자 스칼라를 16채널로 투영, 나머지 11칸은 학습된 편향(bias)뿐. 이후 8×8 업샘플에서만 보간으로 살짝 섞임.

30

[약 4분]

양자 stream의 실제 처리 범위를 공식 GitHub 코드 기준으로 정리한 슬라이드입니다. 논문 본문은 양자 stream이 특징 절반을 받아 16큐빗 VQC 다섯 개로 처리한다고 서술하는데, 공식 코드를 따라가 보면 4×4 특징 맵의 16개 위치 중 5개만 실제 양자 회로를 통과합니다.

위치 선택은 0에서 15 사이를 5등분해 반올림한 [0, 4, 8, 11, 15]입니다. 이 다섯 위치가 각각 sub-generator에 들어가 평균 기댓값 스칼라 하나를 냅니다. 나머지 11칸은 0이고, 이후 1×1 conv가 5채널을 16채널로 투영합니다. 1×1 conv는 칸을 독립적으로 처리하므로 값이 있는 5칸만 실제 양자 스칼라를 받고 나머지 11칸은 학습된 편향값만 가집니다. 이웃 칸 정보는 이후 8×8 업샘플링에서만 보간으로 섞입니다.

논문 설명과 공식 코드의 차이는 숨기지 않고 짚어야 하는 부분입니다. 3일차 실습은 코드 기준으로 구현되어 있습니다.

02 · MEDIQ-GAN 논문

Hybrid 분류체계 - "어디까지가 양자인가"

같은 '양자 생성모델'이라도 Generator 전체/일부 양자 여부로 구분됨

model-level hybrid

예: HAM10000 QGAN, MosaiQ

Generator = 처음부터 끝까지 양자회로

Discriminator만 고전

PCA 등 고전 전처리가 있어도, Generator 는 양자 회로 구성

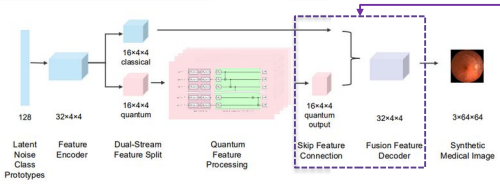
layer-level hybrid

예: MediQ-GAN

Generator 내부가 고전 stream + 양자 stream으로 병렬 분기

두 stream을 skip-connection으로 concat 후 디코딩

"layer 하나 안에서도" 양자·고전이 공존



31

그림 출처: Jiao et al., MediQ-GAN, arXiv:2506.21015 (CC BY 4.0)

[약 3분]

hybrid의 분류 체계입니다. 같은 양자 생성모델이라도 생성자의 어디까지가 양자인가로 구분합니다.

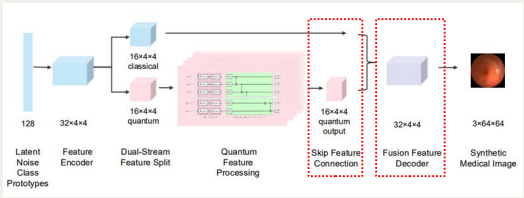
model-level hybrid는 생성자가 처음부터 끝까지 양자회로이고 판별자만 고전인 경우입니다. HAM10000 QGAN과 MosaiQ가 해당합니다. PCA 같은 고전 전처리가 있어도 생성자 자체는 양자회로로 구성됩니다. layer-level hybrid는 생성자 내부가 고전 stream과 양자 stream으로 병렬 분기하고 skip-connection으로 합쳐집니다. layer 하나의 안에서도 양자와 고전이 공존하는 구조입니다. MediQ-GAN이 대표 사례입니다.

아래 그림의 점선 상자가 두 stream이 합쳐지는 skip-connection 부분입니다.

02 · MEDIQ-GAN 논문

dual-stream Generator 아키텍처

입력을 절반씩 나눠 고전 인코더와 양자회로(VQC)가 병렬 처리 후 하나로 합침



고전 stream

classical encoder / conv

양자 stream

5 × 16큐빗 VQC (8층 깊이)

skip-connection 융합 (concat)

고전 decoder → 생성 이미지

encoding: angle encoding(Rx→Ry) · 학습 layer: Ry+CNOT 반복 · 측정: X-basis readout

32

그림 출처: Jiao et al., MediQ-GAN, arXiv:2506.21015 (CC BY 4.0)

[약 3분]

dual-stream 생성자의 구성을 다시 요약합니다. 입력을 절반씩 나누어 고전 encoder와 양자회로가 병렬로 처리하고 하나로 합칩니다. 양자 stream은 16큐빗 VQC 다섯 개이고 깊이는 8층입니다. 두 출력을 concat으로 융합한 뒤 고전 decoder가 이미지를 생성합니다.

하단의 회로 사양은 encoding이 angle encoding(Rx 다음 Ry), 학습 layer가 Ry와 CNOT 반복, 측정이 X-basis readout입니다.

02 · MEDIQ-GAN 논문

critic과 학습 목표

critic은 고전 convolutional network로 유지하고, 학습 목표는 WGAN-GP를 사용

항목	내용
학습 목표	WGAN-GP: $L = E[D(x)] - E[D(G(z))] + \lambda \cdot E[(\lVert \nabla D(\hat{x}) \rVert_2 - 1)^2]$ (논문 식 (1)·(2))
critic 구조	원 WGAN-GP 논문의 convolutional 구조, 입력 3×64×64
critic을 고전으로 둔 이유 (논문)	1. 3×64×64 입력을 매 iteration 처리해야 하므로 NISQ 소자에서 구현이 비현실적 2. 안정적이고 잘 알려진 critic을 두어 성능 향상을 양자 설계의 효과로 귀속
QGAN과의 차이	QGAN: 5층 완전연결 + BCE (Table 4) MediQ-GAN: convolution + WGAN-GP
실습과의 차이	3일차: MLP 판별자 + 표준 BCE, lr 2×10^{-4}, betas (0.5, 0.999)로 25 epoch 완주 (README '원 논문과 다른 점')

33

[약 4분]

MediQ-GAN의 학습 목표와 critic입니다. 학습 목표는 WGAN-GP이고, 논문 식 (1)과 (2)에 해당합니다. critic은 실제 샘플의 점수에서 생성 샘플의 점수를 뺀 값을 최대화하고, 생성자는 그 반대로 갱신됩니다. 여기에 critic gradient 노름 벌점이 더해집니다.

critic은 양자가 아니라 원 WGAN-GP 논문의 convolutional 구조를 그대로 씁니다. 논문이 제시한 이유는 두 가지입니다. 첫째, critic은 3×64×64 입력을 매 iteration 처리해야 하므로 현재의 NISQ 소자에서 구현하기 비현실적입니다. 둘째, 안정적이고 특성이 잘 알려진 critic을 두어야 성능 향상을 양자 설계의 효과로 귀속할 수 있습니다.

앞에서 본 QGAN의 판별자와는 구조와 손실이 모두 다릅니다. 실습에서는 3일차에 MLP 판별자와 표준 BCE를 사용하고, 학습률 2×10^{-4}와 betas (0.5, 0.999)를 쓰는 관례적 설정으로 25 epoch을 안정적으로 완주했습니다. 논문 조건과 다르다는 점은 마지막 슬라이드에서 다시 정리합니다.

02 · MEDIQ-GAN 논문 · 심화

VQC · VQA·QAOA와의 관계

같은 '파라미터화된 회로 + 고전 최적화' 구조 공유, encoding 대상과 목적은 상이

개념	정의
VQA (Variational Quantum Algorithm)	파라미터화된 양자회로 + 고전 최적화 루프를 사용하는 알고리즘 상위 범주
VQC (Variational Quantum Classifier/Circuit)	분류 등 지도학습 목적의 구체적 구현 - 데이터 encoding + 학습 가능한 ansatz로 구성 (MediQ-GAN의 양자 아키텍처 방식)
QAOA (Quantum Approximate Optimization Algorithm)	조합최적화 문제(MaxCut 등) 등 목적 - cost layer(γ)와 mixer layer(β)를 번갈아 적용



공통점 vs 차이점

- 공통점: 파라미터화된 회로 → 측정 → 고전 optimizer가 파라미터 업데이트(hybrid loop)
- 차이점: encoding 대상(데이터 vs 문제)과 학습 목표

34

[약 3분]

심화 부분에서는 용어를 정리하겠습니다. VQA는 파라미터화된 양자회로와 고전 최적화 루프를 쓰는 알고리즘의 상위 범주입니다. VQC는 분류 같은 지도학습에 쓰는 구체적 구현으로, 데이터 encoding과 학습 가능한 ansatz로 구성되며 MediQ-GAN의 양자 stream이 이 방식입니다. QAOA는 MaxCut 같은 조합최적화 문제용으로, cost layer와 mixer layer를 번갈아 적용합니다.

공통점은 파라미터화된 회로, 측정, 고전 optimizer의 업데이트라는 hybrid loop 구조이고, 차이점은 encoding 대상이 데이터인지 문제인지, 그리고 학습 목표입니다.

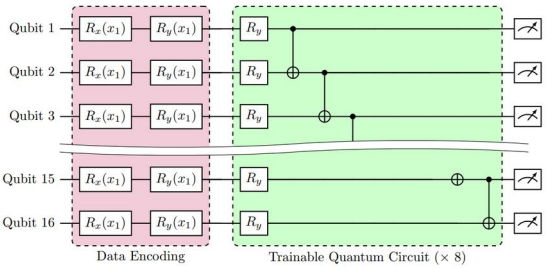
02 · MEDIQ-GAN 논문 · 심화

회로 안의 두 종류 파라미터 - encoding vs 학습

데이터를 넣는 게이트와 학습으로 값이 바뀌는 게이트, 역할 차이

구분	위치 / 값의 성격
encoding 파라미터	회로 앞단, 데이터 encoding 게이트 - 입력 데이터 x (대부분 고정, 학습 대상 아님)
학습 파라미터 θ	encoding 이후 variational ansatz - 회전 게이트 각도, CNOT, entangling 게이트 사이사이에 위치, 학습으로 업데이트됨

layer = 회전게이트(θ, 파라미터 O) + CNOT 체인(파라미터 X, 얽힘 담당)
16큐빗 × 8층 → sub-generator당 파라미터 128개 (5개 합계 640개)



※ 그림은 논문 기준(Rx→Ry·CNOT), 공식 코드는 RY→RX·CZ - 3일차 데모는 코드 기준

그림 출처: Jiao et al., MediQ-GAN, arXiv:2506.21015 (CC BY 4.0)

[약 3분]

회로 안의 파라미터는 두 종류입니다. encoding 파라미터는 회로 앞단에서 입력 데이터 x를 넣는 게이트의 각도로, 대부분 고정이며 학습 대상이 아닙니다. 학습 파라미터 θ는 그 뒤 variational ansatz의 회전각이고, 학습으로 갱신됩니다. CNOT 같은 얽힘 게이트에는 파라미터가 없습니다.

16큐빗에 8층이면 sub-generator 하나에 128개, 다섯 개 합계 640개입니다. 그림은 논문 기준인 Rx, Ry, CNOT 순서이고 공식 코드는 RY, RX, CZ 순서입니다. 3일차 데모는 코드 기준이라는 점을 하단 각주에 밝혔습니다.

02 · MEDIQ-GAN 논문 · 심화

VQC의 출력값 - bitstring이 아니라 연속값(기댓값)

단일 측정은 0/1, 모델이 실제로 쓰는 값은 여러 번 측정을 평균낸 기댓값

$$m(z;\Theta) = (\langle X_1\rangle, \ldots, \langle X_N\rangle) \in [-1, 1]^N$$

항목	내용
단일 shot 결과	이산적 0/1 bitstring - 확률적 결과
실제 모델 출력	$\langle X_i\rangle$ 연속값(continuous) - classical decoder에 바로 투입 가능, gradient 계산도 가능
수치 안정화	h(m) = σ(LeakyReLU(LayerNorm(m))) 적용 후 classical stream과 fusion

36

[약 3분]

VQC의 출력은 bitstring이 아니라 연속값입니다. 단일 측정은 0 또는 1이지만 모델이 실제로 쓰는 값은 큐빗별 기댓값 벡터로, 각 성분이 −1에서 1 사이입니다.

이 값은 연속적이므로 classical decoder에 바로 넣을 수 있고 gradient 계산도 가능합니다. 수치 안정화를 위해 LayerNorm, LeakyReLU, 시그모이드를 순서대로 적용한 뒤 classical stream과 fusion합니다.

02 · MEDIQ-GAN 논문 · 심화

실제 채택 방식 - Exact State Vector Simulation

공식 코드(mediq-gan.py) 설정

```
dev = qml.device("lightning.qubit", wires=args.n_qubits)
@qml.qnode(dev, interface="torch", diff_method="adjoint")
def circuit(...):
    ...
    return [qml.expval(qml.PauliX(i)) for i in range(args.n_qubits)]
```

항목	내용
shots 미지정	PennyLane 기본값 shots=None → 분석적(exact) 기댓값 계산, 반복 측정 없음
diff_method="adjoint"	정확한 state vector 접근이 있어야만 가능한 gradient 계산법 - 데모도 공식 레포와 동일하게 adjoint 사용
state vector 규모	n큐빗 = 2^n차원 복소벡터로 완전 표현(16qubit→65,536차원, 노트북 처리 가능) - 게이트 적용=유니터리 행렬곱(확률적 요소 없음)

37

[약 3분]

공식 코드(mediq-gan.py)의 실제 설정입니다. 장치는 lightning.qubit이고 diff_method는 adjoint, 반환값은 큐빗별 PauliX 기댓값입니다.

shots를 지정하지 않으면 PennyLane은 반복 측정 없이 분석적으로 정확한 기댓값을 계산합니다. adjoint는 정확한 state vector에 접근할 수 있을 때만 쓸 수 있는 gradient 계산법으로, 데모도 공식 저장소와 같이 adjoint를 씁니다. 16큐빗의 state vector는 65,536차원이어서 노트북에서 처리 가능합니다. 게이트 적용은 유니터리 행렬곱이라 확률적 요소가 없습니다.

02 · MEDIQ-GAN 논문 · 심화

'Hardware-agnostic'의 정확한 의미

논문 원문 그대로 인용 시 오해하기 쉬운 표현

논문 원문 인용

"Our approach is quantum-inspired and **hardware-agnostic**: the correctness does not depend on quantum execution, and quantum devices serve only to accelerate computation."

구분	내용
오해 (X)	하드웨어를 아예 안 썼다는 뜻
정확한 뜻 (O)	모델의 타당성이 특정 실행 환경(시뮬레이터 vs 실제 큐빗)에 좌우되지 않도록 설계했다는 뜻
학습(training)	state vector 시뮬레이터로 진행
NISQ evaluation	학습 완료된 회로를 IBM Marrakesh 실기에 올려 inference만 검증 (클래스별 FID +19 ~ +79 상승, 논문은 '비교 가능한 수준'으로 평가)

38

[약 3분]

논문의 'hardware-agnostic'이라는 표현은 오해하기 쉽습니다. 원문은 접근법이 quantum-inspired이며 정확성이 양자 실행에 의존하지 않고, 양자 소자는 계산 가속에만 쓰인다고 말합니다.

이는 하드웨어를 전혀 쓰지 않았다는 뜻이 아니라, 모델의 타당성이 실행 환경, 즉 시뮬레이터인지 실제 큐빗인지에 좌우되지 않도록 설계했다는 뜻입니다. 학습은 state vector 시뮬레이터로 진행했고, NISQ 평가는 학습이 끝난 회로를 IBM Marrakesh에 올려 inference만 검증했습니다. 이 검증의 구체적인 수치는 결과 부분에서 다시 봅니다.

02 · MEDIQ-GAN 논문 · 심화

shot 기반으로 학습한다면 - Parameter-shift Rule

Exact statevector 방식이 아니라, gradient를 구할 때 쓰는 규칙

$$\partial \langle X_i \rangle / \partial \theta_j = [\langle X_i \rangle(\theta_j+\pi/2) - \langle X_i \rangle(\theta_j-\pi/2)] / 2$$

개념	설명
계산 방식	회로 내부를 역전파로 거슬러 올라가는 게 아니라, θ_j를 shift한 회로를 처음부터 끝까지 2번 새로 실행해 얻은 결과값의 단순 뺄셈
순전파(forward) 시점	shift된 회로는 전혀 실행되지 않음 - 원래 θ값으로 1번만 실행, 그 출력이 다음 classical layer로 전달
역전파(backward) 시점	$+\pi/2$, $-\pi/2$ 두 회로가 파라미터 하나마다 개별적으로 실행됨

전체 chain rule: $dLoss/d\theta_j = dLoss/d\langle X_i \rangle$ (classical backprop) × $d\langle X_i \rangle/d\theta_j$ (parameter-shift, 뺄셈 기반)

39

[약 4분]

shot 기반으로 학습한다면 gradient는 parameter-shift rule로 구합니다. 기댓값을 파라미터로 미분한 값은, 해당 파라미터를 ±π/2 이동시킨 회로 두 개의 기댓값 차이를 2로 나눈 것과 같습니다.

핵심은 회로 내부를 역전파로 거슬러 올라가는 것이 아니라 shift한 회로를 처음부터 끝까지 두 번 새로 실행해 얻은 결과를 빼는 것이라는 점입니다. 순전파에서는 shift한 회로를 전혀 실행하지 않고 원래 값으로 한 번만 실행하며, 역전파 시점에 파라미터마다 두 회로가 개별적으로 실행됩니다. 전체 chain rule은 손실의 기댓값에 대한 미분, 즉 고전 backpropagation과 이 parameter-shift 값의 곱입니다.

02 · MEDIQ-GAN 논문 · 심화

계산 비용 - 현재 학습의 어려움

파라미터 수만큼 회로를 반복 실행해야 하는 구조적 한계

총 회로 실행 횟수 = C (순전파 회로 수) + 2P (파라미터 별 +shift, −shift)

파라미터 수 P	회로 실행 횟수
640 (회로 5개 × 16큐빗 × 8층)	5 + 1,280 = 1,285회
10,000	1 + 20,000 = 20,001회

측정 횟수까지 곱하면

총 측정 횟수 = 회로 실행 횟수 × shots.
- P=10,000, shots=1,024 → 20,001×1,024 ≈ 약 2,048만 회.
- batch 32 · 학습 step 10,000까지 포함하면 → 20,001×1,024×32×10,000 ≈ 6.5×10^{12}(약 6.5조 회)

40

[약 3분]

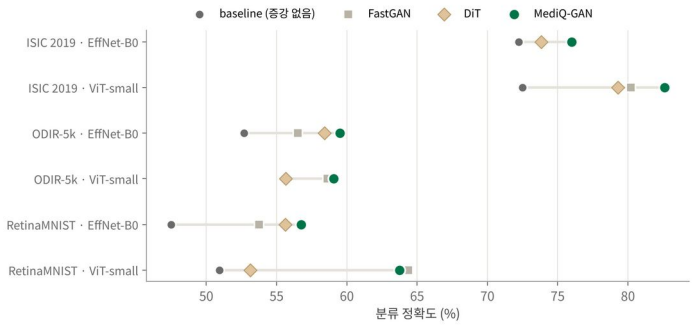
그 결과 계산 비용은 파라미터 수에 비례합니다. 총 회로 실행 횟수는 순전파 회로 수 C에 파라미터마다 +shift, −shift 두 번을 더한 C + 2P입니다.

파라미터가 640개인 이 모델은 5 + 1,280 = 1,285회, 파라미터가 1만 개로 늘면 20,001회입니다. 여기에 측정 횟수를 곱하면, P가 1만이고 shots가 1,024일 때 약 2,048만 회, batch 32와 학습 step 1만까지 포함하면 약 6.5×10^{12}, 6.5조 회입니다. 현재 하드웨어에서 parameter-shift로 이 규모를 학습하는 것이 비현실적인 이유이고, 논문이 학습을 시뮬레이터에서 한 이유이기도 합니다.

02 · MEDIQ-GAN 논문 결과

결과 ① - 분류 성능 (Table 1)

baseline 대비 정확도는 3개 데이터셋 · 2개 분류기 모두에서 상승하나, 모든 행에서 최고는 아님



읽는 법

- EfficientNet-B0 정확도 상승: ISIC +3.75, ODIR +6.83, RetinaMNIST +9.25
- ViT-small 정확도 상승: +10.11, +3.44, +12.82
- RetinaMNIST ViT-small: FastGAN 64.37이 MediQ-GAN 63.75보다 높음
- ISIC ViT-small AUC: FastGAN 0.9549 > 0.9517
- MosaiQ는 baseline 이하 (ISIC ViT-small 50.25%)

수치 출처: Jiao et al., arXiv:2506.21015 Table 1

[약 4분]

MediQ-GAN의 첫 번째 결과, 분류 성능입니다. 논문 Table 1을 점으로 다시 그렸습니다. 각 행은 데이터셋과 분류기 조합이고, 점은 증강하지 않은 baseline, FastGAN, DiT, MediQ-GAN의 정확도입니다.

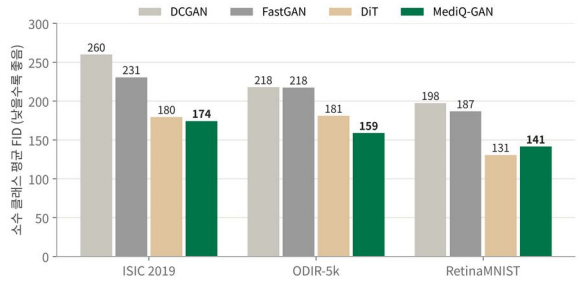
MediQ-GAN은 여섯 행 모두에서 baseline보다 높습니다. EfficientNet-B0 기준 정확도 상승은 ISIC 2019 +3.75, ODIR-5k +6.83, RetinaMNIST +9.25이고, ViT-small은 각각 +10.11, +3.44, +12.82입니다. 논문이 평균 상승으로 인용한 수치가 EfficientNet-B0 기준과 같다는 점도 확인했습니다.

다만 모든 행에서 최고는 아닙니다. RetinaMNIST ViT-small에서는 FastGAN의 정확도 64.37이 MediQ-GAN의 63.75보다 높고, ISIC ViT-small AUC도 FastGAN이 0.9549로 0.9517보다 높습니다. 고전 모델 MosaiQ는 baseline보다 낮아져 ISIC ViT-small에서 정확도가 50.25%까지 떨어졌습니다. 논문의 서술도 '가장 큰 또는 그에 근접한 개선'입니다.

02 · MEDIQ-GAN 논문 결과

결과 ② - 생성 품질: FID와 LPIPS

소수 클래스 FID는 ISIC·ODIR에서 MediQ-GAN이 가장 낮고, RetinaMNIST에서는 DiT가 더 낮음



해석

- DiT는 확산 모델로 용량이 훨씬 큼. 논문 서술은 'best or second-best'
- MosaiQ: FID 316 ~ 593, RetinaMNIST LPIPS 0.079로 거의 같은 이미지만 생성
- FID는 클래스당 표본이 적을수록 불안정함

소수 클래스 평균 LPIPS (높을수록 다양)	Real	DiT	FastGAN	MediQ-GAN
ISIC 2019	0.457	0.367	0.422	0.409
ODIR-5k	0.612	0.609	0.609	0.601
RetinaMNIST	0.396	0.321	0.394	0.384

수치 출처: Jiao et al., Extended Data Table 2·3

[약 4분]

생성 품질 지표입니다. 왼쪽 그래프는 소수 클래스 평균 FID로, 논문 Extended Data Table 2입니다. 낮을수록 좋습니다.

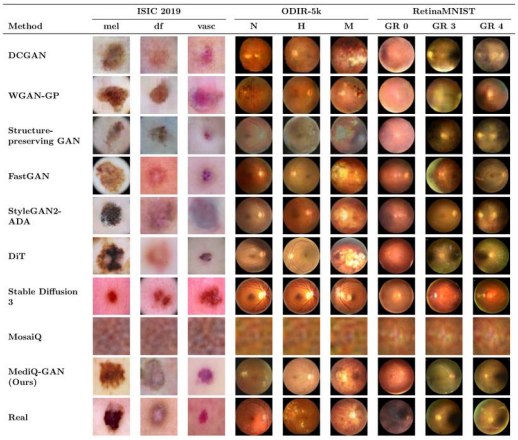
ISIC 2019에서는 MediQ-GAN이 174.5로 DiT 179.6과 FastGAN 230.8보다 낮고, ODIR-5k에서도 158.9로 가장 낮습니다. 그러나 RetinaMNIST에서는 DiT가 130.8로 MediQ-GAN의 141.4보다 낮습니다. 즉 모든 데이터셋에서 최고는 아니며, 논문도 'best or second-best'라고 서술합니다. DiT가 확산 모델로 훨씬 큰 용량을 가진다는 점도 함께 읽어야 합니다.

아래 표는 소수 클래스 평균 LPIPS입니다. 높을수록 다양합니다. MediQ-GAN은 실제 값에 가까운 수준이지만 FastGAN이 소폭 더 높은 경우가 있습니다. 한편 앞서 언급한 MosaiQ는 FID가 316에서 593 범위이고 RetinaMNIST의 LPIPS가 0.079로 매우 낮아, 거의 같은 이미지만 만든다는 뜻입니다.

02 · MEDIQ-GAN 논문 결과

결과 ③ - 생성 이미지 비교 (Fig. 2)

열은 데이터셋별 대표 클래스, 행은 방법, 마지막 행은 실제 이미지



논문의 정성 서술

- DCGAN, Structure-preserving GAN: 흐린 dermoscopic 질감
- StyleGAN2-ADA: 다수 클래스는 개선, 희소 클래스에서 약함
- FastGAN, DiT: 데이터가 극히 적은 ISIC df에서 구조 손실
- MosaiQ: PCA 축소로 색과 구조가 사라진 흐린 패치
- MediQ-GAN: 클래스 특징 보존 (논문 서술)
- 저자의 정성 평가이므로 FID, LPIPS와 함께 해석함

그림 출처: Jiao et al., arXiv:2506.21015 Fig. 2 (CC BY 4.0)

[약 3분]

논문 Fig. 2의 생성 이미지 비교입니다. 열은 데이터셋별 대표 클래스, 행은 방법이고 마지막 행이 실제 이미지입니다.

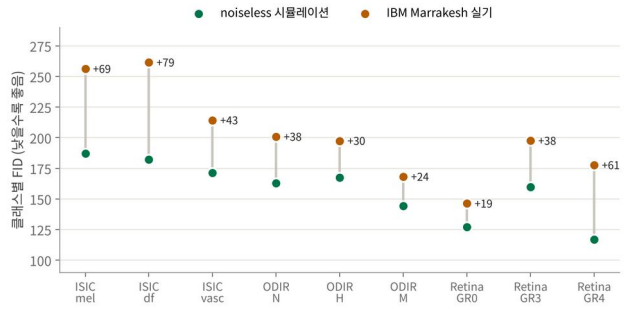
논문의 서술을 정리하면 다음과 같습니다. DCGAN과 Structure-preserving GAN은 흐린 질감을 만들고, StyleGAN2-ADA는 다수 클래스에서는 개선되지만 희소 클래스에서 약합니다. FastGAN과 DiT는 데이터가 극히 적은 ISIC의 df에서 구조를 잃습니다. MosaiQ는 PCA로 차원을 줄인 영향으로 색과 구조가 사라진 흐린 패치만 나옵니다. MediQ-GAN은 클래스 특징을 보존한다고 논문은 서술합니다.

이 비교는 저자의 정성 평가라는 점에 유의하십시오. 앞 슬라이드의 FID와 LPIPS와 함께 볼 때 의미가 있고, 이미지 몇 장만으로 우열을 판단하기는 어렵습니다.

02 · MEDIQ-GAN 논문 결과

결과 ④ - IBM 실기 검증

학습된 회로를 IBM Marrakesh에서 inference만 실행: 모든 클래스에서 FID 상승



읽는 법

- 범위: 데이터셋별 대표 클래스 9개, inference만 (학습은 시뮬레이션)
- FID 상승폭: +19 (RetinaMNIST GR0) ~ +79 (ISIC df)
- 논문 평가: 시뮬레이션보다 약간 낮으나 비교 가능한 수준

비교

ISIC df: 실기 FID 261.5는 FastGAN 225.0보다 나쁘고 DCGAN 272.6보다 좋음. 노이즈에 무너지지 않는다는 근거이며, 실기에서 고전 baseline보다 우위라는 근거는 아님

수치 출처: Jiao et al., Extended Data Table 4, Table 2

[약 3분]

IBM 실기 검증 결과입니다. 학습이 끝난 5개의 16큐빗 회로를 IBM Marrakesh에서 실행했고, 대기 시간과 shot 제한 때문에 데이터셋별 대표 클래스의 inference로 한정했습니다. 학습은 하지 않았습니다.

그래프에서 초록 점이 noiseless 시뮬레이션, 주황 점이 실기 결과이고 숫자는 FID 증가분입니다. 아홉 개 클래스 모두에서 FID가 올랐고 상승폭은 RetinaMNIST GR0의 +19에서 ISIC df의 +79 까지입니다. 논문은 이를 '시뮬레이션보다 약간 낮지만 비교 가능한 수준'이라고 평가합니다.

수치로 보면 ISIC df의 실기 FID 261.5는 FastGAN의 225.0보다 나쁘고 DCGAN의 272.6보다는 좋습니다. 노이즈에도 결과가 크게 무너지지 않는다는 점은 의미가 있지만, 실기에서 고전 baseline 보다 우위라는 근거는 아닙니다. 이 검증이 inference에 한정된다는 점도 함께 기억해야 합니다.

02 · MEDIQ-GAN 논문 결과

결과 ⑤ - 생성자의 학습 가능성 분석

Jacobian 특이값 분포와 DLA 분석으로 hybrid 생성자를 평가함

분석	의미	논문 결과
effective rank, participation ratio	잠재 방향 중 출력에 실제 영향을 주는 비율 (높을수록 좋음)	특이값 감쇠가 고전 baseline보다 완만 (Extended Data Fig. 3)
log10 condition number	생성자 conditioning (낮을수록 좋음)	MediQ-GAN 2.09 / 2.04 / 2.01 (ISIC / ODIR / Retina) DCGAN 2.54 / 2.54 / 2.44, StyleGAN2-ADA 5.78 / 6.25 / 6.58
DLA 분석	회로가 만드는 변환군의 차원으로 표현력과 barren plateau 위험을 판단	depth 8에서 표현력이 충분하고 barren plateau를 피함
ablation	양자 채널 수, VQC 개수	늘릴수록 성능과 effective rank 개선, 현 설정 이후 이득 감소. 16채널 · 5 VQC는 시뮬레이션 비용과 절충

한계

논문 결론: MediQ-GAN은 모든 unconstrained benchmark에서 고전 생성모델을 넘어서지는 못함. 이 분석은 생성자의 수치적 성질에 대한 것임

수치 출처: Jiao et al., Extended Data Table 5, Discussion

[약 3분]

논문은 성능 외에 생성자의 학습 가능성과 표현력을 분석합니다. 세 가지입니다.

첫째, effective rank와 participation ratio는 잠재 방향 중 출력에 실제 영향을 주는 비율로, Jacobian 특이값 감쇠가 고전 baseline보다 완만하다고 보고합니다. 둘째, log condition number는 생성자의 conditioning으로 낮을수록 좋습니다. MediQ-GAN은 세 데이터셋에서 2.09, 2.04, 2.01이고, DCGAN은 2.54, 2.54, 2.44, StyleGAN2-ADA는 5.78, 6.25, 6.58입니다. 셋째, DLA 분석에서 depth 8이 충분한 표현력을 가지면서 barren plateau를 피한다고 설명합니다. ablation에서는 양자 채널이나 VQC를 늘릴수록 성능과 effective rank가 개선되지만 현재 설정 이후에는 이득이 줄고, 16채널과 VQC 5개는 시뮬레이션 비용과 절충한 선택이라고 합니다.

이 분석은 수치적 성질에 대한 것이고, 논문 스스로도 결론에서 MediQ-GAN이 모든 unconstrained benchmark에서 고전 생성모델을 넘어서지는 못했다고 밝힙니다.

CHAPTER 3

내용 정리

46

[약 1분]

마지막 장은 내용 정리입니다. 두 논문을 비교하고 앞으로의 연구 방향을 짚은 뒤 2·3일차 실습과의 연결로 마무리합니다.

03 · 내용 정리

두 논문 비교 요약 및 정리

QGAN 및 MediQ-GAN 정리

구분	QGAN	MediQ-GAN
Hybrid 유형	model-level (Generator 전체 양자)	layer-level (dual-stream)
큐빗 규모	7+1큐빗 × sub-generator 16개	5 × 16큐빗 VQC(stream 하나)
데이터셋	HAM10000 (피부병변, 2클래스 집중)	ISIC2019 · ODIR-5k · RetinaMNIST
검증 방식	증강 전/후 CNN 분류 성능(AUC-ROC)	클래스별 FID·LPIPS + 실기(IBM) 검증

47

[약 3분]

두 논문을 표로 비교하겠습니다. hybrid 유형은 QGAN이 model-level, MediQ-GAN이 layer-level입니다. 큐빗 규모는 QGAN이 7+1큐빗 회로 16개, MediQ-GAN이 16큐빗 VQC 5개입니다. 데이터셋은 QGAN이 HAM10000의 두 클래스에 집중하고, MediQ-GAN은 ISIC 2019, ODIR-5k, RetinaMNIST 세 가지입니다. 검증 방식은 QGAN이 증강 전후 CNN 분류 성능이고, MediQ-GAN은 클래스별 FID와 LPIPS에 IBM 실기 검증을 더했습니다.

이 차이 때문에 두 논문의 수치를 직접 비교할 수 없다는 점에 유의하십시오.

03 · 내용 정리

두 논문을 읽을 때의 점검 항목

양자 생성모델 논문의 주장을 평가할 때 적용하는 다섯 가지 기준

점검 항목	QGAN	MediQ-GAN
비교 대상	고전 vanilla GAN 1종	고전 GAN 5종, 확산 모델 2종, MosaiQ
평가 방식	분류 성능 (AUC-ROC, 정확도)	분류 성능 + FID + LPIPS
양자 요소의 범위	생성자 전체	생성자 일부 (공식 코드 기준 16개 위치 중 5개)
조건 의존성	segmentation 입력에서만 증강 효과	모든 지표에서 최고는 아님 (결과 ①, ②)
한계의 명시	개선 폭 AUC +0.017. 이 저장소 8×8 재현에서는 정확도 하락	실기 검증은 inference에 한정. 고전 모델을 전 영역에서 넘지는 못함

48

[약 4분]

두 논문을 읽을 때 적용할 점검 항목을 다섯 가지로 정리했습니다. 양자 생성모델 논문뿐 아니라 어떤 논문에도 쓸 수 있는 기준입니다.

비교 대상은 QGAN이 고전 GAN 한 종류인 반면 MediQ-GAN은 고전 GAN 다섯 종, 확산 모델 두 종, 양자 모델 MosaiQ를 포함합니다. 평가 방식은 QGAN이 분류 성능 하나이고 MediQ-GAN은 분류 성능, FID, LPIPS를 함께 씁니다. 양자 요소의 범위는 QGAN이 생성자 전체, MediQ-GAN은 일부이며 공식 코드 기준으로 16개 위치 중 5개입니다. 조건 의존성에서 QGAN은 segmentation 입력에서만 효과가 있었고, MediQ-GAN은 모든 지표에서 최고가 아니었습니다. 마지막으로 한계의 명시 여부입니다. QGAN 개선 폭은 AUC +0.017로 작고 이 저장소의 재현에서는 정확도가 하락했으며, MediQ-GAN은 실기 검증이 inference에 한정됩니다.

결론적으로 두 논문 모두 양자 모델이 고전 모델보다 우월하다는 증거를 제시하는 것이 아니라, 양자 구성 요소를 포함한 생성모델이 실제로 동작하고 일부 조건에서 경쟁력이 있음을 보입니다.

03 · 내용 정리

2·3일차 실습과의 대응

회로 사양은 유지하고 해상도와 학습량을 줄여 Colab 무료 CPU에서 끝까지 실행

이론 (1일차)	실습 구현	원 논문과의 차이
QGAN patch 생성자	2일차: sub-generator 4개 × 7큐빗(데이터 6 + ancilla 1), depth 10	논문: 16개 × 8큐빗. 16×16 그레이스케일
QGAN 판별자	5층 완전연결 (2·3일차 공통)	동일 (Table 4)
MediQ-GAN dual-stream	3일차: 양자 stream 16큐빗 × 5, depth 8. 25 epoch 미세조정	고전 부분·판별자는 MLP + 표준 BCE (논문: conv + WGAN-GP)
평가	지표 4종 (16×16에서 FID 불가)	논문: FID, LPIPS, 분류 성능
실행 환경	PennyLane exact 시뮬레이션, Colab CPU	논문: GPU, IBM 실기는 inference

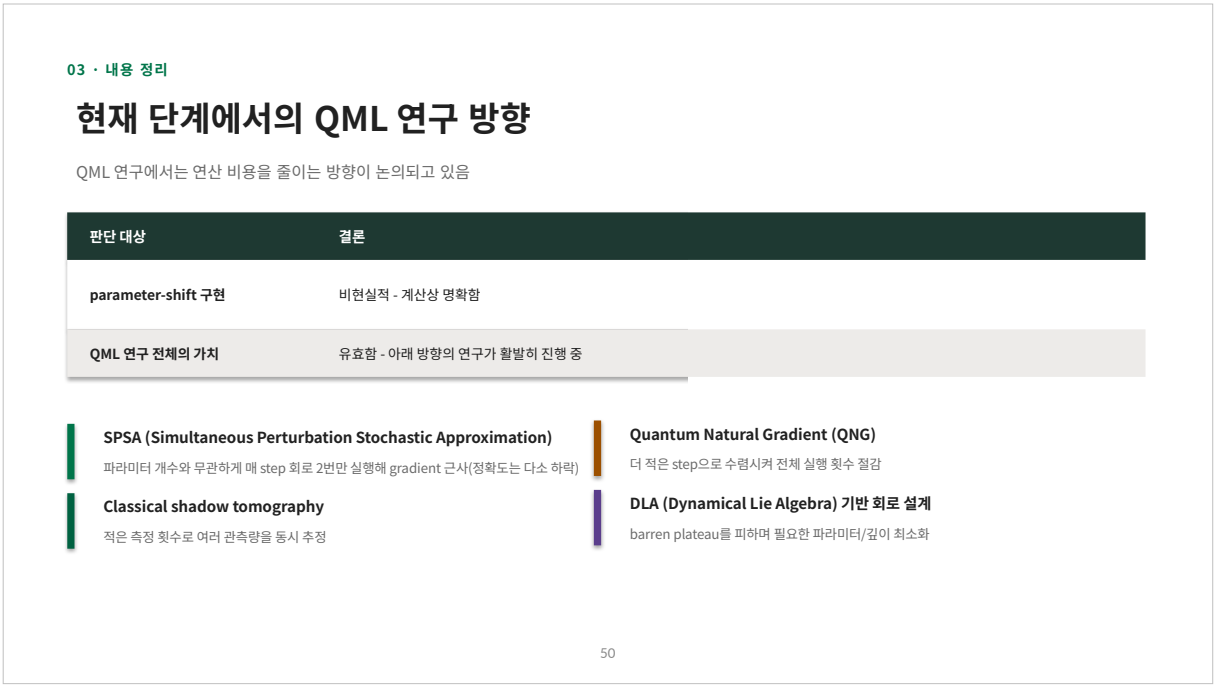
실측 (로컬 CPU, README)
QGAN 600 step: 클래스 평균 상관 0.195. MediQ-GAN 25 epoch: 0.365, 단 다양성은 실제의 약 1/8. 두 모델의 평균 형태와 다양성 절충이 다르게 나타남

[약 3분]

오늘 이론이 2·3일차 실습에서 어떻게 구현되는지 정리했습니다. 실습은 Colab 무료 CPU에서 끝까지 실행할 수 있도록 해상도와 학습량을 줄였고, 회로 사양은 줄이지 않았다는 것이 설계 원칙입니다.

QGAN은 sub-generator를 논문의 16개에서 4개로 줄였습니다. 2, 4, 8, 16개를 같은 조건에서 실측했더니 16개에서 판별자가 이겨 loss_d가 0.003까지 떨어지고 품질이 오르지 않았고, 4개가 가장 좋았습니다. MediQ-GAN은 양자 stream 사양을 그대로 쓰되 고전 부분과 판별자는 MLP와 표준 BCE로 단순화했습니다. 평가는 16×16에서 FID를 쓸 수 없어 지표 4종을 사용합니다.

실측 결과는 QGAN 600 step에서 클래스 평균 상관이 0.195, MediQ-GAN 25 epoch에서 0.365이지만, MediQ-GAN의 다양성은 실제의 약 1/8로 비슷한 이미지를 반복합니다. 평균 형태와 다양성 사이의 절충이 두 모델에서 다르게 나타나는 것을 3일차에 직접 확인하게 됩니다.



[약 3분]

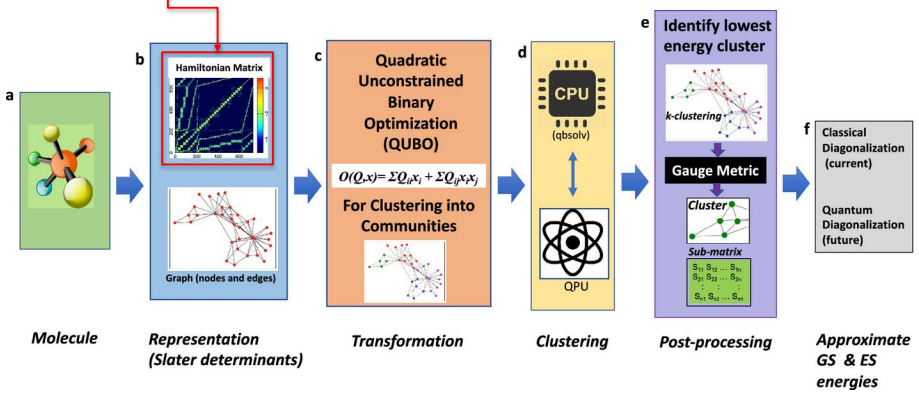
현재 단계의 QML 연구 방향입니다. 앞에서 본 것처럼 parameter-shift를 그대로 구현하는 것은 비현실적이지만 QML 연구 전체의 가치는 유효하며, 연산 비용을 줄이는 연구가 활발합니다.

SPSA는 파라미터 수와 무관하게 step마다 회로를 두 번만 실행해 gradient를 근사하는 방법으로 정확도는 다소 낮아집니다. Quantum Natural Gradient는 더 적은 step으로 수렴시켜 전체 실행 횟수를 줄입니다. Classical shadow tomography는 적은 측정으로 여러 관측량을 동시에 추정하고, DLA 기반 회로 설계는 barren plateau를 피하면서 필요한 파라미터와 깊이를 줄입니다. MediQ-GAN 논문도 향후 과제로 QNG와 회로 설계를 언급합니다.

03 · 내용 정리

이미지 생성 분야에서 양자 알고리즘 유의점

양자 생성 모델은 **양자 데이터, 해밀토니안 상태 등을 만드는 데** 특화되어 있기에, **기존 데이터가 많은 영역, 모델, 컴퓨팅이 잘하는 영역에 대한 성과는 검증 단계**



51

그림 출처: https://www.nature.com/articles/s41598-021-83561-x (CC BY 4.0)

[약 2분]

마지막으로 이미지 생성 분야에서 양자 알고리즘을 해석할 때의 유의점입니다. 양자 생성모델은 양자 데이터나 해밀토니안 상태처럼 양자적 대상을 만드는 데 특화되어 있습니다. 그림은 분자의 해밀토니안 행렬을 그래프로 바꿔 QUBO로 풀고 양자 대각화로 이어지는 양자화학 pipeline이고, 빨간 박스가 양자적 대상을 다루는 부분입니다.

반면 이미지처럼 기존 데이터가 많고 고전 모델과 컴퓨팅이 잘 발달한 영역에서는 양자 모델의 우위가 아직 검증 단계에 있습니다. 오늘 본 두 논문의 결과도 이 맥락에서 읽어야 합니다.

감사합니다.

52

[약 1분]

이것으로 1일차 이론을 마칩니다. 질문을 받겠습니다. 2일차에는 전처리와 QGAN 학습 실습을 진행합니다.