QML Lecture

양자 머신러닝
의료 이미지 데이터 증강

1

[약 1분]

안녕하세요, 오늘부터 3주간 진행할 양자 머신러닝 강의의 1일차입니다. 주제는 의료 이미지 데이터 증강이고, 1일차는 2·3일차 실습에 필요한 이론을 정리하는 시간입니다.

오늘 순서는 네 부분입니다. 먼저 HAM10000 데이터셋과 클래스 불균형 문제를 확인하고, 이어서 GAN과 양자회로의 기초를 정리합니다. 그다음 QGAN 논문과 MediQ-GAN 논문의 구조와 결과를 차례로 살펴보고, 마지막으로 두 논문을 같은 기준으로 비교합니다.

기초 부분이 끝나는 지점에서 한 차례 휴식을 두겠습니다.



[약 1분]

전체적인 QML 목차입니다. 오늘은 이론이고, 2일차에는 전처리와 QGAN 학습, 3일차에는 MediQ-GAN 학습을 Colab에서 직접 실행합니다.

오리엔테이션

학습목표

INDEX

1. HAM10000 데이터셋 EDA와 클래스 불균형 문제
2. GAN 학습 구조·평가 지표(FID, LPIPS)와 양자회로 기초(qubit, 게이트, 측정, VQC)
3. QGAN과 고전 GAN의 차이 - patch 방식 아키텍처
4. 아키텍처 '전체가 양자'(QGAN)와 '일부만 양자'(MediQ-GAN, dual-stream) 차이 구분
5. 두 논문의 결과를 같은 기준(비교 대상, 지표, 실행 환경)으로 해석

3

[약 1분]

오늘의 학습목표는 다섯 가지입니다.

첫째, HAM10000의 클래스 분포를 확인하고 불균형이 왜 문제인지 설명할 수 있어야 합니다. 둘째, GAN의 학습 구조와 평가 지표, 그리고 양자회로의 기본 요소를 이해합니다. 셋째, QGAN이 고전 GAN과 어디가 다른지, patch 방식이 무엇인지 설명합니다. 넷째, 생성자 전체가 양자회로인 QGAN과 일부만 양자인 MediQ-GAN의 구조적 차이를 구분합니다. 다섯째, 두 논문의 결과를 비교 대상, 지표, 실행 환경이라는 같은 기준으로 해석합니다.

01 · 데이터셋

HAM10000 데이터셋

"Human Against Machine with 10,000 training images" - 피부병변 진단 AI 연구의 대표 벤치마크

10,015
총 이미지 수
피부경검사(dermatoscopic) 촬영

7
병변 클래스 수
akiec·bcc·bkl·df·mel·nv·vasc

600×450
원본 해상도
RGB, 실제 임상 촬영 이미지



akiec · 광선각화증 | bcc · 기저세포암 | bkl · 양성각화증 | **df · 피부섬유종**

mel · 흑색종 | **nv · 모반** | vasc · 혈관병변

병변 유형	코드	이미지 수	비율
광선각화증 (Actinic keratoses)	akiec	327	3.3%
기저세포암 (Basal cell carcinoma)	bcc	514	5.1%
양성각화증 (Benign keratosis-like lesions)	bkl	1,099	11.0%
피부섬유종 (Dermatofibroma)	**df**	**115**	**1.1%**
흑색종 (Melanoma)	mel	1,113	11.1%
모반 (Melanocytic nevi)	**nv**	**6,705**	**66.9%**
혈관병변 (Vascular lesions)	vasc	142	1.4%

4

이미지·데이터 출처: HAM10000 (Tschandl et al., Scientific Data 5, 180161, 2018)

[약 1분]

사용하는 데이터는 HAM10000입니다. 'Human Against Machine with 10,000 training images'의 약자이고, 피부경 검사로 촬영한 이미지 10,015장으로 구성됩니다. 병변 클래스는 7개이고 원본 해상도는 600×450 RGB입니다.

오른쪽 표의 클래스별 수를 보면 편차가 매우 큽니다. 모반(nv)이 6,705장으로 66.9%를 차지하고, 피부섬유종(df)은 115장으로 1.1%입니다. 두 클래스의 비율은 약 1 대 58입니다.

이 강의에서 증강 대상은 df, 비교 기준은 nv입니다. 두 클래스를 강조 표시한 이유입니다.

01 · 데이터셋

EDA 분석 결과 : 데이터 불균형

클래스	이미지 수
광선각화증 (akiec)	327
기저세포암 (bcc)	514
양성각화증 (bkl)	1,099
피부섬유종 (df)	**115**
흑색종 (mel)	1,113
모반 (nv)	**6,705**
혈관병변 (vasc)	142

클래스 불균형 데이터 처리 방법

방법	설명	한계
Under sampling	소수 클래스에 맞춰, 다수 클래스를 줄임	정보 손실 - NV 6,500장 넘게 버려야 함
Over sampling	소수 클래스를 복제해서 늘림	복제본이라 새로운 정보가 없음 - 과적합 위험
Augmentation 기하학적 증강	회전·반전·크롭 등으로 변형	병변의 실제 형태·질감 다양성은 만들지 못함
생성모델(GAN/QGAN)	학습된 분포에서 '새로운' 그럴듯한 샘플 생성	품질 검증 필요

초점

- QGAN이 '고전 GAN보다 좋다'가 결론은 아님
- QGAN의 실제 동작 방식과 조건을 논문 데이터로 확인

5

표 출처: HAM10000 메타데이터 (Tschandl et al., Scientific Data 5, 180161, 2018)

[약 2분]

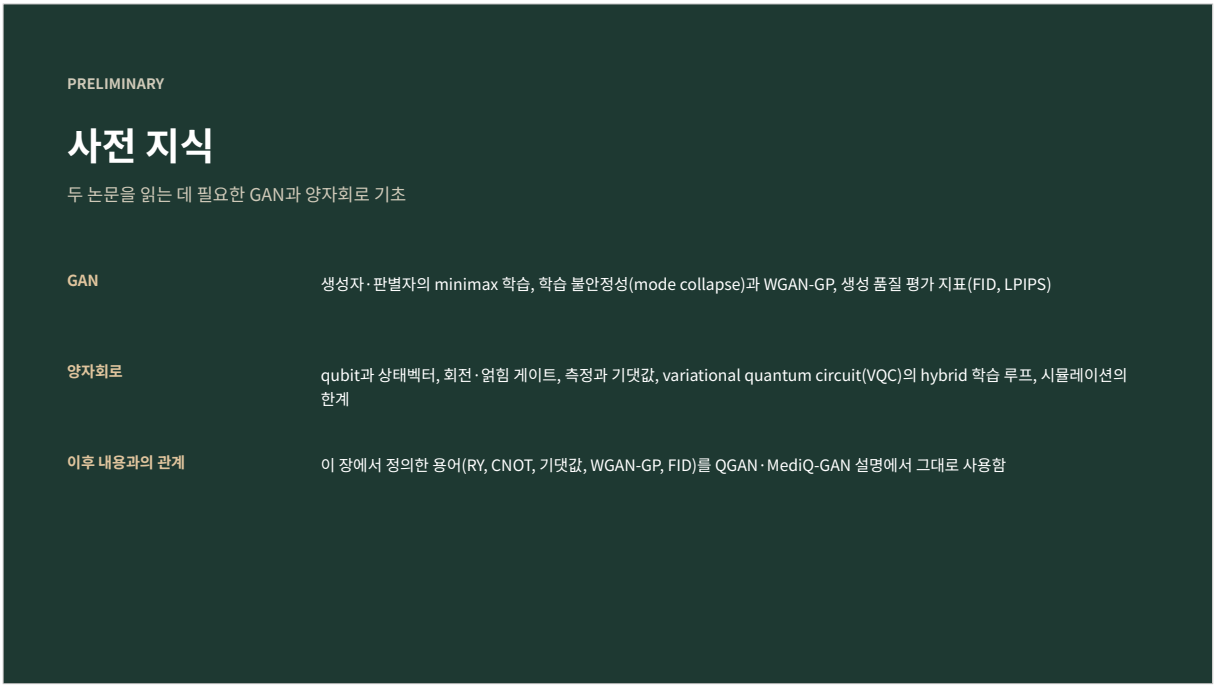
불균형 데이터를 다루는 방법은 크게 네 가지입니다.

Under sampling은 다수 클래스를 줄이는 방법으로, nv를 df 수준으로 맞추려면 6,500장 넘게 버려야 해서 정보 손실이 큽니다.

Over sampling은 소수 클래스를 복제하는 방법인데, 복제본에는 새로운 정보가 없어 과적합 위험이 있습니다. 기하학적 증강은 90, 180, 270도 또는 임의 각도 회전, 좌우 또는 상하 반전, 이미지 축소, 크롭으로 변형하지만 병변의 실제 형태와 질감의 다양성을 만들지는 못합니다.

생성모델은 학습한 분포에서 새로운 샘플을 만든다는 점에서 위 세 방법과 다릅니다. 다만 생성된 이미지가 실제로 유용한지는 별도로 검증해야 합니다.

아래 초점 상자에 적은 것처럼 이 강의의 질문은 'QGAN이 고전 GAN보다 좋은가'가 아닙니다. QGAN이 실제로 어떻게 동작하고 어떤 조건에서 성립하는지를 논문 데이터로 확인하는 것이 목적입니다.



[약 2분]

두 논문을 읽기 위한 사전 지식을 먼저 정리하겠습니다. GAN 쪽에서는 구조와 학습 목표, 학습 불안정성과 WGAN-GP, 그리고 생성 품질을 평가하는 지표와 그 용어를 다룹니다. 양자 쪽에서는 양자 컴퓨팅과 양자 머신러닝의 위치, 중첩·얽힘·간섭의 역할, variational quantum circuit(VQC)를 신경망 layer에 대응시키는 관점을 먼저 정리하고, 이후에 상태벡터, 게이트, 측정, 학습 루프를 구체적으로 보겠습니다.

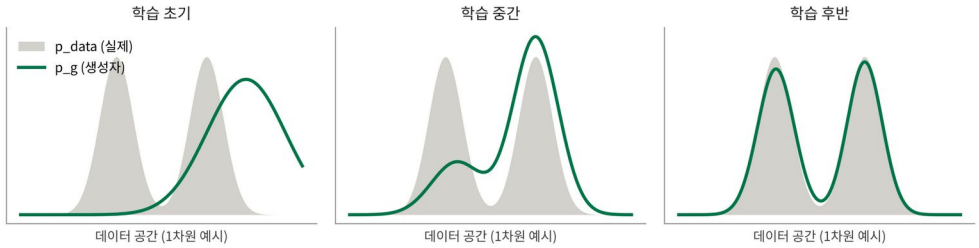
여기서 정의한 용어는 이후 두 논문 설명에서 별도 설명 없이 사용합니다.

사전 지식 장의 구성은 다음과 같습니다. GAN 부분은 도입 세 장으로 시작해 목적함수, 학습 불안정성과 그 시각화, 평가 지표 용어 순으로 이어지고, 양자 부분은 개요, 세 가지 성질, layer 대응, 상태벡터, Bloch 구, 게이트, 측정, 학습 루프, encoding 방식, 시뮬레이션 한계 순입니다.

사전 지식 · GAN

GAN: 적대적 학습으로 데이터 분포를 근사하는 생성모델

Generative Adversarial Network(생성적 적대 신경망). Goodfellow et al., NeurIPS 2014



- **목적**: 실제 분포 p_data를 근사하는 생성 분포 p_g를 학습해 새 샘플을 만듦
- **구성**: 생성자 G와 판별자 D, 두 신경망
- **학습 신호**: D의 판단이 G의 손실이 됨. 정답 이미지와 픽셀 단위로 비교하지 않음

의료 이미지 증강에서의 용도

희귀 병변은 수집이 어렵고 개인정보 문제로 공유가 제한됨
소수 클래스(df 115장)를 새 샘플로 보충. 유용성은 지표로 별도 검증

7

그림: 개념도(1차원 예시). 수치 데이터가 아님

[약 2분]

GAN은 Generative Adversarial Network의 약자이고, 우리말로는 생성적 적대 신경망입니다. 2014년 Goodfellow 등이 NeurIPS에 발표한 생성모델입니다.

위 그림은 GAN이 무엇을 학습하는지를 1차원 예시로 보여 줍니다. 회색 영역이 실제 데이터 분포 p_data이고, 초록 선이 생성자가 만드는 분포 p_g입니다. 학습 초기에는 p_g가 엉뚱한 위치에 있고, 중간에는 한쪽 mode만 맞추며, 후반에는 두 mode를 모두 덮습니다. 즉 GAN의 목적은 개별 이미지를 외우는 것이 아니라 분포를 근사하는 것입니다. 중간 단계처럼 한쪽 mode에 머무는 현상은 뒤의 학습 불안정성 슬라이드에서 mode collapse로 다시 나옵니다.

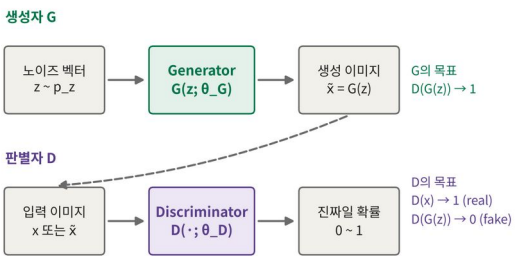
아래 왼쪽 상자에 정리했듯이 GAN은 생성자와 판별자 두 신경망으로 구성되고, 판별자의 판단이 생성자의 손실이 됩니다. 정답 이미지와 픽셀 단위로 비교하지 않는다는 점이 autoencoder 같은 재구성 모델과 다릅니다.

의료 영상에서 GAN을 쓰는 이유를 덧붙이면, 희귀 병변 영상은 수집이 어렵고 개인정보 문제로 공유도 제한되어 학습 데이터가 부족합니다. 이 강의의 대상인 df 클래스는 115장입니다. 생성모델이 학습 분포에서 새로운 샘플을 만들 수 있다면 이 부족분을 보충하는 수단이 될 수 있습니다. 다만 앞의 EDA에서 말씀드렸듯이 생성된 이미지가 실제로 유용한지는 별도로 검증해야 하고, 이 강의는 그 검증 방법까지 다룹니다.

사전 지식 · GAN

생성자와 판별자의 역할

두 신경망은 입력·출력이 다르고 목표가 서로 반대임. 이 반대 관계가 '적대적'의 의미임



항목	생성자 G	판별자 D
입력	노이즈 벡터 z	이미지 (실제 x 또는 생성 x̂)
출력	이미지 x̂ = G(z)	진짜일 확률 (0 ~ 1)
목표	D(G(z))를 1에 가깝게	D(x)는 1, D(G(z))는 0에 가깝게
모델 유형	생성모델	이진 분류기

두 논문에서의 구현

QGAN · MediQ-GAN 모두 G에만 양자회로를 넣고 D는 고전 신경망으로 둠. D는 QGAN이 5층 완전연결(Table 4), MediQ-GAN이 convolutional critic

8

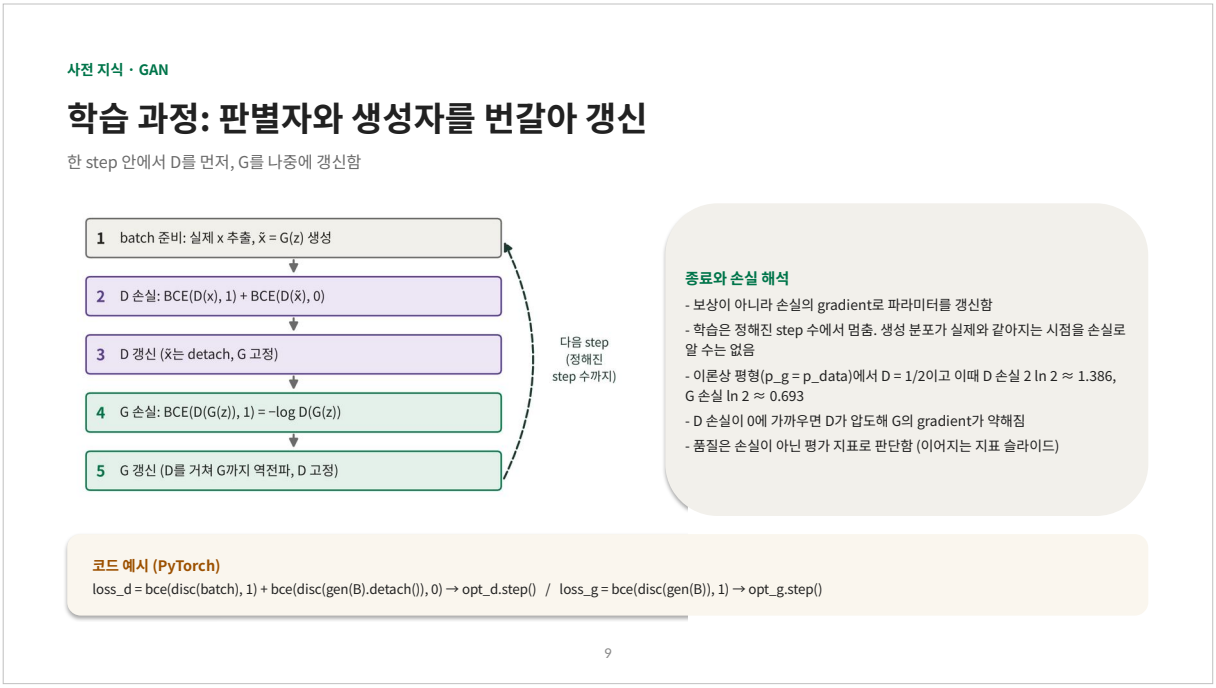
[약 2분]

두 모델의 역할을 정리하겠습니다. 생성자는 무작위 노이즈 벡터 z를 입력받아 이미지를 출력하는 신경망이고, 목표는 판별자가 생성 이미지를 진짜로 판단하게 만드는 것, 즉 D(G(z))를 1에 가깝게 만드는 것입니다.

판별자는 이미지를 입력받아 그것이 진짜일 확률을 0과 1 사이 값으로 내는 이진 분류기입니다. 목표는 실제 이미지에는 1, 생성 이미지에는 0을 내는 것입니다. 그림의 점선은 생성자의 출력이 판별자의 입력으로 들어간다는 뜻입니다.

D(G(z))에 대해 생성자는 1을, 판별자는 0을 원합니다. 같은 값에 대해 두 모델의 목표가 반대라는 점이 적대적이라는 이름의 의미입니다.

아래 상자처럼 QGAN과 MediQ-GAN 모두 양자회로는 생성자에만 들어가고 판별자는 고전 신경망이라는 점을 기억해 두시기 바랍니다. 판별자는 QGAN이 5층 완전연결 신경망, MediQ-GAN이 convolutional critic으로 서로 다릅니다.



[약 2분]

학습은 한 step 안에서 판별자와 생성자를 번갈아 갱신하는 방식으로 진행됩니다.

첫째, 실제 이미지 batch를 뽑고 생성자로 가짜 batch를 만듭니다. 둘째, 판별자 손실을 계산합니다. 실제 이미지에는 라벨 1, 생성 이미지에는 라벨 0을 두고 binary cross entropy를 더합니다. 셋째, 판별자를 갱신합니다. 이때 생성 이미지는 detach해서 생성자로 gradient가 흘러가지 않게 합니다. 넷째, 생성자 손실을 계산합니다. 생성 이미지에 라벨 1을 붙여 binary cross entropy를 구하며, 이는 −log D(G(z))와 같습니다. 다섯째, 이 손실을 판별자를 거쳐 생성자까지 역전파해 생성자만 갱신합니다.

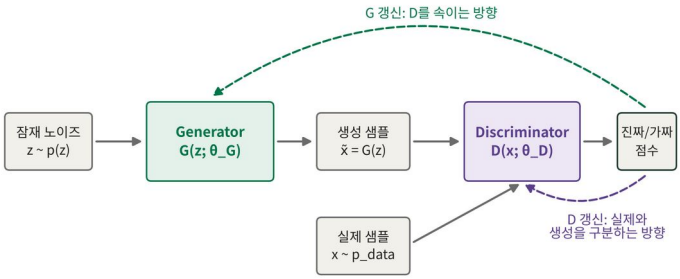
오른쪽 상자의 첫 줄처럼 갱신은 보상이 아니라 손실의 gradient로 이루어집니다. 학습은 정해진 step 수에서 멈춥니다. 이론상 생성 분포가 실제 분포와 같아지면 판별자 출력은 모든 입력에서 1/2이 되고, 이때 판별자 손실은 2 ln 2, 약 1.386, 생성자 손실은 ln 2, 약 0.693입니다.

판별자 손실이 0에 가까워지면 판별자가 압도한 상태여서 생성자가 받는 gradient가 약해집니다. 다만 손실 값만으로 생성 품질을 판단할 수는 없으므로 별도의 평가 지표가 필요하고, 이 내용이 뒤의 지표 슬라이드로 이어집니다.

사전 지식 · GAN

GAN의 목적함수(minimax)

앞의 학습 과정을 하나의 목적함수와 갱신 방향으로 정식화함



- **D 갱신**: 실제 x는 1, 생성 x̂는 0으로 분류하도록 V를 최대화
- **G 갱신**: D가 x̂를 1로 판단하도록 V를 최소화
- **D의 최적해**: D*(x) = p_data(x) / (p_data(x) + p_g(x)). p_g = p_data이면 1/2
- QGAN · MediQ-GAN은 이 구조에서 G만 양자회로를 포함함

$$\min_G \max_D \; V(D, G) = E[\log D(x)] + E[\log(1 - D(G(z)))]$$

x ~ p_data(실제), z ~ p_z(노이즈). G의 손실은 학습 초반 gradient 소실을 피하려고 −log D(G(z))로 바꿔 쓰는 경우가 많음

10

[약 2분]

앞에서 본 학습 과정을 하나의 식으로 정리하겠습니다. 목적함수 V(D, G)는 판별자가 실제 데이터에 대해 log D(x)를, 생성 데이터에 대해 log(1 − D(G(z)))를 키우는 형태입니다. 판별자는 V를 최대화하는 방향, 즉 실제는 1에 가깝게 생성은 0에 가깝게 분류하도록 갱신되고, 생성자는 V를 최소화하는 방향, 즉 판별자가 생성 샘플을 진짜로 판단하도록 갱신됩니다. 오른쪽 상자의 D의 최적해는 생성자를 고정했을 때 V를 최대화하는 판별자이고, 생성 분포가 실제 분포와 같으면 모든 입력에서 1/2이 됩니다.

생성자의 손실은 log(1 − D(G(z)))를 그대로 쓰기보다 −log D(G(z))로 바꿔 쓰는 경우가 많습니다. 학습 초반에 판별자가 압도하면 앞의 형태는 gradient가 거의 0이 되기 때문입니다. 이 점은 다음 슬라이드의 학습 불안정성과 이어집니다.

QGAN과 MediQ-GAN 모두 이 구조에서 생성자만 양자회로를 포함하도록 바꾼 모델입니다. 그림의 Generator 상자 안이 이 강의 전체의 관심 대상입니다.

수식을 읽는 순서를 한 번 더 정리하겠습니다. 첫째 항은 실제 데이터 x가 판별자를 통과했을 때의 로그 확률이고, 둘째 항은 생성 데이터 G(z)가 판별자를 통과했을 때 가짜일 확률의 로그입니다. 판별자가 완벽하면 두 항이 모두 0이 되어 V가 최댓값 0이 되고, 판별자가 구분하지 못해 모든 출력이 0.5이면 V는 −2 ln 2, 약 −1.386이 됩니다.

사전 지식 · GAN

학습 불안정성과 WGAN-GP

원 GAN의 손실은 학습이 불안정하고, 두 논문은 서로 다른 학습 목표를 사용함

문제	현상	원인
Vanishing gradient	D가 너무 잘 구분하면 G의 gradient가 0에 수렴	두 분포의 support가 겹치지 않으면 JS divergence가 상수
Mode collapse	G가 일부 유형의 샘플만 반복 생성	D가 다양성을 직접 평가하지 않음
진동	손실이 수렴하지 않고 진동	두 모델을 동시에 최적화하는 min-max 구조

항목	원 GAN (BCE)	WGAN-GP
D의 출력	확률 (시그모이드)	실수 점수 (critic)
손실	BCE: log D(x) + log(1 − D(G(z)))	E[D(x)] − E[D(G(z))] + λ·GP
거리	Jensen-Shannon	Wasserstein-1
안정화	없음	critic gradient 노름을 1로 유도 (1-Lipschitz)
사용 논문	**QGAN (Table 4)**	**MediQ-GAN (식 (1)·(2))**

용어

support: 분포가 0이 아닌 값을 갖는 영역. JS divergence, Wasserstein-1: 두 확률분포 사이의 거리 척도

critic: WGAN에서 판별자 자리의 신경망(확률 대신 실수 점수). 1-Lipschitz: 입력이 변할 때 출력 변화율이 1 이하인 함수

11

[약 3분]

원 GAN의 학습은 불안정한 것으로 알려져 있습니다. 대표적인 문제는 세 가지입니다.

첫째, vanishing gradient입니다. 판별자가 너무 잘 구분하면 생성자에게 전달되는 gradient가 사라집니다. 이론적으로는 실제 분포와 생성 분포의 support, 즉 확률이 0이 아닌 영역이 겹치지 않을 때 Jensen-Shannon divergence가 상수가 되기 때문입니다. Jensen-Shannon divergence("젠슨-섀넌 다이버전스")는 두 확률분포 사이의 거리를 재는 척도의 하나입니다. 둘째, mode collapse입니다. 생성자가 판별자를 속이기 쉬운 몇 가지 유형만 반복해서 만듭니다. 판별자가 다양성을 직접 평가하지 않으므로 생긴 현상입니다. 셋째, 두 모델을 동시에 최적화하는 구조 때문에 손실이 수렴하지 않고 진동하는 문제입니다.

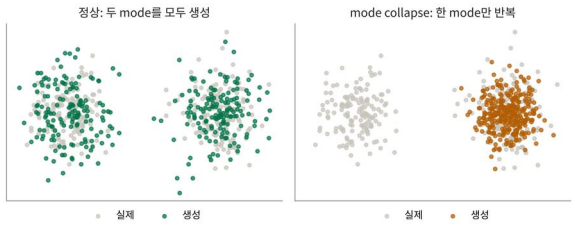
WGAN은 거리 척도를 Wasserstein-1("바서슈타인 원") 거리로 바꿔 이 문제를 줄입니다. 이 거리는 한 분포를 다른 분포로 옮기는 데 드는 최소 비용으로 정의되며, 분포가 겹치지 않아도 값이 의미를 가집니다. critic은 WGAN에서 판별자(discriminator) 자리를 대신하는 신경망입니다. 역할은 판별자와 같고 출력이 다릅니다. 확률 대신 실수 점수를 내며, 손실은 실제와 생성에 대한 critic 출력의 차이입니다. 이때 critic이 1-Lipschitz("원 립시츠")여야 합니다. 입력이 변할 때 출력이 변하는 비율이 1 이하인 함수라는 뜻입니다. WGAN-GP는 critic gradient의 노름이 1에서 벗어나는 만큼 벌점을 부여해 이 조건을 맞춥니다.

두 논문의 선택은 다릅니다. QGAN 논문은 Table 4에서 Binary Cross Entropy를 사용하고, MediQ-GAN 논문은 WGAN-GP를 기본 학습 목표로 삼습니다.

사전 지식 · GAN

학습 불안정성 시각화: mode collapse, JS 대 Wasserstein

앞 슬라이드의 두 문제를 2차원 예시와 거리 척도 비교로 확인함





mode collapse

- 실제 분포가 두 mode(예: 서로 다른 두 병변 형태)를 가져도 한 mode만 반복하면 판별자를 속일 수 있음
- 다양성 지표(LPIPS, 샘플 간 거리)로 점검함

vanishing gradient와 WGAN

- support가 겹치지 않으면 JS는 ln 2로 일정해 생성자에게 방향 정보가 없음
- Wasserstein-1은 거리에 비례해 gradient가 남음

12

개념도(2차원 예시와 점질량 분포 가정). 수치 데이터가 아님

[약 2분]

앞 슬라이드의 두 문제를 그림으로 확인하겠습니다.

왼쪽은 mode collapse입니다. 실제 분포가 두 덩어리, 즉 mode를 가진다고 가정한 2차원 예시입니다. 위쪽 정상 사례에서는 생성 분포가 두 mode를 모두 덮고, 아래쪽 mode collapse에서는 한쪽 mode만 반복해서 생성합니다. 판별자는 개별 샘플이 진짜 같은지만 판단하므로, 한 mode에서 아주 그럴듯한 샘플만 만들어도 속일 수 있습니다. 병변 이미지에 대응시키면 서로 다른 형태의 병변을 만들지 못하고 비슷한 모양만 반복하는 상태입니다. 이를 점검하는 것이 샘플 간 거리와 LPIPS 같은 다양성 지표입니다.

오른쪽은 vanishing gradient와 WGAN의 관계입니다. 두 분포가 서로 겹치지 않으면, 얼마나 멀리 떨어져 있든 Jensen-Shannon 거리는 ln 2로 일정합니다. 값이 변하지 않으면 gradient가 0이므로 생성자는 어느 방향으로 가야 하는지 알 수 없습니다. Wasserstein-1 거리는 분포 사이의 거리에 비례해 커지므로 겹치지 않는 구간에서도 방향 정보가 남습니다. 이것이 WGAN을 쓰는 이유입니다.

이 그림은 개념을 보이기 위한 예시이며 실험 데이터가 아닙니다.

사전 지식 · GAN

생성 품질 평가: 지표별 측정 대상

생성 이미지의 품질은 눈으로 판단하기 어려워 정량 지표를 병행함. 용어는 이어지는 세 장에서 풀어 설명함

지표	측정 대상	방향
Downstream 분류 성능 (AUC-ROC, 정확도)	생성 이미지를 학습 데이터에 추가했을 때 분류기 성능 변화 QGAN 논문, MediQ-GAN Table 1	높을수록 좋음
FID	실제와 생성 이미지의 Inception 특징 분포(평균·공분산) 사이 Fréchet 거리 MediQ-GAN 논문 (클래스별)	낮을수록 좋음
intra-class LPIPS	같은 클래스 생성 이미지 쌍의 지각적 거리 평균. mode collapse 점검 MediQ-GAN 논문	높을수록 다양

해석 시 유의

- FID가 낮아도 LPIPS가 낮으면 비슷한 이미지만 생성한 것이므로 두 지표를 함께 봄
- 표본이 적은 클래스(df 115장)에서는 FID 공분산 추정이 불안정함
- 분류 성능은 분류기와 증강 비율에 의존함
- 정확도만으로는 불균형 데이터의 성능을 판단하기 어려워 AUC를 함께 봄

13

[약 2분]

생성 이미지의 품질은 눈으로 보는 것만으로 판단하기 어렵기 때문에 정량 지표를 함께 사용합니다. 논문에서 쓰는 지표는 세 가지이고, 각 지표의 용어는 이어지는 세 장에서 풀어서 설명합니다.

첫째, downstream 분류 성능입니다. 생성 이미지를 학습 데이터에 추가했을 때 분류기의 AUC와 정확도가 어떻게 변하는지 봅니다. 목적에 가장 직접적이지만 분류기와 증강 비율에 따라 결과가 달라집니다. 둘째, FID입니다. 실제 이미지 집합과 생성 이미지 집합의 분포가 얼마나 가까운지를 특징 공간에서 재며, 낮을수록 좋습니다. 셋째, intra-class LPIPS입니다. 같은 클래스에서 생성한 이미지끼리 얼마나 다른지를 재며, 높을수록 다양하다는 뜻이고 mode collapse 점검에 쓰입니다.

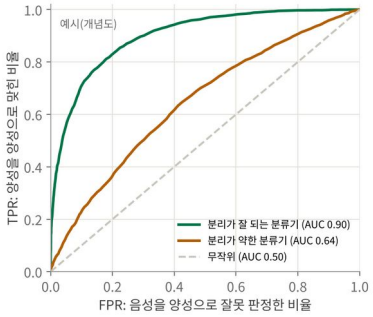
오른쪽 상자의 유의점은 세 가지입니다. FID가 낮아도 LPIPS가 낮으면 비슷한 이미지만 만든다는 의미이므로 두 지표를 함께 봅니다. 표본이 적은 클래스에서는 FID의 공분산 추정이 불안정합니다. 정확도만으로는 불균형 데이터의 성능을 판단하기 어려워 AUC를 함께 봅니다.

사전 지식 · 평가 지표

지표 용어 ① 분류 성능: 정확도, ROC, AUC

증강 효과를 분류기 성능으로 확인할 때 쓰는 용어

용어	설명
downstream 평가	생성 이미지를 실제로 쓰는 후속 작업(여기서는 분류)의 성능으로 생성 품질을 간접 평가
양성 / 음성	찾으려는 클래스(df)를 양성, 비교 클래스(nv)를 음성으로 둠 (이진 분류)
정확도	전체 중 맞힌 비율, (TP + TN) / 전체. df 대 nv 분류에서 nv가 98.3%(6,705 / 6,820)이므로 모두 nv로 답해도 98.3%라서 불균형 데이터에서는 높게 나옴
ROC 곡선	판정 기준값(threshold)을 바꾸며 TPR(양성을 맞힌 비율)과 FPR(음성을 양성으로 잘못 판정한 비율)을 그린 곡선
AUC	ROC 곡선 아래 면적. 무작위 양성이 무작위 음성보다 높은 점수를 받을 확률. 0.5는 무작위, 1.0은 완벽. 기준값과 클래스 비율의 영향을 덜 받음



TP, TN: 양성, 음성을 맞힌 수. 곡선이 왼쪽 위로 휠수록 AUC가 큼

14

[약 3분]

분류 성능 지표의 용어를 먼저 정리하겠습니다.

downstream 평가는 생성 이미지를 실제로 쓰는 후속 작업의 성능으로 생성 품질을 간접 평가하는 방식입니다. 여기서 후속 작업은 df와 nv를 구분하는 이진 분류입니다. 이진 분류에서는 찾으려는 클래스를 양성, 비교 클래스를 음성이라고 부르고, 이 강의에서는 df가 양성, nv가 음성입니다.

정확도는 전체 중 맞힌 비율입니다. 양성을 양성으로 맞힌 수 TP와 음성을 음성으로 맞힌 수 TN을 더해 전체로 나눕니다. df와 nv만 구분하는 이진 분류에서는 nv가 6,705장으로 98.3%(6,705 / 6,820)를 차지하므로, 모든 이미지를 nv로 답해도 정확도가 98.3%가 됩니다. 불균형 데이터에서 정확도가 높게 나와도 성능이 좋다고 단정할 수 없는 이유입니다.

그래서 AUC를 함께 봅니다. 분류기는 이미지마다 양성일 점수를 내고, 점수가 판정 기준값을 넘으면 양성으로 판정합니다. 기준값을 바꾸면서 양성을 맞힌 비율 TPR과 음성을 양성으로 잘못 판정한 비율 FPR을 그린 것이 ROC 곡선이고, 그 아래 면적이 AUC입니다. 의미는 무작위로 고른 양성이 무작위로 고른 음성보다 높은 점수를 받을 확률입니다. 0.5는 무작위, 1.0은 완벽한 분리입니다. 기준값을 하나로 정하지 않고 클래스 비율의 영향도 덜 받기 때문에 불균형 데이터의 비교에 많이 쓰입니다.

오른쪽 그림은 개념을 보이기 위한 예시입니다. 두 클래스의 점수 분포가 많이 떨어져 있으면 곡선이 왼쪽 위로 휘고 AUC가 커집니다.

사전 지식 · 평가 지표

지표 용어 ② FID: Inception 특징과 Fréchet 거리

실제 이미지 집합과 생성 이미지 집합이 얼마나 비슷한 분포인지를 한 숫자로 나타냄

용어	설명
Inception 특징	ImageNet으로 사전학습한 Inception-v3의 마지막 pooling 출력(2,048차원). 이미지를 숫자 벡터로 바꾼 표현
특징 분포	이미지 집합을 특징 공간의 점 구름으로 보고 평균 μ와 공분산 Σ로 요약(가우시안 근사)
Fréchet 거리	두 가우시안 사이의 거리. 평균 차이와 분산 형태 차이를 함께 반영함
FID 해석	0에 가까울수록 두 분포가 비슷함. 클래스당 표본이 적으면 Σ 추정이 불안정함

$$FID = \| \mu_r - \mu_g \|^2 + Tr(\Sigma_r + \Sigma_g - 2(\Sigma_r \Sigma_g)^{1/2})$$



읽는 법

- r은 실제(real), g는 생성(generated) 이미지 집합
- 왼쪽 그림: 분포가 겹쳐 FID 낮음. 오른쪽: 분포가 어긋나고 일부 영역만 덮어 FID 높음
- 표본이 적은 클래스(df 115장)는 공분산 추정이 불안정해 FID 변동이 큼

15

[약 3분]

FID의 용어를 풀어서 설명하겠습니다. FID는 Fréchet Inception Distance의 약자입니다.

먼저 Inception 특징입니다. ImageNet으로 사전학습한 Inception-v3 네트워크에 이미지를 넣고 마지막 pooling 층의 출력을 꺼내면 2,048차원 벡터가 되는데, 이 벡터가 이미지를 숫자로 요약한 표현입니다. 픽셀을 직접 비교하지 않고 이 특징 공간에서 비교하는 이유는 픽셀 차이가 사람이 느끼는 유사성과 잘 맞지 않기 때문입니다.

이미지 집합 전체는 이 공간에서 점 구름이 됩니다. 이를 평균 μ와 공분산 Σ로 요약하고 가우시안 분포로 근사합니다. 실제 이미지 집합과 생성 이미지 집합 각각에 대해 이 요약을 구한 뒤, 두 가우시안 사이의 Fréchet 거리를 계산한 것이 FID입니다. 식의 첫 항은 평균의 차이, 둘째 항은 공분산의 모양 차이를 반영합니다. 0에 가까울수록 두 분포가 비슷합니다.

오른쪽 그림은 이 개념을 2차원으로 그린 예시입니다. 왼쪽은 생성 분포가 실제 분포와 겹쳐 FID가 낮고, 오른쪽은 생성 분포가 한쪽 영역에만 몰려 FID가 높습니다. 후자는 다양성이 부족한 경우에 해당합니다.

유의할 점은 공분산 추정입니다. 공분산은 표본이 적으면 추정이 불안정하므로 df처럼 표본이 115장인 클래스의 FID는 변동이 큽니다. 또 Inception-v3는 299×299 크기의 자연 이미지로 학습된 네트워크이므로, 해상도가 매우 낮거나 의료 영상처럼 분포가 다른 이미지에서는 특징의 의미가 약해질 수 있습니다.

사전 지식 · 평가 지표

지표 용어 ③ LPIPS: 지각적 거리와 다양성

같은 클래스에서 만든 이미지끼리 얼마나 다른지로 mode collapse를 점검함



d가 클수록 두 이미지가 지각적으로 다름 → 쌍 평균이 높을수록 생성 이미지가 다양함

용어

- **지각적 거리**: 픽셀 값 차이가 아니라 사전학습 CNN 특징으로 잰 이미지 간 차이. 사람의 유사성 판단과 더 잘 맞음
- **LPIPS**: Learned Perceptual Image Patch Similarity. layer별 특징 차이를 학습된 가중치로 합산한 거리

intra-class LPIPS의 해석

- **intra-class**: 같은 클래스 안의 생성 이미지 쌍만 비교함
- 값이 실제 이미지 쌍의 값에 가까우면 다양성이 충분하고, 크게 낮으면 비슷한 이미지만 만드는 mode collapse

16 정의 출처: Zhang et al., The Unreasonable Effectiveness of Deep Features as a Perceptual Metric (CVPR 2018)

[약 2분]

LPIPS는 Learned Perceptual Image Patch Similarity의 약자로, 두 이미지의 지각적 거리를 재는 지표입니다. 지각적 거리는 픽셀 값의 차이가 아니라 사전학습된 CNN의 특징으로 잰 차이를 말하며, 사람이 느끼는 유사성과 더 잘 맞는 것으로 알려져 있습니다.

계산 흐름은 슬라이드의 그림과 같습니다. 두 이미지를 고정된 사전학습 CNN에 넣고, 각 layer의 특징을 채널별로 정규화한 뒤 차이를 제곱합니다. 이 차이를 학습된 가중치로 합산하면 두 이미지 사이의 거리 d가 나옵니다. d가 클수록 두 이미지가 다르다는 뜻입니다.

MediQ-GAN 논문은 이를 intra-class로 사용합니다. 같은 클래스에서 생성한 이미지 쌍만 골라 거리를 구하고 평균을 내며, 값이 높을수록 같은 클래스 안에서도 다양한 이미지를 만든다는 의미입니다. 해석은 실제 이미지 쌍의 값과 비교해서 합니다. 실제 값에 가까우면 다양성이 충분하고, 크게 낮으면 비슷한 이미지만 반복하는 mode collapse가 의심됩니다. 앞에서 본 FID가 분포의 일치를 보는 지표라면, LPIPS는 다양성을 보는 지표라는 점에서 서로 보완적입니다.

사전 지식 · 양자 컴퓨팅

양자 컴퓨팅과 양자 머신러닝

양자회로를 머신러닝 모델의 일부로 쓰는 접근을 데이터와 알고리즘 종류로 분류함



정의

- **양자 컴퓨팅**: 중첩, 얽힘, 간섭을 이용하는 계산 모델. 입력은 큐빗, 연산은 양자 게이트, 출력은 측정
- **양자 머신러닝(QML)**: 양자회로를 학습 가능한 모델의 일부로 사용함
- **hybrid**: 회로는 일부이고 입출력 처리, 손실 계산, optimizer는 고전 컴퓨터가 담당함

이 강의의 범위

QGAN과 MediQ-GAN은 고전 데이터(이미지)를 각도로 바꿔 양자회로에 넣는 CQ 유형임. 양자 컴퓨터가 이미지를 직접 읽는다는 뜻이 아니라, 회로가 파라미터를 가진 함수로 쓰이는 것임

분류 출처: Schuld, Sinayskiy & Petruccione, Contemporary Physics 56 (2015)

[약 2분]

양자 쪽 사전 지식은 먼저 위치를 정리하는 것으로 시작합니다. 양자 컴퓨팅은 양자역학의 중첩, 얽힘, 간섭을 이용하는 계산 모델입니다. 입력은 큐빗, 연산은 양자 게이트, 출력은 측정입니다.

양자 머신러닝은 이 양자회로를 학습 가능한 모델의 일부로 쓰는 것을 말하며, 데이터의 종류와 알고리즘의 종류에 따라 네 가지로 나눕니다. 왼쪽 그림에서 고전 데이터를 고전 알고리즘으로 다루는 것이 일반 머신러닝이고, 양자 시스템 자체를 고전 기법으로 분석하는 것, 양자 데이터를 양자 알고리즘으로 처리하는 것이 나머지입니다. 이 강의의 QGAN과 MediQ-GAN은 고전 데이터인 이미지를 양자 알고리즘으로 처리하는 유형입니다.

이때 양자 컴퓨터가 이미지를 직접 읽는 것은 아닙니다. 이미지나 노이즈의 값을 회전각으로 바꿔 회로에 넣고, 회로를 파라미터를 가진 함수처럼 쓰는 것입니다. 회로는 모델의 일부이고, 입출력 처리와 손실 계산, optimizer는 고전 컴퓨터가 담당하므로 이를 hybrid라고 부릅니다.

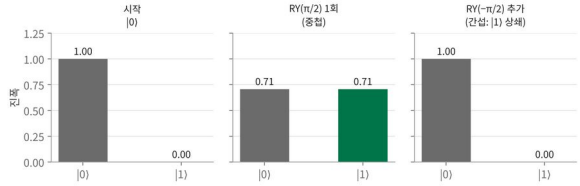
양자 머신러닝에 대한 기대와 현실을 함께 말씀드립니다. 기대는 큐빗 수에 따라 표현 공간이 지수적으로 커진다는 점이지만, 표현 공간이 크다는 것이 곧 성능이 높다는 뜻은 아닙니다. 이 강의에서 다루는 모델은 모두 고전 컴퓨터로 시뮬레이션할 수 있는 규모이므로, 양자 우위를 주장하는 것이 아니라 양자 구성 요소를 가진 생성모델이 실제로 동작하는지를 확인하는 것이 목적입니다. 이 구분은 시뮬레이션 한계 슬라이드에서 다시 다룹니다.

사전 지식 · 양자 컴퓨팅

양자 연산의 세 가지 성질: 중첩, 얽힘, 간섭

세 성질이 회로 안에서 각각 어떤 역할을 하는지를 이 강의의 회로와 연결함

성질	의미	이 강의의 회로에서의 역할
중첩	큐빗이 |0⟩과 |1⟩의 진폭을 동시에 가짐. 측정하면 확률에 따라 하나로 정해짐	RY(θ)로 각도를 조절해 측정 확률을 정함 (노이즈 encoding, 학습 파라미터)
얽힘	여러 큐빗의 측정 결과가 독립이 아니라 상관을 가짐	CNOT, CZ로 픽셀 또는 특징 사이의 상관을 표현함
간섭	진폭이 더해지거나 상쇄되어 측정 확률이 달라짐	variational layer가 진폭을 조합해 확률 분포를 만들고, 학습은 이 결과를 조절함



간섭 예시

- RY(π/2)로 |0⟩과 |1⟩의 진폭이 각각 0.71로 나뉨 (중첩)
- RY(−π/2)를 이어 적용하면 |1⟩의 진폭이 0.71×0.71 − 0.71×0.71 = 0으로 상쇄되어 |0⟩만 남음 (간섭)

18

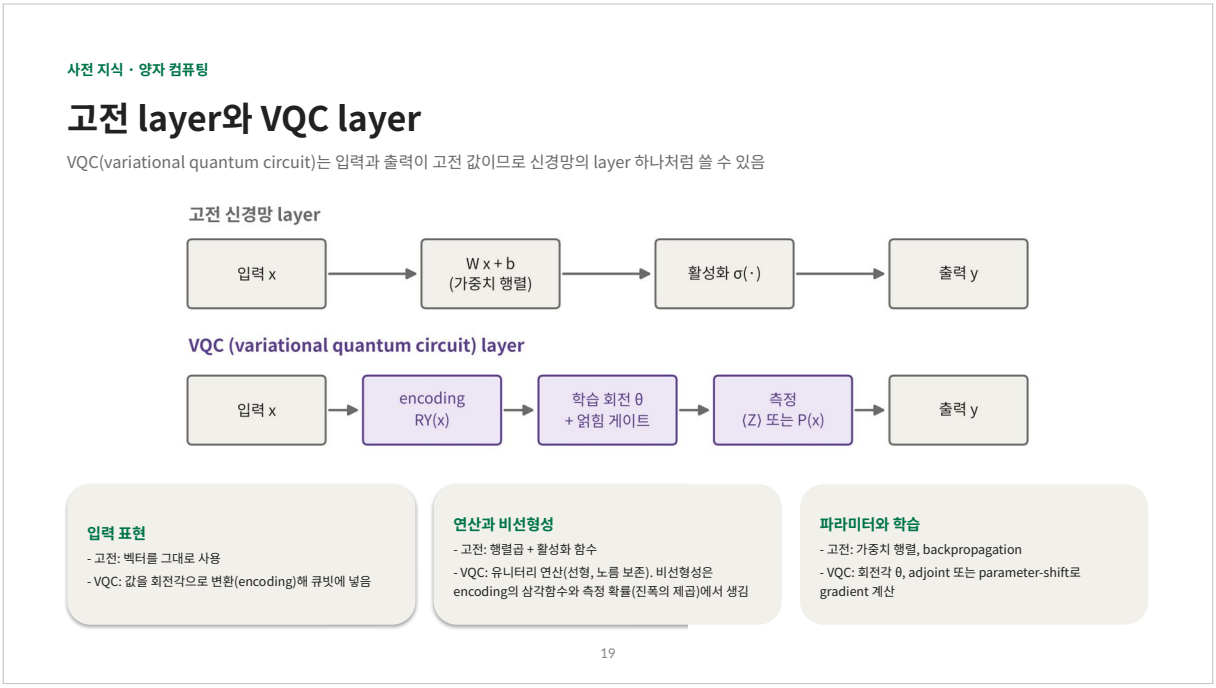
[약 2분]

양자 연산의 세 가지 성질이 이 강의의 회로에서 어떤 역할을 하는지 보겠습니다.

중첩은 큐빗이 |0⟩과 |1⟩의 진폭을 동시에 가지는 것입니다. 측정하면 진폭 크기의 제곱에 해당하는 확률로 하나가 정해집니다. 회로에서는 RY 게이트의 각도로 이 확률을 조절합니다. 노이즈를 넣는 encoding과 학습되는 파라미터가 모두 이 각도입니다.

얽힘은 여러 큐빗의 측정 결과가 독립이 아니라 상관을 가지는 것입니다. 회로에서는 CNOT과 CZ가 이를 만들고, 픽셀이나 특징 사이의 상관을 표현하는 수단이 됩니다.

간섭은 진폭이 더해지거나 상쇄되어 측정 확률이 달라지는 현상입니다. 아래 그림이 가장 작은 예입니다. |0⟩에 RY(π/2)를 적용하면 |0⟩과 |1⟩의 진폭이 각각 0.71이 됩니다. 여기에 RY(−π/2)를 이어 적용하면 |1⟩의 진폭은 0.71×0.71에서 0.71×0.71을 뺀 0이 되어 상쇄되고, |0⟩만 남습니다. variational layer는 이런 진폭의 합과 상쇄를 여러 큐빗에 걸쳐 조합해 최종 확률 분포를 만들고, 학습은 각도를 바꿔 그 결과를 조절하는 과정입니다.



[약 2분]

마지막으로 variational quantum circuit, 즉 VQC를 신경망의 layer와 대응시켜 보겠습니다. 이렇게 대응시켜 두면 이후 슬라이드의 구조도를 읽을 때 기준이 됩니다.

고전 layer는 입력 벡터에 가중치 행렬을 곱하고 활성화 함수를 거쳐 출력을 냅니다. VQC layer는 입력 값을 회전각으로 바꾸는 encoding, 학습되는 회전과 얽힘 게이트, 측정으로 구성되고, 출력은 기댓값이나 확률입니다. 입력과 출력이 모두 고전 값이므로 신경망 안에 layer 하나로 끼워 넣을 수 있습니다.

차이는 세 가지입니다. 입력 표현은 벡터를 그대로 쓰는 대신 각도로 바꿉니다. 연산 측면에서는 회로 자체가 유니터리, 즉 선형이고 노름을 보존하며, 비선형성은 encoding의 삼각함수와 측정 확률이 진폭의 제곱이라는 점에서 생깁니다. 학습 파라미터는 가중치 행렬이 아니라 회전각 θ이고, gradient는 시뮬레이터에서는 adjoint, 실제 장치에서는 parameter-shift로 구합니다.

여기까지가 개념 부분입니다. 다음 장부터는 상태벡터, 게이트, 측정을 구체적인 식과 그림으로 보겠습니다.

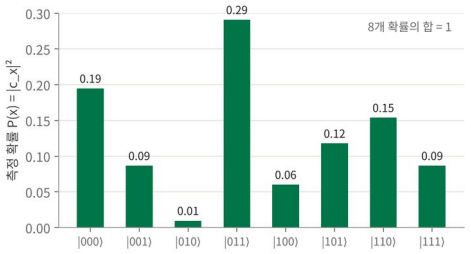
사전 지식 · 양자회로

qubit과 상태벡터

n큐빗 상태는 2ⁿ개의 복소 진폭이며, 측정 확률은 진폭 크기의 제곱

$$|\psi\rangle = \alpha|0\rangle + \beta|1\rangle, \quad |\alpha|^2 + |\beta|^2 = 1$$
$$\text{n큐빗: } |\psi\rangle = \Sigma\, c_x |x\rangle, \quad P(x) = |c_x|^2$$

구분	고전	양자
상태	n bit = 문자열 하나	n큐빗 = 2ⁿ 진폭 벡터
갱신	논리 연산	유니터리 행렬 곱 (노름 보존)
읽기	값을 그대로 읽음	측정 시 확률 P(x)로 bitstring 하나 결정



이후 논문과의 연결

- QGAN: 데이터 7큐빗 → 확률 128개 = patch 픽셀 128개
- MediQ-GAN: 16큐빗 → 상태벡터 65,536차원

20

[약 2분]

지금부터는 양자회로 기초를 다섯 장에 걸쳐 구체적으로 정리합니다. 첫 장은 상태 표현입니다.

1큐빗 상태는 |0⟩과 |1⟩의 선형결합 α|0⟩ + β|1⟩이고, 진폭의 제곱합은 1입니다. n큐빗이 되면 2의 n 제곱 개의 복소 진폭을 가진 벡터가 되며, 이것이 상태벡터입니다. 측정하면 basis state x가 $|c_x|^2$의 확률로 하나 나옵니다.

오른쪽 그림은 3큐빗 예시로, 진폭 8개가 측정 확률 8개로 바뀌고 합이 1이 됩니다. 고전 비트와의 차이는 표에 정리했습니다. 상태는 문자열 하나가 아니라 진폭 벡터이고, 게이트는 노름을 보존하는 유니터리 행렬 곱이며, 읽을 때는 확률에 따라 bitstring 하나가 확률적으로 결정됩니다.

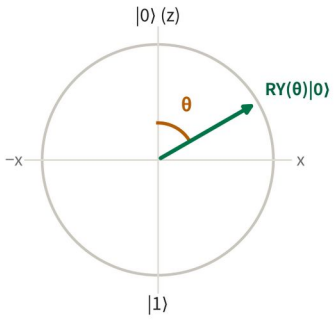
이후 논문과 연결되는 숫자는 두 가지입니다. QGAN은 데이터 큐빗이 7개이므로 확률이 128개 나오고, 이 128개가 patch의 픽셀 값이 됩니다. MediQ-GAN의 양자 stream은 16큐빗이므로 상태벡터 차원이 65,536입니다.

표의 갱신 항목을 보충하면, 고전 비트의 연산은 AND, OR 같은 논리 연산이지만 양자 상태의 연산은 상태벡터에 유니터리 행렬을 곱하는 것입니다. 유니터리는 벡터의 길이를 보존하므로 진폭의 제곱합이 항상 1로 유지됩니다. 측정은 이 상태를 확률분포로 읽는 연산이어서, 같은 회로를 여러 번 실행하면 매번 다른 bitstring이 나올 수 있습니다.

사전 지식 · 양자회로

1큐빗 상태의 시각화: Bloch 구 단면과 RY 회전

RY(θ)는 상태를 x-z 평면의 원 위에서 θ만큼 회전시키고, 측정 확률은 z축 성분이 정함



θ = π/3: $P(0) = \cos^2(\theta/2) = 0.75$, $P(1) = \sin^2(\theta/2) = 0.25$

항목	설명
Bloch 구	1큐빗 순수 상태를 구 위의 한 점으로 나타냄. 북극이 |0⟩, 남극이 |1⟩
RY(θ)	y축 주위의 회전. 상태가 x-z 평면을 벗어나지 않아 이 슬라이드는 그 단면을 그림
측정 확률	z축 성분이 정함. 북극에 가까울수록 0이 나올 확률이 큼
RX, RZ	RX는 x축 주위, RZ는 z축 주위의 회전. RZ는 확률을 바꾸지 않고 위상만 바꿔 간섭에 영향을 줌

읽는 법

θ = 0이면 |0⟩, θ = π이면 |1⟩, θ = π/2이면 x축 방향(50 : 50). 학습은 이 θ들을 조정해 확률 분포를 만드는 과정임

21

[약 2분]

1큐빗 상태를 그림으로 보겠습니다. 1큐빗 순수 상태는 Bloch 구 위의 한 점으로 나타낼 수 있고, 북극이 |0⟩, 남극이 |1⟩입니다. 슬라이드는 구의 x-z 단면입니다.

RY(θ)는 y축 주위의 회전이어서, |0⟩에서 시작하면 상태가 이 단면의 원 위에서만 움직입니다. 그림의 초록 화살표가 θ가 π/3일 때의 상태입니다. 측정 확률은 z축 성분이 정합니다. 화살표가 북극에 가까울수록 0이 나올 확률이 크고, 이 예에서는 P(0)이 0.75, P(1)이 0.25입니다. θ가 0이면 항상 0, π이면 항상 1, π/2이면 x축 방향이 되어 50 대 50입니다.

RX는 x축 주위, RZ는 z축 주위의 회전입니다. RZ는 확률을 바꾸지 않고 위상만 바꾸지만, 뒤이어 다른 게이트가 작용하면 간섭을 통해 확률에 영향을 줍니다. 이 강의의 회로는 RY 중심이고, MediQ-GAN의 encoding에서 RX가 함께 쓰입니다. 학습이란 결국 이 각도들을 조정해 원하는 확률 분포를 만드는 과정입니다.

사전 지식 · 양자회로

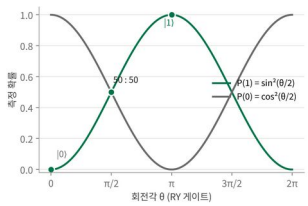
게이트: 회전과 얽힘

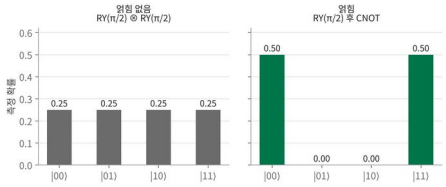
두 논문의 회로는 회전 게이트와 얽힘 게이트 두 종류로만 구성됨

게이트	작용	학습 대상
RY(θ)	$\|0\rangle \to \cos(\theta/2)\|0\rangle + \sin(\theta/2)\|1\rangle$ $P(1) = \sin^2(\theta/2)$	θ (학습)
RX(θ)	X축 회전. MediQ-GAN의 encoding에 사용	입력값 (고정)
CNOT	제어 큐빗이 1이면 목표 큐빗 반전	파라미터 없음
CZ	두 큐빗이 모두 1이면 위상에 −1	파라미터 없음

두 논문의 회로 구성

- QGAN: RY(z) encoding → [RY(θ) + CZ 체인] × depth 10
- MediQ-GAN: RX, RY encoding → [RY(θ) + CNOT 체인] × 8





[약 2분]

게이트를 보겠습니다. 두 논문의 회로는 회전 게이트와 얽힘 게이트 두 종류로만 구성됩니다.

RY(θ)는 Y축 회전이고, |0⟩에 적용하면 cos(θ/2)|0⟩ + sin(θ/2)|1⟩이 됩니다. 따라서 측정 시 1이 나올 확률은 $\sin^2(\theta/2)$입니다. 오른쪽 위 그래프가 이 관계이고, θ가 0이면 항상 0, π이면 항상 1, π/2이면 50 대 50입니다. 각도를 바꾸어 확률을 조절하는 것이 이 회로의 기본 동작이며, 학습 대상인 θ가 곧 이 각도입니다.

RX는 X축 회전으로 MediQ-GAN의 encoding에서 사용합니다. CNOT은 제어 큐빗이 1일 때 목표 큐빗을 뒤집고, CZ는 두 큐빗이 모두 1일 때 위상에 −1을 곱합니다. 둘 다 학습 파라미터가 없고 큐빗 사이의 얽힘만 담당합니다.

오른쪽 아래 그림이 얽힘의 효과입니다. 두 큐빗에 각각 RY(π/2)만 적용하면 네 결과가 각각 0.25로 독립입니다. 첫 큐빗에 RY(π/2)를 적용하고 CNOT을 걸면 00과 11만 0.5씩 나오는 Bell 상태가 되어 두 큐빗의 결과가 상관을 가집니다. 이 상관이 픽셀 사이의 관계를 표현하는 수단이 됩니다.

정리하면 QGAN은 RY encoding 뒤에 RY와 CZ 체인을 반복하고, MediQ-GAN은 RX, RY encoding 뒤에 RY와 CNOT 체인을 반복합니다.

사전 지식 · 양자회로

측정과 기댓값

측정 한 번은 bitstring 하나이고, 모델이 쓰는 값은 반복 측정의 통계량

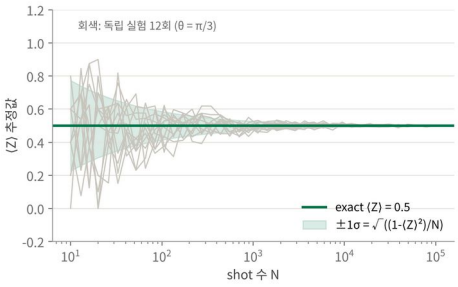
출력 방식	정의와 출력 크기	사용 논문
확률 분포 P(x)	2^n개 basis state의 측정 확률 출력 크기 2^n (지수)	QGAN
기댓값 ⟨X_i⟩	큐빗별 관측량의 평균, −1 ~ 1 출력 크기 n (선형)	MediQ-GAN

$$\langle Z \rangle = P(0) - P(1) \in [-1, 1]$$
$$\text{shot N회 추정의 표준오차} = \sqrt{((1 - \langle Z \rangle^2) / N)} \leq 1/\sqrt{N}$$

출력 구조의 차이

QGAN: 8큐빗 중 ancilla qubit = 0인 128개 확률을 patch 픽셀로 사용

MediQ-GAN: 16큐빗 → 기댓값 16개를 특징으로 사용, 이미지는 고전 decoder가 생성



정밀도를 10배 높이려면 shot이 100배 필요함. 이 비용이 뒤의 VQC 학습 비용 계산에 들어감

시뮬레이터에서 shots를 지정하지 않으면 이 오차 없이 exact 기댓값을 계산함

[약 2분]

측정과 기댓값입니다. 회로를 한 번 실행하고 측정하면 bitstring 하나가 나올 뿐이고, 모델이 쓰는 값은 반복 측정으로 얻은 통계량입니다. 이 통계량을 어떻게 정의하느냐가 두 논문의 출력 구조를 가릅니다.

QGAN은 2의 n제곱 개 basis state의 확률 분포 전체를 출력으로 씁니다. 8큐빗 중 ancilla qubit이 0인 128개를 patch의 픽셀 값으로 사용합니다. MediQ-GAN은 큐빗별 기댓값 ⟨X_i⟩를 씁니다. 16큐빗이면 출력이 16개이고, 값의 범위는 −1에서 1 사이입니다.

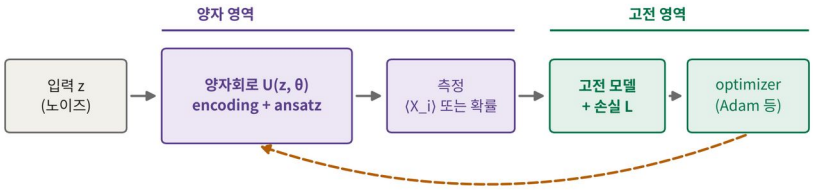
같은 큐빗 수에서 출력 차원이 전자는 지수적, 후자는 선형적으로 늘어난다는 점이 중요합니다. 이미지를 직접 쓰는 QGAN은 큐빗 수가 조금만 늘어도 patch 크기가 급격히 커지므로 여러 sub-generator로 나누고, MediQ-GAN은 양자 출력을 특징으로만 쓰고 이미지는 고전 decoder가 만듭니다.

shot 수와 정확도의 관계는 오른쪽 그래프입니다. 기댓값은 shot N회로 추정하고 표준오차가 $1/\sqrt{N}$ 이하로 줄어듭니다. 정밀도를 한 자리 올리려면 shot이 100배 필요하다는 뜻이고, 이 비용이 뒤에서 다룰 학습 비용 계산에 그대로 들어갑니다. 시뮬레이터에서 shot을 지정하지 않으면 이 오차 없이 정확한 기댓값을 계산합니다.

사전 지식 · 양자회로

PQC·VQC와 hybrid 학습 루프

PQC(parameterized quantum circuit)를 variational 방식으로 학습시킨 것이 VQC(variational quantum circuit)임. QGAN 논문은 PQC, MediQ-GAN 논문은 VQC로 부름



θ 갱신: ∂L/∂θ (adjoint 또는 parameter-shift)

encoding
- 입력을 회전각으로 변환 (angle encoding). 두 논문 모두 사용
- 대안인 amplitude encoding은 2^n개 값을 적재하나 상태 준비 회로가 깊어질 수 있음

ansatz
- 학습 가능한 회전 + 얽힘 게이트의 반복
- 두 논문 모두 hardware-efficient 구조 (RY + CNOT 또는 CZ)

gradient
- 시뮬레이터: adjoint 또는 backpropagation
- 실기: parameter-shift rule, 파라미터마다 회로 2회 추가 실행

24

[약 3분]

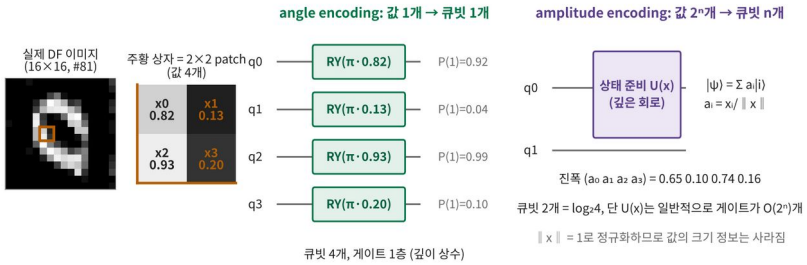
PQC와 VQC의 학습 구조입니다. PQC는 parameterized quantum circuit, 즉 학습 가능한 파라미터를 가진 양자회로이고, VQC는 variational quantum circuit으로, 이 회로를 고전 optimizer가 파라미터를 조정하는 variational 방식으로 학습시킨 것을 부릅니다. QGAN 논문은 PQC, MediQ-GAN 논문은 VQC라는 이름을 쓰며, 이 강의에서는 같은 구조로 다룹니다. 그림의 흐름은 입력 z를 회로에 encoding하고, 학습 가능한 회전을 거쳐 측정하고, 측정값을 고전 모델에 넣어 손실을 계산하는 것입니다. 이후 optimizer가 손실의 gradient로 회로 파라미터 θ를 갱신합니다. 양자 영역은 앞의 두 상자이고 나머지는 모두 고전 영역입니다. 이 구조를 hybrid 학습 루프라고 부릅니다.

구성 요소는 세 가지입니다. encoding은 입력을 회전각으로 바꾸는 단계로, 두 논문 모두 angle encoding을 씁니다. 대안인 amplitude encoding은 n큐빗에 2의 n제곱 개 값을 담을 수 있지만 상태를 준비하는 회로가 깊어질 수 있습니다. 같은 값을 두 방식으로 넣는 예는 바로 다음 슬라이드에서 샘플 이미지로 확인합니다. ansatz는 학습 가능한 회전과 얽힘 게이트를 반복하는 부분이며, 두 논문 모두 hardware-efficient 구조입니다. gradient는 시뮬레이터에서는 adjoint나 backpropagation으로 효율적으로 구하고, 실제 하드웨어에서는 parameter-shift rule로 파라미터마다 회로를 두 번 더 실행합니다. 이 차이는 뒤에서 비용 계산으로 다시 다룹니다.

사전 지식 · 양자회로

Encoding 방식 비교: angle encoding과 amplitude encoding

같은 값 4개(실제 DF 이미지의 2×2 patch)를 두 방식으로 큐빗에 넣는 예



비교	angle encoding	amplitude encoding
큐빗 수	값 n개 → 큐빗 n개	값 2ⁿ개 → 큐빗 n개
회로 깊이	게이트 1층	상태 준비 회로가 일반적으로 깊음
두 논문	QGAN RY(z), MediQ-GAN RX → RY	사용하지 않음

두 논문에서 encoding되는 값은 이미지가 아니라 노이즈(QGAN)와 특징 벡터(MediQ-GAN)임. 위 이미지는 두 방식을 비교하기 위한 예시임

25

[약 2분]

encoding 방식 두 가지를 같은 값으로 비교하겠습니다. 왼쪽 그림은 실제 DF 이미지에서 2×2 patch를 하나 잘라 값 네 개를 얻은 것입니다. 값은 0과 1 사이로 맞춘 예시입니다.

angle encoding은 값 하나를 큐빗 하나의 회전각으로 바꿉니다. 슬라이드의 예에서는 값 x를 RY(π·x)로 넣어 큐빗 네 개가 필요하고, 게이트는 한 층이면 충분합니다. 측정하면 1이 나올 확률이 $\sin^2(\pi x/2)$이므로 값이 클수록 1에 가까워집니다. 큐빗 수는 값의 개수와 같지만 회로가 얕아 현재의 NISQ 장치에 적합합니다.

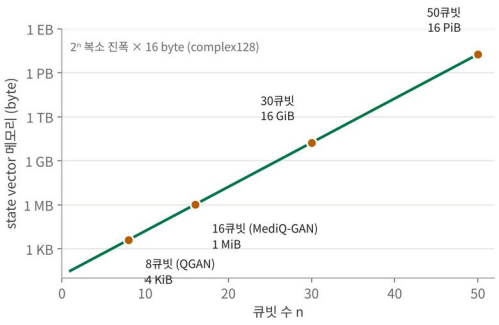
amplitude encoding은 값 전체를 진폭에 담습니다. 값 네 개를 길이 1로 정규화해 진폭으로 쓰면 큐빗 두 개로 충분합니다. 값 2의 n제곱 개를 큐빗 n개에 담는 것이 장점입니다. 단점은 두 가지입니다. 임의의 진폭을 만드는 상태 준비 회로는 일반적으로 게이트가 2의 n제곱에 비례해 깊어질 수 있고, 정규화하므로 값의 전체 크기 정보가 사라집니다.

두 논문은 모두 angle encoding을 씁니다. QGAN은 노이즈 각도를 RY로, MediQ-GAN은 학습된 특징값을 RX와 RY로 넣습니다. 여기서 encoding되는 값은 이미지가 아니라 노이즈와 특징 벡터입니다. 이 슬라이드의 이미지는 두 방식의 차이를 보이기 위한 예시입니다.

사전 지식 · 양자회로

시뮬레이션의 한계와 학습 가능성

state vector 시뮬레이션은 큐빗 수에 지수적이고, 회로가 넓고 깊을수록 학습이 어려워짐



항목	내용
시뮬레이션 규모	16큐빗은 1 MiB로 개인 PC에서 처리 가능. 30큐빗부터 16 GiB로 일반 PC 한계
해석	정확히 시뮬레이션되는 규모의 회로는 양자 우위의 근거가 아님. MediQ-GAN 논문도 quantum-inspired로 규정하고 양자 소자를 계산 가속 용도로 한정
NISQ 실기	게이트 오류와 decoherence로 얕은 회로만 신뢰 가능
Barren plateau	큐빗 수·깊이가 커질수록 gradient 분산이 지수적으로 감소하는 현상
표현력 대 학습 가능성	표현력이 큰 회로일수록 barren plateau 위험이 큼. MediQ-GAN은 DLA 분석으로 depth 8을 선택

26

[약 2분]

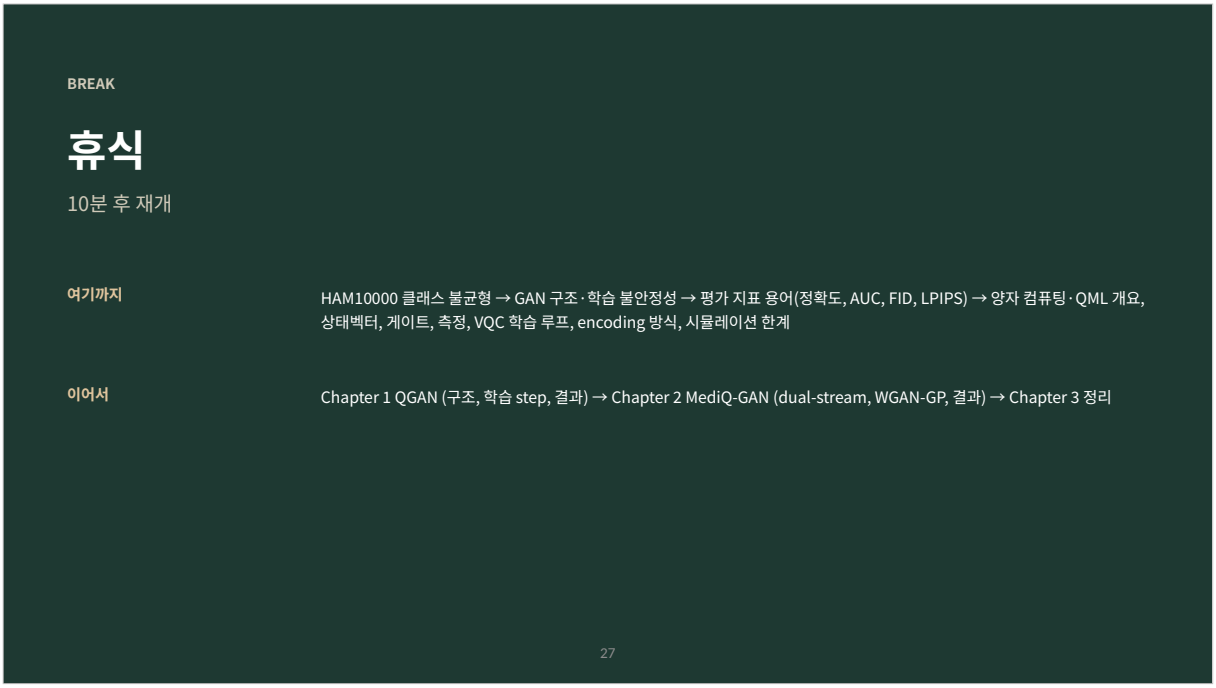
마지막으로 시뮬레이션의 한계와 학습 가능성입니다.

state vector 시뮬레이션은 큐빗 수에 지수적으로 메모리를 씁니다. complex128 기준으로 8큐빗은 4KiB, 16큐빗은 1MiB여서 개인 PC에서 문제없이 돌아가지만, 30큐빗은 16GiB, 50큐빗은 16PiB입니다. 이 강의의 두 모델은 모두 16큐빗 이하이므로 시뮬레이션이 가능합니다.

여기서 해석상 중요한 점이 있습니다. 고전 컴퓨터에서 정확히 시뮬레이션할 수 있는 규모의 회로는 양자 우위의 근거가 될 수 없습니다. MediQ-GAN 논문도 스스로를 quantum-inspired, hardware-agnostic이라고 규정하고, 양자 소자는 계산 가속 역할에 한정된다고 밝힙니다.

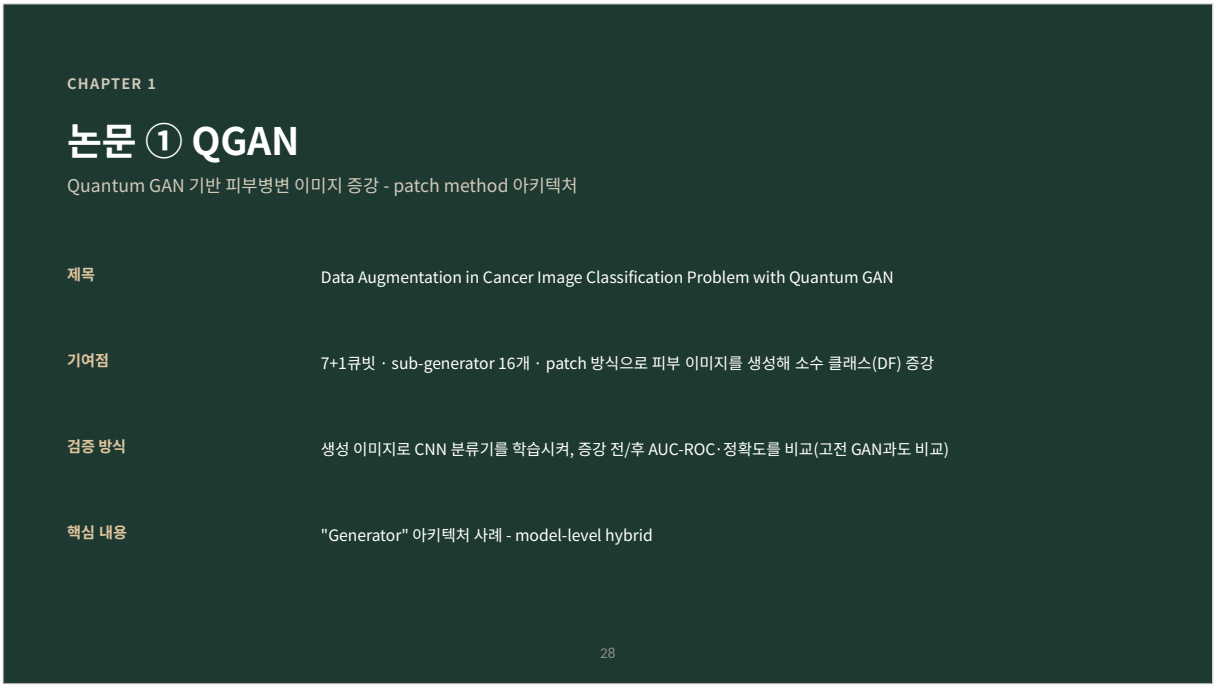
실제 NISQ 소자는 게이트 오류와 decoherence 때문에 얕은 회로만 신뢰할 수 있습니다. 또 회로가 넓고 깊을수록 barren plateau, 즉 gradient 분산이 지수적으로 줄어드는 현상이 나타나 학습이 어려워집니다. 표현력이 큰 회로일수록 이 위험이 커지므로 표현력과 학습 가능성은 절충 관계입니다. MediQ-GAN 논문은 dynamical Lie algebra 분석으로 depth 8이 충분한 표현력을 가지면서 barren plateau를 피한다고 밝힙니다.

사전 지식은 여기까지입니다. 10분간 휴식하겠습니다.



휴식 시간입니다. 10분 후에 재개합니다.

재개 후에는 Chapter 1에서 QGAN 논문의 구조와 학습 과정, 결과를 먼저 다루고, 이어서 Chapter 2에서 MediQ-GAN 논문을 다룹니다. 휴식 중에 앞 내용에서 질문이 있으면 말씀해 주십시오.

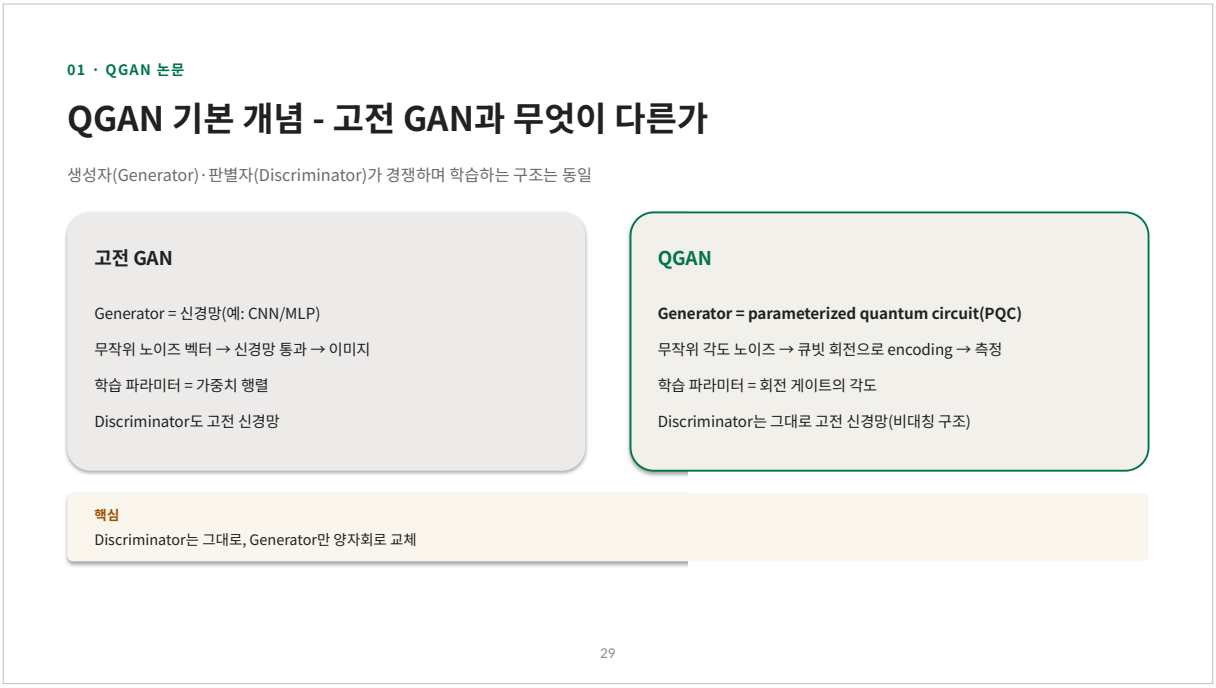


[약 2분]

첫 번째 논문은 Andra 등이 Quantum Machine Intelligence 7권에 발표한 'Data Augmentation in Cancer Image Classification Problem with Quantum GAN'입니다.

기여는 7+1큐빗 회로 16개를 sub-generator로 두는 patch 방식으로 피부 이미지를 생성해 소수 클래스 df를 증강한 것입니다. 검증은 생성 이미지로 CNN 분류기를 학습시켜 증강 전후의 AUC-ROC와 정확도를 비교하고, 고전 GAN과도 비교하는 방식입니다. 이 강의에서는 생성자 전체가 양자회로인 model-level hybrid의 사례로 사용합니다.

이 논문을 첫 번째로 다루는 이유는 구조가 가장 단순하기 때문입니다. 생성자 전체가 양자회로이고 판별자만 고전이어서, 양자 부분의 동작을 다른 요소와 섞지 않고 볼 수 있습니다. 반대로 해상도가 낮고 평가가 분류 성능 하나라는 한계가 있으며, 이 한계는 뒤의 결과 슬라이드에서 하나씩 짚겠습니다.



[약 1분]

QGAN의 기본 개념입니다. 생성자와 판별자가 경쟁하며 학습하는 구조는 앞에서 본 GAN과 같고, 달라지는 것은 생성자의 구현입니다.

고전 GAN의 생성자는 CNN이나 MLP이고 학습 파라미터는 가중치 행렬입니다. QGAN의 생성자는 parameterized quantum circuit, 즉 PQC이고, 무작위 각도 노이즈를 회전 게이트로 encoding 한 뒤 측정하며, 학습 파라미터는 회전 게이트의 각도입니다. 판별자는 두 경우 모두 고전 신경망이므로 구조가 비대칭입니다.

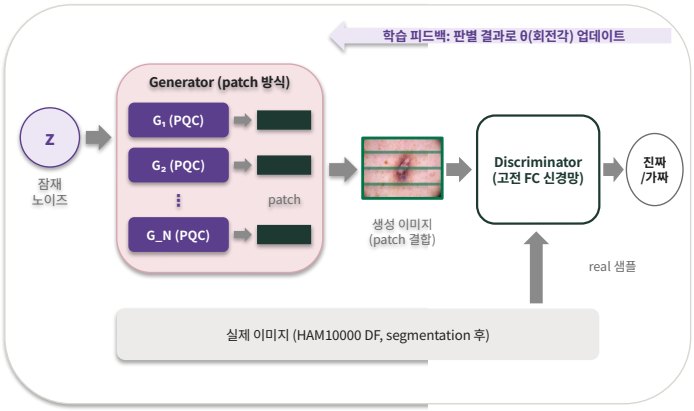
정리하면 판별자는 그대로 두고 생성자만 양자회로로 교체한 모델입니다.

비교 항목을 하나만 더 보면, 고전 GAN에서는 학습 파라미터가 가중치 행렬이라 수가 매우 많고 미분은 backpropagation으로 구합니다. QGAN의 생성자는 파라미터가 회전각이라 수가 적지만 회로 실행 비용이 큽니다.

01 · QGAN 논문

QGAN 아키텍처 다이어그램 - patch 기반 Generator

Generator-Discriminator 구조를 도식으로 재구성



30

원 논문 Fig. 10 구조를 도식으로 재구성: Andra et al., Quantum Machine Intelligence 7, 90 (2025)

[약 2분]

논문 Fig. 10을 도식으로 재구성한 구조도입니다. 잠재 노이즈 z가 N개의 sub-generator에 들어가고, 각각의 PQC가 patch 하나를 출력합니다. patch를 이어 붙인 것이 생성 이미지이고, 판별자는 이 이미지와 실제 이미지를 입력받아 진짜 또는 가짜를 판별합니다.

위쪽 화살표가 학습 피드백입니다. 판별 결과로 계산한 손실이 회전각 θ까지 전달되어 갱신됩니다. 실제 이미지는 HAM10000의 df를 segmentation한 뒤의 이미지입니다. 이 전처리가 결과에서 중요한 역할을 하는데, 뒤의 결과 슬라이드에서 확인합니다.

그림에서 생성 이미지가 patch를 결합한 결과라는 점과, 판별자가 결합된 이미지 전체를 입력으로 받는다는 점을 구분해 주십시오. 생성은 patch 단위로 독립적으로 이루어지지만 판단은 이미지 전체에 대해 이루어집니다. 그래서 patch 사이의 연속성은 판별자의 피드백을 통해서만 간접적으로 학습됩니다.

01 · QGAN 논문

Patch 방식 아키텍처

큐빗 한 세트로 이미지 전체를 만들기 어려워, 여러 개의 '작은 회로'가 조각(patch)을 나눠 생성

sub-generator 1
PQC → patch

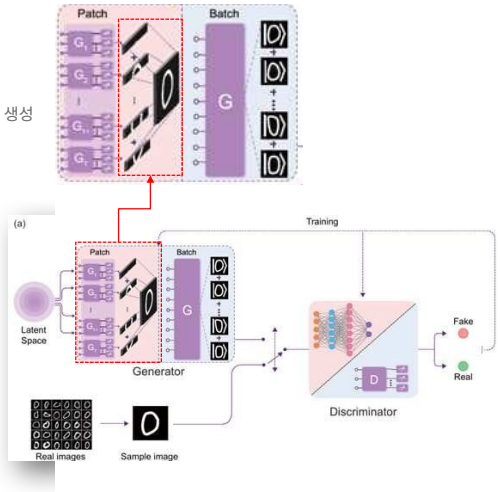
sub-generator 2
PQC → patch

sub-generator 3
PQC → patch

sub-generator N
PQC → patch

(논문: 16개 sub-generator)

patch 1 + patch 2 + patch 3 + ⋯ + patch N
→ 이어 붙여 최종 이미지 벡터



[약 2분]

patch 방식이 필요한 이유는 큐빗 수의 제약입니다. 큐빗 한 세트로 이미지 전체를 만들기 어려우므로 작은 회로 여러 개가 조각을 나누어 생성합니다. 논문은 sub-generator 16개를 사용하고, 각 patch를 이어 붙여 최종 이미지 벡터를 만듭니다.

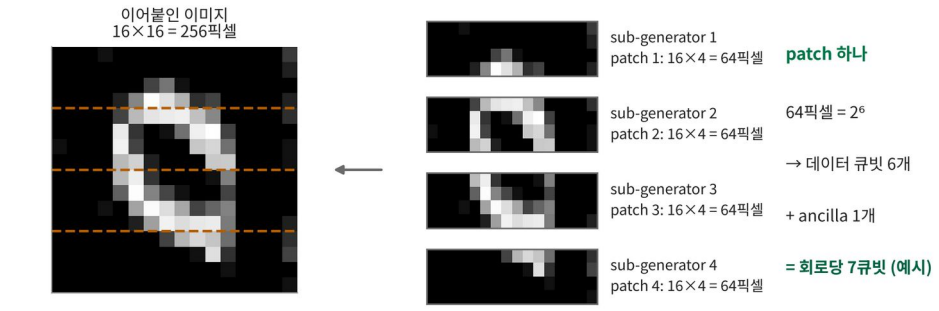
오른쪽 그림은 논문의 원 도식으로, 빨간 점선 영역이 patch 부분입니다. 논문은 patch 외에 batch 방식도 제안하는데, 이 데이터에는 patch 방식을 적용했습니다. 이 구조는 기존 연구(Huang 등)의 patch GAN을 가져온 것이라는 점도 알아 두시면 좋습니다.

논문은 patch 외에 batch 방식도 제안하며, 큐빗 수가 출력 크기에 비해 충분한지에 따라 둘 중 하나를 고릅니다. patch 방식은 이미지를 나눠 여러 회로가 서로 다른 부분을 만드는 방식이고, 이 데이터에는 patch 방식을 적용했습니다. 다음 슬라이드에서 patch 하나를 만드는 회로를 자세히 보기에 앞서, 바로 뒤의 분할 예시에서 실제 이미지가 어떻게 나뉘는지 확인하겠습니다.

01 · QGAN 논문

patch 분할 예시: 16×16 = 4 patch × 64픽셀

큐빗 수에 맞춰 이미지를 띠로 나누고, sub-generator마다 patch 하나를 생성함



논문의 구성

논문: sub-generator 16개 × 데이터 큐빗 7개(patch당 128픽셀). 위 그림은 4 patch로 나눈 예시임. patch는 서로 독립인 회로가 만들어 경계가 어긋날 수 있음

32

[약 2분]

patch 분할을 실제 이미지로 보겠습니다. 오른쪽 이미지가 16×16, 256픽셀입니다. 점선으로 가로 띠 네 개로 나누면 각 띠가 16×4, 즉 64픽셀이고, 이 띠 하나가 sub-generator 하나가 만드는 patch입니다.

64는 2의 6제곱이므로 patch 하나의 픽셀 값을 측정 확률로 표현하려면 데이터 큐빗이 6개 필요하고, post-selection용 ancilla qubit 1개를 더하면 회로당 7큐빗이 됩니다. 이 그림은 설명을 위해 4 patch로 나눈 예시이고, 논문 구성은 sub-generator 16개에 데이터 큐빗 7개이므로 patch 당 128픽셀입니다.

patch 사이에는 회로가 서로 독립이라는 점에 유의해야 합니다. 각 sub-generator가 자기 patch만 만들고 이어 붙이므로, patch 경계에서 형태가 어긋날 수 있습니다. 이미지 전체의 형태를 잡기 어려운 patch 방식의 구조적 한계입니다.

분할 예시를 보고 나면 patch 방식의 한계도 분명해집니다. 회로가 만드는 patch의 크기는 큐빗 수의 지수에 비례하므로, 큐빗을 하나 늘리면 patch의 픽셀 수가 두 배가 됩니다. 반대로 큐빗이 제한되면 patch가 작아져 sub-generator 수가 늘어야 하고, 이는 회로 실행 횟수의 증가로 이어집니다.

01 · QGAN 논문

sub-generator 회로 상세

각 sub-generator = 3단계로 이루어진 하나의 parameterized quantum circuit(

① 노이즈 encoding

무작위 각도를 RY 게이트로 각 큐빗에 회전시켜 입력

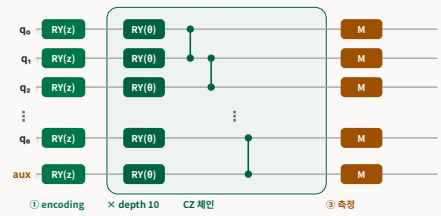
② variational layer (반복)

학습 가능한 RY 회전 + 인접 큐빗 CZ 얽힘 - 각도가 '학습되는 가중치'

③ 측정

ancilla qubit까지 전체 측정 후, ancilla qubit=0인 항목만 patch로 사용(post-selection)

sub-generator 1개 회로 (논문 Table 3 기준, 8큐빗)



측정 결과 $2^8 = 256$개 확률 중 ancilla qubit = 0 인 128개만 선택(post-selection) → patch 1장

sub-generator 16개의 patch를 이어붙여 이미지 1장을 구성

항목	값
큐빗 수	데이터 7 + ancilla 1 = 총 8
sub-generator 수	16개
회로 깊이(PQC depth)	10
학습률 / epoch	0.1 / 2,000

33

[약 2분]

sub-generator 하나의 회로를 단계별로 보겠습니다. 논문 Table 3 기준으로 8큐빗입니다.

첫째, 노이즈 encoding입니다. 무작위 각도를 RY 게이트로 각 큐빗에 넣습니다. 둘째, variational layer를 depth 10만큼 반복합니다. 각 layer는 학습 가능한 RY 회전과 인접 큐빗 사이의 CZ 얽힘으로 구성되고, 각도가 학습되는 가중치입니다. 셋째, 측정입니다. ancilla qubit까지 전체를 측정해 2의 8제곱, 즉 256개의 확률을 얻고, 그중 ancilla qubit이 0인 128개만 patch로 사용합니다. 이것이 post-selection입니다.

아래 표에 규격을 정리했습니다. 데이터 큐빗 7개와 ancilla 1개, sub-generator 16개, depth 10, 학습률 0.1, 2,000 epoch입니다.

ancilla qubit을 쓰는 이유는 다음과 같습니다. 데이터 큐빗만 측정하면 확률의 합이 항상 1이어서 배경이 대부분인 patch처럼 밝기 총합이 작은 경우를 표현할 수 없습니다. ancilla가 0인 항목만 쓰면 합이 0과 1 사이에서 자유로워집니다. 일반적인 ancilla의 용도인 오류 정정 등과는 목적이 다르다는 점에 유의하십시오.

01 · QGAN 논문

QGAN 한 step의 학습 과정

판별자와 생성자를 번갈아 갱신하며, 생성자의 gradient는 회로 파라미터 θ까지 전달됨

단계	동작	손실
1 생성	z → sub-generator 16개 → patch 결합 → 생성 이미지 $\tilde{x}$	-
2 D 갱신	실제 x는 1, 생성 $\tilde{x}$는 0으로 분류하도록 D의 가중치 갱신	$L_D = -[\log D(x) + \log(1 - D(\tilde{x}))]$ (BCE)
3 G 갱신	D가 $\tilde{x}$를 1로 판단하도록 회로 각도 θ 갱신	$L_G = -\log D(\tilde{x})$ (non-saturating)
4 반복	2,000 epoch (논문 Table 3·4)	-

설정에서 확인할 점

- 학습률: 생성자 0.1, 판별자 5×10^{-3} (Table 3·4). 생성자가 20배 큼
- 논문은 손실을 Binary Cross Entropy로 표기함. G 손실 형태는 일반적인 non-saturating 형태로 적은 것임

34

[약 2분]

QGAN의 학습 한 step을 정리하겠습니다. 먼저 노이즈 z로 sub-generator 16개를 실행해 patch를 만들고 이어 붙여 생성 이미지를 얻습니다. 다음으로 판별자를 갱신합니다. 실제 이미지는 1, 생성 이미지는 0으로 분류하도록 Binary Cross Entropy를 최소화합니다. 이어서 생성자를 갱신합니다. 판별자가 생성 이미지를 1로 판단하도록 손실을 만들고, 이 손실의 gradient를 회로 각도 θ까지 전달합니다. 생성자 손실은 일반적인 non-saturating 형태로 적었고, 논문은 손실 함수를 Binary Cross Entropy로 표기합니다. 이 과정을 2,000 epoch 반복합니다.

설정에서 눈에 띄는 점은 학습률입니다. 생성자 0.1, 판별자 5×10^{-3}으로 생성자가 20배 큽니다. 두 모델의 갱신 속도가 크게 다르다는 뜻이므로, 판별자가 이기는 현상이 나타나면 이 비율부터 확인해야 합니다.

01 · QGAN 논문

Discriminator 구조 + 평가 프로토콜

"QGAN이 잘 만들었는지"는 생성 이미지 직접 확인 대신 별도 CNN 분류기 성능으로 검증

Discriminator (Table 4)

Table 4 · Discriminator	값
Layer 수	5 (완전연결)
활성화 함수	ReLU
출력층 활성화	Sigmoid
PQC 깊이 (생성자)	10
학습률	5×10^{-3}
Epoch	2,000
손실 함수	Binary Cross Entropy

평가용 CNN

Table 1 · CNN 학습 설정	값
학습률	15×10^{-4} (=1.5×10^{-3})
손실 함수	Binary Cross Entropy
Optimizer	ADAM
정규화 layer	Batch Normalization 2D
출력 활성화	Sigmoid
파라미터 수	460k

Table 2 · Conv layer	값
Kernel 크기	3
Stride	1
활성화 함수	ReLU
정규화 layer	Batch Normalization 2D
Max Pooling	2×2

35

표 내용 출처: Andra et al., Quantum Machine Intelligence 7, 90 (2025), Table 1·2·4

[약 2분]

판별자와 평가 방법입니다. 판별자는 Table 4 기준으로 5층 Fully connected layer이고, 활성화는 ReLU, 출력층은 시그모이드, 학습률은 5×10^{-3}, 2,000 epoch, 손실은 Binary Cross Entropy 입니다.

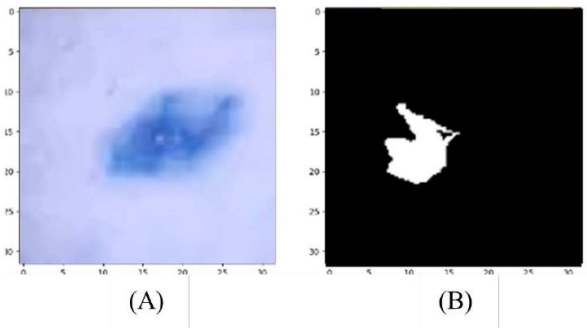
이 논문의 검증 방식은 생성 이미지를 직접 평가하는 대신 별도의 CNN 분류기 성능으로 확인하는 것입니다. 오른쪽이 평가용 CNN의 설정입니다. 학습률 1.5×10^{-3}, Adam, Batch Normalization, 파라미터 약 46만 개의 작은 네트워크입니다. 논문에는 FID 같은 생성 품질 지표가 없다는 점이 이후 MediQ-GAN 논문과의 차이입니다.

판별자 표의 항목을 풀어서 설명하겠습니다. Layer 수 5는 완전연결 층이 다섯 개라는 뜻이고, 활성화 ReLU와 출력층 시그모이드의 조합은 마지막에 0과 1 사이의 확률을 내기 위한 일반적 구성입니다. 평가용 CNN은 증강한 데이터로 학습하는 별도 모델이며, 이 CNN의 구조와 학습 설정을 증강 전후에 동일하게 유지해야 비교가 의미를 가집니다. 논문도 분류기 설정을 바꾸지 않았다고 서술합니다.

01 · QGAN 논문 결과

결과 0 - QGAN 생성 이미지

논문 Fig. 21: 원본 유래 합성 이미지(A)와 합성 segmentation(B)



관찰

- 병변의 위치와 대략적인 경계는 재현됨
- 해상도가 낮아 질감 같은 세부는 확인하기 어려움
- 이 논문은 FID 같은 생성 품질 지표를 제시하지 않고(프리프린트 기준) 증강 후 분류 성능으로 간접 검증함
- 따라서 우열 판단의 근거는 다음 슬라이드의 분류 성능임

그림 출처: Andra et al., Fig. 21 (프리프린트 Research Square rs-5191116v1, CC BY 4.0)

[약 1분]

논문이 제시한 QGAN 생성 이미지입니다. (A)는 원본 이미지에서 유래한 합성 이미지이고 (B)는 합성 segmentation입니다. 해상도가 낮아 병변의 대략적인 위치와 경계가 재현되는 수준이며, 질감 같은 세부는 확인하기 어렵습니다.

이 논문은 생성 이미지의 품질을 FID 같은 지표로 보고하지 않고 분류 성능으로 간접 검증하므로, 이미지 자체에서 판단할 수 있는 것은 제한적입니다. 판단 근거는 다음 슬라이드의 분류 성능입니다.

그림의 축 눈금은 약 32픽셀까지이고 병변이 이미지 중앙에 위치합니다. 합성 segmentation (B)는 병변 영역을 이진 마스크로 만든 것입니다. 이 마스크가 실제 segmentation 마스크와 얼마나 유사한지에 대한 정량 평가는 논문에 없으므로, 이 그림은 정성적 참고로만 사용합니다.

01 · QGAN 논문 결과

결과 ① - DF vs NV 분류 성능 개선

Table 6: QGAN 증강 후 AUC-ROC 개선



막대 높이는 0부터 비례. 증가폭은 +0.017이며, 이 저장소의 8×8 재현 실험에서는 AUC +0.004, 정확도는 오히려 하락해 개선으로 단정하지 않음 (README 참고)

[약 2분]

첫 번째 결과입니다. Table 6 기준으로 df 대 nv 분류에서 QGAN 증강 후 AUC-ROC가 0.953에서 0.970으로 올랐습니다. 막대의 높이는 0부터 비례하도록 그렸고, 증가 폭은 +0.017입니다.

이 수치는 개선 폭이 작다는 점을 같이 보셔야 합니다. 이 저장소에서 8×8 해상도로 재현한 실험에서는 AUC가 +0.004 올랐지만 정확도는 0.946에서 0.913으로 오히려 떨어졌습니다. df가 92장 규모에서는 이 차이를 개선이라고 단정하기 어렵습니다.

증가 폭 +0.017의 의미를 해석하면, AUC가 0.953에서 0.970이 되었다는 것은 무작위로 고른 양성과 음성의 순서를 맞힐 확률이 약 1.7%포인트 올랐다는 뜻입니다. 한 번의 학습 결과이므로 시드에 따른 변동 범위가 함께 제시되지 않으면 이 차이의 유의성은 판단하기 어렵습니다. 이 저장소의 재현 실험에서 정확도가 오히려 내려간 사례는 그 불확실성을 보여 줍니다.

01 · QGAN 논문 결과

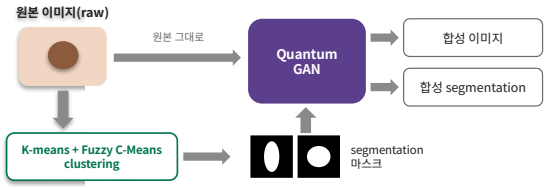
결과 ② - 조건부 증강 효과

segmentation 전처리 이미지에서만 증강 효과 있음

입력 전처리 방식	QGAN 증강 효과
원본/리사이즈 이미지	증강 효과 없음 - 오히려 성능 저하
segmentation(K-means+FCM) 전처리 이미지	증강 효과 있음 - 성능 개선

왜 중요한가

실제로는 배경 노이즈를 제거한(segmentation) 입력에서만 생성 품질이 분류 성능 개선으로 이어짐



원 논문 pipeline을 도식으로 재구성: Andra et al., Quantum Machine Intelligence 7, 90 (2025)

[약 2분]

두 번째 결과는 증강 효과가 입력 전처리에 따라 달라진다는 것입니다. 원본이나 단순 리사이즈 이미지로 학습했을 때는 QGAN 증강의 효과가 없거나 오히려 성능이 떨어졌고, K-means와 Fuzzy C-means로 segmentation한 이미지에서만 성능이 개선되었습니다.

오른쪽 그림이 논문의 pipeline입니다. 원본 이미지에서 clustering으로 병변 마스크를 만들고, 이 마스크 이미지로 QGAN을 학습해 합성 이미지와 합성 segmentation을 얻습니다. 배경 잡음을 제거한 입력에서만 생성 품질이 분류 성능으로 이어졌다는 의미입니다.

K-means와 Fuzzy C-means의 역할을 덧붙이면, 두 방법은 병변과 배경 픽셀을 밝기로 나누는 clustering이고 이 결과가 마스크가 됩니다. 전처리가 결과를 좌우한다는 것은 증강 모델을 비교할 때 입력 조건을 반드시 함께 보고해야 한다는 뜻이기도 합니다.

01 · QGAN 논문 결과

결과 ③ - 고전 GAN과의 비교

Table 11: 조건에 따라 승자 교체 - "양자가 항상 이긴다"는 아님

입력 조건	정확도 비교	비고
원본(raw) 이미지	고전 GAN (정확도 0.98 vs 0.89)	QGAN 열세
segmentation 이미지	QGAN (정확도 0.96 vs 0.95)	AUC는 0.97로 동률

해석

"고전 대비 무조건적 속도·성능 우위"가 성공 기준이 아니라,
(1) 문제→양자 pipeline의 실제 성립 여부, (2) 어떤 조건에서 고전과 동등·우위인지(crossover 조건) 평가

39

[약 2분]

세 번째 결과는 고전 GAN과의 비교입니다. Table 11 기준으로 승자가 조건에 따라 바뀝니다.

원본 이미지에서는 고전 GAN이 정확도 0.98, QGAN이 0.89로 QGAN이 열세입니다. segmentation 이미지에서는 QGAN 0.96, 고전 GAN 0.95로 근소하게 앞서고, AUC는 0.97로 같습니다.

해석은 아래에 적은 대로입니다. 고전 대비 무조건적 우위를 성공 기준으로 삼지 않고, 첫째 문제와 양자 pipeline이 실제로 성립하는지, 둘째 어떤 조건에서 고전과 동등하거나 우위인지를 평가해야 합니다. 이 결과는 양자가 항상 이긴다는 근거가 아닙니다.

표의 정확도를 함께 읽어야 합니다. 원본 이미지 조건에서 QGAN은 고전 GAN보다 정확도가 0.09 낮고, segmentation 조건에서는 0.01 높습니다. 두 조건의 차이가 0.09와 0.01로 크게 다르다는 점이 입력 조건에 따라 우열이 바뀐다는 근거입니다. 다만 0.01 차이는 한 번의 실험 결과이므로 우위라고 단정하지 않는 편이 안전합니다.



[약 2분]

두 번째 논문은 MediQ-GAN입니다. arXiv 2506.21015로, Jiao 등이 발표했습니다.

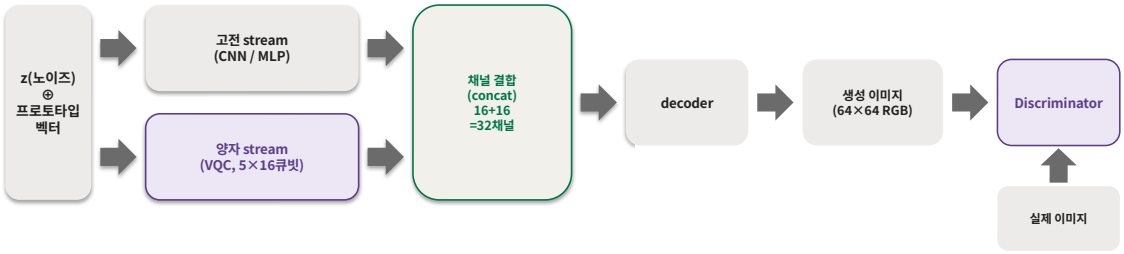
핵심 기여는 생성자를 고전 stream과 양자 stream으로 나누어 병렬 처리한 뒤 skip-connection으로 융합한 것입니다. 의료영상 세 가지 데이터셋에서 DCGAN, WGAN-GP, StyleGAN2-ADA 같은 고전 모델과 양자 모델 MosaiQ를 클래스별 FID와 LPIPS로 비교하고, 실제 IBM 하드웨어 실행까지 확인했습니다. 이 강의에서는 생성자 일부만 양자인 layer-level hybrid의 대표 사례로 사용합니다.

이 논문의 특징은 양자 부분을 생성자의 일부로 제한했다는 점입니다. 동기는 논문이 직접 밝힙니다. 이전의 hybrid 모델들은 8×8이나 28×28 흑백 이미지에 머물렀고, 이를 64×64 RGB로 확장하기 위해 고전 부분과 양자 부분을 나눴다는 것입니다. 이후 슬라이드에서 이 구조를 입력부터 decoder까지 따라가겠습니다.

02 · MEDIQ-GAN 논문

MediQ-GAN 아키텍처 다이어그램 - dual-stream Generator

고전 stream과 양자 stream을 함께 학습해 합치는 구조를 도식으로 재구성



41

[약 2분]

MediQ-GAN의 생성자 구조도입니다. 노이즈 z에 클래스 프로토타입 벡터를 결합해 입력으로 쓰고, 이 입력이 고전 stream과 양자 stream으로 갈라집니다. 양자 stream은 16큐빗 VQC를 다섯 개 사용합니다. 두 stream의 출력을 16채널씩 이어 붙여 32채널로 만들고, decoder가 64×64 RGB 이미지로 복원합니다. 판별자는 고전 네트워크입니다.

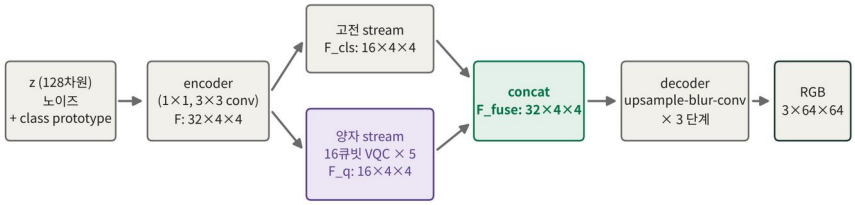
QGAN과 비교해 보면 양자회로가 이미지 픽셀을 직접 만들지 않고 특징 맵의 일부를 처리한다는 점이 가장 큰 차이입니다.

그림의 skip-connection이라는 말은 양자 stream의 출력이 decoder로 바로 전달되어 고전 stream의 출력과 결합된다는 뜻입니다. 두 stream의 역할을 논문은 고전 층이 전역 구조를, 양자 sub-generator가 표현력을 맡는다고 설명합니다. 이 설명이 실험으로 분리 검증되었는지는 따로 확인해야 하며, 뒤의 결과 슬라이드에서 ablation 내용을 다룹니다.

02 · MEDIQ-GAN 논문

입력 구성과 decoder

class prototype을 노이즈에 결합하고, 양자 stream 출력은 decoder에서 64×64 RGB로 복원



encoder 출력 32채널 중 16채널을 양자 stream에 투입

prototype conditioning

- EfficientNet-B0(30 epoch 미세조정) 특징의 클래스별 평균 벡터를 노이즈에 결합
- centroid 간 거리를 최대화하는 regularization loss로 클래스 구분 유지

decoder

- 3×3 conv → upsample-blur-conv 3단계 → 3×3 conv
- 양자 stream 출력과 고전 stream 출력을 concat한 32×4×4를 3×64×64로 확대

구조 출처: Jiao et al., arXiv:2506.21015 Method 절

[약 2분]

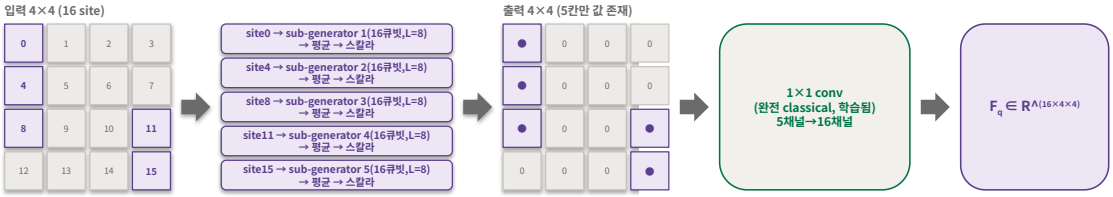
입력과 decoder를 구체적인 텐서 크기로 보겠습니다. 입력은 128차원 벡터 z이고, 노이즈에 클래스 prototype이 결합된 형태입니다. 작은 conv encoder가 이를 32×4×4 특징 맵으로 바꾸고, 절반인 16채널은 고전 stream, 나머지 16채널은 양자 stream으로 보냅니다. 양자 stream의 출력 16×4×4와 고전 stream의 16×4×4를 이어 붙이면 32×4×4가 되고, decoder가 이를 3×64×64 RGB로 키웁니다. decoder는 3×3 conv, upsample-blur-conv 세 단계, 마지막 3×3 conv로 구성됩니다.

prototype conditioning은 논문이 소수 클래스를 위해 도입한 장치입니다. EfficientNet-B0를 30 epoch 미세조정하고 최종 layer 특징의 클래스별 평균 벡터를 구해 노이즈에 결합합니다. 생성자가 클래스 공통 구조를 처음부터 학습하지 않고 클래스 내 변이에 용량을 쓰게 하려는 설계입니다. 다만 prototype만 쓰면 다양성이 줄 수 있어, 클래스 centroid 사이 거리를 최대화하는 prototype regularization loss를 추가했다고 논문은 설명합니다.

02 · MEDIQ-GAN 논문

sub-generator 상세 - 16 site 중 5개만 실제 양자 처리

나머지 11칸은 classical 1×1 conv의 편향값만 받음 (공식 GitHub 코드 기준)



site 선택: linspace(0,15,5)round → [0, 4, 8, 11, 15] (row×4+col). 나머지 11칸은 그 sub-generator의 4×4 맵에서 0으로 남음.
1×1 conv는 칸별 독립 처리(이웃 안 봄) - 값이 있는 5칸만 진짜 양자 스칼라를 16채널로 투영, 나머지 11칸은 학습된 편향(bias)뿐. 이후 8×8 업샘플에서만 보간으로 살짝 섞임.

43

[약 2분]

양자 stream의 실제 처리 범위를 공식 GitHub 코드 기준으로 정리한 슬라이드입니다. 논문 본문은 양자 stream이 특징 절반을 받아 16큐빗 VQC 다섯 개로 처리한다고 서술하는데, 공식 코드를 따라가 보면 4×4 특징 맵의 16개 위치 중 5개만 실제 양자 회로를 통과합니다.

위치 선택은 0에서 15 사이를 5등분해 반올림한 [0, 4, 8, 11, 15]입니다. 이 다섯 위치가 각각 sub-generator에 들어가 평균 기댓값 스칼라 하나를 냅니다. 나머지 11칸은 0이고, 이후 1×1 conv가 5채널을 16채널로 투영합니다. 1×1 conv는 칸을 독립적으로 처리하므로 값이 있는 5칸만 실제 양자 스칼라를 받고 나머지 11칸은 학습된 편향값만 가집니다. 이웃 칸 정보는 이후 8×8 업샘플링에서만 보간으로 섞입니다.

논문 설명과 공식 코드의 차이는 숨기지 않고 짚어야 하는 부분입니다.

이 차이가 중요한 이유는 학습되는 양자 파라미터의 수와 양자 계산이 실제로 기여하는 비중이 논문 서술보다 작을 수 있기 때문입니다.

02 · MEDIQ-GAN 논문

Hybrid 분류체계 - "어디까지가 양자인가"

같은 '양자 생성모델'이라도 Generator 전체/일부 양자 여부로 구분됨

model-level hybrid

예: HAM10000 QGAN, MosaiQ

Generator = 처음부터 끝까지 양자회로

Discriminator만 고전

PCA 등 고전 전처리가 있어도, Generator 는 양자 회로 구성

layer-level hybrid

예: MediQ-GAN

Generator 내부가 고전 stream + 양자 stream으로 병렬 분기

두 stream을 skip-connection으로 concat 후 디코딩

"layer 하나 안에서도" 양자·고전이 공존

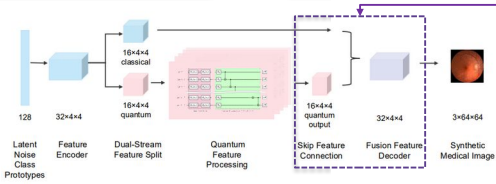


그림 출처: Jiao et al., MediQ-GAN, arXiv:2506.21015 (CC BY 4.0)

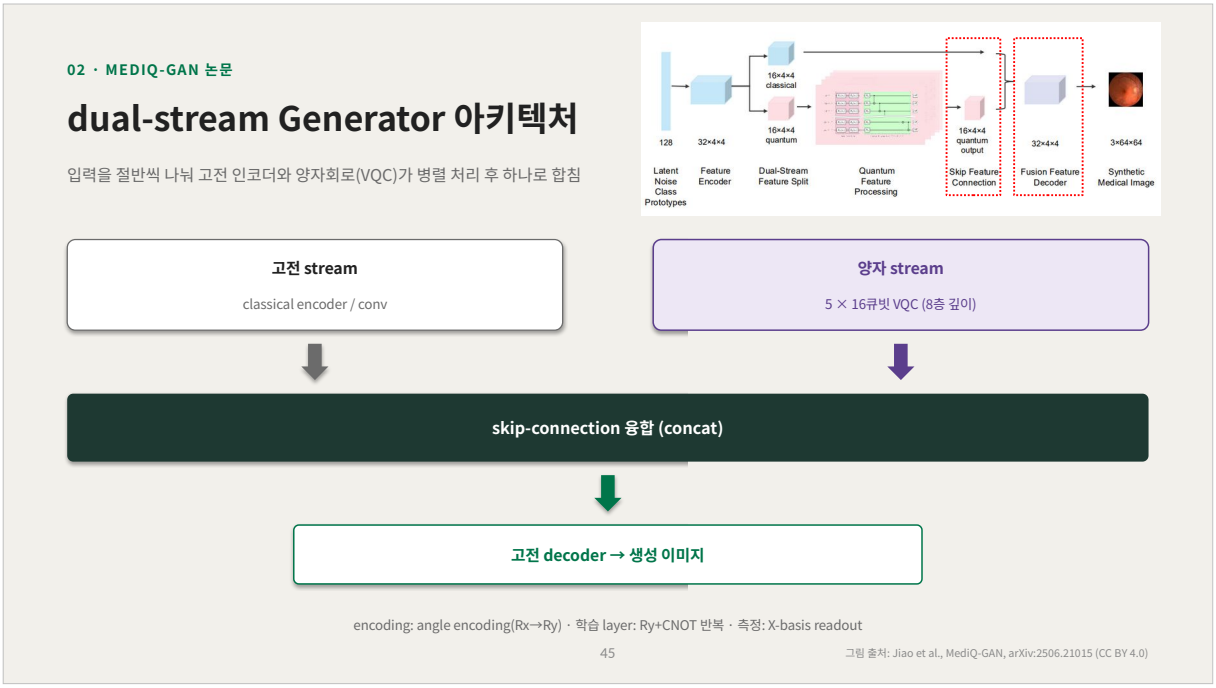
[약 2분]

hybrid의 분류 체계입니다. 같은 양자 생성모델이라도 생성자의 어디까지가 양자인가로 구분합니다.

model-level hybrid는 생성자가 처음부터 끝까지 양자회로이고 판별자만 고전인 경우입니다. HAM10000 QGAN과 MosaiQ가 해당합니다. PCA 같은 고전 전처리가 있어도 생성자 자체는 양자회로로 구성됩니다. layer-level hybrid는 생성자 내부가 고전 stream과 양자 stream으로 병렬 분기하고 skip-connection으로 합쳐집니다. layer 하나의 안에서도 양자와 고전이 공존하는 구조입니다. MediQ-GAN이 대표 사례입니다.

아래 그림의 점선 상자가 두 stream이 합쳐지는 skip-connection 부분입니다.

분류 기준을 정리하면 질문은 양자 부분이 모델 전체를 차지하는가, 모델 안의 한 부분인가입니다. 이 구분은 계산 비용과 확장성에 직접 영향을 줍니다. model-level은 모든 계산이 양자회로 안에 있어 해상도가 큐빗 수에 묶이고, layer-level은 고전 layer가 해상도를 담당해 더 큰 이미지로 확장하기 쉽습니다.



[약 1분]

dual-stream 생성자의 구성을 다시 요약합니다. 입력을 절반씩 나누어 고전 encoder와 양자회로가 병렬로 처리하고 하나로 합칩니다. 양자 stream은 16큐빗 VQC 다섯 개이고 깊이는 8층입니다. 두 출력을 concat으로 융합한 뒤 고전 decoder가 이미지를 생성합니다.

하단의 회로 사양은 encoding이 angle encoding(Rx 다음 Ry), 학습 layer가 Ry와 CNOT 반복, 측정이 X-basis readout입니다.

encoding과 측정의 구체적 형태도 짚겠습니다. 입력은 angle encoding으로 Rx 다음 Ry를 적용하고, 학습 layer는 Ry와 CNOT의 반복이며, 측정은 X 기저에서 큐빗마다 기댓값을 읽습니다. 출력이 큐빗당 하나의 연속값이므로 16큐빗이면 16차원 벡터가 되고, 이 벡터가 고전 stream과 결합됩니다.

02 · MEDIQ-GAN 논문

critic과 학습 목표

critic은 고전 convolutional network로 유지하고, 학습 목표는 WGAN-GP를 사용

항목	내용
학습 목표	WGAN-GP: $L = E[D(x)] - E[D(G(z))] + \lambda \cdot E[(\lVert \nabla D(\hat{x}) \rVert_2 - 1)^2]$ (논문 식 (1)·(2))
critic 구조	원 WGAN-GP 논문의 convolutional 구조, 입력 3×64×64
critic을 고전으로 둔 이유 (논문)	1. 3×64×64 입력을 매 iteration 처리해야 하므로 NISQ 소자에서 구현이 비현실적 2. 안정적이고 잘 알려진 critic을 두어 성능 향상을 양자 설계의 효과로 귀속
QGAN과의 차이	QGAN: 5층 완전연결 + BCE (Table 4) MediQ-GAN: convolution + WGAN-GP

46

[약 1분]

MediQ-GAN의 학습 목표와 critic입니다. 학습 목표는 WGAN-GP이고, 논문 식 (1)과 (2)에 해당합니다. critic은 실제 샘플의 점수에서 생성 샘플의 점수를 뺀 값을 최대화하고, 생성자는 그 반대로 갱신됩니다. 여기에 critic gradient 노름 벌점이 더해집니다.

critic은 양자가 아니라 원 WGAN-GP 논문의 convolutional 구조를 그대로 씁니다. 논문이 제시한 이유는 두 가지입니다. 첫째, critic은 3×64×64 입력을 매 iteration 처리해야 하므로 현재의 NISQ 소자에서 구현하기 비현실적입니다. 둘째, 안정적이고 특성이 잘 알려진 critic을 두어야 성능 향상을 양자 설계의 효과로 귀속할 수 있습니다.

앞에서 본 QGAN의 판별자와는 구조와 손실이 모두 다릅니다.

02 · MEDIQ-GAN 논문 · 심화

VQC · VQA·QAOA와의 관계

같은 '파라미터화된 회로 + 고전 최적화' 구조 공유, encoding 대상과 목적은 상이

개념	정의
VQA (Variational Quantum Algorithm)	parameterized quantum circuit(PQC) + 고전 최적화 루프를 사용하는 알고리즘 상위 범주
VQC (Variational Quantum Circuit / Classifier)	PQC를 variational 방식으로 학습시키는 구현. 분류 등 지도학습에 쓰며 data encoding + 학습 가능한 ansatz로 구성 (MediQ-GAN의 양자 stream)
QAOA (Quantum Approximate Optimization Algorithm)	조합최적화 문제(MaxCut 등) 등 목적 - cost layer(γ)와 mixer layer(β)를 번갈아 적용



공통점 vs 차이점

- 공통점: PQC → 측정 → 고전 optimizer가 파라미터 업데이트(hybrid loop)
- 차이점: encoding 대상(데이터 vs 문제)과 학습 목표

47

[약 2분]

심화 부분에서는 용어를 정리하겠습니다. VQA, 즉 variational quantum algorithm은 parameterized quantum circuit인 PQC와 고전 최적화 루프를 쓰는 알고리즘의 상위 범주입니다. VQC, 즉 variational quantum circuit은 이 PQC를 variational 방식으로 학습시키는 구체적 구현으로, 분류 같은 지도학습에 쓰며 데이터 encoding과 학습 가능한 ansatz로 구성됩니다. MediQ-GAN의 양자 stream이 이 방식입니다. QAOA는 MaxCut 같은 조합최적화 문제용으로, cost layer와 mixer layer를 번갈아 적용합니다.

공통점은 PQC, 측정, 고전 optimizer의 업데이트라는 hybrid loop 구조이고, 차이점은 encoding 대상이 데이터인지 문제인지, 그리고 학습 목표입니다.

표에서 관계를 한 줄로 기억하면, VQA가 가장 넓은 범주이고 VQC와 QAOA는 그 안의 구체적 알고리즘입니다. 이 강의의 두 모델은 VQC 쪽이고, 그 안에서 QGAN은 PQC라는 이름을, MediQ-GAN은 VQC라는 이름을 씁니다. 이름이 달라도 구조는 encoding, 학습 가능한 회전, 얽힘, 측정으로 같습니다.

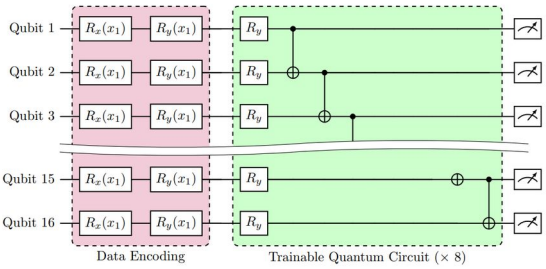
02 · MEDIQ-GAN 논문 · 심화

회로 안의 두 종류 파라미터 - encoding vs 학습

데이터를 넣는 게이트와 학습으로 값이 바뀌는 게이트, 역할 차이

구분	위치 / 값의 성격
encoding 파라미터	회로 앞단, 데이터 encoding 게이트 - 입력 데이터 x (대부분 고정, 학습 대상 아님)
학습 파라미터 θ	encoding 이후 variational ansatz - 회전 게이트 각도, CNOT, entangling 게이트 사이사이에 위치, 학습으로 업데이트됨

layer = 회전게이트(θ, 파라미터 O) + CNOT 체인(파라미터 X, 얽힘 담당)
16큐빗 × 8층 → sub-generator당 파라미터 128개 (5개 합계 640개)



※ 그림은 논문 기준(Rx→Ry·CNOT), 공식 코드는 RY→RX·CZ

그림 출처: Jiao et al., MediQ-GAN, arXiv:2506.21015 (CC BY 4.0)

[약 2분]

회로 안의 파라미터는 두 종류입니다. encoding 파라미터는 회로 앞단에서 입력 데이터 x를 넣는 게이트의 각도로, 대부분 고정이며 학습 대상이 아닙니다. 학습 파라미터 θ는 그 뒤 variational ansatz의 회전각이고, 학습으로 갱신됩니다. CNOT 같은 얽힘 게이트에는 파라미터가 없습니다.

16큐빗에 8층이면 sub-generator 하나에 128개, 다섯 개 합계 640개입니다. 그림은 논문 기준인 Rx, Ry, CNOT 순서이고 공식 코드는 RY, RX, CZ 순서입니다. 이 차이는 하단 각주에 밝혔습니다.

파라미터 수 계산을 확인하면, sub-generator 하나는 16큐빗 × 8층이라 128개이고 다섯 개면 640개입니다. QGAN 논문 설정은 sub-generator 16개 × 8큐빗 × depth 10이라 1,280개입니다. 두 모델 모두 양자 파라미터 수가 고전 신경망에 비해 매우 적다는 점이 특징입니다.

02 · MEDIQ-GAN 논문 · 심화

VQC의 출력값 - bitstring이 아니라 연속값(기댓값)

단일 측정은 0/1, 모델이 실제로 쓰는 값은 여러 번 측정을 평균낸 기댓값

$$m(z;\Theta) = (\langle X_1\rangle, \ldots, \langle X_N\rangle) \in [-1, 1]^N$$

항목	내용
단일 shot 결과	이산적 0/1 bitstring - 확률적 결과
실제 모델 출력	$\langle X_i\rangle$ 연속값(continuous) - classical decoder에 바로 투입 가능, gradient 계산도 가능
수치 안정화	h(m) = σ(LeakyReLU(LayerNorm(m))) 적용 후 classical stream과 fusion

49

[약 1분]

VQC의 출력은 bitstring이 아니라 연속값입니다. 단일 측정은 0 또는 1이지만 모델이 실제로 쓰는 값은 큐빗별 기댓값 벡터로, 각 성분이 −1에서 1 사이입니다.

이 값은 연속적이므로 classical decoder에 바로 넣을 수 있고 gradient 계산도 가능합니다. 수치 안정화를 위해 LayerNorm, LeakyReLU, 시그모이드를 순서대로 적용한 뒤 classical stream과 fusion합니다.

논문은 이 변환을 수치 안정화를 위해 적용한다고 설명합니다. 순서는 LayerNorm으로 분포를 정규화하고, LeakyReLU와 시그모이드를 거쳐 값의 범위를 다음 layer가 다루기 좋게 만든 뒤 고전 stream과 결합하는 것입니다. 출력이 연속값이므로 시뮬레이터에서는 gradient가 그대로 계산됩니다.

02 · MEDIQ-GAN 논문 · 심화

실제 채택 방식 - Exact State Vector Simulation

공식 코드(mediq-gan.py) 설정

```
dev = qml.device("lightning.qubit", wires=args.n_qubits)
@qml.qnode(dev, interface="torch", diff_method="adjoint")
def circuit(...):
    ...
    return [qml.expval(qml.PauliX(i)) for i in range(args.n_qubits)]
```

항목	내용
shots 미지정	PennyLane 기본값 shots=None → 분석적(exact) 기댓값 계산, 반복 측정 없음
diff_method="adjoint"	정확한 state vector 접근이 있어야만 가능한 gradient 계산법
state vector 규모	n큐빗 = 2^n차원 복소벡터로 완전 표현(16qubit→65,536차원, 개인 PC로 처리 가능) - 게이트 적용=유니터리 행렬곱(확률적 요소 없음)

50

[약 2분]

공식 코드(mediq-gan.py)의 실제 설정입니다. 장치는 lightning.qubit이고 diff_method는 adjoint, 반환값은 큐빗별 PauliX 기댓값입니다.

shots를 지정하지 않으면 PennyLane은 반복 측정 없이 분석적으로 정확한 기댓값을 계산합니다. adjoint는 정확한 state vector에 접근할 수 있을 때만 쓸 수 있는 gradient 계산법입니다. 16 큐빗의 state vector는 65,536차원이어서 개인 PC에서 처리 가능합니다. 게이트 적용은 유니터리 행렬곱이라 확률적 요소가 없습니다.

코드의 세 줄을 읽어 보면, 첫 줄은 C++로 구현된 lightning.qubit 시뮬레이터를 큐빗 수만큼의 wire로 만들고, 둘째 줄은 이 회로를 PyTorch와 연결해 adjoint로 미분하겠다는 선언이며, 마지막 줄은 큐빗마다 X 기댓값을 반환합니다. 반환값이 16개의 실수이므로 이후 고전 layer와 자연스럽게 이어집니다.

02 · MEDIQ-GAN 논문 · 심화

'Hardware-agnostic'의 정확한 의미

논문 원문 그대로 인용 시 오해하기 쉬운 표현

논문 원문 인용

"Our approach is quantum-inspired and **hardware-agnostic**: the correctness does not depend on quantum execution, and quantum devices serve only to accelerate computation."

구분	내용
오해 (X)	하드웨어를 아예 안 썼다는 뜻
정확한 뜻 (O)	모델의 타당성이 특정 실행 환경(시뮬레이터 vs 실제 큐빗)에 좌우되지 않도록 설계했다는 뜻
학습(training)	state vector 시뮬레이터로 진행
NISQ evaluation	학습 완료된 회로를 IBM Marrakesh 실기에 올려 inference만 검증 (클래스별 FID +19 ~ +79 상승, 논문은 '비교 가능한 수준'으로 평가)

51

[약 2분]

논문의 'hardware-agnostic'이라는 표현은 오해하기 쉽습니다. 원문은 접근법이 quantum-inspired이며 정확성이 양자 실행에 의존하지 않고, 양자 소자는 계산 가속에만 쓰인다고 말합니다.

이는 하드웨어를 전혀 쓰지 않았다는 뜻이 아니라, 모델의 타당성이 실행 환경, 즉 시뮬레이터인지 실제 큐빗인지에 좌우되지 않도록 설계했다는 뜻입니다. 학습은 state vector 시뮬레이터로 진행했고, NISQ 평가는 학습이 끝난 회로를 IBM Marrakesh에 올려 inference만 검증했습니다. 이 검증의 구체적인 수치는 결과 부분에서 다시 봅니다.

정리하면 hardware-agnostic은 양자 우위가 있다는 주장이 아니라, 결과가 어디서 실행하든 유지되도록 설계했다는 설명입니다. 따라서 이 논문의 성능을 양자 컴퓨터의 성능으로 읽으면 안 되고, 시뮬레이션으로 학습한 hybrid 모델의 성능으로 읽어야 합니다. 이 구분은 앞의 시뮬레이션 한계 슬라이드와도 연결됩니다.

02 · MEDIQ-GAN 논문 · 심화

shot 기반으로 학습한다면 - Parameter-shift Rule

Exact statevector 방식이 아니라, gradient를 구할 때 쓰는 규칙

$$\partial \langle X_i \rangle / \partial \theta_j = [\langle X_i \rangle(\theta_j+\pi/2) - \langle X_i \rangle(\theta_j-\pi/2)] / 2$$

개념	설명
계산 방식	회로 내부를 역전파로 거슬러 올라가는 게 아니라, θ_j를 shift한 회로를 처음부터 끝까지 2번 새로 실행해 얻은 결과값의 단순 뺄셈
순전파(forward) 시점	shift된 회로는 전혀 실행되지 않음 - 원래 θ값으로 1번만 실행, 그 출력이 다음 classical layer로 전달
역전파(backward) 시점	$+\pi/2$, $-\pi/2$ 두 회로가 파라미터 하나마다 개별적으로 실행됨

전체 chain rule: $dLoss/d\theta_j = dLoss/d\langle X_i \rangle$ (classical backprop) × $d\langle X_i \rangle/d\theta_j$ (parameter-shift, 뺄셈 기반)

52

[약 2분]

shot 기반으로 학습한다면 gradient는 parameter-shift rule로 구합니다. 기댓값을 파라미터로 미분한 값은, 해당 파라미터를 ±π/2 이동시킨 회로 두 개의 기댓값 차이를 2로 나눈 것과 같습니다.

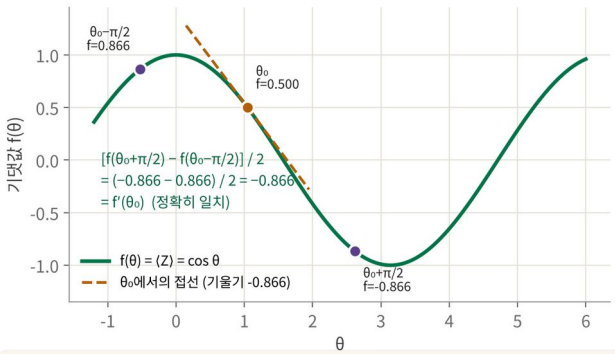
핵심은 회로 내부를 역전파로 거슬러 올라가는 것이 아니라 shift한 회로를 처음부터 끝까지 두 번 새로 실행해 얻은 결과를 빼는 것이라는 점입니다. 순전파에서는 shift한 회로를 전혀 실행하지 않고 원래 값으로 한 번만 실행하며, 역전파 시점에 파라미터마다 두 회로가 개별적으로 실행됩니다. 전체 chain rule은 손실의 기댓값에 대한 미분, 즉 고전 backpropagation과 이 parameter-shift 값의 곱입니다.

유도 과정 대신 결과만 기억하면, 회전 게이트로 파라미터화된 회로에서는 파라미터를 ±π/2 이동한 두 번의 실행으로 정확한 미분을 얻는다는 것입니다. 다음 슬라이드에서 가장 단순한 예로 확인합니다.

02 · MEDIQ-GAN 논문 · 심화

parameter-shift rule 예시: f(θ) = ⟨Z⟩ = cos θ

shift한 회로 두 번의 기댓값 차이로 정확한 미분을 얻음



계산 순서 ($\theta_o = \pi/3$)

- $f(\theta_o) = \cos(\pi/3) = 0.500$
- $\theta_o + \pi/2$ 회로를 실행: $f = -0.866$
- $\theta_o - \pi/2$ 회로를 실행: $f = 0.866$
- 차이를 2로 나눔: $(-0.866 - 0.866) / 2 = -0.866 = -\sin\theta_o = f'(\theta_o)$

유의점

파라미터마다 회로를 2번 더 실행해야 하고, shot 기반이면 각 기댓값에 통계 오차가 붙음. 시뮬레이터에서는 adjoint나 backpropagation으로 대체함

53

[약 2분]

parameter-shift rule을 가장 단순한 예로 확인하겠습니다. 큐빗 하나에 RY(θ)를 적용하고 Z 기댓값을 재면 f(θ)는 cos θ가 됩니다.

θ_o를 π/3로 잡으면 $f(\theta_o)$는 0.5입니다. 미분 값을 얻으려면 θ_o에 π/2를 더한 회로와 π/2를 뺀 회로를 각각 실행합니다. 첫 회로의 기댓값은 −0.866, 둘째 회로의 기댓값은 0.866입니다. 두 값의 차이를 2로 나누면 −0.866이 되는데, 이는 $-\sin\theta_o$, 즉 θ_o에서의 접선 기울기와 정확히 일치합니다. 근사가 아니라 정확한 값이라는 점이 이 규칙의 특징입니다.

이 규칙은 시뮬레이터가 아닌 실제 장치에서도 같은 방식으로 쓸 수 있다는 장점이 있습니다. 반면 파라미터마다 회로를 두 번 더 실행해야 하고, shot 기반이면 각 기댓값에 통계 오차가 붙습니다. 이 비용은 바로 다음 슬라이드에서 계산합니다. 시뮬레이터에서는 adjoint나 backpropagation으로 같은 gradient를 훨씬 싸게 구합니다.

02 · MEDIQ-GAN 논문 · 심화

계산 비용 - 현재 학습의 어려움

파라미터 수만큼 회로를 반복 실행해야 하는 구조적 한계

총 회로 실행 횟수 = C (순전파 회로 수) + 2P (파라미터 별 +shift, −shift)

파라미터 수 P	회로 실행 횟수
640 (회로 5개 × 16큐빗 × 8층)	5 + 1,280 = 1,285회
10,000	1 + 20,000 = 20,001회

측정 횟수까지 곱하면

총 측정 횟수 = 회로 실행 횟수 × shots.
- P=10,000, shots=1,024 → 20,001×1,024 ≈ 약 2,048만 회.
- batch 32 · 학습 step 10,000까지 포함하면 → 20,001×1,024×32×10,000 ≈ 6.5×10^{12}(약 6.5조 회)

54

[약 2분]

그 결과 계산 비용은 파라미터 수에 비례합니다. 총 회로 실행 횟수는 순전파 회로 수 C에 파라미터마다 +shift, −shift 두 번을 더한 C + 2P입니다.

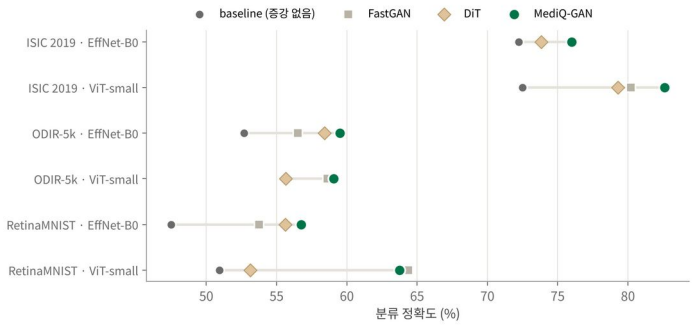
파라미터가 640개인 이 모델은 5 + 1,280 = 1,285회, 파라미터가 1만 개로 늘면 20,001회입니다. 여기에 측정 횟수를 곱하면, P가 1만이고 shots가 1,024일 때 약 2,048만 회, batch 32와 학습 step 1만까지 포함하면 약 6.5×10^{12}, 6.5조 회입니다. 현재 하드웨어에서 parameter-shift로 이 규모를 학습하는 것이 비현실적인 이유이고, 논문이 학습을 시뮬레이터에서 한 이유이기도 합니다.

표의 숫자를 다시 읽어 보면 파라미터 640개에서는 한 번의 gradient 계산에 회로 1,285회가 필요하고, 파라미터가 1만 개로 늘면 20,001회입니다. 파라미터 수에 정비례해 늘어나므로 모델이 커질수록 하드웨어 학습은 급격히 비싸집니다. 이 때문에 이 논문뿐 아니라 많은 연구가 시뮬레이터에서 학습하고 실기에서는 inference만 확인합니다.

02 · MEDIQ-GAN 논문 결과

결과 ① - 분류 성능 (Table 1)

baseline 대비 정확도는 3개 데이터셋 · 2개 분류기 모두에서 상승하나, 모든 행에서 최고는 아님



읽는 법

- EfficientNet-B0 정확도 상승: ISIC +3.75, ODIR +6.83, RetinaMNIST +9.25
- ViT-small 정확도 상승: +10.11, +3.44, +12.82
- RetinaMNIST ViT-small: FastGAN 64.37이 MediQ-GAN 63.75보다 높음
- ISIC ViT-small AUC: FastGAN 0.9549 > 0.9517
- MosaiQ는 baseline 이하 (ISIC ViT-small 50.25%)

수치 출처: Jiao et al., arXiv:2506.21015 Table 1

[약 2분]

MediQ-GAN의 첫 번째 결과, 분류 성능입니다. 논문 Table 1을 점으로 다시 그렸습니다. 각 행은 데이터셋과 분류기 조합이고, 점은 증강하지 않은 baseline, FastGAN, DiT, MediQ-GAN의 정확도입니다.

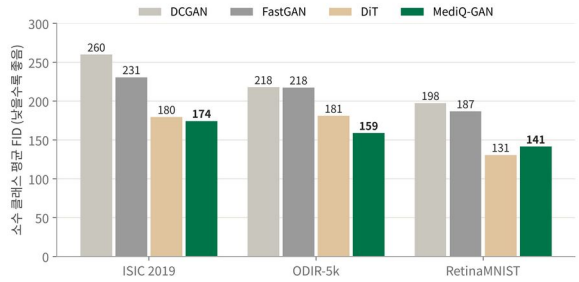
MediQ-GAN은 여섯 행 모두에서 baseline보다 높습니다. EfficientNet-B0 기준 정확도 상승은 ISIC 2019 +3.75, ODIR-5k +6.83, RetinaMNIST +9.25이고, ViT-small은 각각 +10.11, +3.44, +12.82입니다. 논문이 평균 상승으로 인용한 수치가 EfficientNet-B0 기준과 같다는 점도 확인했습니다.

다만 모든 행에서 최고는 아닙니다. RetinaMNIST ViT-small에서는 FastGAN의 정확도 64.37이 MediQ-GAN의 63.75보다 높고, ISIC ViT-small AUC도 FastGAN이 0.9549로 0.9517보다 높습니다. 고전 모델 MosaiQ는 baseline보다 낮아져 ISIC ViT-small에서 정확도가 50.25%까지 떨어졌습니다. 논문의 서술도 '가장 큰 또는 그에 근접한 개선'입니다.

02 · MEDIQ-GAN 논문 결과

결과 ② - 생성 품질: FID와 LPIPS

소수 클래스 FID는 ISIC·ODIR에서 MediQ-GAN이 가장 낮고, RetinaMNIST에서는 DiT가 더 낮음



해석

- DiT는 확산 모델로 용량이 훨씬 큼. 논문 서술은 'best or second-best'
- MosaiQ: FID 316 ~ 593, RetinaMNIST LPIPS 0.079로 거의 같은 이미지만 생성
- FID는 클래스당 표본이 적을수록 불안정함

소수 클래스 평균 LPIPS (높을수록 다양)	Real	DiT	FastGAN	MediQ-GAN
ISIC 2019	0.457	0.367	0.422	0.409
ODIR-5k	0.612	0.609	0.609	0.601
RetinaMNIST	0.396	0.321	0.394	0.384

수치 출처: Jiao et al., Extended Data Table 2·3

[약 2분]

생성 품질 지표입니다. 왼쪽 그래프는 소수 클래스 평균 FID로, 논문 Extended Data Table 2입니다. 낮을수록 좋습니다.

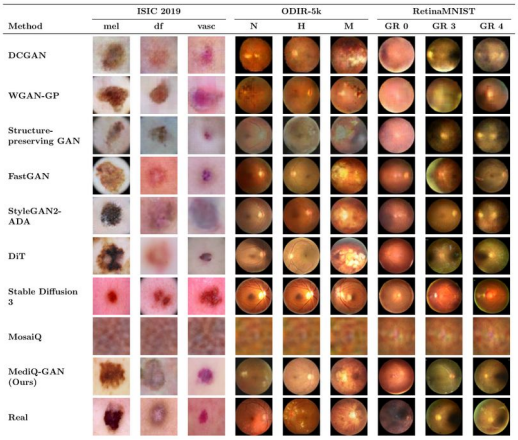
ISIC 2019에서는 MediQ-GAN이 174.5로 DiT 179.6과 FastGAN 230.8보다 낮고, ODIR-5k에서도 158.9로 가장 낮습니다. 그러나 RetinaMNIST에서는 DiT가 130.8로 MediQ-GAN의 141.4보다 낮습니다. 즉 모든 데이터셋에서 최고는 아니며, 논문도 'best or second-best'라고 서술합니다. DiT가 확산 모델로 훨씬 큰 용량을 가진다는 점도 함께 읽어야 합니다.

아래 표는 소수 클래스 평균 LPIPS입니다. 높을수록 다양합니다. MediQ-GAN은 실제 값에 가까운 수준이지만 FastGAN이 소폭 더 높은 경우가 있습니다. 한편 앞서 언급한 MosaiQ는 FID가 316에서 593 범위이고 RetinaMNIST의 LPIPS가 0.079로 매우 낮아, 거의 같은 이미지만 만든다는 뜻입니다.

02 · MEDIQ-GAN 논문 결과

결과 ③ - 생성 이미지 비교 (Fig. 2)

열은 데이터셋별 대표 클래스, 행은 방법, 마지막 행은 실제 이미지



논문의 정성 서술

- DCGAN, Structure-preserving GAN: 흐린 dermoscopic 질감
- StyleGAN2-ADA: 다수 클래스는 개선, 희소 클래스에서 약함
- FastGAN, DiT: 데이터가 극히 적은 ISIC df에서 구조 손실
- MosaiQ: PCA 축소로 색과 구조가 사라진 흐린 패치
- MediQ-GAN: 클래스 특징 보존 (논문 서술)
- 저자의 정성 평가이므로 FID, LPIPS와 함께 해석함

그림 출처: Jiao et al., arXiv:2506.21015 Fig. 2 (CC BY 4.0)

[약 1분]

논문 Fig. 2의 생성 이미지 비교입니다. 열은 데이터셋별 대표 클래스, 행은 방법이고 마지막 행이 실제 이미지입니다.

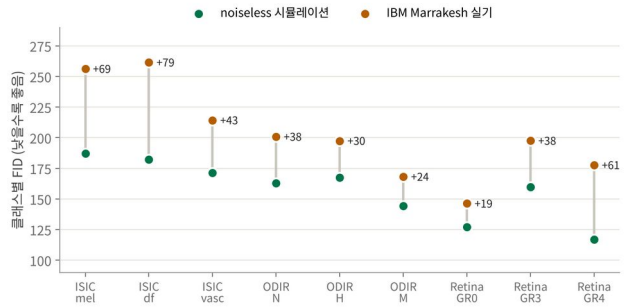
논문의 서술을 정리하면 다음과 같습니다. DCGAN과 Structure-preserving GAN은 흐린 질감을 만들고, StyleGAN2-ADA는 다수 클래스에서는 개선되지만 희소 클래스에서 약합니다. FastGAN과 DiT는 데이터가 극히 적은 ISIC의 df에서 구조를 잃습니다. MosaiQ는 PCA로 차원을 줄인 영향으로 색과 구조가 사라진 흐린 패치만 나옵니다. MediQ-GAN은 클래스 특징을 보존한다고 논문은 서술합니다.

이 비교는 저자의 정성 평가라는 점에 유의하십시오. 앞 슬라이드의 FID와 LPIPS와 함께 볼 때 의미가 있고, 이미지 몇 장만으로 우열을 판단하기는 어렵습니다.

02 · MEDIQ-GAN 논문 결과

결과 ④ - IBM 실기 검증

학습된 회로를 IBM Marrakesh에서 inference만 실행: 모든 클래스에서 FID 상승



읽는 법

- 범위: 데이터셋별 대표 클래스 9개, inference만 (학습은 시뮬레이션)
- FID 상승폭: +19 (RetinaMNIST GR0) ~ +79 (ISIC df)
- 논문 평가: 시뮬레이션보다 약간 낮으나 비교 가능한 수준

비교

ISIC df: 실기 FID 261.5는 FastGAN 225.0보다 나쁘고 DCGAN 272.6보다 좋음. 노이즈에 무너지지 않는다는 근거이며, 실기에서 고전 baseline보다 우위라는 근거는 아님

수치 출처: Jiao et al., Extended Data Table 4, Table 2

[약 2분]

IBM 실기 검증 결과입니다. 학습이 끝난 5개의 16큐빗 회로를 IBM Marrakesh에서 실행했고, 대기 시간과 shot 제한 때문에 데이터셋별 대표 클래스의 inference로 한정했습니다. 학습은 하지 않았습니다.

그래프에서 초록 점이 noiseless 시뮬레이션, 주황 점이 실기 결과이고 숫자는 FID 증가분입니다. 아홉 개 클래스 모두에서 FID가 올랐고 상승폭은 RetinaMNIST GR0의 +19에서 ISIC df의 +79 까지입니다. 논문은 이를 '시뮬레이션보다 약간 낮지만 비교 가능한 수준'이라고 평가합니다.

수치로 보면 ISIC df의 실기 FID 261.5는 FastGAN의 225.0보다 나쁘고 DCGAN의 272.6보다는 좋습니다. 노이즈에도 결과가 크게 무너지지 않는다는 점은 의미가 있지만, 실기에서 고전 baseline 보다 우위라는 근거는 아닙니다. 이 검증이 inference에 한정된다는 점도 함께 기억해야 합니다.

02 · MEDIQ-GAN 논문 결과

결과 ⑤ - 생성자의 학습 가능성 분석

Jacobian 특이값 분포와 DLA 분석으로 hybrid 생성자를 평가함

분석	의미	논문 결과
effective rank, participation ratio	잠재 방향 중 출력에 실제 영향을 주는 비율 (높을수록 좋음)	특이값 감쇠가 고전 baseline보다 완만 (Extended Data Fig. 3)
log10 condition number	생성자 conditioning (낮을수록 좋음)	MediQ-GAN 2.09 / 2.04 / 2.01 (ISIC / ODIR / Retina) DCGAN 2.54 / 2.54 / 2.44, StyleGAN2-ADA 5.78 / 6.25 / 6.58
DLA 분석	회로가 만드는 변환군의 차원으로 표현력과 barren plateau 위험을 판단	depth 8에서 표현력이 충분하고 barren plateau를 피함
ablation	양자 채널 수, VQC 개수	늘릴수록 성능과 effective rank 개선, 현 설정 이후 이득 감소. 16채널 · 5 VQC는 시뮬레이션 비용과 절충

한계

논문 결론: MediQ-GAN은 모든 unconstrained benchmark에서 고전 생성모델을 넘어서지는 못함. 이 분석은 생성자의 수치적 성질에 대한 것임

수치 출처: Jiao et al., Extended Data Table 5, Discussion

[약 2분]

논문은 성능 외에 생성자의 학습 가능성과 표현력을 분석합니다. 세 가지입니다.

첫째, effective rank와 participation ratio는 잠재 방향 중 출력에 실제 영향을 주는 비율로, Jacobian 특이값 감쇠가 고전 baseline보다 완만하다고 보고합니다. 둘째, log condition number는 생성자의 conditioning으로 낮을수록 좋습니다. MediQ-GAN은 세 데이터셋에서 2.09, 2.04, 2.01이고, DCGAN은 2.54, 2.54, 2.44, StyleGAN2-ADA는 5.78, 6.25, 6.58입니다. 셋째, DLA 분석에서 depth 8이 충분한 표현력을 가지면서 barren plateau를 피한다고 설명합니다. ablation에서는 양자 채널이나 VQC를 늘릴수록 성능과 effective rank가 개선되지만 현재 설정 이후에는 이득이 줄고, 16채널과 VQC 5개는 시뮬레이션 비용과 절충한 선택이라고 합니다.

이 분석은 수치적 성질에 대한 것이고, 논문 스스로도 결론에서 MediQ-GAN이 모든 unconstrained benchmark에서 고전 생성모델을 넘어서지는 못했다고 밝힙니다.

CHAPTER 3

내용 정리

60

[약 1분]
마지막 장은 내용 정리입니다. 두 논문을 비교하고 앞으로의 연구 방향을 짚는 것으로 마무리합니다.

03 · 내용 정리

두 논문 비교 요약 및 정리

QGAN 및 MediQ-GAN 정리

구분	QGAN	MediQ-GAN
Hybrid 유형	model-level (Generator 전체 양자)	layer-level (dual-stream)
큐빗 규모	7+1큐빗 × sub-generator 16개	5 × 16큐빗 VQC(stream 하나)
데이터셋	HAM10000 (피부병변, 2클래스 집중)	ISIC2019 · ODIR-5k · RetinaMNIST
검증 방식	증강 전/후 CNN 분류 성능(AUC-ROC)	클래스별 FID·LPIPS + 실기(IBM) 검증

61

[약 2분]

두 논문을 표로 비교하겠습니다. hybrid 유형은 QGAN이 model-level, MediQ-GAN이 layer-level입니다. 큐빗 규모는 QGAN이 7+1큐빗 회로 16개, MediQ-GAN이 16큐빗 VQC 5개입니다. 데이터셋은 QGAN이 HAM10000의 두 클래스에 집중하고, MediQ-GAN은 ISIC 2019, ODIR-5k, RetinaMNIST 세 가지입니다. 검증 방식은 QGAN이 증강 전후 CNN 분류 성능이고, MediQ-GAN은 클래스별 FID와 LPIPS에 IBM 실기 검증을 더했습니다.

이 차이 때문에 두 논문의 수치를 직접 비교할 수 없다는 점에 유의하십시오.

표를 읽을 때의 주의점을 덧붙이면, 큐빗 규모의 7+1과 16은 단순 비교할 수 없습니다. 앞의 값은 patch 하나를 만드는 회로이고 sub-generator 16개가 이를 나눠 맡으며, 뒤의 값은 양자 stream의 한 회로이고 이를 다섯 개 씁니다. 총 큐빗 수보다 회로가 출력에서 차지하는 역할이 더 중요한 비교 기준입니다.

03 · 내용 정리

두 논문을 읽을 때의 점검 항목

양자 생성모델 논문의 주장을 평가할 때 적용하는 다섯 가지 기준

점검 항목	QGAN	MediQ-GAN
비교 대상	고전 vanilla GAN 1종	고전 GAN 5종, 확산 모델 2종, MosaiQ
평가 방식	분류 성능 (AUC-ROC, 정확도)	분류 성능 + FID + LPIPS
양자 요소의 범위	생성자 전체	생성자 일부 (공식 코드 기준 16개 위치 중 5개)
조건 의존성	segmentation 입력에서만 증강 효과	모든 지표에서 최고는 아님 (결과 ①, ②)
한계의 명시	개선 폭 AUC +0.017. 이 저장소 8×8 재현에서는 정확도 하락	실기 검증은 inference에 한정. 고전 모델을 전 영역에서 넘지는 못함

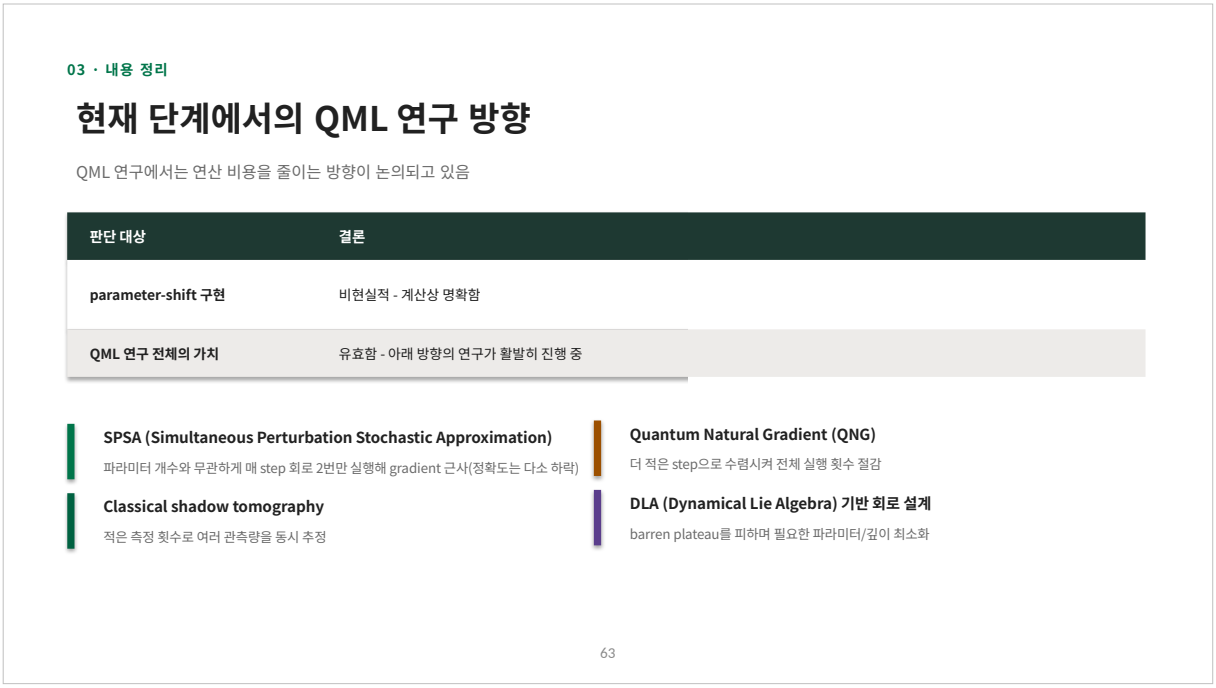
62

[약 2분]

두 논문을 읽을 때 적용할 점검 항목을 다섯 가지로 정리했습니다. 양자 생성모델 논문뿐 아니라 어떤 논문에도 쓸 수 있는 기준입니다.

비교 대상은 QGAN이 고전 GAN 한 종류인 반면 MediQ-GAN은 고전 GAN 다섯 종, 확산 모델 두 종, 양자 모델 MosaiQ를 포함합니다. 평가 방식은 QGAN이 분류 성능 하나이고 MediQ-GAN은 분류 성능, FID, LPIPS를 함께 씁니다. 양자 요소의 범위는 QGAN이 생성자 전체, MediQ-GAN은 일부이며 공식 코드 기준으로 16개 위치 중 5개입니다. 조건 의존성에서 QGAN은 segmentation 입력에서만 효과가 있었고, MediQ-GAN은 모든 지표에서 최고가 아니었습니다. 마지막으로 한계의 명시 여부입니다. QGAN 개선 폭은 AUC +0.017로 작고 이 저장소의 재현에서는 정확도가 하락했으며, MediQ-GAN은 실기 검증이 inference에 한정됩니다.

결론적으로 두 논문 모두 양자 모델이 고전 모델보다 우월하다는 증거를 제시하는 것이 아니라, 양자 구성 요소를 포함한 생성모델이 실제로 동작하고 일부 조건에서 경쟁력이 있음을 보입니다.



[약 2분]

현재 단계의 QML 연구 방향입니다. 앞에서 본 것처럼 parameter-shift를 그대로 구현하는 것은 비현실적이지만 QML 연구 전체의 가치는 유효하며, 연산 비용을 줄이는 연구가 활발합니다.

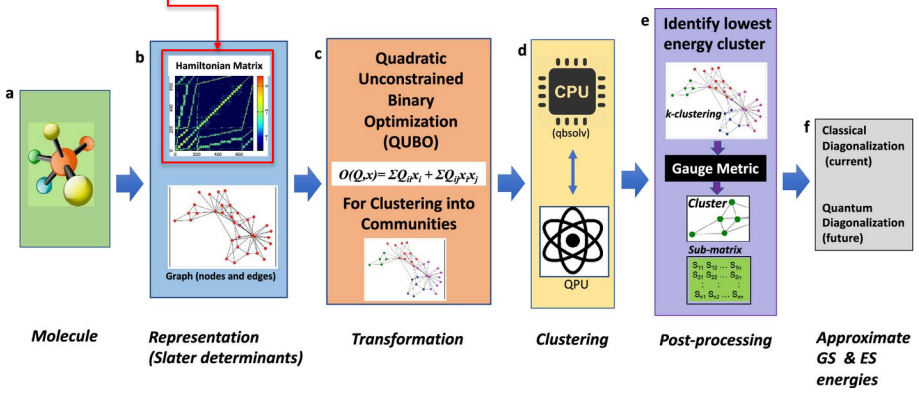
SPSA는 파라미터 수와 무관하게 step마다 회로를 두 번만 실행해 gradient를 근사하는 방법으로 정확도는 다소 낮아집니다. Quantum Natural Gradient는 더 적은 step으로 수렴시켜 전체 실행 횟수를 줄입니다. Classical shadow tomography는 적은 측정으로 여러 관측량을 동시에 추정하고, DLA 기반 회로 설계는 barren plateau를 피하면서 필요한 파라미터와 깊이를 줄입니다. MediQ-GAN 논문도 향후 과제로 QNG와 회로 설계를 언급합니다.

각 방법이 줄이는 비용을 정리하겠습니다. SPSA는 파라미터 수에 따른 회로 실행 횟수를 상수로 줄이고, QNG는 필요한 step 수를 줄이며, classical shadow는 측정 횟수를 줄이고, DLA 기반 설계는 회로 자체의 크기를 줄입니다. 네 방법이 서로 다른 축의 비용을 줄이므로 함께 적용할 가능성도 연구되고 있습니다.

03 · 내용 정리

이미지 생성 분야에서 양자 알고리즘 유의점

양자 생성 모델은 **양자 데이터, 해밀토니안 상태 등을 만드는 데** 특화되어 있기에, **기존 데이터가 많은 영역, 모델, 컴퓨팅이 잘하는 영역에 대한 성과는 검증 단계**



64

그림 출처: https://www.nature.com/articles/s41598-021-83561-x (CC BY 4.0)

[약 2분]

마지막으로 이미지 생성 분야에서 양자 알고리즘을 해석할 때의 유의점입니다. 양자 생성모델은 양자 데이터나 해밀토니안 상태처럼 양자적 대상을 만드는 데 특화되어 있습니다. 그림은 분자의 해밀토니안 행렬을 그래프로 바꿔 QUBO로 풀고 양자 대각화로 이어지는 양자화학 pipeline이고, 빨간 박스가 양자적 대상을 다루는 부분입니다.

반면 이미지처럼 기존 데이터가 많고 고전 모델과 컴퓨팅이 잘 발달한 영역에서는 양자 모델의 우위가 아직 검증 단계에 있습니다. 오늘 본 두 논문의 결과도 이 맥락에서 읽어야 합니다.

이 슬라이드의 메시지는 양자 모델이 쓸모없다는 것이 아니라, 적용 영역에 따라 검증의 수준이 다르다는 것입니다. 양자 상태나 해밀토니안은 고전 컴퓨터로 표현하기 어려운 대상이어서 양자 모델이 자연스러운 후보이고, 이미지는 고전 모델이 이미 매우 강한 영역이어서 우위를 입증하려면 더 엄격한 비교가 필요합니다. 오늘 본 논문들이 고전 baseline과 비교한 방식이 그 엄격함의 한 예입니다.



[약 1분]

이것으로 1일차 이론을 마칩니다. 질문을 받겠습니다. 2일차에는 전처리와 QGAN 학습 실습을 진행합니다.