QML Lecture · 3일차

실습 설명 자료

MediQ-GAN 미세조정 → QGAN과 같은 지표로 비교

hybrid 수준 : model-level과 layer-level

QGAN은 생성자 전체가 양자회로, MediQ-GAN은 생성자 안의 한 갈래만 양자회로

QGAN - model-level hybrid

Andra et al., 2025 · 2일차 실습

- 생성자 = 양자회로 (sub-generator 4개)
- patch를 나눠 만들고 이어붙임
- 출력 = 측정 확률 (patch별 합 0 ~ 1)
- 판별자만 고전

z → [양자회로 × 4] → 이미지

MediQ-GAN - layer-level hybrid

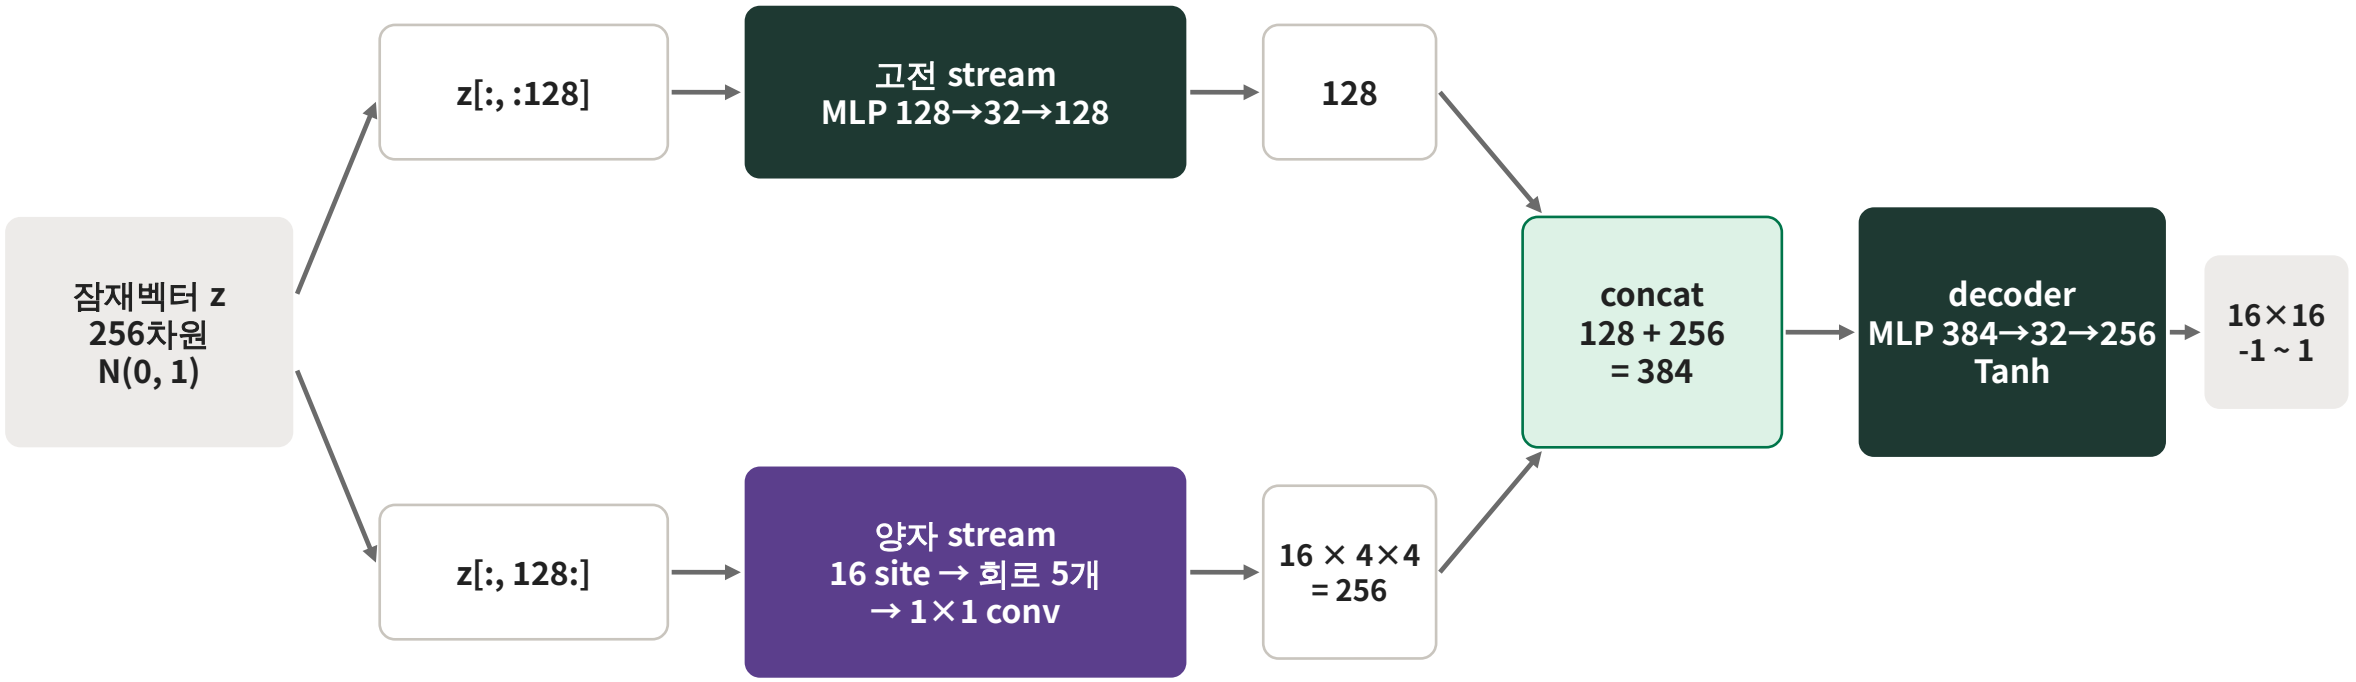
Jiao et al., 2025 · 3일차 실습

- 생성자 = 고전 stream + 양자 stream
- 입력을 절반씩 나눠 병렬 처리 후 concat
- 출력 = 고전 decoder → Tanh (-1 ~ 1)
- 양자 stream은 원 논문 스펙(16큐빗 × 5, depth 8)

z → [고전 ‖ 양자] → concat → decoder

dual-stream의 데이터 흐름

잠재벡터 256차원을 절반씩 나누고, 두 stream의 출력을 이어붙여 decoder로 보냄

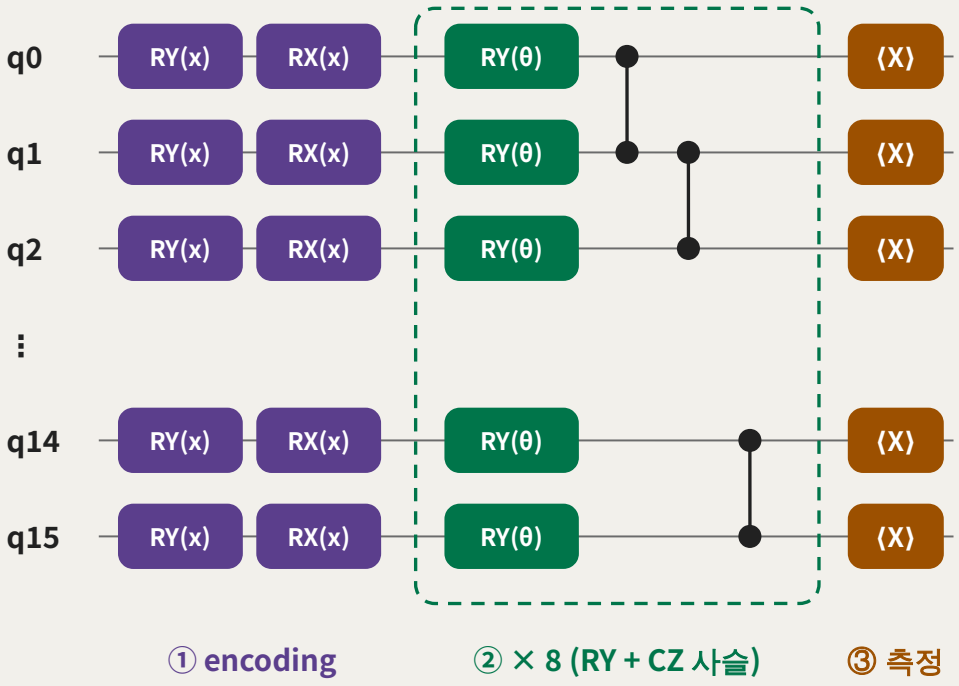



```
z_c, z_q = z[:, :self.half], z[:, self.half:]
fused = torch.cat([self.classical_stream(z_c),
                   self.quantum_stream(z_q)], dim=1)
return self.decoder(fused)
```

양자 회로 : 16큐빗, depth 8

같은 값으로 RY → RX encoding, [학습 RY + 인접 CZ] × 8, 큐빗별 PauliX 기댓값

```
@qml.qnode(dev, interface="torch", diff_method="adjoint")
def q_circuit(x, weights):
    for i in range(n_qubits):          # 1 encoding
        qml.RY(x[i], wires=i)
        qml.RX(x[i], wires=i)
    for layer in range(q_depth):       # 2 x 8
        for i in range(n_qubits):
            qml.RY(weights[layer, i], wires=i)
        for i in range(n_qubits - 1):
            qml.CZ(wires=[i, i + 1])
    return [qml.expval(qml.PauliX(i))  # 3
            for i in range(n_qubits)]
```



출력: 큐빗 16개의 기댓값 → 평균 → site당 스칼라 1개

생성자 파라미터 구성

30,000개 중 양자 회전각은 640개(2.1%). 2일차 QGAN 생성자는 280개 전부가 양자 회전각임

모듈	구성	파라미터	비율
decoder	Linear 384 → 32 → 256 + Tanh	20,768	69.2%
고전 stream	Linear 128 → 32 → 128	8,352	27.8%
양자 회전각	**sub-generator 5 × 8층 × 16큐빗**	**640**	**2.1%**
q_align	Linear 8 → 16 (site 벡터를 큐빗 수에 맞춤)	144	0.5%
proj_qexp	1×1 conv, 5 → 16채널	96	0.3%
합계		**30,000**	100%

파라미터 수로는 2%지만, 학습 시간의 대부분은 이 640개가 들어 있는 16큐빗 회로의 시뮬레이션에서 나옴.

노트북 ToyDualStreamGenerator(in_dim 256)에서 직접 센 값

원 논문과 실습의 차이

양자 stream은 원 논문 스펙 그대로, 고전 부분과 판별자·평가를 단순화함

항목	원 논문 (Jiao et al.)	3일차 실습	비고
양자 stream	16큐빗 × 5, depth 8	**동일**	공식 레포와 같은 회로
고전 encoder / decoder	conv	MLP	16×16 저해상도라 단순화
입력 · 출력	64×64 RGB	16×16 그레이스케일	2일차 전처리 자산 사용
판별자	WGAN-GP critic	표준 BCE 판별자 (Table 4)	QGAN과 같은 판별자
학습	GPU, 전체 학습	25 epoch 사전학습 + 수업 중 미세조정	16큐빗 시뮬레이션 비용
평가	FID, 분류 성능	지표 4종	FID는 16×16에서 의미 없음

계산 비용 : 수업에서 미세조정만 하는 이유

16큐빗 회로 시뮬레이션이 비싸 25 epoch 사전학습에 196분(약 3시간 15분)이 걸림

	2일차 QGAN	3일차 MediQ-GAN
큐빗 (회로 하나)	7	16
상태벡터 차원	$2^7 = 128$	$2^{16} = 65{,}536$
미분 방식	backprop (default.qubit)	adjoint (lightning.qubit)
1 step	약 2.2초 (batch 8)	**약 20초 (batch 4)**
전체 학습	600 step 약 22분	**25 epoch 196분 (epoch당 7.8분)**
수업 중 학습	처음부터 400 step (Colab 약 35분)	10 epoch checkpoint에서 20 step

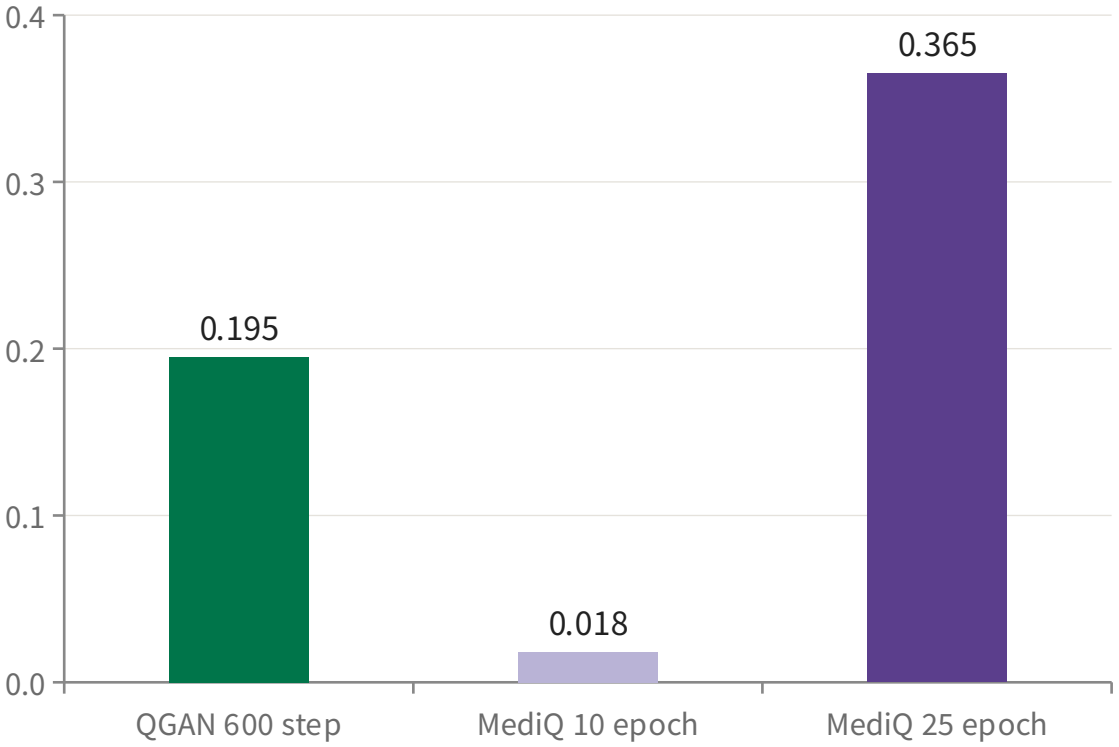
16큐빗은 12큐빗보다 상태벡터가 16배 크고(2^{16} vs 2^{12}), 실측 소요 시간은 약 20배였음.

로컬 CPU 실측. epoch 시간은 checkpoint epoch_sec 평균

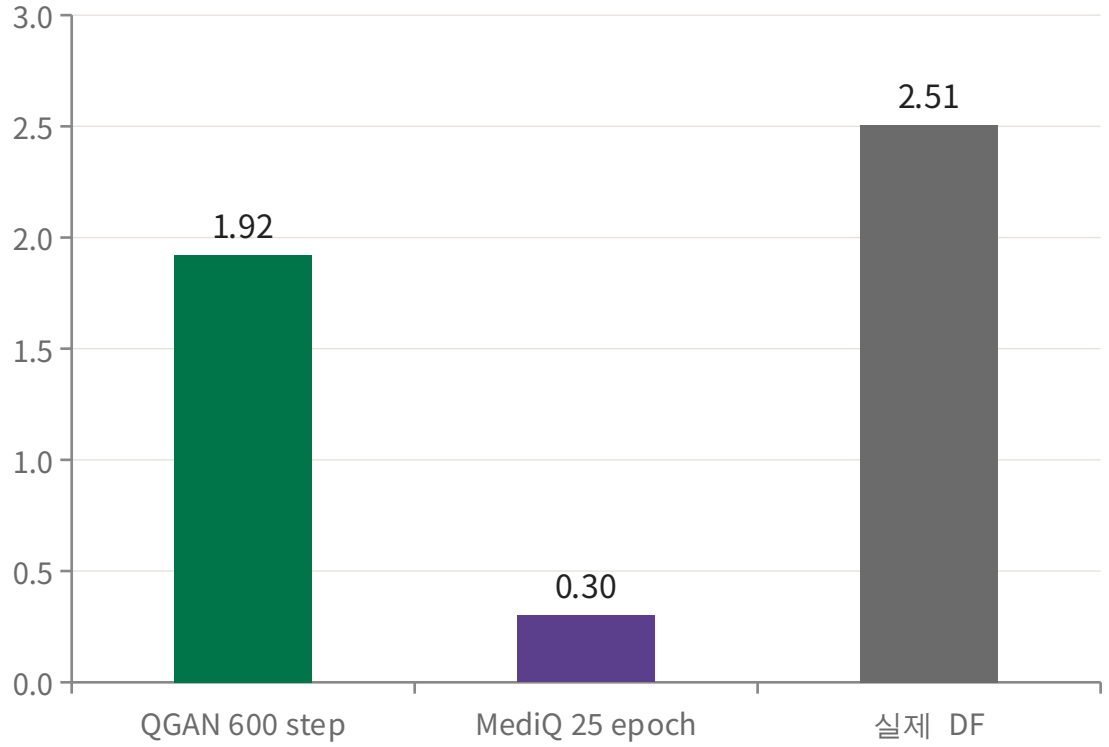
지표 비교 : 형태 재현과 다양성

상관은 MediQ-GAN이 높고, 샘플 간 거리는 QGAN이 실제 DF에 가까움

② 클래스 평균 상관 (높을수록 형태 재현)



④ 샘플 간 거리 (0 에 가까우면 mode collapse)



수치: README 결과표 (로컬 CPU). MediQ-GAN은 16장, QGAN은 64장으로 평가

결과 해석 : 두 모델의 한계

QGAN은 형태 재현이 약하고, MediQ-GAN은 평균 이미지에 가까운 그림을 반복함

지표	QGAN 600 step	MediQ-GAN 25 epoch	의미
② 클래스 평균 상관 ↑	0.195	**0.365**	평균 형태는 MediQ-GAN이 더 가까움
③ 최근접 실제 거리	1.64	3.44	MediQ-GAN은 실제 이미지 어느 것과도 멂
④ 샘플 간 거리 (실제 2.505)	**1.92**	0.30	MediQ-GAN은 비슷한 그림을 반복

해석

QGAN: 다양성은 실제에 가깝지만 병변 형태 재현이 약함. patch를 서로 독립적으로 만들어 이미지 전체 구조를 잡기 어려움.
MediQ-GAN: 평균 형태는 잘 맞추지만 다양성이 실제의 1/8. 최종 출력을 고전 decoder가 만들기 때문에 Tanh가 포화되면 z와 무관한 이미지가 나옴.
②만 보면 MediQ-GAN이 낫다고 결론 내리게 됨. ②는 평균 형태만 보므로 같은 이미지를 반복해도 높게 나옴.

정리

3일차 정리

MediQ-GAN 구조와 미세조정, QGAN과의 비교

주제	정리
hybrid 수준	QGAN은 생성자 전체가 양자회로(model-level), MediQ-GAN은 생성자 안의 양자 stream만 양자회로(layer-level)
dual-stream	잠재벡터 256차원을 절반씩 고전 MLP와 양자 stream으로 나눠 처리한 뒤 concat → decoder → Tanh
양자 stream	16큐빗 × depth 8 회로 5개가 16 site 중 5개만 처리. PauliX 기댓값 출력이라 ancilla qubit이 필요 없음
파라미터와 비용	30,000개 중 양자 회전각은 640개(2.1%)지만 학습 시간 대부분이 16큐빗 시뮬레이션 (25 epoch 196분)
checkpoint와 미세조정	config로 같은 구조를 만든 뒤 가중치를 불러옴. 판별자도 같은 시점 상태로 불러와 20 step 추가 학습
학습 안정성	BCE 판별자가 우세함 (lr_g 0.02에서 3 epoch 만에 mode collapse). 원 논문은 WGAN-GP critic을 씀
비교 결과	상관은 MediQ-GAN 0.365 > QGAN 0.195, 다양성은 QGAN 1.92 > MediQ-GAN 0.30. 지표 하나로 순위를 정하지 않음