QML Lecture · 3일차

실습 설명 자료

MediQ-GAN 미세조정 → QGAN과 같은 지표로 비교

1

3일차 노트북(practice/day3_practice.ipynb)의 내용을 설명하는 자료.

- 핵심만 10장: MediQ-GAN 구조, 계산 비용, QGAN과의 비교. 2일차 복습·checkpoint 코드·논문 결과는 노트북에 있음.

MediQ-GAN 구조 · 1일차 복습

hybrid 수준 : model-level과 layer-level

QGAN은 생성자 전체가 양자회로, MediQ-GAN은 생성자 안의 한 갈래만 양자회로

QGAN - model-level hybrid

Andra et al., 2025 · 2일차 실습

- 생성자 = 양자회로 (sub-generator 4개)
- patch를 나눠 만들고 이어붙임
- 출력 = 측정 확률 (patch별 합 0 ~ 1)
- 판별자만 고전

z → [양자회로 × 4] → 이미지

MediQ-GAN - layer-level hybrid

Jiao et al., 2025 · 3일차 실습

- 생성자 = 고전 stream + 양자 stream
- 입력을 절반씩 나눠 병렬 처리 후 concat
- 출력 = 고전 decoder → Tanh (-1 ~ 1)
- 양자 stream은 원 논문 스펙(16큐빗 × 5, depth 8)

z → [고전 ‖ 양자] → concat → decoder

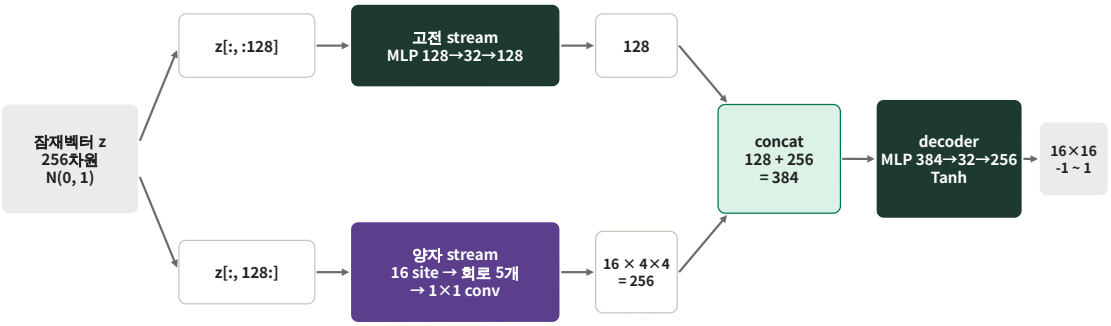
2

- 1일차 슬라이드 31 'Hybrid 분류체계' 복습.
- model-level hybrid: 판별자만 고전, 생성자는 처음부터 끝까지 양자회로. 출력이 측정 확률이라 척도가 확률(patch별 합 0 ~ 1).
- layer-level hybrid: 생성자 안에서 고전 layer와 양자 layer가 함께 동작. 최종 출력은 고전 decoder가 만들고 Tanh(-1 ~ 1).
  - MediQ-GAN 논문의 주장: 전역 구조는 고전, 세부는 양자가 맡는 쪽이 더 높은 해상도로 확장됨.

MediQ-GAN 구조 · 노트북 §3 코드

dual-stream의 데이터 흐름

잠재벡터 256차원을 절반씩 나누고, 두 stream의 출력을 이어붙여 decoder로 보냄




```
z_c, z_q = z[:, :self.half], z[:, self.half:]
fused = torch.cat([self.classical_stream(z_c),
                   self.quantum_stream(z_q)], dim=1)
return self.decoder(fused)
```

3

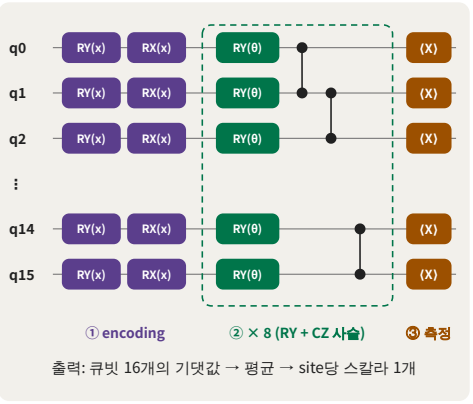
- forward 코드: z[:, :half]는 고전 stream, z[:, half:]는 양자 stream으로 감(논문 Fig. 1 'Feature Split').
- 고전 stream은 128 → 32 → 128 MLP. 논문은 conv encoder지만 16×16 저해상도라 MLP로 단순화함.
- 양자 stream은 128차원을 4×4 = 16 site(site당 8차원)로 보고, site [0, 4, 8, 11, 15]만 회로 5개가 하나씩 처리함. 나머지 11칸은 0.
- 양자 stream 출력은 16채널 × 4×4 = 256차원. 고전 128과 concat하면 384차원.
  - decoder는 384 → 32 → 256 MLP + Tanh. 최종 이미지는 이 고전 decoder가 만듦 → Tanh가 포화되면 z와 무관한 상수 이미지가 나올 수 있음(README 학습 안정성).

MediQ-GAN 구조 · 노트북 §3 코드

양자 회로 : 16큐빗, depth 8

같은 값으로 RY → RX encoding, [학습 RY + 인접 CZ] × 8, 큐빗별 PauliX 기댓값

```
@qml.qnode(dev, interface="torch", diff_method="adjoint")
def q_circuit(x, weights):
    for i in range(n_qubits):         # 1 encoding
        qml.RY(x[i], wires=i)
        qml.RX(x[i], wires=i)
    for layer in range(q_depth):      # 2 x 8
        for i in range(n_qubits):
            qml.RY(weights[layer, i], wires=i)
        for i in range(n_qubits - 1):
            qml.CZ(wires=[i, i + 1])
    return [qml.expval(qml.PauliX(i))  # 3
            for i in range(n_qubits)]
```



출력: 큐빗 16개의 기댓값 → 평균 → site당 스칼라 1개

4

- 2일차 회로와 다른 점: ① 입력이 난수가 아니라 q_align이 만든 학습된 특징값, ② RY와 RX를 같은 값으로 연속 적용, ③ 확률 대신 PauliX 기댓값(-1 ~ 1, 큐빗당 1개)을 출력.
- 기댓값 출력이라 ancilla qubit이나 post-selection이 필요 없음.
- lightning.qubit(C++ 시뮬레이터)은 backprop을 지원하지 않아 adjoint 미분을 씀. 16큐빗 상태벡터는 2^16 = 65,536차원.
  - 공식 레포(mediq-gan.py의 quantum_circuit)와 같은 구성. depth는 논문 그림 기준 8(레포 CLI 기본값은 6).

MediQ-GAN 구조 · 파라미터 분포

생성자 파라미터 구성

30,000개 중 양자 회전각은 640개(2.1%). 2일차 QGAN 생성자는 280개 전부가 양자 회전각임

모듈	구성	파라미터	비율
decoder	Linear 384 → 32 → 256 + Tanh	20,768	69.2%
고전 stream	Linear 128 → 32 → 128	8,352	27.8%
양자 회전각	**sub-generator 5 × 8층 × 16큐빗**	**640**	**2.1%**
q_align	Linear 8 → 16 (site 벡터를 큐빗 수에 맞춤)	144	0.5%
proj_qexp	1×1 conv, 5 → 16채널	96	0.3%
합계		**30,000**	100%

파라미터 수로는 2%지만, 학습 시간의 대부분은 이 640개가 들어 있는 16큐빗 회로의 시뮬레이션에서 나옴.

5

노트북 ToyDualStreamGenerator(in_dim 256)에서 직접 센 값

- 값은 노트북의 ToyDualStreamGenerator(in_dim 256)를 그대로 만들어 센 것.
- 파라미터 수로는 양자 stream이 2.1%에 불과하지만, 학습 시간의 대부분은 16큐빗 회로 시뮬레이션에서 나옴.
- 2일차 QGAN은 생성자 280개가 전부 양자 파라미터. '양자 비율'이 hybrid 수준의 차이를 수치로 보여줌.
  - parameter-shift로 실제 장치에서 학습한다면 640개 × 2 = 1,280회 회로 실행이 샘플 하나의 기울기에 필요함.

MediQ-GAN 구조 · 한계

원 논문과 실습의 차이

양자 stream은 원 논문 스펙 그대로, 고전 부분과 판별자·평가를 단순화함

항목	원 논문 (Jiao et al.)	3일차 실습	비고
양자 stream	16큐빗 × 5, depth 8	**동일**	공식 레포와 같은 회로
고전 encoder / decoder	conv	MLP	16×16 저해상도라 단순화
입력 · 출력	64×64 RGB	16×16 그레이스케일	2일차 전처리 자산 사용
판별자	WGAN-GP critic	표준 BCE 판별자 (Table 4)	QGAN과 같은 판별자
학습	GPU, 전체 학습	25 epoch 사전학습 + 수업 중 미세조정	16큐빗 시뮬레이션 비용
평가	FID, 분류 성능	지표 4종	FID는 16×16에서 의미 없음

6

- 양자 stream을 줄이지 않은 이유: 줄이면 '논문이 말한 모델'이 아니게 됨. 대신 해상도와 학습 구간을 줄임(README 설계 원칙 1).
- 판별자 차이가 가장 큼: 원 논문은 WGAN-GP critic(gradient penalty로 판별자를 제약). 실습은 QGAN과 같은 표준 BCE 판별자라 판별자가 우세함(README 학습 안정성).
  - 평가: 16×16에서는 FID가 의미 없어 지표 4종을 씀.

미세조정 · 계산 비용

계산 비용 : 수업에서 미세조정만 하는 이유

16큐빗 회로 시뮬레이션이 비싸 25 epoch 사전학습에 196분(약 3시간 15분)이 걸림

	2일차 QGAN	3일차 MediQ-GAN
큐빗 (회로 하나)	7	16
상태벡터 차원	$2^7 = 128$	$2^{16} = 65{,}536$
미분 방식	backprop (default.qubit)	adjoint (lightning.qubit)
1 step	약 2.2초 (batch 8)	**약 20초 (batch 4)**
전체 학습	600 step 약 22분	**25 epoch 196분 (epoch당 7.8분)**
수업 중 학습	처음부터 400 step (Colab 약 35분)	10 epoch checkpoint에서 20 step

16큐빗은 12큐빗보다 상태벡터가 16배 크고(2^{16} vs 2^{12}), 실측 소요 시간은 약 20배였음.

7

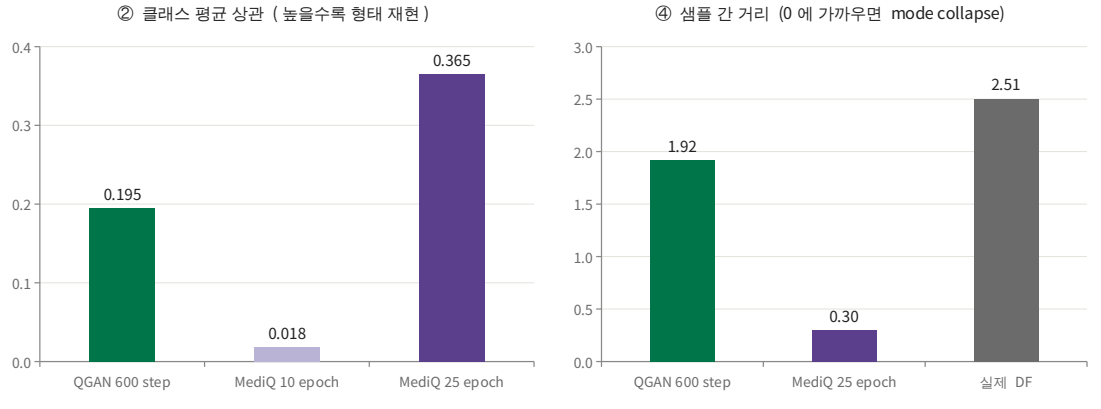
로컬 CPU 실측. epoch 시간은 checkpoint epoch_sec 평균

- 1 epoch = DF 115장을 batch 4로 28 step. checkpoint 기록상 epoch당 평균 7.8분(453 ~ 487초).
- 1 step 약 20초: batch 4 × 샘플당 약 3초(판별자 step + 생성자 step).
- 큐빗 수에 따른 비용: 16큐빗은 12큐빗 대비 상태벡터가 16배(2^16 vs 2^12), 실측 소요시간은 약 20배였음(3일차 노트북 §6 ④).
  - 그래서 수업에서는 10 epoch checkpoint(약 80분 학습분)에서 출발해 20 step만 더 돌림.

비교 · 노트북 §5

지표 비교 : 형태 재현과 다양성

상관은 MediQ-GAN이 높고, 샘플 간 거리는 QGAN이 실제 DF에 가까움



8

수치: README 결과표 (로컬 CPU). MediQ-GAN은 16장, QGAN은 64장으로 평가

- MediQ-GAN 25 epoch: 클래스 평균 상관 0.365로 QGAN(0.195)보다 높음 - 평균적인 병변 형태를 더 잘 맞춤.
- 그러나 샘플 간 거리 0.30은 실제 DF(2.505)의 약 1/8 - 비슷한 이미지를 반복 생성(mode collapse 경향).
- QGAN은 상관이 낮지만 다양성 1.92로 실제 분포에 가까움.
- 10 epoch(0.018)과 25 epoch(0.365) 차이로 학습량이 결과를 크게 바꾼다는 점도 확인함.
  - 이 자료 작성 중 노트북 실행 결과: MediQ-GAN 25 epoch 상관 0.366, 다양성 0.285 - README와 일치.

비교 · 결과 해석

결과 해석 : 두 모델의 한계

QGAN은 형태 재현이 약하고, MediQ-GAN은 평균 이미지에 가까운 그림을 반복함

지표	QGAN 600 step	MediQ-GAN 25 epoch	의미
② 클래스 평균 상관 ↑	0.195	**0.365**	평균 형태는 MediQ-GAN이 더 가까움
③ 최근접 실제 거리	1.64	3.44	MediQ-GAN은 실제 이미지 어느 것과도 멂
④ 샘플 간 거리 (실제 2.505)	**1.92**	0.30	MediQ-GAN은 비슷한 그림을 반복

해석

QGAN: 다양성은 실제에 가깝지만 병변 형태 재현이 약함. patch를 서로 독립적으로 만들어 이미지 전체 구조를 잡기 어려움.
MediQ-GAN: 평균 형태는 잘 맞추지만 다양성이 실제의 1/8. 최종 출력을 고전 decoder가 만들기 때문에 Tanh가 포화되면 z와 무관한 이미지가 나옴.
②만 보면 MediQ-GAN이 낫다고 결론 내리게 됨. ②는 평균 형태만 보므로 같은 이미지를 반복해도 높게 나옴.

9

- MediQ-GAN의 최근접 실제 거리 3.44는 QGAN(1.64)의 두 배. 생성 이미지가 어떤 실제 이미지와도 가깝지 않음 → 개별 병변이 아니라 평균적인 형태를 반복해 그린다는 해석과 맞음(상관은 높고 다양성은 낮음).
- 클래스 평균 상관(②)은 평균 형태만 보므로, 같은 평균 이미지를 반복해도 높게 나옴. ②만 보면 MediQ-GAN이 낫다고 잘못 결론 내리게 됨.
  - 토론: 데이터 증강이 목적이라면 어느 쪽이 더 쓸모 있는가 / 지표 하나로 순위를 매길 수 있는가.

정리

3일차 정리

MediQ-GAN 구조와 미세조정, QGAN과의 비교

주제	정리
hybrid 수준	QGAN은 생성자 전체가 양자회로(model-level), MediQ-GAN은 생성자 안의 양자 stream만 양자회로(layer-level)
dual-stream	잠재벡터 256차원을 절반씩 고전 MLP와 양자 stream으로 나눠 처리한 뒤 concat → decoder → Tanh
양자 stream	16큐빗 × depth 8 회로 5개가 16 site 중 5개만 처리. PauliX 기댓값 출력이라 ancilla qubit이 필요 없음
파라미터와 비용	30,000개 중 양자 회전각은 640개(2.1%)지만 학습 시간 대부분이 16큐빗 시뮬레이션 (25 epoch 196분)
checkpoint와 미세조정	config로 같은 구조를 만든 뒤 가중치를 불러옴. 판별자도 같은 시점 상태로 불러와 20 step 추가 학습
학습 안정성	BCE 판별자가 우세함 (lr_g 0.02에서 3 epoch 만에 mode collapse). 원 논문은 WGAN-GP critic을 씀
비교 결과	상관은 MediQ-GAN 0.365 > QGAN 0.195, 다양성은 QGAN 1.92 > MediQ-GAN 0.30. 지표 하나로 순위를 정하지 않음

오늘 다룬 내용을 노트북 순서대로 정리함.