QML Lecture · 3일차

실습 설명 자료

MediQ-GAN 미세조정 → QGAN과 같은 지표로 비교

1

[약 2분]

3일차 실습 설명을 시작하겠습니다. 오늘은 노트북 practice/day3_practice.ipynb의 내용을 설명합니다. 핵심만 10장으로 구성했습니다. MediQ-GAN의 구조, 계산 비용, QGAN과의 비교를 다루고, 2일차 복습과 checkpoint 코드, 논문 결과는 노트북에 있습니다. 오늘의 목표는 같은 지표로 두 모델을 비교하고, 그 비교를 어떻게 해석해야 하는지 확인하는 것입니다.

진행 방식을 말씀드리겠습니다. 노트북을 Colab으로 열고 Drive에 사본을 저장하는 과정은 2일차와 같습니다. 2일차 런타임은 남아 있지 않으므로 1번 섹션부터 순서대로 실행합니다. 대부분의 셀은 수초 안에 끝나고, 오래 걸리는 셀은 3번 구조 확인이 십여 초, 4번 미세조정 20 step이 Colab 무료 CPU에서 약 14분입니다. 연결이 끊기면 다시 1번 섹션부터 실행하며, 미세조정 셀을 빼면 1 ~ 2분이면 됩니다.

순서는 노트북 §1과 §2에서 QGAN 기준선을 다시 계산하고, §3에서 MediQ-GAN 구조를 확인한 뒤, §4 미세조정 셀을 실행해 둔 상태에서 이 슬라이드의 비용과 비교 부분을 설명하겠습니다.

MediQ-GAN 구조 · 1일차 복습

hybrid 수준 : model-level과 layer-level

QGAN은 생성자 전체가 양자회로, MediQ-GAN은 생성자 안의 한 갈래만 양자회로

QGAN - model-level hybrid

Andra et al., 2025 · 2일차 실습

- 생성자 = 양자회로 (sub-generator 4개)
- patch를 나눠 만들고 이어붙임
- 출력 = 측정 확률 (patch별 합 0 ~ 1)
- 판별자만 고전

z → [양자회로 × 4] → 이미지

MediQ-GAN - layer-level hybrid

Jiao et al., 2025 · 3일차 실습

- 생성자 = 고전 stream + 양자 stream
- 입력을 절반씩 나눠 병렬 처리 후 concat
- 출력 = 고전 decoder → Tanh (-1 ~ 1)
- 양자 stream은 원 논문 스펙(16큐빗 × 5, depth 8)

z → [고전 ‖ 양자] → concat → decoder

2

[약 3분]

먼저 1일차 슬라이드 44번 hybrid 분류체계의 복습입니다. model-level hybrid는 판별자만 고전이고 생성자는 처음부터 끝까지 양자회로입니다. QGAN이 이 유형이고, 출력이 측정 확률이라 척도가 확률, 즉 patch별 합이 0에서 1입니다. layer-level hybrid는 생성자 안에서 고전 layer와 양자 layer가 함께 동작하는 유형입니다. MediQ-GAN이 이 유형이며, 최종 출력은 고전 decoder가 만들고 Tanh를 거친 −1에서 1 사이 값입니다. 왼쪽 상자의 정보에서 보듯 QGAN은 sub-generator 4개가 patch를 나눠 만들어 이어 붙입니다. 오른쪽 상자는 입력을 절반씩 나누어 병렬로 처리한 뒤 concat하고, 양자 stream은 원 논문 스펙인 16큐빗 5개, depth 8입니다. MediQ-GAN 논문은 전역 구조는 고전 층이, 세부 표현은 양자 sub-generator가 맡는다고 설명합니다.

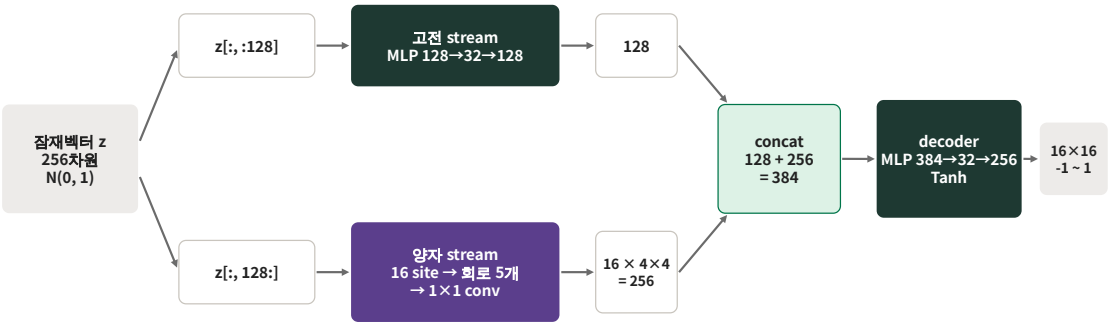
§1에서 다시 정의하는 QGAN은 2일차와 같은 구조이지만, 불러오는 checkpoint는 강사가 600 step 학습한 것입니다. 2일차 수업에서 돌린 400 step보다 학습량이 많습니다.

확인 질문입니다. 두 모델의 출력 척도가 다른데 같은 지표로 어떻게 비교합니까. 2일차의 to_unit_scale로 QGAN 출력은 prob 모드, 즉 이미지별 min-max로, MediQ-GAN 출력은 tanh 모드, 즉 x 더하기 1을 2로 나눠 모두 0과 1 사이로 되돌린 뒤 계산합니다.

MediQ-GAN 구조 · 노트북 §3 코드

dual-stream의 데이터 흐름

잠재벡터 256차원을 절반씩 나누고, 두 stream의 출력을 이어붙여 decoder로 보냄




```
z_c, z_q = z[:, :self.half], z[:, self.half:]
fused = torch.cat([self.classical_stream(z_c),
                   self.quantum_stream(z_q)], dim=1)
return self.decoder(fused)
```

3

[약 3분]

dual-stream의 데이터 흐름입니다. 잠재벡터 z는 256차원이고 정규분포에서 뽑습니다. forward 코드를 보면 z의 앞 절반은 고전 stream으로, 뒤 절반은 양자 stream으로 갑니다. 논문 Fig. 1의 Feature Split에 해당합니다. 고전 stream은 128에서 32, 128로 가는 MLP입니다. 논문은 conv encoder지만 16×16 저해상도라 MLP로 단순화했습니다. 양자 stream은 128차원을 4×4, 즉 16 site로 보고 site당 8차원으로 나눕니다. 그중 0, 4, 8, 11, 15번 site만 회로 5개가 하나씩 처리하고 나머지 11칸은 0입니다. 양자 stream의 출력은 16채널 곱하기 4×4로 256차원이고, 고전 128과 concat하면 384차원입니다. decoder는 384에서 32, 256으로 가는 MLP에 Tanh를 붙인 구조이며 최종 이미지는 이 고전 decoder가 만듭니다. 그래서 Tanh가 포화되면 z와 무관한 상수 이미지가 나올 수 있고, README의 학습 안정성 사례가 이에 해당합니다.

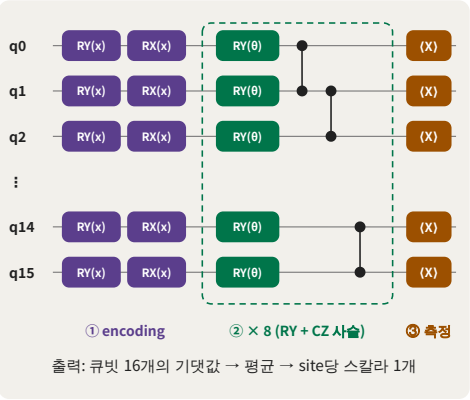
다섯 site의 위치는 코드에서 0부터 15까지를 다섯 칸으로 고르게 나눈 뒤 반올림해 정합니다. 그 결과가 0, 4, 8, 11, 15입니다. 즉 양자 stream의 16 site 가운데 회로가 실제로 값을 만드는 곳은 다섯 곳이고, 1일차 슬라이드 43번의 '16 site 중 5개만 실제 양자 처리'가 이 부분입니다. 이 구조에서 양자회로가 생성 이미지에 기여하는 비중은 생각보다 작다는 점을 결과 해석 때 기억해 주십시오.

MediQ-GAN 구조 · 노트북 §3 코드

양자 회로 : 16큐빗, depth 8

같은 값으로 RY → RX encoding, [학습 RY + 인접 CZ] × 8, 큐빗별 PauliX 기댓값

```
@qml.qnode(dev, interface="torch", diff_method="adjoint")
def q_circuit(x, weights):
    for i in range(n_qubits):          # 1 encoding
        qml.RY(x[i], wires=i)
        qml.RX(x[i], wires=i)
    for layer in range(q_depth):       # 2 x 8
        for i in range(n_qubits):
            qml.RY(weights[layer, i], wires=i)
        for i in range(n_qubits - 1):
            qml.CZ(wires=[i, i + 1])
    return [qml.expval(qml.PauliX(i))  # 3
            for i in range(n_qubits)]
```



출력: 큐빗 16개의 기댓값 → 평균 → site당 스칼라 1개

4

[약 2분]

양자 회로를 보겠습니다. 16큐빗, depth 8입니다. 2일차 회로와 다른 점이 세 가지 있습니다. 첫째, 입력이 난수가 아니라 q_align이 만든 학습된 특징값입니다. 둘째, encoding에서 RY와 RX를 같은 값으로 연속 적용합니다. 셋째, 확률 대신 PauliX 기댓값을 큐빗당 하나씩 출력하며 범위는 −1에서 1입니다. 기댓값 출력이라 ancilla qubit이나 post-selection이 필요 없습니다. 미분은 adjoint 방식을 씁니다. C++로 구현된 lightning.qubit은 backprop을 지원하지 않아서입니다. 16큐빗의 상태벡터는 2의 16제곱, 65,536차원입니다. 이 구성은 공식 레포의 mediq-gan.py에 있는 quantum_circuit과 같고, depth는 논문 그림 기준 8을 따랐으며 레포 CLI의 기본값은 6입니다. 출력 16개의 기댓값은 평균을 내어 site당 스칼라 하나로 만듭니다.

확인 질문입니다. 확률 출력과 기댓값 출력은 하드웨어에서 어떻게 다릅니까. 2일차 회로의 확률 출력은 2의 7제곱인 128개 값을 shot으로 추정해야 합니다. 기댓값 출력은 큐빗마다 값 하나라 16개만 추정하면 됩니다. 다만 PauliX 기댓값은 X basis 측정이므로, 하드웨어에서는 측정 직전에 Hadamard 게이트로 basis를 바꿔 측정합니다. 시뮬레이터에서는 상태벡터에서 바로 계산하므로 이 차이가 드러나지 않습니다.

MediQ-GAN 구조 · 파라미터 분포

생성자 파라미터 구성

30,000개 중 양자 회전각은 640개(2.1%). 2일차 QGAN 생성자는 280개 전부가 양자 회전각임

모듈	구성	파라미터	비율
decoder	Linear 384 → 32 → 256 + Tanh	20,768	69.2%
고전 stream	Linear 128 → 32 → 128	8,352	27.8%
양자 회전각	**sub-generator 5 × 8층 × 16큐빗**	**640**	**2.1%**
q_align	Linear 8 → 16 (site 벡터를 큐빗 수에 맞춤)	144	0.5%
proj_qexp	1×1 conv, 5 → 16채널	96	0.3%
합계		**30,000**	100%

파라미터 수로는 2%지만, 학습 시간의 대부분은 이 640개가 들어 있는 16큐빗 회로의 시뮬레이션에서 나옴.

5

노트북 ToyDualStreamGenerator(in_dim 256)에서 직접 센 값

[약 2분]
생성자의 파라미터 구성입니다. 이 표는 노트북의 ToyDualStreamGenerator, in_dim 256을 그대로 만들어 센 값입니다. 전체는 30,000개입니다. decoder가 20,768개로 69.2%, 고전 stream이 8,352개로 27.8%를 차지하고, 양자 회전각은 sub-generator 5개 곱하기 8층 곱하기 16큐빗인 640개로 2.1%입니다. q_align이 144개, proj_qexp이 96개입니다. 파라미터 수로는 양자 stream이 2.1%에 불과하지만, 학습 시간의 대부분은 이 640개가 들어 있는 16큐빗 회로의 시뮬레이션에서 나옵니다. 2일차 QGAN은 생성자 280개가 전부 양자 파라미터입니다. 이 양자 비율이 두 hybrid 수준의 차이를 수치로 보여 줍니다. 참고로 parameter-shift로 실제 장치에서 학습한다면 640개 곱하기 2, 1,280회의 회로 실행이 샘플 하나의 gradient에 필요합니다.
표의 숫자는 직접 확인할 수 있습니다. decoder는 384 곱하기 32에 bias 32를 더한 12,320개와 32 곱하기 256에 bias 256을 더한 8,448개의 합입니다. 고전 stream도 같은 방식으로 4,128개와 4,224개를 더한 값입니다. 노트북에서 sum(p.numel() for p in mq_gen.parameters())를 실행하면 30,000이 나옵니다.

MediQ-GAN 구조 · 한계

원 논문과 실습의 차이

양자 stream은 원 논문 스펙 그대로, 고전 부분과 판별자·평가를 단순화함

항목	원 논문 (Jiao et al.)	3일차 실습	비고
양자 stream	16큐빗 × 5, depth 8	**동일**	공식 레포와 같은 회로
고전 encoder / decoder	conv	MLP	16×16 저해상도라 단순화
입력 · 출력	64×64 RGB	16×16 그레이스케일	2일차 전처리 자산 사용
판별자	WGAN-GP critic	표준 BCE 판별자 (Table 4)	QGAN과 같은 판별자
학습	GPU, 전체 학습	25 epoch 사전학습. 수업에서는 10 epoch checkpoint + 20 step	16큐빗 시뮬레이션 비용
평가	FID, 분류 성능	지표 4종	FID는 16×16에서 의미 없음

6

[약 2분]

원 논문과 실습의 차이입니다. 양자 stream은 줄이지 않았습니다. 줄이면 논문이 말한 모델이 아니게 되기 때문이고, 대신 해상도와 학습 구간을 줄였습니다. 이것이 README의 설계 원칙 1입니다. 고전 encoder와 decoder는 conv에서 MLP로 단순화했는데, 16×16 저해상도이기 때문입니다. 입력과 출력은 64×64 RGB가 아니라 2일차 전처리 자산인 16×16 그레이스케일입니다. 판별자의 차이가 가장 큽니다. 원 논문은 WGAN-GP critic, 즉 gradient penalty로 판별자를 제약하는데 실습은 QGAN과 같은 표준 BCE 판별자라 판별자가 우세해집니다. 학습은 논문이 GPU 전체 학습이고, 실습은 25 epoch까지 사전학습해 두고 수업에서는 10 epoch checkpoint에서 20 step만 미세조정합니다. 평가는 논문이 FID와 분류 성능이고 실습은 지표 4종입니다. 16×16에서는 FID가 의미 없기 때문입니다.

이 표는 결과를 해석할 때 무엇을 원 논문의 성질로 보고, 무엇을 실습의 단순화 탓으로 볼지를 가르는 기준입니다. 양자 stream이 같으므로 양자 부분의 비용은 원 논문과 같은 규모입니다. 반면 생성 품질이 낮은 것은 고전 decoder, 판별자, 학습량의 차이에서 오는 부분이 크므로, 오늘 결과로 MediQ-GAN 논문의 성능을 평가하지 않습니다.

미세조정 · 계산 비용

계산 비용 : 수업에서 미세조정만 하는 이유

16큐빗 회로 시뮬레이션이 비싸 25 epoch 사전학습에 196분(약 3시간 15분)이 걸림

	2일차 QGAN	3일차 MediQ-GAN
큐빗 (회로 하나)	7	16
상태벡터 차원	$2^7 = 128$	$2^{16} = 65{,}536$
미분 방식	backprop (default.qubit)	adjoint (lightning.qubit)
1 step	약 2.2초 (batch 8)	**약 20초 (batch 4)**
전체 학습	600 step 약 22분	**25 epoch 196분 (epoch당 7.8분)**
수업 중 학습	처음부터 400 step (Colab 약 35분)	10 epoch checkpoint에서 20 step

7

로컬 CPU 실측. epoch 시간은 checkpoint epoch_sec 평균

[약 3분]

미세조정만 수업에서 하는 이유를 비용으로 설명합니다. 표는 로컬 CPU 실측입니다. 회로 하나가 QGAN은 7큐빗, MediQ-GAN은 16큐빗이고 상태벡터 차원은 128과 65,536입니다. 미분 방식은 backprop과 adjoint입니다. 1 step은 QGAN이 약 2.2초, MediQ-GAN이 약 20초입니다. MediQ-GAN의 1 epoch은 DF 115장을 batch 4로 28 step이고, checkpoint 기록상 epoch당 평균 7.8분, 범위로는 453초에서 487초입니다. 1 step 약 20초는 batch 4 곱하기 샘플당 약 3초, 즉 판별자 step과 생성자 step 합계입니다. 그래서 수업에서는 약 80분 학습분인 10 epoch checkpoint에서 출발해 20 step만 더 돌립니다.

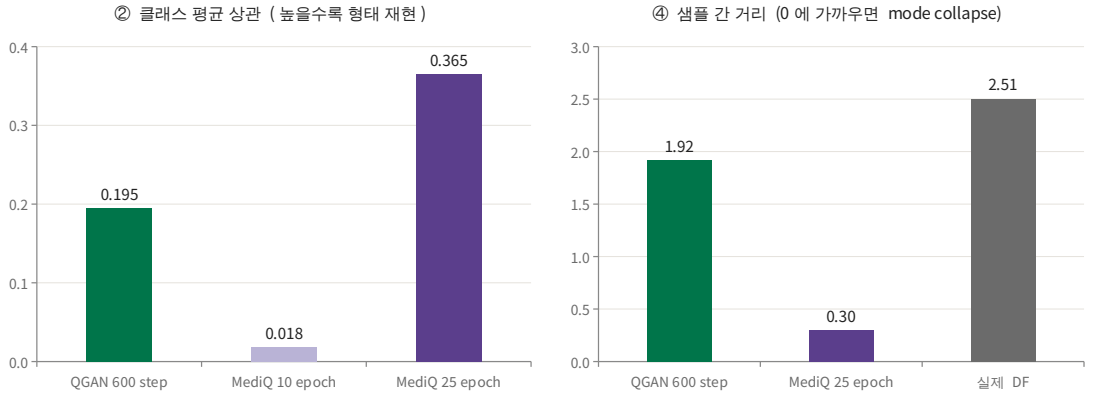
adjoint 미분을 쓰는 이유도 비용과 연결됩니다. backprop은 계산 중간의 상태벡터를 모두 저장해야 해서 16큐빗, 65,536차원 회로를 depth 8로 쌓으면 메모리 부담이 큽니다. adjoint는 forward 한 번과 역방향 한 번으로 gradient를 구하고 중간 상태를 저장하지 않습니다.

Colab에서는 1 step이 약 40초로 로컬 CPU의 두 배가 걸리고, 20 step 실측은 13.8분이었습니다. 시간이 부족하면 노트북 주석대로 셀을 중단하거나 FINE_TUNE_STEPS를 줄여도 됩니다. 노트북 결과 설명에 있듯이 20 step은 출발점까지 학습한 280 step의 7% 정도라, 미세조정 전후의 이미지와 지표는 거의 같습니다. Colab 실행 예에서 상관은 0.027에서 −0.010, 판별자 손실은 1.19에서 1.17로 움직였습니다. 오늘 미세조정의 목적은 성능 개선이 아니라 checkpoint를 불러와 이어서 학습하는 과정을 직접 실행해 보는 것입니다.

비교 · 노트북 §5

지표 비교 : 형태 재현과 다양성

상관은 MediQ-GAN이 높고, 샘플 간 거리는 QGAN이 실제 DF에 가까움



8

수치: README 결과표(로컬 CPU), MediQ-GAN 16장, QGAN 64장 평가. 지표 정의는 2일차 참고

[약 3분]

두 모델을 같은 지표로 비교합니다. 먼저 용어를 다시 짚겠습니다. 클래스 평균 상관은 생성 이미지와 실제 DF 클래스 평균 이미지의 Pearson 상관계수입니다. 샘플 간 거리는 생성 이미지 쌍의 L2 거리를 평균한 값이고, 정의는 2일차의 지표 용어 슬라이드와 같습니다. 왼쪽 그래프는 ② 클래스 평균 상관입니다. QGAN 600 step이 0.195, MediQ-GAN 25 epoch이 0.365로 평균적인 병변 형태는 MediQ-GAN이 더 잘 맞춥니다. 10 epoch의 0.018과 25 epoch의 0.365 차이를 보면 학습량이 결과를 크게 바꾼다는 점도 확인됩니다. 오른쪽은 ④ 샘플 간 거리입니다. 실제 DF가 2.505인데 QGAN은 1.92로 실제 분포에 가깝고, MediQ-GAN은 0.30으로 실제의 약 1/8입니다. 비슷한 이미지를 반복 생성하는 mode collapse 경향입니다. 평가 장수가 MediQ-GAN은 16장, QGAN은 64장이라는 점도 감안해야 합니다. 이 자료를 만드는 중에 노트북을 실행한 결과, MediQ-GAN 25 epoch의 상관은 0.366, 다양성은 0.285로 README와 일치했습니다.

평가 장수가 다른 이유는 노트북 주석에 있습니다. 16큐빗 시뮬레이션이 비싸서 MediQ-GAN은 16장만 생성합니다. 2일차에서 말씀드린 것처럼 8장에서 16장으로 평가하면 상관계수가 0.05에서 0.17까지 흔들리므로, 이 그래프에서는 소수점이 아니라 두 모델 사이의 격차를 보아야 합니다. 0.195와 0.365, 1.92와 0.30의 차이는 이 흔들림보다 충분히 큽니다.

비교 · 결과 해석

결과 해석 : 두 모델의 한계

QGAN은 형태 재현이 약하고, MediQ-GAN은 평균 이미지에 가까운 그림을 반복함

지표	QGAN 600 step	MediQ-GAN 25 epoch	의미
② 클래스 평균 상관 ↑ (평균 이미지와의 Pearson 상관)	0.195	**0.365**	평균 형태는 MediQ-GAN이 더 가까움
③ 최근접 실제 거리 (가장 가까운 실제 이미지까지 L2)	1.64	3.44	MediQ-GAN은 실제 이미지 어느 것과도 멂
④ 샘플 간 거리 (실제 2.505) (생성 이미지 쌍 L2 평균)	**1.92**	0.30	MediQ-GAN은 비슷한 그림을 반복

해석

QGAN: 다양성은 실제에 가깝지만 병변 형태 재현이 약함. patch를 서로 독립적으로 만들어 이미지 전체 구조를 잡기 어려움.
MediQ-GAN: 평균 형태는 잘 맞추지만 다양성이 실제의 1/8. 최종 출력을 고전 decoder가 만들기 때문에 Tanh가 포화되면 z와 무관한 이미지가 나옴.
②만 보면 MediQ-GAN이 낫다고 결론 내리게 됨. ②는 평균 형태만 보므로 같은 이미지를 반복해도 높게 나옴.

[약 3분]

결과 해석입니다. 표의 세 지표 가운데 ③ 최근접 실제 거리는 생성 이미지 하나에서 가장 가까운 실제 이미지까지의 L2 거리입니다. MediQ-GAN은 3.44로 QGAN의 1.64의 두 배입니다. 생성 이미지가 어떤 실제 이미지와도 가깝지 않다는 뜻으로, 개별 병변이 아니라 평균적인 형태를 반복해서 그린다는 해석과 맞습니다. 상관은 높고 다양성은 낮은 결과와 일관됩니다. 아래 해석을 읽겠습니다. QGAN은 다양성이 실제에 가깝지만 병변 형태 재현이 약합니다. patch를 서로 독립적으로 만들어 이미지 전체 구조를 잡기 어렵기 때문입니다. MediQ-GAN은 평균 형태는 잘 맞추지만 다양성이 실제의 1/8입니다. 최종 출력을 고전 decoder가 만들기 때문에 Tanh가 포화되면 z와 무관한 이미지가 나옵니다. ②만 보면 MediQ-GAN이 낫다고 결론 내리게 되는데, ②는 평균 형태만 보므로 같은 이미지를 반복해도 높게 나옵니다. 토론 주제를 드립니다. 데이터 증강이 목적이라면 어느 쪽이 더 쓸모 있는가, 그리고 지표 하나로 순위를 매길 수 있는가입니다.

노트북의 미세조정 결과 설명에는 원인으로 보이는 단순화가 정리되어 있습니다. hidden이 32인 작은 MLP decoder, 표준 BCE 판별자, 25 epoch의 짧은 사전학습입니다. 양자 stream은 원 논문 스펙 그대로입니다. 또 생성 이미지의 배경이 0이 아니라 0.2 부근이라 검지 않다는 점도 픽셀 histogram 에서 확인할 수 있습니다.

노트북 §5의 끝에는 두 논문의 생성 이미지가 있습니다. 같은 구조를 원 논문 조건, 즉 높은 해상도와 GPU 학습으로 돌린 결과이므로, 오늘 결과와 나란히 보면 해상도와 학습량의 차이가 얼마나 큰지 알 수 있습니다.

정리

3일차 정리

MediQ-GAN 구조와 미세조정, QGAN과의 비교

주제	정리
hybrid 수준	QGAN은 생성자 전체가 양자회로(model-level), MediQ-GAN은 생성자 안의 양자 stream만 양자회로(layer-level)
dual-stream	잠재벡터 256차원을 절반씩 고전 MLP와 양자 stream으로 나눠 처리한 뒤 concat → decoder → Tanh
양자 stream	16큐빗 × depth 8 회로 5개가 16 site 중 5개만 처리. PauliX 기댓값 출력이라 ancilla qubit이 필요 없음
파라미터와 비용	30,000개 중 양자 회전각은 640개(2.1%)지만 학습 시간 대부분이 16큐빗 시뮬레이션 (25 epoch 196분)
checkpoint와 미세조정	config로 같은 구조를 만든 뒤 가중치를 불러옴. 판별자도 같은 시점 상태로 불러와 20 step 추가 학습
학습 안정성	BCE 판별자가 우세함 (lr_g 0.02에서 3 epoch 만에 mode collapse). 원 논문은 WGAN-GP critic을 씀
비교 결과	상관은 MediQ-GAN 0.365 > QGAN 0.195, 다양성은 QGAN 1.92 > MediQ-GAN 0.30. 지표 하나로 순위를 정하지 않음

10

[약 3분]

3일차 내용을 노트북 순서대로 정리합니다. hybrid 수준은 QGAN이 생성자 전체가 양자회로인 model-level, MediQ-GAN이 생성자 안의 양자 stream만 양자회로인 layer-level입니다. dual-stream은 잠재벡터 256차원을 절반씩 고전 MLP와 양자 stream으로 나눠 처리한 뒤 concat하고 decoder, Tanh를 거칩니다. 양자 stream은 16큐빗, depth 8 회로 5개가 16 site 중 5개만 처리하고, PauliX 기댓값을 출력하므로 ancilla qubit이 필요 없습니다. 파라미터는 30,000개 중 양자 회전각이 640개, 2.1%이지만 학습 시간 대부분이 16큐빗 시뮬레이션에서 나옵니다. checkpoint는 config로 같은 구조를 만든 뒤 가중치를 불러오고, 판별자도 같은 시점 상태로 불러와 20 step을 추가 학습합니다. 학습 안정성에서는 BCE 판별자가 우세해 lr_g 0.02에서 3 epoch 만에 mode collapse가 일어났고, 원 논문은 WGAN-GP critic을 씁니다. 비교 결과는 상관이 MediQ-GAN 0.365로 QGAN 0.195보다 높고, 다양성은 QGAN 1.92가 MediQ-GAN 0.30보다 높습니다. 지표 하나로 순위를 정하지 않는다는 점이 오늘의 결론입니다.

노트북 §6의 정리표는 여섯 가지 관찰로 이 강의 전체를 묶습니다. 측정 방식이 학습 성패를 가른다는 것, 학습이 시뮬레이터 규모에 머문다는 것, 해상도 한계가 곧 평가 한계라는 것, 큐빗 수에 지수적으로 비용이 늘어난다는 것, 고전 쪽 안정화가 결과를 좌우한다는 것, 그리고 고전 이미지 생성에서 양자의 우위는 아직 검증되지 않았다는 것입니다. MediQ-GAN 논문도 IBM 실기에서는 학습이 아니라 추론만 검증했습니다. 이 여섯 가지가 1일차에 제시한 '같은 기준으로 해석한다'는 학습목표에 대한 답입니다.